



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIAS DA COMPUTAÇÃO
MESTRADO ACADÊMICO EM CIÊNCIAS DA COMPUTAÇÃO

MELISSA DE SOUSA FELIPE

UMA ABORDAGEM PARA A DETECÇÃO AUTOMÁTICA DE PRECONCEITO EM
APLICATIVOS DE MENSAGENS INSTANTÂNEAS

FORTALEZA

2026

MELISSA DE SOUSA FELIPE

UMA ABORDAGEM PARA A DETECÇÃO AUTOMÁTICA DE PRECONCEITO EM
APLICATIVOS DE MENSAGENS INSTANTÂNEAS

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciência da Computação. Área de Concentração: Ciência da Computação

Orientador: Prof. Dr. José Maria da Silva Monteiro Filho

FORTALEZA

2026

MELISSA DE SOUSA FELIPE

UMA ABORDAGEM PARA A DETECÇÃO AUTOMÁTICA DE PRECONCEITO EM
APLICATIVOS DE MENSAGENS INSTANTÂNEAS

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciência da Computação. Área de Concentração: Ciência da Computação

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. José Maria da Silva Monteiro Filho
(Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXX XXXXXX XXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

Dedico este trabalho à minha família e, sobretudo, à minha mãe, que sempre acreditou em mim, me guiou com amor e força, e me ensinou a nunca desistir. Tudo o que conquistei é reflexo da sua coragem, do seu cuidado e do seu exemplo.

AGRADECIMENTOS

Agradeço, primeiramente, à minha família, pelo apoio incondicional ao longo de toda a minha formação. Pelos conselhos, pelos abraços, pelo incentivo diário e, sobretudo, por acreditarem em mim nos momentos em que eu mesma duvidei. Este trabalho é reflexo da força, do cuidado e do amor que sempre encontrei em vocês. Agradeço, de forma especial, à minha mãe, Maria de Lourdes, que sempre me incentivou a estudar, a perseverar e a nunca desistir dos meus objetivos, sendo a principal fonte de inspiração para a realização desta conquista.

Ao meu namorado, Artur Aureliano, por acreditar na minha capacidade, oferecer apoio emocional em todas as fases deste processo e por caminhar ao meu lado com paciência, carinho e incentivo.

Ao meu orientador, Prof. Dr. José Maria da Silva Monteiro Filho, pela orientação, dedicação, disponibilidade e pelas valiosas discussões que contribuíram decisivamente para o desenvolvimento desta dissertação. Seu conhecimento e rigor acadêmico foram fundamentais para o amadurecimento deste trabalho.

À doutoranda Fernanda Nascimento, pela grande contribuição, ajuda técnica e teórica, e por todo o apoio durante o desenvolvimento deste estudo. Ao graduando Gustavo Martins, pela colaboração, parceria e participação em etapas importantes desta pesquisa.

Aos colegas do Laboratório ARiDa, pelas discussões produtivas, troca de conhecimento e ambiente colaborativo que possibilitaram meu crescimento como pesquisadora.

Ao LSBd, pelo financiamento parcial desta pesquisa, que tornou possível a continuidade deste projeto.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ), onde este template foi originalmente desenvolvido.

Ao doutorando em Engenharia Elétrica Ednardo Moreira Rodrigues e ao seu assistente Alan Batista de Oliveira, graduando em Engenharia Elétrica, pela adaptação do template utilizado neste trabalho, garantindo conformidade com as normas da Biblioteca da Universidade Federal do Ceará (UFC).

A todos os professores com quem tive a oportunidade de aprender ao longo da minha trajetória acadêmica, agradeço pela dedicação, pelo compromisso com o ensino e por despertarem em mim não apenas conhecimento técnico, mas valores, ética, sensibilidade e o verdadeiro significado da educação. Levo comigo cada aprendizagem e cada gesto.

Agradeço também à Fundação Cearense de Apoio ao Desenvolvimento Científico

e Tecnológico (FUNCAP), pelo financiamento desta pesquisa por meio da bolsa de estudos de mestrado, sem o qual este trabalho não teria sido possível.

Por fim, deixo meu sincero agradecimento a todos que, direta ou indiretamente, contribuíram para a realização deste trabalho. Cada gesto, palavra ou apoio fez diferença no meu percurso.

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

RESUMO

Aplicativos de mensagens instantâneas revolucionaram a comunicação ao torná-la mais acessível, rápida e eficiente. Contudo, essas plataformas também passaram a facilitar a disseminação ampla de conteúdos preconceituosos. Nesse cenário, a detecção rápida e eficaz de preconceito em mensagens textuais é fundamental para promover um ambiente comunicativo mais saudável, diverso e tolerante. Apesar dessa relevância, poucos métodos de detecção de preconceito foram desenvolvidos especificamente para aplicativos de mensagens instantâneas. Além disso, a construção de abordagens eficazes depende da disponibilidade de conjuntos de dados rotulados contendo mensagens reais dessas plataformas, uma vez que as expressões linguísticas utilizadas diferem significativamente daquelas observadas em outras redes sociais, como Facebook, Instagram e X. Até onde se tem conhecimento, não existiam conjuntos de dados em português brasileiro (PT-BR) contendo mensagens preconceituosas extraídas do WhatsApp ou do Telegram. Diante dessa lacuna, este trabalho apresenta dois conjuntos de dados rotulados e publicamente disponíveis *PrejudiceWhatsApp.Br* e *PrejudiceTelegram.Br* compostos por mensagens em português brasileiro coletadas de grupos públicos dessas plataformas. Adicionalmente, foi desenvolvido o dicionário *PrejudicePT-br*, formado por 842 palavras organizadas em nove categorias de preconceito. Também foi proposto um modelo de aprendizado de máquina baseado em dicionário para a detecção automática de preconceito em mensagens do WhatsApp e do Telegram. Para avaliar a eficácia das abordagens propostas, conduzimos uma série de experimentos de classificação de texto envolvendo três estratégias distintas: (i) o uso de modelos clássicos de aprendizado de máquina, (ii) a aplicação de modelos pré-treinados voltados à detecção de linguagem preconceituosa e (iii) o emprego de grandes modelos de linguagem (LLMs) por meio de diferentes estratégias de prompting. Os melhores resultados alcançaram um F1-score de 0,88, demonstrando a viabilidade e o potencial das soluções apresentadas para a detecção automática de preconceito em aplicativos de mensagens instantâneas.

Palavras-chave: Preconceito. Conjunto de dados. WhatsApp. Telegram. Detecção Automática.

ABSTRACT

Instant messaging applications have revolutionized communication by making it more accessible, faster, and more efficient. However, these platforms have also facilitated the widespread dissemination of prejudiced content. In this context, the rapid and effective detection of prejudice in textual messages is essential to promote a healthier, more diverse, and more tolerant communicative environment. Despite this relevance, few prejudice detection methods have been developed specifically for instant messaging applications. Moreover, the development of effective approaches depends on the availability of labeled datasets containing real messages from these platforms, since the linguistic expressions used differ significantly from those observed in other social networks, such as Facebook, Instagram, and X. To the best of our knowledge, there were no datasets in Brazilian Portuguese (PT-BR) containing prejudiced messages extracted from WhatsApp or Telegram. To address this gap, this work presents two labeled and publicly available datasets, PrejudiceWhatsApp.Br and PrejudiceTelegram.Br, composed of Brazilian Portuguese messages collected from public groups on these platforms. Additionally, we developed the PrejudicePT-br dictionary, consisting of 842 words organized into nine categories of prejudice. We also proposed a dictionary-based machine learning model for the automatic detection of prejudice in WhatsApp and Telegram messages. To evaluate the effectiveness of the proposed approaches, we conducted a series of text classification experiments involving three distinct strategies: (i) the use of classical machine learning models, (ii) the application of pre-trained models tailored to prejudiced language detection, and (iii) the use of large language models (LLMs) through different prompting strategies. The best results achieved an F1-score of 0.88, demonstrating the feasibility and potential of the proposed solutions for the automatic detection of prejudice in instant messaging applications.

Keywords: Prejudice. Datasets. WhatsApp. Telegram. Automatic Detection.

LISTA DE FIGURAS

Figura 1 – Estrutura do PrejudicePT-br	51
Figura 2 – Curva de aprendizado para o melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceTelegram.Br.	69
Figura 3 – Matriz de confusão do melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceTelegram.Br.	74
Figura 4 – Curva de aprendizado para o melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceWhatsApp.Br.	74
Figura 5 – Matriz de confusão do melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceWhatsApp.Br.	75
Figura 6 – Curva de aprendizado para o melhor modelo pré treinado (HATEBr) para o PrejudiceTelegram.Br.	78
Figura 7 – Matrix de confusão para o melhor modelo pré treinado (HATEBr) para o PrejudiceTelegram.Br.	78
Figura 8 – Curva de aprendizado para o melhor modelo pré treinado (TupiBert) para o PrejudiceWhatsApp.Br	79
Figura 9 – Matrix de confusão para o melhor modelo pré treinado (TupiBert) para o PrejudiceWhatsApp.Br	79
Figura 10 – Matriz de confusão do modelo GPT-4 Mini usando a estratégia de <i>role prompting</i> no PrejudiceTelegram.Br	81
Figura 11 – Matriz de confusão para o modelo GPT-4 Mini usando a estratégia prompting por papel no PrejudiceWhatsApp.Br	81

LISTA DE TABELAS

Tabela 1 – Principais características de trabalhos relacionados	49
Tabela 2 – Quantidade de palavras por categoria no dicionário PrejudicePT-br	53
Tabela 3 – Top 5 palavras do PrejudicePT-br mais frequentes no PrejudiceWhatsApp.Br	53
Tabela 4 – Top 5 palavras do PrejudicePT-br mais frequentes no PrejudiceTelegram.Br	53
Tabela 5 – Estatísticas dos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br	55
Tabela 6 – Termos mais frequentes nas mensagens do dataset PrejudiceWhatsApp.Br .	56
Tabela 7 – Termos mais frequentes nas mensagens do dataset PrejudiceTelegram.Br . .	56
Tabela 8 – Resultados para o PrejudiceTelegram.Br usando o método BoW	70
Tabela 9 – Resultados para o PrejudiceTelegram.Br usando o método TF-IDF	71
Tabela 10 – Resultados para o PrejudiceWhatsApp.Br usando o método BoW	72
Tabela 11 – Resultados para o PrejudiceWhatsApp.Br usando o método TF-IDF	73
Tabela 12 – Resultados utilizando modelos pré treinados - BERT - no conjunto de dados PrejudiceTelegram.Br.	76
Tabela 13 – Resultados utilizando modelos pré treinados - BERT - no conjunto de dados PrejudiceWhatsApp.Br.	77
Tabela 14 – Melhores resultados dos LLMs utilizando o PrejudiceTelegram.Br	80
Tabela 15 – Melhores resultados dos LLMs utilizando o PrejudiceWhatsApp.Br	80
Tabela 16 – Resultados da utilização das 9 categorias do dicionário PrejudicePT-br com BoW, TF-IDF e BERT	83
Tabela 17 – Resultados da utilização das 842 palavras do dicionário PrejudicePT-br com BoW, TF-IDF e BERT	84
Tabela 18 – Resultados da utilização das 9 categorias do dicionário PrejudicePT-br . . .	85
Tabela 19 – Resultados da utilização das 842 palavras do dicionário PrejudicePT-br . .	86
Tabela 20 – Diferenças nas categorias LIWC entre mensagens com e sem preconceito (PrejudiceWhatsApp.Br)	87
Tabela 21 – Diferenças nas categorias LIWC entre mensagens com e sem preconceito (PrejudiceTelegram.Br)	88
Tabela 22 – As 5 palavras mais influentes identificadas pelo LIME para as classes <i>preconceito</i> e <i>não preconceito</i> (BoW Bigram + Palavras [LR]) para o <i>PrejudiceWhatsApp.Br</i>	90

Tabela 23 – As 5 palavras mais influentes identificadas pelo SHAP para as classes <i>preconceito</i> e <i>não preconceito</i> (BoW Unigram [LR]) para o <i>PrejudiceWhatsApp.Br.</i>	90
Tabela 24 – Resultados das métricas de fidelidade para o <i>PrejudiceWhatsApp.Br.</i>	91
Tabela 25 – As 5 palavras mais influentes identificadas pelo LIME para as classes <i>preconceito</i> e <i>não preconceito</i> (TF-IDF Trigram + Palavras[GB]) para o <i>PrejudiceTelegram.Br.</i>	92
Tabela 26 – As 5 palavras mais influentes identificadas pelo SHAP para as classes <i>preconceito</i> e <i>não preconceito</i> (bigrama TF-IDF [GB]) para o <i>PrejudiceTelegram.Br.</i>	92
Tabela 27 – Resultados das métricas de Fidelidade para o <i>PrejudiceTelegram.Br.</i>	93
Tabela 28 – Análise dos erros da melhor abordagem - <i>PrejudicePT-br</i> (palavras) + <i>Tupi-BERTBase</i>	94

LISTA DE ABREVIATURAS E SIGLAS

AUC	Area Under the ROC Curve / Área sob a Curva ROC
BERT	Bidirectional Encoder Representations from Transformers / Representações de Codificadores Bidirecionais a partir de Transformadores
BNB	Bernoulli Naive Bayes / Naive Bayes Bernoulli
BoW	Bag of Words / Saco de Palavras
FN	Falso Negativo
FP	Falso Positivo
GB	Gradient Boosting / Boosting de Gradiente
KNN	K-Nearest Neighbors / K-vizinhos mais próximos
LIME	Local Interpretable Model-agnostic Explanations / Explicações Locais Interpretáveis e Independentes de Modelo
LIWC	<i>Linguistic Inquiry and Word Count / Pesquisa Linguística e Contagem de Palavras</i>
LLMs	Large Language Model / Modelos de Linguagem de Grande Escala
LR	Logistic Regression / Regressão Logística
LSVM	Linear Support Vector Machine / Máquina de Vetores de Suporte Linear
MLP	Multilayer Perceptron / Perceptron Multicamada
MNB	Multinomial Naive Bayes / Naive Bayes Multinomial
PT-BR	Português brasileiro
RF	Random Forest / Floresta Aleatória
SGD	Stochastic Gradient Descent Classifier / Classificador por Gradiente Descendente Estocástico
SHAP	SHapley Additive exPlanations / Explicações Aditivas de Shapley
TF-IDF	Term Frequency-Inverse Document Frequency / Frequência do Termo - Inverso da Frequência dos Documentos
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo
XAI	Explainable Artificial Intelligence / Inteligência Artificial Explicável

SUMÁRIO

1	INTRODUÇÃO	16
1.1	Motivação	16
1.2	Principais Desafios	18
1.2.1	<i>Linguagem Preconceituosa no Contexto do WhatsApp e Telegram</i>	<i>19</i>
1.2.2	<i>Principais Desafios Para Detectar Linguagem Preconceituosa</i>	<i>19</i>
1.2.3	<i>Mitigação de Conteúdo Preconceituoso no WhatsApp e Telegram</i>	<i>20</i>
1.2.4	<i>Desafios de Pesquisa</i>	<i>21</i>
1.3	Contribuições Científicas	22
1.4	Organização da Dissertação	22
2	FUNDAMENTAÇÃO TEÓRICA	24
2.1	Tipos de Linguagens Abusivas	24
2.2	Preconceito	26
2.2.1	<i>Tipos de Preconceito</i>	<i>26</i>
2.2.2	<i>Preconceito em Redes Sociais</i>	<i>29</i>
2.3	Técnicas de Vetorização	30
2.3.1	<i>Bag of Words (BoW)</i>	<i>30</i>
2.3.2	<i>Term Frequency-Inverse Document Frequency (TF-IDF)</i>	<i>31</i>
2.3.3	<i>Embeddings</i>	<i>32</i>
2.3.3.1	<i>BERT</i>	<i>34</i>
2.3.3.2	<i>Modelos Pré Treinados Bert</i>	<i>34</i>
2.4	LLM's	35
2.4.1	<i>Engenharia de Prompt</i>	<i>36</i>
2.5	Linguistic Inquiry and Word Count (LIWC)	37
2.6	Algoritmos de Classificação	37
2.7	Métricas de Desempenho	39
2.8	Métodos de Explicabilidade	40
2.8.1	<i>LIME</i>	<i>41</i>
2.8.2	<i>SHAP</i>	<i>41</i>
2.9	Conclusão	42
3	TRABALHOS RELACIONADOS	43

3.1	Detecção de Textos Abusivos em Redes Sociais	43
3.2	Avaliando o Uso de Dicionário para Análise de Texto	46
3.3	Análise de Vieses em Modelos de Linguagem	47
3.4	Análise dos Resultados por Meio de Modelos de Explicabilidade	48
3.5	Análise Comparativa	48
3.6	Conclusão	49
4	OS CONJUNTOS DE DADOS EXPLORADOS	50
4.1	Dicionário PrejudicePT-br	50
4.1.1	<i>Coleta de Dados</i>	50
4.1.2	<i>Estrutura</i>	51
4.1.3	<i>Análise Exploratória</i>	51
4.2	Datasets PrejudiceTelegram.Br e PrejudiceWhatsApp.Br	53
4.2.1	<i>Coleta de Dados</i>	53
4.2.2	<i>Seleção dos Dados</i>	54
4.2.3	<i>Rotulagem dos Dados</i>	54
4.2.4	<i>Análise das Mensagens Rotuladas</i>	55
4.3	Limitações e Vieses nos Dados	57
4.4	Conclusão	57
5	DETECÇÃO DE PRECONCEITO EM APLICATIVOS DE MENSAGE- RIA	58
5.1	Avaliação de Algoritmos Clássicos de Aprendizado de Máquina	58
5.1.1	<i>Pré processamento Textual</i>	59
5.1.2	<i>Classificação</i>	60
5.1.3	<i>Métricas de Desempenho</i>	61
5.2	Avaliação de Modelos de Linguagem Pré-treinados	62
5.3	Avaliação dos Grandes Modelos de Linguagem	63
5.3.1	<i>Modelos de Prompting Utilizados</i>	63
5.4	LIWC	66
5.5	Modelos de Explicabilidade	66
5.5.1	<i>LIME</i>	66
5.5.2	<i>SHAP</i>	67
5.6	Conclusão	67

6	RESULTADOS	68
6.1	Avaliação de Algoritmos Clássicos de Aprendizado de Máquina	68
6.2	Avaliação de Modelos de Linguagem Pré-treinados	70
6.3	Avaliação de Grandes Modelos de Linguagem	76
6.4	Resultados Obtidos Usando o Dicionário	80
6.4.1	<i>Resultados Obtidos com Dicionários e Métodos de Vetorização</i>	<i>82</i>
6.4.2	<i>Resultados Obtidos Usando Somente as Categorias do Dicionário</i>	<i>84</i>
6.4.3	<i>Resultados Obtidos Usando Somente as Palavras do Dicionário</i>	<i>86</i>
6.5	Resultados Obtidos Usando o LIWC	87
6.6	Resultados Obtidos Usando SHAP e LIME	88
6.7	Análise de Erros do Melhor Resultado	91
6.8	Conclusão	93
7	CONCLUSÕES E TRABALHOS FUTUROS	95
7.1	Trabalhos Futuros	97
	REFERÊNCIAS	99

1 INTRODUÇÃO

1.1 Motivação

Nos últimos anos, a crescente popularidade dos aplicativos de mensagens instantâneas transformou significativamente a maneira como produzimos, compartilhamos e consumimos informações. No Brasil, o WhatsApp se destaca como um dos aplicativos mais utilizados, com mais de 165 milhões de usuários (SÁ *et al.*, 2023b). Da mesma forma, o Telegram também apresentou um crescimento notável, com a proporção de smartphones com o aplicativo instalado aumentando de 45% para 60% em apenas um ano, em 2022 (SÁ *et al.*, 2023a). A ampla adoção desses aplicativos pode ser atribuída à sua versatilidade e facilidade de uso. Eles permitem o compartilhamento instantâneo de diversos tipos de mídia, como mensagens de texto, links, imagens, áudios e vídeos. Além disso, oferecem um recurso particularmente relevante: grupos de conversa públicos. Esses grupos, acessíveis por meio de links de convite, geralmente são organizados em torno de temas específicos, como política, esportes, finanças ou educação. Tanto o WhatsApp quanto o Telegram permitem que os usuários participem simultaneamente de centenas de grupos, conectando-se, assim, com milhares de outras pessoas de forma integrada. No entanto, embora esses aplicativos promovam uma comunicação rápida e eficiente, a falta de controle e de regulamentação adequados os torna propícios à disseminação em larga escala de discursos preconceituosos.

A literatura apresenta diversas definições de preconceito, cada uma refletindo diferentes tradições teóricas e contribuindo de forma significativa para o entendimento do fenômeno. Allport, pioneiro nos estudos psicológicos sobre o tema, descreveu o preconceito como um juízo favorável ou desfavorável formulado sem base em experiência real (ALLPORT *et al.*, 1954). Aronson, por sua vez, enfatizou seu caráter social ao defini-lo como uma atitude negativa baseada em generalizações distorcidas sobre determinados grupos (ARONSON *et al.*, 2010). Mezan ampliou essa perspectiva ao conceituá-lo como um conjunto de crenças e comportamentos que atribuem características negativas a indivíduos exclusivamente por pertencerem a um grupo específico (MEZAN, 2021). Essas definições, ainda que distintas, são fundamentais para compreender a complexidade e a natureza multifacetada do preconceito.

O preconceito é uma das formas mais cruéis de opressão e discriminação entre indivíduos na sociedade contemporânea. Ele também funciona como uma forma de autossabotagem, pois gera um sentimento de culpa na vítima. Qualquer forma de preconceito nas relações humanas é prejudicial ao desenvolvimento de uma sociedade justa, diversa e inclusiva. A violência do preconceito favorece o isolamento entre os indivíduos e, de maneira sutil, instaura um clima de desconfiança entre pares.

Nesse contexto, a detecção rápida e eficaz de discursos preconceituosos compartilhados em aplicativos de mensagens instantâneas torna-se fundamental para a construção de um ambiente comunicacional democrático e tolerante. No entanto, apesar desse cenário, há poucos métodos de detecção especificamente desenvolvidos para essas plataformas. Além disso, para que métodos eficientes sejam desenvolvidos, é essencial a disponibilidade de conjuntos de dados rotulados contendo mensagens preconceituosas disseminadas nesses aplicativos, uma vez que a forma como os usuários se expressam difere significativamente daquela observada nas redes sociais públicas, como Facebook, Instagram e X (ROSENFELD *et al.*, 2018). No entanto, não encontramos nenhum conjunto de dados contendo mensagens preconceituosas extraídas do WhatsApp ou do Telegram no idioma Português brasileiro (PT-BR).

Dessa forma, com o objetivo de suprir essa lacuna, construímos dois conjuntos de dados rotulados, anonimizados e publicamente disponíveis, compostos por mensagens em português brasileiro (PT-BR) coletadas a partir de grupos públicos do WhatsApp e do Telegram. Esses conjuntos, denominados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br, reúnem mensagens com linguagem preconceituosa e fornecem uma base inédita para a investigação desse fenômeno em aplicativos de comunicação instantânea. Adicionalmente, desenvolvemos o dicionário léxico PrejudicePT-br, específico do português brasileiro, composto por 842 palavras, organizadas em nove categorias distintas de preconceito. Até onde sabemos, trata-se do primeiro recurso lexical que sistematiza explicitamente diferentes tipos de preconceito nesse idioma, contribuindo de forma significativa para pesquisas linguísticas e computacionais na área.

Subsequentemente, com base no dicionário PrejudicePT-br, propomos três abordagens distintas para a detecção automática de mensagens preconceituosas. A primeira baseia-se exclusivamente em algoritmos clássicos de aprendizado de máquina; a segunda utiliza modelos pré-treinados adaptados à detecção de linguagem preconceituosa; e a terceira emprega grandes modelos de linguagem (LLMs) por meio de diferentes estratégias de *prompting*. Em todas as abordagens, o objetivo é classificar os textos em duas classes: mensagens preconceituosas, asso-

ciadas a alguma forma de preconceito, e mensagens não preconceituosas. Os experimentos foram conduzidos utilizando os conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br, permitindo uma avaliação comparativa das estratégias propostas em diferentes plataformas de mensagens instantâneas.

Detectar preconceito em mensagens compartilhadas nas redes sociais não é simples. A forma como as pessoas se expressam nesses ambientes costuma envolver ironia, sarcasmo, ambiguidades, gírias, abreviações e forte dependência do contexto, além de elementos como tom e intenção, que as máquinas ainda têm dificuldade em compreender. Muitas vezes, entender se uma mensagem é preconceituosa exige conhecimento cultural, social e situacional, algo que vai além da simples análise das palavras usadas. Diante disso, este trabalho opta por focar principalmente em abordagens baseadas no léxico e em padrões linguísticos explícitos, reconhecendo que essa escolha impõe limitações, especialmente na identificação de casos mais sutis ou implícitos de preconceito. Ainda assim, a proposta contribui ao oferecer recursos e métodos iniciais para a detecção automática desse tipo de conteúdo, servindo como um ponto de partida para pesquisas futuras que possam explorar análises mais profundas do contexto e do significado.

1.2 Principais Desafios

O desenvolvimento e a validação de métodos eficazes para detectar linguagem preconceituosa em redes sociais dependem diretamente da disponibilidade de dados representativos do fenômeno em questão. No contexto da detecção de preconceito textual, esses dados consistem em mensagens reais compartilhadas pelos usuários nas plataformas, acompanhadas de rótulos que indiquem a presença ou ausência de conteúdo discriminatório. Esses rótulos constituem a base para o treinamento de modelos de Aprendizado de Máquina, que devem aprender a reproduzir tal julgamento de forma automatizada. A natureza desses dados varia conforme a plataforma de origem, podendo incluir textos curtos, mensagens multimodais, metadados ou interações entre usuários. Embora a coleta possa ser automatizada por meio de APIs, web crawlers ou ferramentas de captura de mensagens, o processo de rotulagem (anotação) permanece uma das etapas mais desafiadoras (CUNHA, 2021). A anotação exige julgamento humano cuidadoso, uma vez que envolve a interpretação do conteúdo, o reconhecimento de nuances linguísticas e, muitas vezes, a contextualização sociocultural das mensagens. Como apontado por (RUBIN *et al.*, 2015), esse procedimento é tipicamente conduzido por anotadores treinados ou especialistas, o que demanda tempo, esforço e recursos substanciais.

1.2.1 Linguagem Preconceituosa no Contexto do WhatsApp e Telegram

O WhatsApp é atualmente o aplicativo de mensagens mais utilizado no mundo, com mais de 2,78 bilhões de usuários ativos mensais em 180 países. Sua ampla penetração social, especialmente na América Latina, na Índia e na África, faz da plataforma um espaço central para o compartilhamento de informações, debates públicos e mobilizações políticas. Nesse ambiente altamente dinâmico, pesquisas recentes têm identificado a circulação frequente de conteúdos prejudiciais, como desinformação, discurso de ódio, linguagem preconceituosa e propaganda política extremista. A ausência de mecanismos eficazes de moderação em tempo real, aliada à natureza privada das conversas, favorece a disseminação de mensagens ofensivas, discriminatórias ou ideologicamente exacerbadas, tornando o WhatsApp um ecossistema propenso à linguagem preconceituosa (LIU *et al.*, 2025).

De forma semelhante, o Telegram que reúne cerca de 700 milhões de usuários em todo o mundo, apresenta características estruturais que também intensificam a circulação de conteúdo nocivo. A possibilidade de criar grupos com até 200 mil participantes e canais com audiência ilimitada amplia significativamente o alcance das mensagens, permitindo sua disseminação em larga escala. Esse modelo comunicacional tem sido amplamente explorado em contextos políticos, inclusive por grupos de extrema direita, para difusão massiva de conteúdos ideológicos e potencialmente ofensivos ou discriminatórios. A crescente adoção do Telegram em debates polarizados, combinada à falta de mecanismos de moderação plenamente eficazes, favorece a propagação rápida e pouco supervisionada de discurso de ódio, linguagem preconceituosa e outras formas de linguagem negativa (MATOS *et al.*, 2024).

1.2.2 Principais Desafios Para Detectar Linguagem Preconceituosa

Detectar automaticamente conteúdo preconceituoso no WhatsApp é um desafio significativo, pois a criptografia de ponta a ponta impede qualquer acesso ao teor das mensagens, inclusive pela própria plataforma. Isso torna inviáveis as técnicas tradicionais de moderação empregadas em redes abertas, nas quais o conteúdo pode ser analisado e monitorado. A ausência de mecanismos internos de moderação agrava o cenário, permitindo que grupos públicos sejam utilizados para a disseminação de discurso ofensivo, extremista ou discriminatório sem qualquer forma eficaz de controle. Diante da impossibilidade de intervir diretamente no conteúdo, o WhatsApp passou a adotar estratégias focadas na limitação da velocidade de circulação das

mensagens. Entre essas medidas, destacam-se a restrição do número de encaminhamentos e a rotulagem de conteúdos amplamente compartilhados com o aviso “encaminhada várias vezes” (LIU *et al.*, 2025). Embora essas ações reduzam parcialmente a viralidade, ainda são insuficientes para combater efetivamente a propagação de linguagem negativa na plataforma.

Essas limitações observadas no WhatsApp também se refletem no Telegram, embora assumam contornos ainda mais complexos devido às características próprias da plataforma. A detecção automática de discurso de ódio no Telegram enfrenta desafios substanciais: assim como o WhatsApp, o aplicativo adota mecanismos de criptografia que dificultam o acesso ao conteúdo das mensagens, restringindo diretamente a aplicação de métodos tradicionais de moderação e de análise textual. As próprias plataformas alegam que a natureza criptografada das comunicações inviabiliza intervenções mais robustas, o que justifica a ausência de sistemas eficazes de controle. A falta de consenso sobre as definições operacionais de discurso de ódio, preconceito ou linguagem negativa também dificulta avanços metodológicos. Além disso, o Telegram oferece ainda mais camadas de anonimato e estruturas sociotécnicas, como grupos massivos, canais de audiência ilimitada e alto potencial de viralização, que favorecem a disseminação rápida e contínua de mensagens extremistas. Esses fatores não determinam, mas condicionam e amplificam a propagação de conteúdo nocivo, tornando o enfrentamento ao discurso de ódio ainda mais desafiador (MATOS *et al.*, 2024).

1.2.3 Mitigação de Conteúdo Preconceituoso no WhatsApp e Telegram

Apesar do WhatsApp ser hoje a plataforma de mensagens mais utilizada do mundo e o Telegram figurar entre os aplicativos com maior número de usuários, a coleta e análise sistemática de dados provenientes dessas redes ainda são pouco exploradas quando comparadas a outras plataformas digitais. Detectar linguagem negativa, seja discurso de ódio, linguagem preconceituosa ou outros tipos de conteúdo nocivo, constitui o primeiro passo fundamental para mitigar o problema. A seguir, apresentamos possíveis aplicações práticas decorrentes de métodos automáticos de detecção:

- Desenvolvimento de um *bot* ou serviço Web que permita aos usuários consultar a probabilidade de uma mensagem recebida ser preconceituosa;
- Construção de modelos capazes de identificar usuários maliciosos que, de forma recorrente e intencional, disseminam linguagem preconceituosa. Esses modelos poderiam auxiliar as plataformas a restringir ou bloquear a atividade desses perfis.

1.2.4 Desafios de Pesquisa

Dado o cenário exposto, é possível identificar duas lacunas centrais de pesquisa:

- A ausência de conjuntos de dados representativos e publicamente disponíveis que contemplem o contexto de linguagem preconceituosa no WhatsApp e no Telegram em português brasileiro (PT-BR).
- A escassez de estudos que investiguem métodos de detecção automática de linguagem preconceituosa especificamente nessas plataformas, cujas características técnicas, como criptografia e anonimato, tornam o problema mais desafiador.

Com base nesses desafios, esta dissertação propõe um estudo avaliativo de métodos de detecção de linguagem preconceituosa, baseados em técnicas de Processamento de Linguagem Natural (PLN) e de Aprendizado de Máquina, aplicados a dados coletados diretamente do WhatsApp e do Telegram, em português brasileiro (PT-BR). Para isso, buscamos responder às seguintes questões de pesquisa:

- **Q1.** Quão desafiadora é a detecção de linguagem preconceituosa no WhatsApp e no Telegram utilizando técnicas de Processamento de Linguagem Natural e métodos supervisionados e não supervisionados de Aprendizado de Máquina?
- **Q2.** Quais combinações de pré-processamento, estratégias de extração de atributos e algoritmos de classificação apresentam melhor desempenho na tarefa de detecção de mensagens preconceituosas nessas plataformas?
- **Q3.** Quais são as limitações das melhores abordagens identificadas e quais aspectos específicos das plataformas dificultam a detecção automática desse tipo de linguagem?

Para responder a essas questões, este trabalho apresenta as seguintes contribuições:

1. Criação e disponibilização pública de dois conjuntos de dados inéditos, rotulados e anonimizados, compostos por mensagens coletadas de grupos públicos do WhatsApp e Telegram, majoritariamente em português: os datasets **PrejudiceWhatsApp.Br** e **PrejudiceTelegram.Br**¹. Até onde sabemos, estes são os primeiros conjuntos de dados do tipo disponíveis para pesquisa, o que viabiliza estudos futuros na área.
2. Definição de um protocolo rigoroso de anotação, no qual cada mensagem foi rotulada manualmente por três anotadores com perfis distintos, garantindo maior consistência na distinção entre textos preconceituosos e não preconceituosos.

¹ <https://github.com/jmmfilho/PrejudicePT-br/tree/main>

3. Realização de uma ampla série de experimentos de classificação, combinando diferentes técnicas de representação textual e algoritmos de Aprendizado de Máquina para distinguir mensagens preconceituosas de não preconceituosas. Esses experimentos estabelecem uma linha de base (*baseline*) para pesquisas futuras e ajudam a identificar quais abordagens são mais adequadas a esse cenário ainda pouco explorado.

1.3 Contribuições Científicas

Com base nos experimentos e resultados obtidos durante o desenvolvimento desta Dissertação foram publicados os seguintes artigos científicos:

Sousa, M., Nascimento, F., Martins, G., Monteiro, J.M., Machado, J. An Approach for the Automatic Detection of Prejudice in Instant Messaging Applications”. Trabalho publicado nos Proceedings of the 14th International Conference on Data Science, Technology and Applications (DATA), 2025.

1.4 Organização da Dissertação

Esta dissertação está organizada em sete capítulos, descritos brevemente a seguir:

– Capítulo 1. Introdução

Este capítulo apresenta o problema de detecção de preconceito em mensagens de redes sociais, seu contexto social, bem como os desafios técnicos e científicos envolvidos. Também fornece uma visão geral da proposta desta dissertação.

– Capítulo 2. Fundamentação Teórica

São introduzidos os conceitos essenciais para a compreensão do estudo, incluindo definições de linguagem negativa, aprofundamento do conceito de preconceito e suas diversas categorias, além de uma descrição das principais técnicas de vetorização, dos algoritmos de classificação e dos métodos de explicabilidade utilizados ao longo do trabalho.

– Capítulo 3. Trabalhos Relacionados

Este capítulo apresenta uma revisão bibliográfica comparativa das abordagens existentes na literatura, destacando métodos, resultados e limitações de pesquisas relacionadas ao tema desta dissertação.

– Capítulo 4. Os Conjuntos de Dados Explorados

Descreve-se o processo de construção dos conjuntos de dados *PrejudicePT-br*, *Preju-*

diceWhatsApp.Br e *PrejudiceTelegram.Br*, incluindo a metodologia de coleta, filtragem, rotulação e anonimização. O capítulo também apresenta uma análise exploratória dos dados e discute suas principais limitações e vieses.

– Capítulo 5. Detecção de Preconceito em Aplicativos de Mensagens Instantâneas

Este capítulo detalha os experimentos conduzidos para a detecção de preconceito, organizados em três abordagens: modelos clássicos de Aprendizado de Máquina, modelos pré-treinados e LLMs. Ao final, apresenta-se uma análise complementar do *dataset* utilizando a ferramenta LIWC e uma descrição dos experimentos de explicabilidade aplicados.

– Capítulo 6. Resultados

São analisados os resultados obtidos nos experimentos, destacando-se as melhores e as piores abordagens em termos de desempenho. O capítulo também discute os achados obtidos com os métodos de explicabilidade aplicados aos modelos.

– Capítulo 7. Conclusões e Trabalhos Futuros

O capítulo final sintetiza as contribuições científicas desta dissertação, discute as principais descobertas, limitações e ameaças à validade e apresenta possíveis melhorias e direções para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Nesta seção, apresentamos os principais fundamentos teóricos que sustentam o trabalho. Inicialmente, discutimos as formas de linguagem abusiva e o conceito de preconceito, incluindo seus diferentes tipos. Em seguida, abordamos as técnicas de vetorização usadas para representar textos numericamente, desde métodos clássicos como Bag of Words / Saco de Palavras (BoW) e Term Frequency-Inverse Document Frequency / Frequência do Termo - Inverso da Frequência dos Documentos (TF-IDF) até abordagens baseadas em embeddings, como o Bidirectional Encoder Representations from Transformers / Representações de Codificadores Bidirecionais a partir de Transformadores (BERT).

Também introduzimos Large Language Mode / Modelos de Linguagem de Grande Escala (LLMs) e o papel da engenharia de *prompt* na adaptação desses modelos a tarefas específicas. Apresentamos ainda o *Linguistic Inquiry and Word Count* / *Pesquisa Linguística e Contagem de Palavras* (LIWC), utilizado na análise linguística e psicossocial do texto. Por fim, descrevemos os algoritmos de classificação, as métricas de desempenho aplicadas e os métodos de explicabilidade adotados, com foco em Local Interpretable Model-agnostic Explanations / Explicações Locais Interpretáveis e Independentes de Modelo (LIME) e SHapley Additive exPlanations / Explicações Aditivas de Shapley (SHAP).

2.1 Tipos de Linguagens Abusivas

A linguagem utilizada de forma intencional para desrespeitar, insultar ou atacar um indivíduo pode ser classificada como linguagem abusiva ou ofensiva (ÇÖLTEKIN, 2020). É fundamental distinguir suas variações, uma vez que cada manifestação apresenta características e impactos distintos. Entre os principais tipos de linguagem abusiva, destacam-se a linguagem ofensiva, preconceituosa, pejorativa e tóxica, e o discurso de ódio, cada um deles expressando diferentes graus de hostilidade e potenciais consequências sociais.

- **Linguagem Ofensiva:** engloba qualquer forma de comunicação considerada inaceitável ou que cause ofensa, seja explícita ou velada. Essa categoria inclui o uso de palavrões, insultos, ameaças e publicações com conteúdo profano (BORIOLA; PAETZOLD, 2021). Um exemplo é a mensagem: “@USER Imagina! O que há de errado com esses idiotas? Graças a Deus pelo @USER”, que demonstra um discurso ofensivo direcionado a indivíduos, grupos ou até a terceiros (ZAMPIERI *et al.*, 2019).

- **Linguagem Pejorativa:** refere-se ao uso de palavras ou expressões que desvalorizam, insultam ou menosprezam alguém ou algo. Também conhecida como termo depreciativo ou termo de abuso, pode variar de acordo com o contexto: uma palavra considerada pejorativa em determinada situação pode assumir um caráter neutro ou até positivo em outra (NORDQUIST, 2019). Frequentemente, termos pejorativos ganham maior força quando direcionados a mulheres. Por exemplo, o termo “vadia” dificilmente é interpretado como elogio, enquanto “bastardo” pode, em certas circunstâncias, ser ressignificado como um termo de afeto ou até respeito. De forma semelhante, enquanto o termo masculino “mago” é geralmente associado a prestígio ou admiração, sua contraparte feminina, “bruxa”, tende a carregar conotações negativas (MCARTHUR; MCARTHUR, 2005).
- **Linguagem Tóxica:** é qualquer comunicação que use insultos, ameaças, assédio ou outros comentários degradantes contra um indivíduo ou grupo. Ela abrange uma ampla gama de expressões prejudiciais que, embora nem sempre se enquadrem legalmente como discurso de ódio, podem causar danos significativos, especialmente em ambientes online anônimos e de grande escala (MUMINOVIC; MUMINOVIC, 2025).
- **Discurso de Ódio:** refere-se a manifestações verbais ou textuais que expressam hostilidade contra indivíduos ou grupos, com a intenção de insultar, ofender ou intimidar, com base em características como raça, religião, orientação sexual, nacionalidade ou deficiência. Esse tipo de discurso não se limita ao uso de palavras negativas ou associadas ao ódio, mas depende fortemente do contexto em que são empregadas. Por exemplo, a frase “Eu odeio vê-los perdendo todas as vezes! É simplesmente injusto!” utiliza o termo “ódio”, mas não constitui discurso de ódio, pois não está direcionada a um grupo social específico, tampouco busca discriminá-lo. Em contrapartida, a frase “Eu odeio esses negros; eles continuam tornando a vida muito dolorosa” representa claramente um discurso de ódio, por atacar explicitamente um grupo étnico de forma discriminatória (WATANABE *et al.*, 2018).

Como discutido anteriormente, existem diferentes tipos de linguagem abusiva, que, embora apresentem distinções conceituais, frequentemente se sobrepõem em seus significados. Assim, uma mesma frase ou mensagem pode ser classificada simultaneamente como tóxica e ofensiva, entre outras categorias. Neste artigo, o foco recairá especificamente sobre a linguagem preconceituosa e as diferentes formas de preconceito associadas a ela.

2.2 Preconceito

Como abordado anteriormente, o conceito de preconceito passou por diferentes transformações ao longo do tempo. Atualmente, o dicionário o define como “Qualquer opinião ou sentimento concebido sem exame crítico”. Um dos principais estudiosos do tema foi Gordon Allport, que definiu preconceito como “Um sentimento favorável ou desfavorável, em relação a uma pessoa ou coisa, anterior ou não baseado em experiência social”. De forma mais detalhada, Allport caracteriza o preconceito como “Uma atitude aversiva ou hostil em relação a uma pessoa que pertence a um grupo, simplesmente porque ela pertence a esse grupo e, portanto, presume-se que tenha as qualidades questionáveis atribuídas ao grupo” (ALLPORT *et al.*, 1954).

Outros autores também trouxeram contribuições relevantes. Aronson define preconceito como “Uma atitude hostil ou negativa para com determinado grupo, baseada em generalizações deformadas ou incompletas”. Para o autor, qualquer pessoa pode ser alvo de preconceito, desde que pertença a um grupo social, seja por etnia, cor da pele, religião, gênero, idade, nacionalidade, orientação sexual, tamanho corporal ou deficiência, entre outros fatores (ARONSON *et al.*, 2010).

Já Mezan amplia essa compreensão ao definir o preconceito como “Um conjunto de crenças, atitudes e comportamentos que atribuem uma característica negativa a qualquer membro de um determinado grupo humano, unicamente com base em sua pertença a esse grupo; essa característica é percebida como essencial, definindo a natureza do grupo e, portanto, aderindo de forma indelével a todos os indivíduos nele incluídos” (MEZAN, 2021). Podemos adotar as definições de preconceito apresentadas pelos três autores, uma vez que, em conjunto, elas se complementam e oferecem uma compreensão mais abrangente do fenômeno.

2.2.1 Tipos de Preconceito

O preconceito manifesta-se de diversas formas, abrangendo diferentes grupos sociais e contextos. Nesta dissertação, o foco está em nove tipos específicos de preconceito: capacitismo, gordofobia, intolerância religiosa, LGBTQIA+fobia, misoginia, xenofobia, racismo, etarismo e preconceito político. A escolha dessas categorias visa contemplar formas recorrentes de discriminação observadas em ambientes digitais, especialmente nas redes sociais e nos aplicativos de mensagens. A seguir, cada um desses tipos de preconceito é descrito e discutido em maior detalhe.

- **Capacitismo:** Entende-se por capacitismo a atitude que diferencia, desvaloriza e marginaliza pessoas com deficiência com base na avaliação de suas capacidades corporais e/ou cognitivas (CAMPBELL, 2008). Para (AMUNDSON; TAIRA, 2005), o capacitismo pode ser compreendido como uma “doutrina” equivocada que enxerga a deficiência como algo horrível, indesejável e naturalmente inaceitável. Embora ainda não haja consenso absoluto sobre quais comportamentos configuram práticas capacitistas, é possível afirmar que um traço central dessa perspectiva é a crença de que a deficiência é intrinsecamente negativa e deve ser corrigida, curada ou eliminada (IVANOVICH; MARIVETE, 2020).
- **Gordofobia:** Refere-se ao preconceito, à estigmatização e à aversão direcionados às pessoas gordas, expressos por meio de uma opressão estrutural que atravessa a sociedade. Esse fenômeno é compreendido como resultado da influência das estruturas sociais e das instituições, que atuam na padronização de ações e posicionamentos, moldando a forma como os indivíduos entendem e mobilizam os significados atribuídos ao corpo no mundo social (RANGEL, 2018). Segundo outro autor, a gordofobia também pode ser definida como um medo patológico da gordura, frequentemente manifestado por atitudes negativas, estigmatizantes e pela reprodução de estereótipos sobre pessoas gordas (ROBINSON *et al.*, 1993).
- **Intolerância Religiosa:** Segundo o autor (NOGUEIRA, 2020), pode ser entendida como um conjunto de ideologias e atitudes ofensivas voltadas a crenças, rituais e práticas religiosas não hegemônicas. Essas práticas, quando associadas à falta de habilidade ou de vontade em reconhecer e respeitar a diversidade religiosa — como no caso das religiões de terreiro — configuram manifestações de ódio que podem ser enquadradas como crimes, por atentarem contra a liberdade de crença e a dignidade humana.
- **LGBTQIA+fobia:** Refere-se a ações discriminatórias e violentas dirigidas à diversidade, motivadas pela percepção de que esta representa uma ameaça ao ideário machista, que depende da manutenção de identidades binárias para sustentar o padrão masculino hegemônico (IBRAHIM, 2016). A discriminação contra pessoas LGBTQIA+ está diretamente associada ao preconceito em relação ao gênero, à identidade e/ou expressão de gênero e à diversidade sexual. Essa forma de intolerância implica violência e marginalização fundamentadas na ideia de que orientações sexuais não heterossexuais são negativas (CARDOSO *et al.*, 2022).

- **Misoginia:** Refere-se ao ódio, rejeição, aversão ou desprezo direcionado às mulheres e, de modo geral, a tudo o que é associado ao feminino. Esse sentimento frequentemente se manifesta em crenças negativas sobre as mulheres e o feminino, acompanhadas de comportamentos discriminatórios e violentos (PÉREZ; FIOL, 2000). A misoginia também pode ser entendida como a crença de que os homens são superiores às mulheres, ou ainda como a aversão às mulheres em diferentes esferas, incluindo o contato social e sexual (MOTERANI; CARVALHO, 2016).
- **Xenofobia:** Refere-se ao ódio, à hostilidade, à rejeição ou à suspeita em relação a estrangeiros ou a grupos étnicos considerados diferentes, bem como à aversão a pessoas cuja identidade social, cultural ou política é percebida como desconhecida ou ameaçadora. Essa forma de discriminação está enraizada em preconceitos históricos, religiosos, culturais e nacionais, levando o indivíduo xenófobo a justificar práticas de segregação e exclusão como forma de preservar sua própria identidade e a hegemonia do grupo ao qual pertence (GARZA, 2011).
- **Racismo:** Trata-se de uma forma específica de discriminação em que indivíduos, em razão de sua cor de pele ou de seu pertencimento racial, são submetidos a tratamentos desiguais, que podem incluir a negação de oportunidades sociais e econômicas ou a imposição de práticas de segregação (CERQUEIRA; MOURA, 2014). Também pode ser compreendido como um sistema social estruturado em que o grupo racial dominante, sustentado por uma ideologia de inferioridade, classifica e hierarquiza pessoas em categorias raciais, utilizando seu poder para desvalorizar, marginalizar e restringir o acesso a recursos e oportunidades sociais aos grupos considerados inferiores (WILLIAMS *et al.*, 2019).
- **Etarismo:** é a discriminação baseada na idade. Essa forma de preconceito pode ser dirigida a indivíduos ou grupos, resultando em tratamento inadequado por causa da sua faixa etária (PALMORE, 1999). O etarismo afeta principalmente pessoas "envelhecidas" ou mais velhas, com efeitos prejudiciais em suas vidas (LOTH; SILVEIRA, 2014).
- **Preconceito Político:** Define-se como as ideias ainda pouco desenvolvidas sobre o conteúdo do político-teórico que transita entre a organização social sistematizada e o próprio senso comum (CARNUT LEONARDO; AGRIPINO., 2025).

O preconceito está presente em várias fases da vida, afetando a liberdade individual e coletiva. Existem diversas formas de preconceito que exercem um papel negativo sobre a liberdade individual das pessoas, independentemente de sua gravidade (SAID *et al.*, 2023).

2.2.2 Preconceito em Redes Sociais

O preconceito manifesta-se de forma ampla e recorrente nas redes sociais digitais, como X (antigo Twitter) e Facebook, e, apesar dos esforços de governos, organizações internacionais e das próprias plataformas para mitigar esse fenômeno, ele permanece estruturalmente presente no ambiente digital. Um exemplo emblemático desse cenário é o caso em que o Facebook foi responsabilizado por investigadores das Nações Unidas por desempenhar um papel central na disseminação de discurso de ódio contra a comunidade Rohingya em Mianmar, contribuindo para um contexto de violência extrema e de possível genocídio (MATHEW *et al.*, 2019). Esse episódio evidencia como plataformas digitais podem potencializar a disseminação de conteúdos preconceituosos quando os mecanismos de moderação são insuficientes.

No contexto do WhatsApp, também se observa a ocorrência de diferentes formas de preconceito. Um caso noticiado no Brasil, intitulado “Racismo recreativo: Juíza mantém justa causa e usa protocolo do CNJ para derrubar ‘piadas’ de grupo do WhatsApp” (REGIÃO, 2025), relata uma situação explícita de racismo praticado em um grupo da plataforma, demonstrando que mensagens trocadas em ambientes privados ou semiprivados podem reproduzir e reforçar práticas discriminatórias. Outro episódio amplamente divulgado, “Preconceito em vez de analfabetismo digital por trás da disseminação de notícias falsas no WhatsApp na Índia” (ECONOMICS; SCIENCE, 2019), evidencia como preconceitos contra minorias religiosas contribuíram para a disseminação de desinformação, resultando em episódios de violência e intolerância religiosa.

No Telegram, o cenário não é menos preocupante. Estudos recentes indicam que discursos misóginos circulam com frequência na plataforma e, muitas vezes, se entrelaçam com outras formas de discriminação, como racismo e classismo (preconceito associado à posição socioeconômica) (FGV, 2025). A estrutura da plataforma, marcada por grupos públicos de grande alcance e baixa moderação, favorece a disseminação sistemática de conteúdos hostis e preconceituosos.

Diante desse panorama, torna-se evidente a necessidade de desenvolver métodos automáticos capazes de identificar e mitigar a propagação de linguagem preconceituosa em aplicativos de mensagens instantâneas. A ausência de moderação eficaz e o caráter altamente disseminável desses conteúdos reforçam a importância de pesquisas que proponham conjuntos de dados, recursos linguísticos e modelos computacionais voltados especificamente a esse contexto, contribuindo para a promoção de ambientes digitais mais seguros, inclusivos e respeitosos.

2.3 Técnicas de Vetorização

Nesta seção apresentamos três abordagens de vetorização de texto que fundamentam nossos experimentos. Iniciamos com métodos clássicos amplamente utilizados na literatura, como (BoW) e TF-IDF que representam o texto por meio de frequências de termos. Em seguida, avançamos para técnicas mais sofisticadas baseadas em modelos contextualizados, como o BERT, capazes de capturar nuances semânticas e relações complexas entre palavras no contexto da frase.

2.3.1 *Bag of Words (BoW)*

A **representação (BoW)** é uma das formas mais simples de representação textual, na qual cada palavra é tratada como uma unidade independente e igualmente significativa. Nessa abordagem, as frequências de palavras individuais ou de **n-gramas** (combinações de múltiplas palavras) são agregadas e analisadas para identificar padrões por exemplo, indícios de engano (SU QI, 2020).

De maneira ilustrativa, considere o seguinte conjunto de frases:

1. Joe esperou o trem;
2. O trem estava atrasado;
3. Mary e Samantha pegaram o ônibus;
4. Procurei Mary e Samantha na rodoviária;
5. Mary e Samantha chegaram cedo na rodoviária, mas esperaram até o meio-dia pelo ônibus.

Após o processo de **tokenização** e **remoção de stopwords**, é criado um vocabulário (dicionário) contendo todas as palavras distintas do corpus, por exemplo:

[*'e', 'chegou', 'em', 'nibus', 'mas', 'cedo', 'para', 'eu', 'joe', 'atrasado'...*]

Cada frase é então representada como um vetor que indica a frequência de cada termo do vocabulário. Exemplos:

- **Joe esperou o trem** → [0. 0. 0. 0. 0. 0. 1. 0. 1. 0. 0. 0. 0. 0. 0. 0. 2. 0. 1. 0.]
- **O trem estava atrasado** → [0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 1. 0. 1. 0. 0. 1.]
- **Mary e Samantha pegaram o ônibus** → [1. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 1. 0. 0. 1. 0. 0. 0. 0.]

Nesse modelo, a presença de uma palavra em um documento é representada apenas por sua frequência, **sem considerar contexto, ordem ou significado semântico**. Isso implica que documentos semelhantes tendem a apresentar distribuições de palavras semelhantes. Por outro lado, a abordagem BoW apresenta um desafio: a alta dimensionalidade. Como cada documento precisa ser representado por todos os termos presentes em toda a coleção, mesmo um conjunto pequeno de documentos pode gerar milhares de atributos. Por exemplo, apenas 10 documentos de tamanho médio podem gerar mais de 2.000 termos distintos, o que leva a vetores de alta dimensão e a custos computacionais elevados (MATSUBARA EDSON TAKASHI; MONARD, 2003).

2.3.2 *Term Frequency-Inverse Document Frequency (TF-IDF)*

Outra forma amplamente utilizada de representação textual é o **TF-IDF**. Esse modelo combina duas medidas complementares. A primeira delas, **TF (Term Frequency)**, avalia a frequência relativa de um termo em um documento, considerando a proporção entre o número de ocorrências desse termo e o número total de palavras do documento (QAISER; ALI, 2018). Por exemplo, suponha um documento T_1 com 5000 palavras, no qual o termo **Alfa** ocorre 10 vezes. Nesse caso, a frequência do termo é calculada como:

$$TF = \frac{10}{5000} = 0,002.$$

O segundo componente é o **IDF (Inverse Document Frequency)**, que mede a importância de um termo considerando sua frequência em uma coleção de documentos (QAISER; ALI, 2018). Palavras muito frequentes, como artigos e preposições, são menos informativas e recebem menor peso, enquanto termos raros ganham maior relevância. Formalmente, o IDF é definido como:

$$IDF(t) = \log \frac{N}{n_t},$$

onde N é o número total de documentos da coleção e n_t é o número de documentos em que o termo t aparece. Por exemplo, em uma coleção de $N = 10$ documentos, se o termo **technology** ocorre em $n_t = 5$ deles, temos:

$$IDF = \log \left(\frac{10}{5} \right) = 0,3010.$$

Finalmente, o valor do **TF-IDF** é obtido pelo produto das duas medidas:

$$TF-IDF = TF \times IDF = 0,002 \times 0,3010 = 0,000602.$$

A lógica por trás do **TF-IDF** é a seguinte: se uma palavra t ocorre com alta frequência em um documento d_i , mas aparece com baixa frequência nos demais documentos d_j do corpus, isso sugere que t possui maior relevância para caracterizar o conteúdo específico de d_i . Nesse sentido, a importância de t aumenta proporcionalmente à sua frequência em d_i e diminui proporcionalmente à frequência de ocorrência em outros documentos.

Uma das principais vantagens desse modelo é sua capacidade de atribuir maior peso aos termos distintivos de um documento em relação ao restante da coleção, diferentemente do modelo **Bag-of-Words**, que apenas contabiliza ocorrências sem considerar a relevância. Entretanto, o TF-IDF apresenta limitações importantes. Ele não captura aspectos semânticos nem considera a ordem ou dependência entre as palavras, tratando cada termo como independente (POMPEU, 2025).

2.3.3 *Embeddings*

Como definição geral, *embeddings* são dados transformados em vetores de um espaço n -dimensional, de modo a possibilitar seu uso em tarefas de aprendizado profundo (BOYKIS, 2023). Podemos compreender a construção de *embeddings* da seguinte maneira:

A seguir, temos uma única incorporação (*embedding*), também chamada de vetor, representada em três dimensões. Esse vetor corresponde à representação de um único elemento do conjunto de dados. Por exemplo, esta incorporação hipotética pode representar a palavra “mosca” em um espaço tridimensional. Em geral, representamos *embeddings* individuais como vetores linha:

$$\mathbf{v} = [1 \ 4 \ 9]$$

Agora, vejamos um tensor, ou matriz 3D, que corresponde a uma combinação de representações vetoriais de múltiplos elementos. Por exemplo, a matriz abaixo poderia representar conjuntamente as palavras “mosca” e “pássaro”:

$$A = \begin{bmatrix} 1 & 4 & 9 \\ 4 & 5 & 6 \end{bmatrix}$$

Esses *embeddings* são produzidos por meio de um processo de aprendizado, no qual dados de entrada brutos são fornecidos a um modelo de *machine learning*. O modelo transforma essas entradas multidimensionais e as projeta em um espaço de menor dimensão, preservando relações semânticas relevantes. O resultado final é um conjunto de vetores em um espaço de *embeddings*, em que elementos semelhantes ficam mais próximos entre si. Dessa forma, *embeddings* constituem a base para a representação numérica de elementos linguísticos em tarefas de Processamento de Linguagem Natural, permitindo que modelos computacionais capturem similaridades semânticas e relações contextuais entre palavras, frases ou documentos. Ao longo dos anos, diferentes abordagens foram propostas para gerar essas representações vetoriais, variando de métodos estáticos a modelos contextuais mais sofisticados. Nesse contexto, modelos de linguagem baseados em arquiteturas profundas, como o BERT, representam um avanço significativo, pois produzem *embeddings* contextuais capazes de adaptar a representação de cada palavra ao seu uso em diferentes contextos linguísticos.

2.3.3.1 BERT

O BERT é um modelo de linguagem treinado em grandes volumes de dados e baseado em representações contextuais profundas. Sua arquitetura é composta por múltiplas camadas do tipo *Transformer*, responsáveis pela extração hierárquica de características linguísticas, incluindo *embeddings* de palavras e camadas adaptáveis a diferentes tarefas de processamento de linguagem natural, como classificação de texto, resposta a perguntas e reconhecimento de entidades nomeadas. Reconhecido como um dos modelos mais influentes da área, o BERT alcança desempenho de estado da arte em diversas tarefas de PLN. Diferentemente das abordagens tradicionais de incorporação de palavras, seu processo de treinamento utiliza um mecanismo inovador de modelagem bidirecional, que permite que cada *token* seja interpretado considerando simultaneamente o contexto à esquerda e à direita, resultando em representações semânticas mais ricas e precisas (DEVLIN *et al.*, 2019).

2.3.3.2 Modelos Pré Treinados Bert

O modelo BERT é uma arquitetura baseada em modelos pré-treinados, com diversas variantes disponíveis para uso em diferentes tarefas. No entanto, nosso objetivo é selecionar um modelo treinado com dados semelhantes aos presentes nos conjuntos PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Após uma análise inicial, identificamos três modelos que consideramos mais adequados para nossa tarefa:

- **melll-uff/bertweetbr**: Este modelo segue a mesma arquitetura do BERTweet e foi treinado do zero utilizando o procedimento de pré-treinamento RoBERTa. O treinamento foi realizado sobre um corpus de aproximadamente 9 GB contendo cerca de 100 milhões de tweets em português, o que o torna particularmente adequado para lidar com linguagem informal, abreviações e características próprias de interações em redes sociais.
- **FpOliveira/tupi-bert-base-portuguese-cased**: O Tupi-BERT-Base é um modelo derivado do BERTimbau, aprimorado e adaptado para a classificação binária de discurso de ódio em português. Ele passou por um processo de ajuste fino no conjunto de dados *TuPi Hate Speech*, composto por exemplos coletados em diversas redes sociais. Essa especialização é importante, pois modelos de linguagem podem apresentar variações significativas de desempenho quando confrontados com mudanças de domínio entre os dados de treinamento e de teste. Assim, o *Tupi-BERT* se mostra uma alternativa promissora para tarefas que envolvem identificação de linguagem discriminatória.

- **ruanchaves/bert-base-portuguese-cased-hatebr**: Este modelo é uma versão adaptada do *neuralmind/bert-base-portuguese-cased* para a detecção de linguagem ofensiva, com base no conjunto de dados *HateBR*. Sendo um modelo especificamente afinado para o português e voltado ao discurso de ódio, é diretamente aplicável ao nosso problema.

Com esses modelos pré-treinados, seguimos a seguinte abordagem. Geração de *embeddings*: utilizamos os modelos selecionados para extrair representações vetoriais (*embeddings*) dos textos, que foram então empregadas como *features* para algoritmos de aprendizado de máquina clássicos (como Regressão Logística, Random Forest, SVM entre outros) realizarem a classificação.

2.4 LLM's

Normalmente, as LLMs referem-se a arquiteturas baseadas em *Transformers* que possuem centenas de bilhões de parâmetros, ou até mais, e são treinadas em coleções massivas de textos. Exemplos notáveis incluem GPT-3, PaLM, Galactica e LLaMA. Esses modelos seguem, em geral, a mesma estrutura fundamental: uma pilha profunda de camadas *Transformer* composta por mecanismos de atenção multi-cabeças, *feed-forward* e normalização, permitindo que o modelo capture dependências complexas em diferentes escalas (ZHAO *et al.*, 2023). As LLMs podem ser usadas para diversas tarefas, como geração de texto, classificação, resumo automático, tradução, resposta a perguntas, extração de informações, análise de sentimentos, conversação, expansão e reescrita de textos, além de auxiliar no rótulo automático de dados (*data labeling*) e na criação de dados sintéticos para ampliar conjuntos de treinamento (WIGGINS; TEJANI, 2022). Elas também têm sido aplicadas a tarefas mais avançadas, como raciocínio lógico, resolução de problemas, análise de código, planejamento, detecção de padrões discursivos e suporte a decisões em diferentes domínios, demonstrando sua versatilidade e capacidade de adaptação a múltiplos contextos linguísticos e cognitivos (WEI *et al.*, 2022).

Apesar do sucesso das LLMs em tarefas de geração de texto e em diversos cenários de PLN, esses modelos ainda tendem a apresentar desempenho inferior quando comparados a modelos supervisionados especificamente ajustados para tarefas de classificação. Dois fatores principais explicam essa limitação. Primeiro, a tarefa de classificação frequentemente exige capacidades de raciocínio mais refinadas, necessárias para lidar com fenômenos linguísticos complexos como negação, concessão, intensificação, ironia e estruturas composicionais que nem sempre são plenamente capturados pelo aprendizado em contexto. Segundo, o número de

exemplos disponíveis no *prompt* é limitado pelo tamanho máximo da janela de contexto; por exemplo, o GPT-3 permite apenas 4.096 *subtokens*, o que impede o modelo de aproveitar a totalidade dos exemplos disponíveis no conjunto de treinamento. Como consequência, LLMs frequentemente utilizam apenas uma fração reduzida das evidências necessárias para a tarefa, o que leva a resultados inferiores em comparação com abordagens supervisionadas finamente ajustadas (SUN *et al.*, 2023).

Além disso, mesmo com suas capacidades impressionantes, os LLMs enfrentam desafios críticos relacionados a viés, privacidade e transparência, que impactam diretamente sua aplicação em cenários reais (LIYANAGE; RANAWEERA, 2023). Esses modelos podem memorizar e amplificar vieses presentes nos dados de treinamento, reproduzindo e até intensificando vieses de gênero, raça ou contexto, o que pode resultar em decisões discriminatórias ou eticamente problemáticas (BOLUKBASI *et al.*, 2016).

2.4.1 Engenharia de Prompt

O paradigma de *prompting* baseia-se no uso de instruções ou descrições em linguagem natural —frequentemente contendo regras, exemplos, lacunas ou informações de contexto com o objetivo de orientar LLMs na execução de tarefas específicas. À medida que esses modelos evoluem, tanto em número de parâmetros quanto na diversidade e no volume dos dados utilizados no pré-treinamento, passam a demonstrar capacidades emergentes, sendo capazes de resolver tarefas complexas sem a necessidade de ajuste fino (**fine-tuning**) adicional (ZHAO *et al.*, 2024).

No contexto da classificação de textos, o *prompting* pode assumir diferentes estratégias, dentre as quais destacam-se:

- **Zero-shot prompting:** o modelo recebe apenas uma instrução em linguagem natural, sem qualquer exemplo prévio da tarefa (BROWN *et al.*, 2020).
- **One-shot prompting:** uma única demonstração é incluída no prompt como referência para orientar a resposta do modelo (BROWN *et al.*, 2020).
- **Few-shot prompting:** múltiplas demonstrações são fornecidas ao modelo, limitadas pelo tamanho da janela de contexto disponível (BROWN *et al.*, 2020).
- **Role-prompting:** o modelo é instruído a assumir um papel específico, como “especialista em linguística”, “analista de discurso” ou “detector de preconceito”, fornecendo um enquadramento contextual sobre sua identidade e sua área de expertise, o que tende a aumentar a precisão e a consistência das respostas (KONG *et al.*, 2024).

Essas estratégias representam as abordagens de *prompting* mais amplamente utilizadas e eficazes para adaptar LLMs a tarefas de classificação de texto, possibilitando seu emprego sem a necessidade de treinamento supervisionado adicional.

2.5 Linguistic Inquiry and Word Count (LIWC)

Os conjuntos, tanto de palavras de uma língua quanto de termos próprios de um campo, são conhecidos como léxicos ou dicionários. Para tarefas de identificação de emoções em textos, os conjuntos de palavras são focados em emoções e chamados de dicionários afetivos. O LIWC é um programa de análise computadorizada de texto para medir a quantidade de palavras em um texto, inseridas em pelo menos uma das mais de 60 categorias em que está organizado o seu arquivo de dicionário. Pode ser dividido em duas partes: uma é o programa principal e a outra é um dicionário que define quais palavras o programa deve contar nos arquivos de texto a serem analisados (CARVALHO, 2019).

No dicionário, as palavras estão organizadas em grupos de um domínio específico. Esses agrupamentos são chamados de subdicionários ou categorias de palavras. O dicionário contém palavras designadas a uma ou mais categorias que refletem processos linguísticos, psicológicos ou relacionados a diversos assuntos, como pronomes (pronoun), emoções positivas (posemo), processos sociais (social) e assim por diante (CARVALHO, 2019).

2.6 Algoritmos de Classificação

Testaremos nove algoritmos supervisionados de *machine learning*, abrangendo diferentes categorias: modelos lineares, modelos generativos, aprendizado baseado em instâncias, máquinas de vetores de suporte, métodos de aprendizado em conjunto e redes neurais. A seguir, descrevemos cada um deles:

- **Logistic Regression / Regressão Logística (LR):** Segundo (BISHOP; NASRABADI, 2006), a regressão logística (também conhecida como modelo logit ou classificador de máxima entropia) é um método estatístico de classificação cuja superfície de decisão é linear. Em outras palavras, há uma relação linear entre os atributos de entrada e a saída predita. Problemas em que as classes podem ser separadas exatamente dessa forma são denominados linearmente separáveis.
- **Bernoulli Naive Bayes / Naive Bayes Bernoulli (BNB):** Conforme descrito em (QUI-

XADÁ, 2019), trata-se de um algoritmo probabilístico de classificação simples, baseado no teorema de Bayes. Esse teorema descreve a probabilidade de ocorrência de um evento considerando dados prévios. No caso do Bernoulli, utilizam-se recursos binários, que indicam apenas a presença ou a ausência de termos.

- **Multinomial Naive Bayes / Naive Bayes Multinomial (MNB):** Também definido em (QUIXADÁ, 2019), é um algoritmo probabilístico de classificação que assume que cada documento pode ser representado pela frequência de ocorrência de termos. Diferentemente do Bernoulli, o modelo multinomial considera as contagens de palavras, sendo amplamente utilizado em tarefas de classificação de textos.
- **K-Nearest Neighbors / K-vizinhos mais próximos (KNN):** De acordo com (SUYAL; GOYAL, 2022), o modelo KNN atribui uma nova amostra a uma categoria com base na proximidade em relação aos seus K vizinhos mais próximos. A decisão é tomada por votação majoritária, considerando a categoria mais frequente entre os vizinhos.
- **Linear Support Vector Machine / Máquina de Vetores de Suporte Linear (LSVM):** Segundo (Scikit-learn Learner, 2023), o LinearSVC é uma máquina de vetores de suporte linear para tarefas de classificação, otimizada para grandes conjuntos de dados. O modelo constrói um limite de decisão linear ao minimizar uma função de perda regularizada.
- **Stochastic Gradient Descent Classifier / Classificador por Gradiente Descendente Estocástico (SGD):** Como discutido em (NEWTON *et al.*, 2018), trata-se de um método iterativo utilizado para resolver problemas de otimização estocástica. Cada iteração atualiza os parâmetros do modelo a partir de uma estimativa do gradiente baseada em apenas um exemplo aleatório, o que o torna eficiente para grandes volumes de dados.
- **Random Forest / Floresta Aleatória (RF):** Segundo (SCHONLAU; ZOU, 2020), é um algoritmo de aprendizado baseado em árvores de decisão de conjunto. Ele gera múltiplas árvores a partir de amostras *bootstrap* dos dados originais (técnica conhecida como *bagging*) e combina suas previsões por meio da média ou da votação. Esse processo reduz o sobreajuste e melhora a generalização.
- **Gradient Boosting / Boosting de Gradiente (GB):** De acordo com (BIAU; CADRE, 2021), trata-se de uma técnica preditiva de última geração que constrói modelos de forma sequencial, combinando preditores fracos — normalmente árvores de decisão — em um modelo robusto. O processo é formulado como a resolução de um problema de otimização convexa.

- **Multilayer Perceptron / Perceptron Multicamada (MLP):** Conforme descrito em (PO-PESCU *et al.*, 2009), o perceptron multicamadas é um dos modelos de redes neurais mais conhecidos e utilizados. Sua arquitetura é do tipo *feed-forward*, em que os sinais são transmitidos da camada de entrada até a camada de saída, sem retroalimentação.

2.7 Métricas de Desempenho

Para avaliar o desempenho dos métodos experimentados, adotamos métricas de classificação binária amplamente utilizadas na literatura. As mensagens rotuladas como preconceituosas são consideradas positivas (P), enquanto as não preconceituosas são consideradas negativas (N). Dessa forma, o resultado de uma predição pode ser descrito da seguinte maneira:

- **Verdadeiro Positivo (VP):** mensagem preconceituosa corretamente classificada como tal;
- **Verdadeiro Negativo (VN):** mensagem não preconceituosa corretamente classificada como tal;
- **Falso Positivo (FP):** mensagem não preconceituosa incorretamente classificada como preconceituosa;
- **Falso Negativo (FN):** mensagem preconceituosa classificada incorretamente como não-preconceituosa.

Com base nessas definições, as métricas de desempenho adotadas são apresentadas a seguir, sendo calculadas a partir das predições dos modelos no conjunto de teste.

A **Area Under the ROC Curve / Área sob a Curva ROC (AUC)** é uma métrica amplamente utilizada para avaliar o desempenho de classificadores. A curva ROC representa a relação entre a taxa de verdadeiros positivos (recall ou Taxa de Verdadeiros Positivos – TVP) e a taxa de falsos positivos (TFP), considerando todos os possíveis limiares de decisão. Dessa forma, a AUC reflete a capacidade do modelo de distinguir corretamente entre as classes, considerando as probabilidades atribuídas às predições, independentemente de um limiar específico. O valor 0,5 indica um classificador aleatório (curva próxima à diagonal), enquanto 1,0 corresponde a um classificador perfeito, capaz de separar completamente as classes. Sua fórmula é dada por:

$$TVP = \frac{VP}{VP + FN} \quad TFP = \frac{FP}{FP + VN} \quad (2.1)$$

A **Precisão** é definida como a proporção de mensagens previstas como preconceituosas que, de fato, pertencem a essa classe. Quanto maior a precisão, maior a confiança nas predições positivas do modelo. Uma precisão baixa, por outro lado, indica a ocorrência de muitos falsos positivos. Sua fórmula é dada por:

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2.2)$$

O **Recall**, ou taxa de verdadeiros positivos, é a proporção de mensagens preconceituosas corretamente classificadas em relação ao total de mensagens preconceituosas existentes. Quanto maior o *recall*, maior a confiança de que o modelo não deixa de identificar ocorrências de preconceito. Um baixo *recall* indica que o modelo gera muitos falsos negativos. Sua fórmula é dada por:

$$\text{Recall} = \frac{VP}{VP + FN} \quad (2.3)$$

O **F1-score** é a média harmônica entre a precisão e o *recall*. Assim como a acurácia, também é uma média geral, mas leva em conta os falsos positivos e os falsos negativos.

$$\text{F1-score} = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.4)$$

2.8 Métodos de Explicabilidade

Outro conceito fundamental para este trabalho é a explicabilidade dos modelos. Nos últimos anos, o crescimento substancial do poder computacional possibilitou o avanço acelerado de algoritmos de inteligência artificial, como redes neurais profundas e métodos modernos de aprendizado de máquina, ampliando significativamente seu uso em diversos domínios. Esse progresso também estimulou o desenvolvimento de princípios, métodos e aplicações no campo da Explainable Artificial Intelligence / Inteligência Artificial Explicável (XAI).

Apesar disso, ainda não existe uma estrutura conceitual única e amplamente consolidada para a área. No entanto, dois métodos de interpretabilidade *pós-hoc* para modelos de “caixa preta” tornaram-se amplamente reconhecidos e utilizados: LIME e SHAP. Ambos buscam tornar modelos complexos mais compreensíveis, oferecendo explicações transparentes sobre os fatores que influenciam cada decisão (ZHANG *et al.*, 2025).

Além disso, precisamos medir a fidelidade das justificativas que esses modelos geram e, uma das maneiras de fazermos isso em particular, seguindo (YU *et al.*, 2019), definimos métricas destinadas a medir a abrangência (todos os recursos necessários para fazer uma previsão foram selecionados) e a suficiência (as justificativas extraídas contêm sinal suficiente para chegar a uma conclusão?) das justificativas, respectivamente.

2.8.1 LIME

O LIME é um método de interpretabilidade que busca explicar por que um modelo complexo tomou uma decisão específica. A ideia central é que, mesmo que o modelo seja difícil de entender como um todo, seu comportamento, bem perto de uma instância, pode ser aproximado por um modelo simples.

Para isso, o LIME cria várias versões levemente modificadas da entrada original e observa como o modelo reage a essas mudanças. Essas perturbações são, então, ponderadas de acordo com o quão parecidas são com o exemplo real. Com essas informações, o LIME treina um modelo simples e interpretável, como uma regressão linear, que tenta imitar o comportamento do modelo complexo apenas naquela vizinhança. A explicação final surge desse modelo simples, mostrando quais características foram mais importantes e em que direção levaram à predição (GARREAU; LUXBURG, 2020).

2.8.2 SHAP

O método SHAP é uma abordagem de explicabilidade que ajuda a entender por que um modelo de aprendizado de máquina tomou uma decisão específica. A ideia central é atribuir a cada característica (*feature*) um valor que represente o quanto ela contribuiu para a previsão final. Ele se baseia nos valores de Shapley, provenientes da teoria dos jogos cooperativos, que definem uma forma justa de distribuir os ganhos entre os jogadores. No contexto de modelos, cada *feature* é tratada como um “jogador” que contribui para a geração da saída do modelo. Assim, o SHAP divide de forma equilibrada o “crédito” ou até mesmo a “culpa” da previsão entre todas as características envolvidas.

Na prática, o SHAP calcula quanto cada atributo contribui para a diferença entre a previsão específica de uma instância e a previsão média do modelo. Com isso, conseguimos identificar claramente quais variáveis puxaram a decisão para cima ou para baixo, permitindo interpretar até modelos muito complexos de forma transparente (ZHANG *et al.*, 2025).

2.9 Conclusão

Neste capítulo, discutimos os principais conceitos necessários ao desenvolvimento deste trabalho. Apresentamos os diferentes tipos de linguagem negativa e as definições de preconceito, incluindo suas manifestações e categorias. Também revisamos métodos de vetorização textual que serão utilizados ao longo da dissertação, abrangendo desde abordagens tradicionais até modelos avançados, como grandes modelos de linguagem (LLMs). Por fim, introduzimos ferramentas complementares de análise linguística, como o LIWC, e métodos de explicabilidade, como SHAP e LIME, que serão fundamentais para interpretar o comportamento dos modelos nos capítulos seguintes. No capítulo seguinte, são apresentados os trabalhos relacionados a esta dissertação, com o objetivo de evidenciar a lacuna de pesquisa e destacar as contribuições propostas por este estudo.

3 TRABALHOS RELACIONADOS

Este capítulo tem como objetivo apresentar os trabalhos relacionados ao tema deste artigo, especificamente no que se refere à detecção de mensagens preconceituosas nas mídias sociais, no contexto da língua portuguesa. Além disso, serão discutidos os conjuntos de dados disponíveis, as abordagens propostas, os métodos empregados e as ferramentas mais frequentemente utilizadas. Por fim, será realizada uma análise comparativa dos estudos apresentados, destacando as lacunas existentes e indicando os espaços nos quais esta dissertação busca oferecer suas contribuições.

3.1 Detecção de Textos Abusivos em Redes Sociais

Detectar textos com linguagem abusiva nas redes sociais é uma tarefa fundamental para promover um ambiente comunicativo mais saudável. Diversos trabalhos têm se dedicado a esse desafio, como em (DINU *et al.*, 2021), no qual os autores investigaram a seguinte tarefa de classificação: dado um termo e um *tweet* em que esse termo aparece, determinar se ele foi empregado de forma pejorativa ou não. O estudo concentrou-se no nível lexical, explorando questões relacionadas à ambiguidade na linguagem tóxica. Para a avaliação, foram utilizados dois conjuntos de dados, PEJOR1 e PEJOR2, com 944 e 313 pares de *tweet* e palavra, respectivamente. O conjunto PEJOR1 foi construído para manter o equilíbrio entre três rótulos (odioso, ofensivo e nenhum), enquanto o PEJOR2 buscou garantir equilíbrio tanto na distribuição das palavras quanto nos rótulos originais. O melhor desempenho foi obtido com o algoritmo MLP, que alcançou uma pontuação F1 de 0,864, embora também tenham sido avaliados os algoritmos KNN e SVM. Além disso, o trabalho apresentou a construção de um léxico multilíngue de termos pejorativos em inglês, espanhol, italiano e romeno, elaborado com base em dicionários online.

Outro autor (VARGAS *et al.*, 2022) apresentou o HateBR, um corpus em português composto por 7.000 comentários coletados do Instagram, contendo discurso de ódio e linguagem ofensiva. O conjunto foi anotado em três níveis: (i) classificação binária (ofensivo vs. não ofensivo), (ii) gradação do nível de ofensa (leve, moderada e alta) e (iii) nove categorias específicas de discurso de ódio — entre elas, xenofobia, racismo, homofobia, sexismo, intolerância religiosa, partidarismo, defesa da ditadura, antissemitismo e gordofobia. Para validar o corpus, foram conduzidos experimentos com diferentes algoritmos de aprendizado de máquina na tarefa de classificação. Os melhores modelos alcançaram F1-scores de 0,85 na detecção de linguagem ofensiva e de 0,78 na identificação de discurso de ódio.

Um léxico de expressões ofensivas em português, denominado MOL (Multilingual Offensive Lexicon), foi apresentado em (VARGAS *et al.*, 2021b). Esse recurso foi extraído do corpus HateBR (VARGAS *et al.*, 2021c) e construído a partir da anotação manual de termos e expressões por três avaliadores independentes, incorporando informações contextuais relevantes. A partir desse léxico, os autores propuseram uma abordagem inovadora para a detecção de linguagem ofensiva e de discurso de ódio em redes sociais. Os experimentos foram realizados sobre o corpus HateBR, empregando diferentes algoritmos de aprendizado de máquina — SVM, Naive Bayes (NB), MLP, LSTM e modelos pré-treinados de *embeddings*. Os melhores resultados alcançaram um F1-score de 0,88 na detecção de linguagem ofensiva e de 0,85 na detecção de discurso de ódio, ambos obtidos utilizando a representação de atributos B+M (Bag-of-Words incorporado ao MOL).

Em (LEITE *et al.*, 2020), os autores apresentaram o ToLD-Br (Toxic Language Dataset for Brazilian Portuguese), um conjunto de dados composto por 21.000 *tweets* em português anotados manualmente quanto à presença ou ausência de toxicidade, além de diferentes tipos de manifestações tóxicas. As anotações foram realizadas em sete categorias: *não tóxico*, *LGBTQIA+fobia*, *obscenidade*, *insulto*, *racismo*, *misoginia* e *xenofobia*, sendo que cada *tweet* recebeu três avaliações independentes. Para os experimentos, adotou-se a estratégia de considerar um *tweet* como tóxico sempre que ao menos um anotador atribuiu uma categoria ofensiva. O ToLD-Br foi então utilizado para avaliar o desempenho de modelos baseados em BERT na classificação automática de comentários tóxicos, alcançando-se como melhor resultado um macro-F1 de 0,76.

Os autores (VAZ *et al.*, 2025) propuseram a detecção de discurso racista em língua portuguesa do Brasil, apresentando um conjunto de dados rotulado integralmente por representantes negros. Esse corpus foi construído a partir de comentários coletados na plataforma X e utilizado para comparar o desempenho de modelos clássicos (Naive Bayes, Regressão Logística, Random Forest e XGBoost) com modelos baseados em Transformers (BERTimbau e RoBERTa). Nos experimentos, o melhor resultado foi obtido pelo BERTimbau, que atingiu um F1-score de 0,82.

Em (MUMINOVIC; MUMINOVIC, 2025), os autores propõem a detecção de linguagem tóxica em idiomas balcânicos, como o sérvio, o bósnio e o croata. Para isso, utilizaram 4.500 comentários coletados das plataformas YouTube e TikTok, distribuídos igualmente entre os três idiomas (1.500 por idioma), abrangendo diferentes domínios, como política, música, esporte e cultura. O estudo avaliou o desempenho de modelos de LLMs tanto em cenários sem contexto quanto em cenários com contexto adicional. Os resultados mostraram que o melhor desempenho foi um F1-score de 0,81 e que a inclusão de contexto contribuiu para uma leve melhoria nos resultados em todos os idiomas analisados.

O estudo de (ROY *et al.*, 2023) avaliou o uso de LLMs (GPT-3.5, Flan-T5-large e text-davinci-003) na detecção de discurso de ódio em três conjuntos de dados: HateXplain, Implicit Hate e ToxicSpans. Como linha de base, utilizou-se o modelo BERT HateXplain. Nos *prompts* padrão, o Flan-T5 obteve melhor desempenho em HateXplain e em Implicit Hate, enquanto o text-davinci-003 superou o GPT-3.5 em todos os conjuntos de dados. O melhor desempenho geral foi observado em ToxicSpans. A inclusão de definições nos prompts resultou em resultados inconsistentes, podendo melhorar ou prejudicar o desempenho. O uso de explicações/justificativas apresentou um padrão semelhante, com ganhos em alguns modelos e perdas em outros. A estratégia mais eficaz foi a inclusão de alvos (*targets*), que resultou em melhorias significativas, especialmente em HateXplain e Implicit Hate. Combinações de múltiplas estratégias (como definições + explicações) não trouxeram benefícios consistentes. Os resultados mostram que a estruturação do *prompt* influencia fortemente o desempenho das LLMs. O uso de alvos destaca-se como a abordagem mais promissora para aumentar a precisão na detecção de discurso de ódio.

A detecção de discurso de ódio, a análise contextual baseada em geografia e a robustez diante de textos gerados adversariamente foram as tarefas investigadas por (ZAHID *et al.*, 2025), em um estudo conduzido em cinco idiomas (árabe, bengali, hindi, chinês e russo). Os autores avaliaram três LLMs distintos: Llama2, Codellama e Deepseekcoder. Para a detecção de discurso de ódio, o Codellama apresentou o melhor desempenho, com F1-score de 0,52. Já na tarefa de identificação da localização geográfica associada ao discurso de ódio, o Llama2 superou os demais modelos. Por fim, nos experimentos realizados em conjuntos de dados sintéticos, o Deepseekcoder obteve os melhores resultados. Além disso, os autores realizaram um estudo piloto para comparar a qualidade da tradução dos textos pelo Google Tradutor, mostrando que não houve ganhos significativos de desempenho.

3.2 Avaliando o Uso de Dicionário para Análise de Texto

Em (CARVALHO *et al.*, 2018a), os autores propuseram o AffectPT-br, um dicionário afetivo do português brasileiro. O recurso foi desenvolvido a partir do LIWC 2015 em inglês, contemplando 1.139 palavras da categoria affect, sendo 479 positivas (posemo) e 661 negativas (negemo). Para validar o dicionário, os autores compararam o desempenho do AffectPT-br com o LIWC2007pt em tarefas de classificação de polaridade. Os experimentos foram realizados em dois conjuntos de dados distintos: My Dear Diary (MQD) e TAS-PT, utilizando os algoritmos SVM, NBM, RF e J48. Os melhores resultados foram alcançados com o AffectPT-br, obtendo F1-score de 0,715 no MQD e 0,960 no TAS-PT.

O estudo de (CARVALHO *et al.*, 2023) avaliou o desempenho dos dicionários BP-LIWC2015 e BP-LIWC2007 na classificação de polaridade de textos em português brasileiro. Para isso, foram utilizados quatro conjuntos de dados públicos e sete algoritmos de aprendizado de máquina: Naive Bayes (NB), Multinomial Naive Bayes (MNB), Regressão Logística, Support Vector Machine (SVM), Random Forest (RF), LMT e J48. Os resultados da primeira tarefa demonstraram que o BP-LIWC2015 superou o BP-LIWC2007 em termos de eficácia na classificação. Na segunda etapa do estudo, os autores investigaram a equivalência entre os dicionários BP-LIWC2015, BP-LIWC2007 e o original em inglês, LIWC2015. Utilizando um conjunto de dados bilíngue (inglês-português), a análise revelou uma correlação mais forte entre o BP-LIWC2015 e o LIWC2015. Por fim, os pesquisadores buscaram responder à pergunta: "Existe uma diferença significativa entre os dicionários de português brasileiro?". Embora o BP-LIWC2007 contenha mais palavras, os resultados de classificação mostraram que o BP-LIWC2015 alcançou um desempenho superior.

No estudo de (WIDMANN; WICH, 2023), foi introduzido e avaliado um novo dicionário de emoções (ed8), desenvolvido especificamente para analisar textos políticos em alemão. Esse dicionário é capaz de identificar e medir a linguagem associada a oito emoções distintas: raiva, medo, nojo, tristeza, alegria, entusiasmo, orgulho e esperança. Os autores compararam o desempenho do dicionário ed8 com outras abordagens, como redes neurais simples e classificadores baseados em Transformers. Para isso, foram treinados diferentes modelos de aprendizado de máquina. Os resultados mostraram que todas as abordagens personalizadas superaram os dicionários de uso geral na medição da linguagem emocional no discurso político alemão.

A classificação automática da polaridade em postagens relacionadas à ansiedade em uma plataforma de mídia social chinesa foi investigada em (ZHU *et al.*, 2024). Para isso, os autores extraíram características linguísticas das postagens utilizando o dicionário *Simplified Chinese–Linguistic Inquiry and Word Count* (SC-LIWC) e treinaram modelos supervisionados e de aprendizado profundo. O conjunto de dados foi rotulado por três especialistas em psicologia, contendo 3.041 postagens positivas e 3.041 negativas. No total, foram avaliados nove algoritmos de aprendizado de máquina supervisionado e quatro de aprendizado profundo. Os resultados experimentais mostraram que a abordagem proposta superou métodos tradicionais na identificação da polaridade sentimental de postagens relacionadas à ansiedade, alcançando F1-scores de 0,86 com o modelo SVM e 0,87 com o modelo TextCNN.

Da forma semelhante, o estudo de (SERT; ÜLKER, 2023) examinou como a combinação entre o aprendizado de máquina e o dicionário LIWC pode ser utilizada para detectar transtornos mentais por meio da análise de mídias sociais. Os resultados mostraram que os algoritmos de aprendizado de máquina superaram as abordagens que utilizam apenas o dicionário LIWC na análise de texto. Além disso, o estudo concluiu que a integração do aprendizado de máquina ao LIWC oferece uma vantagem significativa, pois possibilita uma compreensão mais profunda de fenômenos complexos, como os relacionados à saúde mental.

No estudo de (BAHGAT *et al.*, 2022), foi introduzido o LIWC-UD, uma extensão do dicionário LIWC que incorpora termos do Urban Dictionary. Enquanto o LIWC original possui 6.547 entradas únicas, o LIWC-UD expande essa base para 141.000 termos, que foram categorizados automaticamente com alta confiança segundo as categorias do LIWC. A categorização dos novos termos foi realizada por meio de dois métodos: um classificador baseado em BERT e o modelo *LIWC Max Category Count*. O estudo demonstrou que o modelo baseado em BERT superou o *LIWC Max Category Count* em termos de desempenho. Além disso, o artigo concluiu que o LIWC-UD possui uma cobertura significativamente maior de termos recém-adotados, que não são capturados pelo dicionário LIWC padrão.

3.3 Análise de Vieses em Modelos de Linguagem

O estudo de (TASO *et al.*, 2023) utiliza uma série de experimentos baseados no Teste de Associação Implícita (IAT), da psicologia, para identificar e quantificar vieses em uma representação de *Word Embedding* (WE) para a língua portuguesa. Para essa análise, os autores usaram um modelo GloVe treinado com um grande conjunto de dados da internet. Os resultados

revelaram a presença de diversos estereótipos de gênero comuns no modelo. A pesquisa destaca a necessidade de um debate mais aprofundado sobre o impacto social dos modelos de linguagem.

3.4 Análise dos Resultados por Meio de Modelos de Explicabilidade

Os autores propõem o primeiro conjunto de dados explicável de discurso de ódio em português brasileiro (HateBRXplain) (SALLES *et al.*, 2025), contendo 7.000 comentários do Instagram (3.500 ofensivos e 3.500 não ofensivos) extraídos do corpus HateBR. Os autores avaliaram o conjunto de dados usando modelos baseados em *Transformers* (mBERT, BERTimbau, DistilBERTimbau e PTT5), sendo o BERTimbau o que apresentou o melhor desempenho de classificação ($F1 = 0,91$). Para investigar a interpretabilidade, aplicaram métodos de explicabilidade *pós-hoc* (LIME e SHAP), avaliando as explicações quanto à plausibilidade (alinhamento com anotações humanas) e à fidelidade (consistência com as decisões do modelo).

O estudo aborda a detecção automática de desinformação em mensagens do WhatsApp sobre a COVID-19, destacando que, apesar do bom desempenho, os modelos de aprendizado de máquina utilizados permanecem caixas-pretas. Para aumentar a transparência, os autores aplicam o método de interpretabilidade LIME, explicando as decisões do modelo SVM linear e identificando palavras-chave que influenciam a classificação das mensagens como desinformação ou não. Além disso, utilizam o LIWC para analisar características linguísticas e psicológicas, revelando padrões significativos: as mensagens de desinformação tendem a expressar mais emoções negativas, ansiedade, raiva e temas como dinheiro e morte, além de apresentar uma linguagem mais sofisticada e persuasiva (MARTINS *et al.*, 2022).

3.5 Análise Comparativa

A Tabela 1 apresenta as principais características dos trabalhos relacionados, incluindo a "Tarefa" ou problema investigado, se o estudo fornece conjuntos de dados disponíveis publicamente, os classificadores avaliados nos experimentos e se implementa métodos de explicabilidade. É importante destacar que, diferentemente de estudos anteriores, este trabalho se concentra especificamente na detecção de linguagem preconceituosa. Além disso, ele se diferencia por utilizar conjuntos de dados coletados de fontes do WhatsApp e do Telegram no idioma português brasileiro (PT-BR), que ainda são relativamente pouco exploradas na literatura, e por incorporar métodos de explicabilidade para tornar as decisões dos modelos mais transparentes.

Tabela 1 – Principais características de trabalhos relacionados

Trabalho	Tarefa	Dataset Público	Classificadores	Explicabilidade
[Dinu et al., 2021]	Deteção de Linguagem Pejorativa	Sim	KNN, SVM, MLP	Não
[Vargas et al., 2022]	Deteção de Linguagem Ofensiva e Discurso de Ódio	Sim	NB, SVM, MLP, LR	Não
[Vargas et al., 2021]	Deteção de Linguagem Ofensiva e Discurso de Ódio	Sim	SVM, MNB, MLP, LSTM	Não
[Leite et al., 2020]	Deteção de Linguagem Tóxica	Sim	BERT	Não
[Carvalho et al., 2018]	Deteção de Polaridade	Sim	SVM, MNB, RF, J48	Não
[Vaz et al., 2025]	Deteção de Discurso Racista	Não	NB, LR, RF, XGB, BERTimbau, RoBERTa	Não
[Muminovic et al., 2025]	Deteção de Linguagem Tóxica	Sim	GPT-3.5 Turbo, GPT-4.1, Gemini 1.5 Pro, Claude 3 Opus	Não
[Roy et al., 2023]	Deteção de Discurso de Ódio	Sim	GPT-3.5, Flan-T5-large, text-davinci-003	Não
[Salles et al., 2025]	Deteção Explicável de Discurso de Ódio (PT-BR)	Sim	mBERT, BERTimbau, DistilBERTimbau, PTT5	Sim
[Martins et al., 2022]	Deteção de Desinformação em Mensagens do WhatsApp	Sim	Linear SVM	Sim
[Este Trabalho]	Deteção de Linguagem Preconceituosa	Sim	LR, BNB, MNB, KNN, LSVM, SGD, RF, GB, MLP, BERTweetBR, TupiBERT-Base, HateBR, GPT-4o-mini, Gemini-2.0-Flash	Sim

3.6 Conclusão

Neste capítulo, foram apresentados e discutidos os principais trabalhos do estado da arte relacionados aos desafios de pesquisa enfrentados nesta dissertação. Também foi realizada uma análise comparativa que evidencia as contribuições inovadoras da tarefa proposta e dos conjuntos de dados desenvolvidos. No capítulo seguinte, descrevemos detalhadamente o processo de criação dos conjuntos de dados, bem como uma análise exploratória de suas características.

4 OS CONJUNTOS DE DADOS EXPLORADOS

Diversos trabalhos têm se dedicado à detecção de linguagem preconceituosa e de tarefas relacionadas; contudo, poucos, ou possivelmente nenhum, exploraram dados provenientes de aplicativos de mensagens instantâneas, tais como WhatsApp e Telegram, no idioma português brasileiro (PT-BR). Diante dessa lacuna, esta dissertação propõe-se a ser uma das primeiras a investigar e utilizar mensagens dessas plataformas para a identificação de preconceito.

Neste estudo, desenvolvemos um dicionário de palavras preconceituosas para o português brasileiro (PT-BR), bem como dois conjuntos de dados rotulados. Este capítulo descreve detalhadamente todas as etapas envolvidas na construção desses recursos: o dicionário PrejudicePT-br e os datasets PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Além disso, apresentamos uma análise exploratória dos conjuntos, destacando suas características linguísticas e a distribuição das classes. Por fim, discutimos as principais limitações do processo e possíveis direções para aprimoramentos futuros. Todos os dados, modelos e demais recursos desenvolvidos neste trabalho estão disponíveis em nosso repositório público ¹.

4.1 Dicionário PrejudicePT-br

O dicionário elaborado foi denominado PrejudicePT-br e construído com base em quatro recursos lexicais: LIWC2015pt (CARVALHO, 2019), AffectPT-br (CARVALHO *et al.*, 2018b), MOL (VARGAS *et al.*, 2021a) e Wiktionary (Wiktionary contributors, 2025). O PrejudicePT-br contém 842 palavras, distribuídas em nove categorias de preconceito: Capacitismo, Gordofobia, Intolerância Religiosa, LGBTQIA+fobia, Misoginia, Xenofobia, Racismo, Etarismo e Preconceito Político.

4.1.1 Coleta de Dados

Para compor o dicionário de palavras, foi realizado um trabalho manual conduzido por um pesquisador, que percorreu cada uma das fontes mencionadas anteriormente em busca de termos associados aos tipos de preconceito considerados neste estudo. A partir dessa análise minuciosa, o pesquisador identificou e selecionou as palavras relevantes, classificando-as conforme o tipo de preconceito a que cada uma se relacionava, resultando em um mapeamento estruturado e alinhado aos objetivos da pesquisa.


¹ <https://github.com/jmmfilho/PrejudicePT-br/tree/main>

4.1.2 Estrutura

A organização do dicionário segue a mesma estrutura adotada pelo LIWC2007. Na Figura 1, observa-se que as primeiras onze linhas descrevem as categorias disponíveis, enquanto, a partir da linha doze, são listadas as palavras que compõem o dicionário, cada termo podendo estar associado a uma ou mais categorias.

Como mencionado anteriormente, o processo de categorização de quais palavras pertencem a quais categorias foi realizado manualmente por uma pesquisadora especializada. Essa curadoria cuidadosa assegura maior precisão semântica e consistência na classificação dos termos.

Figura 1 – Estrutura do PrejudicePT-br



The image shows a screenshot of a text file named 'v2_SocialLIWC_formatado_ordenado.dic'. The file lists categories and words. The first 11 lines define categories (1-9) and a percentage symbol (%). Lines 12-27 list words and their associated category numbers. For example, 'aberração' is associated with category 1, and 'analfabeto' is associated with categories 1 and 6.

Line	Category	Word	Count	Associated Categories
1	%			
2	1	Capacitismo		
3	2	Gordofobia		
4	3	Int.Religiosa		
5	4	LGBTFobia		
6	5	Misoginia		
7	6	Xenofobia		
8	7	Racismo		
9	8	Etarismo		
10	9	Prec.Politico		
11	%			
12	1	aberração	1	
13	1	aberração*	1	
14	1	aberrações	1	
15	1	aleij*	1	
16	1	aleija	1	
17	1	aleijada	1	
18	1	aleijadas	1	
19	1	aleijadinha	1	
20	1	aleijadinho	1	
21	1	aleijado	1	
22	1	aleijados	1	
23	1	aleijai	1	
24	1 6	analfabeto	1	6
25	1	anormais	1	
26	1	anormal	1	
27	1 6	atrasada	1	6

Fonte: o autor.

4.1.3 Análise Exploratória

Para compreender melhor a estrutura e a cobertura do dicionário PrejudicePT-br, realizamos, inicialmente, uma análise exploratória de seus termos. A Tabela 2 apresenta a distribuição do número de palavras por categoria de preconceito. Observa-se que as categorias Intolerância Religiosa e Capacitismo concentram o maior número de termos, com 152 e 150 palavras, respectivamente, indicando uma maior diversidade lexical associada a essas formas de preconceito. Em seguida, destacam-se as categorias Misoginia (141) e Preconceito Político (83), que também apresentam representatividade expressiva no dicionário.

Em contraste, as categorias Etarismo (58), Xenofobia (65) e LGBTQIA+fobia (67) apresentam menor número de termos. Esse resultado pode refletir tanto uma menor variedade lexical explícita dessas manifestações quanto limitações inerentes ao processo de construção do dicionário, especialmente quanto à disponibilidade e à visibilidade de vocabulário associado a essas formas de preconceito. Essa heterogeneidade na distribuição lexical evidencia diferenças importantes entre as categorias, o que pode impactar diretamente o desempenho de abordagens baseadas em léxico na detecção automática de preconceito.

Além da distribuição por categoria, analisamos a sobreposição de termos entre categorias distintas do dicionário. Os resultados indicam que a maioria absoluta das palavras é exclusiva de uma única categoria: 806 termos pertencem apenas a uma categoria, enquanto apenas 45 palavras estão associadas a duas categorias distintas. Esse baixo nível de sobreposição sugere que as categorias do PrejudicePT-br são, em grande medida, semanticamente bem delimitadas, o que favorece uma interpretação mais precisa das ocorrências de preconceito identificadas por métodos baseados em dicionário.

A partir dessa caracterização do dicionário, avançamos para a análise de sua aplicação nos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. As Tabelas 3 e 4 revelam padrões semelhantes no uso dos termos do PrejudicePT-br em ambos os aplicativos. Em particular, a palavra “deus” destaca-se como o termo mais frequente em ambos os conjuntos, indicando a forte presença de referências religiosas nas mensagens analisadas e reforçando a necessidade de uma interpretação contextual cuidadosa, uma vez que tais termos podem ocorrer tanto em mensagens neutras quanto em discursos preconceituosos. Observa-se também a recorrência de termos de cunho político e ofensivo, como “luladrão” e “ladrão”, o que evidencia a interseção entre preconceito político e linguagem ofensiva nos ambientes de comunicação instantânea. Adicionalmente, a presença de palavras como “idiota” e “liberdade” sugere o uso frequente de insultos genéricos e de discursos associados a posicionamentos ideológicos, cujo caráter preconceituoso depende fortemente do contexto em que são empregados.

De forma geral, os resultados indicam uma sobreposição significativa entre linguagens religiosa, política e ofensiva nos dois conjuntos de dados, com padrões de uso bastante semelhantes entre WhatsApp e Telegram. Esses achados reforçam a importância de abordagens de detecção que vão além da simples identificação de termos isolados, incorporando análises contextuais capazes de capturar as nuances discursivas presentes em ambientes marcados por forte polarização social e ideológica.

Tabela 2 – Quantidade de palavras por categoria no dicionário PrejudicePT-br

Categoria	Capacitismo	Gordofobia	Int. Religiosa	LGBTQIA+fobia	Misoginia	Xenofobia	Racismo	Etarismo	Prec. Político
Quantidade	150	90	152	67	141	65	81	58	83

Fonte: o autor.

Tabela 3 – Top 5 palavras do PrejudicePT-br mais frequentes no PrejudiceWhatsApp.Br

PrejudiceWhatsApp.Br	deus	luladrão	ladrão	idiota	liberdade
Quantidade	964	343	162	145	99

Fonte: o autor.

Tabela 4 – Top 5 palavras do PrejudicePT-br mais frequentes no PrejudiceTelegram.Br

PrejudiceTelegram.Br	deus	ladrão	luladrão	liberdade	claro
Quantidade	1213	380	183	123	107

Fonte: o autor.

4.2 Datasets PrejudiceTelegram.Br e PrejudiceWhatsApp.Br

Para desenvolver um detector automático de textos preconceituosos no contexto de aplicativos de mensagens instantâneas, é essencial utilizar um conjunto de dados rotulado em larga escala, composto por mensagens em português brasileiro (PT-BR) que circularam nessas plataformas. Por essa razão, exploraremos dois conjuntos de dados distintos: PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Esses conjuntos de dados, contêm mensagens de texto coletadas de grupos públicos do WhatsApp e do Telegram, respectivamente.

4.2.1 Coleta de Dados

Os dados das plataformas WhatsApp e Telegram utilizados nesse trabalho foram coletados utilizando a plataforma descrita em (SÁ *et al.*, 2023b) entre 1º de agosto de 2022 e 31 de dezembro de 2022. No WhatsApp, foram coletadas 813.106 mensagens únicas (ou seja, não repetitivas) de 179 grupos públicos. No Telegram, foram capturadas 767.847 mensagens únicas de 150 grupos e/ou canais públicos. A rotulagem manual de um volume tão grande de mensagens é inviável. Portanto, uma estratégia para reduzir a quantidade de mensagens a serem anotadas se faz necessária. Para lidar com esse desafio, adotamos uma abordagem baseada no uso de um dicionário de palavras.

4.2.2 Seleção dos Dados

A construção dos conjuntos de dados teve início com a coleta de 813.106 mensagens únicas provenientes de 179 grupos públicos do WhatsApp, além de 767.847 mensagens únicas extraídas de 150 grupos e canais públicos do Telegram. Após a etapa de aquisição, aplicou-se um filtro de inclusão, com base nas palavras-chave do dicionário *PrejudicePT-br*, selecionando apenas mensagens que contivessem ao menos um dos termos associados a potenciais discursos preconceituosos. Esse procedimento reduziu substancialmente o volume inicial: o conjunto do WhatsApp passou de 813.106 para 37.531 mensagens, enquanto o conjunto do Telegram diminuiu de 767.847 para 58.787 mensagens. Importa ressaltar que a presença de uma palavra filtrada não implica necessariamente que a mensagem seja preconceituosa; a filtragem serviu apenas como uma etapa preliminar de triagem.

4.2.3 Rotulagem dos Dados

Dado o volume ainda elevado de mensagens após a aplicação dos filtros iniciais e visando construir conjuntos de dados balanceados e representativos, realizamos um processo de amostragem controlada. A rotulação foi conduzida por dois anotadores: uma estudante de mestrado (mulher) e um estudante de graduação (homem). Em casos de discordância, o rótulo final foi determinado por uma terceira avaliadora, uma doutoranda, o que garantiu maior confiabilidade e reduziu possíveis vieses individuais no processo de anotação.

Modelamos o problema de detecção de linguagem preconceituosa no WhatsApp e no Telegram como uma tarefa de classificação binária, na qual mensagens com conteúdo preconceituoso compõem a classe positiva (rótulo 1) e mensagens sem conteúdo preconceituoso compõem a classe negativa (rótulo 0). Para cada plataforma, selecionamos um subconjunto equilibrado composto por 1.500 mensagens preconceituosas e 1.500 mensagens não preconceituosas, totalizando 3.000 exemplos por conjunto de dados.

Como resultado, o *PrejudiceWhatsApp.Br* é formado por 3.000 mensagens do WhatsApp igualmente distribuídas entre as classes preconceito e não preconceito. De forma análoga, o *PrejudiceTelegram.Br* contém 3.000 mensagens do Telegram, também balanceadas entre as duas categorias. Essa estrutura equilibrada favorece análises mais confiáveis e garante condições adequadas para a comparação entre diferentes modelos de classificação.

Para preservar a privacidade dos usuários, todas as informações pessoais, incluindo nomes e números de telefone, foram devidamente anonimizadas. Além disso, aplicamos uma função *hash* para gerar um identificador único e anônimo para cada usuário, derivado exclusivamente do número de telefone. Da mesma forma, uma função *hash* foi empregada para gerar identificadores anônimos para cada grupo, com base em seus respectivos nomes. Como os grupos utilizados são de acesso público, essa estratégia de anonimização está em conformidade com a política de privacidade do WhatsApp²

Na Tabela 5, apresentamos as principais métricas estatísticas dos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br, incluindo o número de mensagens únicas, os valores mínimo e máximo de tokens, além da média e do desvio padrão da contagem de tokens. A análise desses indicadores mostra que as características textuais dos dois conjuntos são bastante semelhantes, indicando que a estrutura das mensagens não varia de forma substancial entre as plataformas.

Tabela 5 – Estatísticas dos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br

Métrica	PrejudiceWhatsApp.Br	PrejudiceTelegram.Br
Número de mensagens únicas	3.000	3.000
Média e desvio padrão do número de fichas	34,72 $\pm$ 30,76	50,81 $\pm$ 40,03
Número mínimo de tokens	1	1
Número máximo de tokens	186	183

4.2.4 Análise das Mensagens Rotuladas

A análise das Tabelas 6 e 7 evidencia padrões linguísticos consistentes e relevantes nas mensagens rotuladas como preconceituosas e não preconceituosas em ambas as plataformas.

No conjunto PrejudiceWhatsApp.Br, mostrado na tabela 6 os unigrams mais frequentes na classe preconceito estão fortemente associados ao contexto político, com destaque para termos como “luladrão”, “bolsonaro” e “votar”, além de insultos diretos como “idiota”. Esse padrão se intensifica nos bigrams e trigrams, que incluem expressões explicitamente ofensivas ou desqualificadoras, como “pt luladrão”, “ex presidiário” e “analfabeto político fanático”, indicando a presença de ataques pessoais e retórica polarizada. Em contraste, a classe não preconceito apresenta maior recorrência de termos religiosos e institucionais, como “deus”, “jesus”, “senhor” e “presidente”, bem como expressões de cunho positivo ou neutro, como “deus abençoe” e “nome jesus”.

² <https://www.whatsapp.com/legal/privacy-policy>

De forma semelhante, no conjunto PrejudiceTelegram.Br, mostrado na tabela 7 a classe preconceito é marcada por vocabulário político e ideológico, incluindo termos como “comunista”, “ladrão”, “lula” e “bolsonaro”. Os n-gramas revelam construções mais agressivas e polarizadas, como “luladrão lugar prisão” e “brazil acima deus”, reforçando a associação entre o discurso político e a linguagem ofensiva. Já na classe não preconceito, predominam novamente referências religiosas e nomes próprios, como “deus”, “jesus”, “grupo” e “jesus cristo”, além de slogans e expressões neutras ou de apoio.

Em ambos os conjuntos, observa-se a recorrência do termo “brazil” em todas as classes e n-gramas, sugerindo que ele funciona mais como marcador temático do contexto nacional do que como indicador direto de preconceito. De modo geral, os resultados indicam que mensagens preconceituosas tendem a concentrar vocabulário político, ideológico e ofensivo, enquanto mensagens não preconceituosas apresentam maior presença de termos religiosos, institucionais e expressões neutras. Esses padrões reforçam a relevância de características léxicas e de n-gramas para a distinção entre as classes, ao mesmo tempo em que evidenciam a forte influência da polarização política e religiosa nos discursos analisados.

Tabela 6 – Termos mais frequentes nas mensagens do dataset PrejudiceWhatsApp.Br

	Preconceito	Não Preconceito
Unigram	<i>‘brazil’, ‘luladrão’, ‘bolsonaro’, ‘votar’, ‘idiota’</i>	<i>‘brazil’, ‘deus’, ‘presidente’, ‘jesus’, ‘senhor’</i>
Bigram	<i>‘brazil brazil’, ‘primeiro turno’, ‘pt luladrão’, ‘povo brasileiro’, ‘ex presidiario’</i>	<i>‘deus abençoe’, ‘deputado estadual’, ‘presidente bolsonaro’, ‘deus pátria’, ‘nome jesus’</i>
Trigram	<i>‘analfabeto político fanático’, ‘dollar dollar dollar’, ‘hand brazil brazil’</i>	<i>‘pátria família liberdade’, ‘acima deus acima’, ‘jair messio bolsonaro’</i>

Tabela 7 – Termos mais frequentes nas mensagens do dataset PrejudiceTelegram.Br

	Preconceito	Não Preconceito
Unigram	<i>‘brazil’, ‘comunista’, ‘bolsonaro’, ‘ladrão’, ‘lula’</i>	<i>‘brazil’, ‘deus’, ‘presidente’, ‘jesus’, ‘grupo’</i>
Bigram	<i>‘brazil brazil’, ‘primeiro turno’, ‘segundo turno’, ‘povo brasileiro’, ‘ex presidiario’</i>	<i>‘daniel silveira’, ‘jesus cristo’, ‘deus abençoe’, ‘bolsonaro 22’, ‘brazil brazil’</i>
Trigram	<i>‘luladrão lugar prisão’, ‘brazil acima deus’, ‘medium medium medium’</i>	<i>‘escrito palavra deus’, ‘deus senhor céu’, ‘brazil brazil brazil’</i>

4.3 Limitações e Vieses nos Dados

O dicionário ainda não possui um número expressivo de palavras categorizadas, em comparação a outros recursos lexicais, o que pode limitar o alcance e a precisão dos resultados. Além disso, os *datasets* foram anotados manualmente por humanos e, conseqüentemente, carregam vieses inerentes ao processo de anotação, fenômeno amplamente reconhecido e, em certa medida, inevitável em tarefas desse tipo.

4.4 Conclusão

Neste capítulo, exploramos em detalhes os conjuntos de dados utilizados no estudo, incluindo o dicionário PrejudicePT-br e os datasets PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Apresentamos o processo de coleta, seleção e rotulagem das mensagens, bem como análises exploratórias que revelaram padrões linguísticos distintos entre textos preconceituosos e não preconceituosos. Também discutimos limitações e possíveis vieses presentes nos dados, destacando como esses fatores podem influenciar o desempenho dos modelos. Em conjunto, esses recursos formam a base empírica que sustenta os experimentos e análises apresentados nos capítulos seguintes.

5 DETECÇÃO DE PRECONCEITO EM APLICATIVOS DE MENSAGERIA

Nesta dissertação, investigamos a detecção de linguagem preconceituosa por meio de uma abordagem centrada exclusivamente no conteúdo textual das mensagens. Para isso, empregamos técnicas de Processamento de Linguagem Natural (PLN) e de Aprendizado de Máquina, buscando identificar indícios de preconceito diretamente no texto, sem recorrer a metadados, informações contextuais externas ou padrões de interação entre usuários.

Com o objetivo de estabelecer uma base sólida para o problema de detecção de linguagem preconceituosa em mensagens de texto em português no WhatsApp e no Telegram, conduzimos, neste capítulo, uma série de experimentos utilizando os conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Nesses experimentos, avaliamos três categorias de modelos: algoritmos clássicos de aprendizado de máquina, modelos de linguagem pré-treinados e grandes modelos de linguagem (LLMs), todos aplicados à tarefa de classificação binária entre mensagens preconceituosas e não preconceituosas. Assim, buscamos responder às questões de pesquisa Q1 e Q2, apresentadas no Capítulo 1.

Além de comparar diferentes modelos, investigamos diversas estratégias de engenharia de atributos e de construção de prompts para LLMs, com o objetivo de compreender como diferentes formas de representação textual impactam o desempenho dos classificadores. Por fim, aplicamos técnicas de explicabilidade, como SHAP e LIME, para interpretar as decisões dos modelos e identificar quais características linguísticas têm maior influência na detecção de conteúdo preconceituoso.

5.1 Avaliação de Algoritmos Clássicos de Aprendizado de Máquina

A avaliação dos métodos clássicos de aprendizado de máquina foi conduzida por meio de uma abordagem combinatória, integrando diferentes componentes do pipeline de classificação. Ao todo, combinamos duas técnicas de extração de características (BoW e TF-IDF), três estratégias de tokenização (unigramas, bigramas e trigramas), dois esquemas de pré-processamento (com e sem pré-processamento), três métodos de seleção de características (uso isolado de BoW/TF-IDF, integração dessas representações ao dicionário PrejudicePT-br e uso exclusivo das categorias ou palavras do dicionário) e nove algoritmos de classificação.

5.1.1 Pré processamento Textual

O pré-processamento textual envolve diversas etapas fundamentais, sendo a tokenização uma das principais. Essa etapa consiste em segmentar a sequência de caracteres de um texto, identificando os limites entre as palavras, isto é, os pontos onde uma palavra termina e outra começa (BARBOSA *et al.*, 2017). As palavras identificadas nesse processo são chamadas de *tokens*.

Outras etapas de processamento podem ser necessárias, dependendo do domínio, para garantir que os *tokens* extraídos representem padrões úteis para a classificação. No caso de mensagens provenientes do WhatsApp e do Telegram, o pré-processamento se torna especialmente importante devido ao alto nível de ruído, como grande quantidade de emojis, URLs e sequências de caracteres repetidos. Assim, adotamos o seguinte conjunto de etapas:

1. Converter todas as letras para minúsculas;
2. Substituir todas as URLs pela raiz do domínio;
3. Substituir sequências de emojis pelos mesmos emojis separados por espaço. Por exemplo, a sequência “:brazil::brazil::brazil:” é convertida em “:brazil: :brazil: :brazil:”, permitindo que cada emoji seja tratado como um token e evitando o aumento desnecessário do vocabulário;
4. Substituir sequências com mais de três caracteres repetidos por apenas três. Por exemplo, “kkkkkkkkkkkkk” torna-se “kkk”, seguindo o mesmo princípio do passo anterior;
5. Remover caracteres que não sejam letras, emojis ou os caracteres de formatação “*” (negrito) e “_” (itálico);
6. Remover stopwords;
7. Lematizar as palavras, substituindo cada termo por seu lema, independentemente de flexões ou tempo verbal. Por exemplo, “tiver”, “tenho” e “tinha” tornam-se “ter”;
8. Remover acentuação.

5.1.2 Classificação

Os métodos BoW e TF-IDF foram selecionados por sua simplicidade, eficiência e ampla utilização em tarefas de classificação de texto. Para analisar como diferentes representações impactam o desempenho dos modelos, avaliamos três estratégias de tokenização: unigramas, bigramas e trigramas. Embora produzam vetores de alta dimensionalidade, essas tokenizações permitem capturar padrões linguísticos relevantes, especialmente bigramas e trigramas, que preservam mais contexto do que unigramas. Também investigamos o efeito do pré-processamento textual adotando duas configurações: (i) sem qualquer tratamento adicional e (ii) com pré-processamento completo, conforme descrito anteriormente. Essa etapa visa reduzir ruídos e destacar características linguísticas úteis à detecção de linguagem preconceituosa.

A partir dessas combinações, definimos 12 cenários experimentais, resultantes da combinação entre dois métodos de extração de características (BoW e TF-IDF), três tokenizações (unigramas, bigramas e trigramas) e duas opções de pré-processamento (com e sem tratamento). Em cada um desses cenários, avaliamos nove algoritmos clássicos de classificação, contemplando diferentes famílias de modelos: métodos lineares: Regressão Logística (LR), modelos generativos: Bernoulli Naive Bayes (BNB); Multinomial Naive Bayes (MNB), aprendizado por instâncias: K-Nearest Neighbors (KNN), máquinas de vetores de suporte: Linear SVM (LSVM); Stochastic Gradient Descent (SGD), métodos de aprendizado em conjunto: Random Forest (RF); Gradient Boosting (GB) e redes neurais: Perceptron Multicamadas (MLP)³⁵. Todos os algoritmos foram executados com hiperparâmetros padrão, exceto o MLP, cujas particularidades são detalhadas posteriormente.

Em seguida, ampliamos a investigação avaliando cinco estratégias adicionais de seleção de características, com o objetivo de compreender como diferentes combinações de atributos linguísticos influenciam o desempenho dos classificadores:

- (i) uso exclusivo das representações tradicionais BoW e TF-IDF;
- (ii) integração de BoW e TF-IDF às 9 categorias do dicionário PrejudicePT-br;
- (iii) integração de BoW e TF-IDF às 842 palavras do dicionário PrejudicePT-br;
- (iv) uso apenas das 9 categorias do PrejudicePT-br como atributos, calculando a frequência de termos associados a cada categoria;
- (v) uso apenas das 842 palavras do PrejudicePT-br como atributos, contabilizando sua ocorrência em cada mensagem.

A combinação dessas cinco estratégias com os 12 cenários anteriores resultou em um total de 360 experimentos por conjunto de dados. Desses, 324 envolveram BoW e TF-IDF (com ou sem integração ao dicionário) e 36 utilizaram exclusivamente atributos derivados do dicionário PrejudicePT-br. Todos os experimentos foram implementados utilizando a biblioteca scikit-learn em Python (PEDREGOSA *et al.*, 2011).

Para o modelo MLP, adotamos tamanho de lote 64 e técnica de early stopping: 10% dos dados de treinamento foram reservados para validação, interrompendo o treinamento caso a métrica de validação não melhorasse ao menos 0,001 por cinco épocas consecutivas. Os demais algoritmos foram mantidos com os hiperparâmetros padrão. Embora não tenha sido realizada uma busca sistemática por hiperparâmetros, o amplo conjunto de combinações testadas permite identificar estratégias de aprendizado mais adequadas ao problema, estabelecendo uma linha de base robusta.

Por fim, todos os dados e códigos utilizados nesta etapa estão disponíveis em nosso repositório ¹, garantindo a reprodutibilidade e permitindo que futuras pesquisas avancem com base nos resultados aqui obtidos.

5.1.3 Métricas de Desempenho

Como discutido anteriormente, a detecção de linguagem preconceituosa foi tratada como um problema de classificação binária, no qual mensagens contendo preconceito representam a classe positiva (P) e mensagens sem preconceito representam a classe negativa (N). Assim, cada predição do modelo se enquadra em uma das seguintes categorias:

- **Verdadeiro Positivo (VP):** mensagem preconceituosa corretamente classificada como preconceituosa.
- **Verdadeiro Negativo (VN):** mensagem não preconceituosa corretamente classificada como não preconceituosa.
- **Falso Positivo (FP):** mensagem não preconceituosa incorretamente classificada como preconceituosa.
- **Falso Negativo (FN):** mensagem preconceituosa classificada incorretamente como não preconceituosa.

¹ <https://github.com/jmmfilho/PrejudicePT-br/tree/main>

A partir desses quatro cenários de predição, calculamos as métricas avaliadas nos experimentos: AUC, precisão, *recall* e F1-score, conforme descrito no Capítulo 2. Para garantir uma avaliação robusta, utilizamos validação cruzada k-fold com $k = 5$, reportando a média e o desvio padrão de cada métrica em todos os experimentos. Após a etapa de validação cruzada, selecionamos o melhor classificador e o conjunto de características mais eficaz. Em seguida, treinamos novamente o modelo utilizando 80% dos dados, definidos aleatoriamente como conjunto de treinamento, e avaliamos seu desempenho nos 20% restantes, reservados para teste. Essa última etapa fornece uma estimativa mais realista da capacidade de generalização do modelo.

5.2 Avaliação de Modelos de Linguagem Pré-treinados

Para a segunda etapa experimental, avaliamos métodos baseados em embeddings gerados por modelos de linguagem pré-treinados. O objetivo dessa fase foi comparar o desempenho de representações contextuais produzidas por modelos BERT treinados especificamente para a língua portuguesa e/ou para o domínio de redes sociais com o das representações tradicionais utilizadas na etapa anterior (BoW e TF-IDF).

Para isso, utilizamos três modelos previamente apresentados no Capítulo 2: *melluff/bertweetbr*, *FpOliveira/tupi-bert-base-portuguese-cased* e *ruanchaves/bert-base-portuguese-cased-hatebr*. Esses modelos foram escolhidos por sua relevância em cenários reais de comunicação instantânea e pelo bom desempenho observado em tarefas de detecção de linguagem tóxica, ofensiva ou preconceituosa. Todos seguem a arquitetura BERT-base, composta por 12 camadas *Transformer*, cada uma produzindo *embeddings* de 768 dimensões por *token*.

Cada mensagem foi, primeiramente, *tokenizada* utilizando o tokenizer correspondente a cada modelo pré-treinado e, em seguida, processada para a geração de *embeddings* contextualizados ao longo das camadas *Transformer*. Como representação vetorial final de cada texto, adotamos a estratégia de CLS-last4 pooling, que consiste na média do *embedding* do *token* especial [CLS] extraído das quatro últimas camadas do modelo. Essa abordagem resulta em um vetor denso fixo de 768 dimensões, independentemente do comprimento da mensagem.

A escolha do *CLS-last4 pooling* fundamenta-se no fato de que as camadas superiores dos modelos BERT tendem a capturar informações semânticas mais abstratas, enquanto a agregação das últimas camadas reduz a dependência de uma única representação. Dessa forma, obtém-se uma representação textual mais robusta e informativa, adequada ao uso com algoritmos clássicos de aprendizado de máquina.

Embora existam diversas estratégias de agregação de *embeddings* amplamente utilizadas na literatura, neste trabalho optou-se exclusivamente pela estratégia CLS-last4, em função do desempenho reportado em tarefas de classificação de texto. Após a extração dos *embeddings*, os vetores resultantes foram utilizados como entrada para os mesmos algoritmos clássicos avaliados na primeira etapa, permitindo uma comparação direta entre representações tradicionais (BoW/TF-IDF) e representações contextualizadas baseadas em BERT. Esse procedimento permite avaliar em que medida os *embeddings* densos e contextualmente ricos contribuem para uma detecção mais precisa de mensagens preconceituosas no PrejudiceWhatsApp.Br e no PrejudiceTelegram.Br.

5.3 Avaliação dos Grandes Modelos de Linguagem

Na avaliação dos grandes modelos de linguagem, examinamos dois modelos de destaque, GPT-4o-mini e Gemini-2.0-Flash, aplicando quatro metodologias de *prompting*: *zero-shot*, *few-shot*, *role prompting* e *dictionary-based shot learning*. Cada abordagem foi escolhida para investigar diferentes formas de orientar o modelo a identificar mensagens com conteúdo preconceituoso.

Para a condução dos experimentos, elaboramos um *prompt* de instrução padronizado, adaptado à metodologia empregada, que descreve a tarefa e estabelece critérios claros para a identificação de linguagem preconceituosa. Todas as interações ocorreram via API, garantindo controle total sobre o formato das respostas, reprodutibilidade experimental e permitindo uma comparação sistemática do desempenho entre as diferentes estratégias de *prompting*.

5.3.1 Modelos de Prompting Utilizados

A seguir, apresentamos os tipos de *prompts* empregados nos experimentos, acompanhados dos exemplos utilizados em cada categoria:

1. **Classificação sem exemplos prévios (zero-shot):** As sentenças foram apresentadas ao LLM sem contexto adicional, e o modelo foi solicitado a determinar se a mensagem continha ou não preconceito. Um exemplo do *prompt* utilizado é:

"Julgue o seguinte texto: [TEXTO]. Classifique o texto e, caso contenha preconceito, retorne o rótulo 1. Caso não contenha preconceito, retorne o rótulo 0. Não forneça explicações; retorne apenas o rótulo."

2. **Classificação com exemplos ilustrativos (few-shot):** Antes de apresentar uma nova sentença, o modelo recebeu um conjunto de exemplos que ilustravam o que deve e o que não deve ser considerado preconceituoso. Um exemplo desse prompt é:

"Aqui estão alguns exemplos de textos que contêm preconceito (rótulo 1): [TEXTO]

Aqui estão alguns exemplos de textos que não contêm preconceito (rótulo 0): [TEXTO]

Com base nesses exemplos, julgue o seguinte texto: [TEXTO]. Se o texto contiver preconceito, retorne 1; caso contrário, retorne 0. Não forneça explicações; retorne apenas o rótulo."

3. **Classificação com atribuição de papel (role prompting):** Foi atribuída ao modelo uma identidade ou especialidade específica para orientar seu comportamento durante a tarefa de classificação:

"Você é um linguista computacional especializado em análise do discurso e viés linguístico em textos das redes sociais brasileiras. Sua função é identificar expressões preconceituosas, discriminatórias, ofensivas ou que reforcem estereótipos sobre grupos sociais, étnicos, religiosos, políticos, de gênero ou orientação sexual. Sua tarefa é rotular textos com base na presença de preconceito, seguindo as regras abaixo:

Rótulo 1 (preconceito): O texto contém linguagem discriminatória, insultos, ironia depreciativa ou reforça estereótipos negativos sobre um grupo social.

Rótulo 0 (não preconceito): O texto é neutro, descritivo, expressa opinião sem ofensa ou apresenta discordância sem atacar grupos."

4. **Classificação utilizando um dicionário (dictionary-based shot learning):** Antes da classificação, o modelo teve acesso ao dicionário **PrejudicePT-br**, composto por termos e expressões associados a diferentes formas de preconceito, auxiliando na identificação das mensagens.

"Leia o dicionário PrejudicePT.br, que contém categorias e exemplos de palavras que indicam preconceito. Cada categoria representa um tipo de preconceito, e exemplos de termos associados são listados abaixo.

Dicionário PrejudicePT.br (categorias e exemplos):

(CATEGORIA): (PALAVRAS)

...

Use o dicionário PrejudicePT.br como referência para classificar textos nos rótulos preconceituoso (1) e não preconceituoso (0)."

Para os testes com o modelo *GPT-4o-mini*, configuramos o limite máximo de geração de 8.000 tokens. A temperatura foi definida como 0.0, parâmetro que controla a aleatoriedade das respostas (HOLTZMAN *et al.*, 2019): valores baixos resultam em saídas mais determinísticas e consistentes. O número médio estimado de *tokens* por item foi definido como 5, enquanto o parâmetro *top_p* foi configurado como 1.0, restringindo as escolhas do modelo aos *tokens* mais prováveis (WELLECK *et al.*, 2019).

Da mesma forma, no modelo *Gemini-2.0-Flash*, foi realizada a mesma configuração: máximo de 8.000 *tokens*, média estimada de 5 *tokens* por item, temperatura = 0.0 e *top_p* = 1.0. Essas configurações favorecem respostas objetivas, reproduzíveis e não estocásticas, adequadas a tarefas automáticas de classificação de texto.

Foi realizada uma divisão dos dados, destinando 20% do conjunto total para a fase de testes. Dessa amostra, foram selecionadas aleatoriamente 300 mensagens rotuladas como 0 e 300 mensagens rotuladas como 1. Em seguida, seus rótulos foram removidos para simular dados não rotulados. Um novo arquivo foi gerado com os dados restantes, garantindo que nenhuma mensagem aparecesse simultaneamente nos conjuntos de treinamento e de teste.

Nos experimentos do tipo *few-shot*, garantimos que nenhum dos exemplos utilizados, tanto mensagens preconceituosas quanto não preconceituosas, esteja presente nos 20% reservados ao conjunto de teste, evitando qualquer risco de vazamento de dados (*data leakage*). Também asseguramos que o conjunto de exemplos incluísse ao menos uma instância de cada uma das nove categorias de preconceito consideradas. Assim, selecionamos 9 exemplos para a classe preconceito (rótulo 1) e 9 para a classe não preconceito (rótulo 0). A categorização dessas mensagens foi realizada exclusivamente para esses experimentos por uma estudante de mestrado, o que pode introduzir um grau de viés. Testes preliminares com conjuntos maiores de exemplos foram conduzidos, mas apresentaram desempenho muito semelhante, razão pela qual optamos por manter uma configuração mais enxuta e controlada.

Para o cálculo das métricas de desempenho, utilizou-se a técnica de *bootstrap* com 1.000 repetições, a fim de estimar a variabilidade estatística de cada métrica. Em cada iteração, foi realizada uma amostragem aleatória com reposição sobre o conjunto original de predições, gerando subconjuntos (*resamples*) do mesmo tamanho.

5.4 LIWC

Primeiro, dividimos as mensagens dos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br em dois grupos: preconceituosas e não preconceituosas. Em seguida, contamos as ocorrências de cada categoria do LIWC em ambos os grupos. Para isso, processamos todas as mensagens de cada conjunto, identificando as categorias associadas a cada palavra (considerando que uma mesma palavra pode pertencer a múltiplas categorias) e atualizando os contadores correspondentes. Com esses valores, avaliamos se as categorias do LIWC apresentavam distribuições distintas entre os dois grupos, o que nos ajuda a compreender como a linguagem preconceituosa se manifesta. Para verificar a significância estatística das diferenças observadas, aplicamos o teste qui-quadrado com nível de confiança de 95%.

5.5 Modelos de Explicabilidade

Para analisar a interpretabilidade dos modelos e compreender quais características textuais mais influenciam suas decisões, aplicamos duas técnicas amplamente consolidadas na literatura: LIME e SHAP.

5.5.1 LIME

Para o LIME, utilizamos a classe `LimeTextExplainer`, configurando uma separação de *tokens* capaz de lidar adequadamente com elementos comuns em mensagens instantâneas, como emojis e pontuação. O LIME opera construindo perturbações locais do texto original e treinando um modelo linear simples para aproximar a decisão do classificador nesse entorno.

No experimento, selecionamos aleatoriamente uma mensagem do conjunto de teste do último *fold* da validação cruzada. A partir dessa mensagem, o LIME gerou explicações locais indicando as palavras que mais contribuíram para a classificação como preconceito ou não-preconceito. Para isso, fornecemos ao LIME uma função de predição adaptada, que encapsula o pipeline do modelo final (vetorização + classificação).

Além disso, extraímos as palavras explicativas e calculamos métricas de fidelidade, *Comprehensiveness* e *Sufficiency*, que avaliam até que ponto as palavras identificadas pelo LIME de fato influenciam a probabilidade atribuída pelo modelo. Essas métricas permitiram avaliar se as explicações fornecidas pelo LIME são consistentes com o comportamento real do modelo.

5.5.2 SHAP

Complementarmente, aplicamos SHAP, que utiliza valores de Shapley, derivados da teoria dos jogos, para quantificar a contribuição marginal de cada atributo para a predição individual. Como o melhor classificador obtido foi baseado em métodos de *tree boosting*, utilizamos a implementação *TreeExplainer*, que garante eficiência e aderência ao funcionamento do modelo.

Selecionamos também uma instância aleatória do conjunto de teste, geramos uma matriz de fundo (*background*) composta por amostras representativas e calculamos os valores SHAP para cada atributo não nulo do vetor TF-IDF ou BoW correspondente à mensagem analisada. Em seguida, filtramos apenas as palavras efetivamente presentes no texto e construímos uma tabela que exibe o peso de contribuição de cada termo para a probabilidade final. De forma análoga ao processo realizado com LIME, calculamos métricas de fidelidade com base nos valores SHAP, avaliando a influência das palavras mais relevantes.

5.6 Conclusão

Neste capítulo, apresentamos de forma sistemática o conjunto de experimentos realizados para a detecção de linguagem preconceituosa nos conjuntos de dados PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Avaliamos diferentes estratégias de modelagem, abrangendo desde representações textuais tradicionais (BoW e TF-IDF), *embeddings* contextualizados gerados por modelos BERT pré-treinados e, por fim, grandes modelos de linguagem aplicados em cenários *zero-shot*, *few-shot*, *role-prompting* e *dictionary-based shot learning*. Descrevemos detalhadamente os procedimentos adotados em cada etapa, incluindo tokenização, pré-processamento, seleção de atributos, parametrização e escolha dos algoritmos de classificação. Complementarmente, incorporamos técnicas de explicabilidade (LIME e SHAP) para interpretar os modelos de melhor desempenho, identificando padrões linguísticos que influenciam suas decisões e avaliando a fidelidade das explicações geradas. Assim, este capítulo estabelece uma base experimental robusta que fundamenta a análise crítica apresentada no capítulo seguinte, no qual discutimos o desempenho dos métodos, suas limitações e suas implicações para pesquisas futuras.

6 RESULTADOS

Neste capítulo, analisamos detalhadamente os resultados obtidos em cada abordagem avaliada, destacando tanto os cenários de melhor desempenho quanto os que apresentaram os resultados menos satisfatórios. Também discutimos as categorias identificadas pelo LIWC para as classes preconceito e não preconceito, evidenciando os padrões linguísticos mais relevantes em cada grupo. Além disso, apresentamos a interpretação dos modelos por meio dos métodos de explicabilidade LIME e SHAP, ressaltando como essas técnicas contribuem para compreender os fatores linguísticos que influenciam as decisões dos classificadores.

6.1 Avaliação de Algoritmos Clássicos de Aprendizado de Máquina

Cada uma das tabelas apresentadas abaixo contém informações sobre seis cenários distintos. Para cada cenário, destacamos os valores das métricas de desempenho (AUC Score, Precisão, Recall e F1-score) obtidos por cada um dos nove classificadores avaliados, além do número de características geradas e do tempo de treinamento necessário para o modelo de classificação. Mais especificamente, os seis cenários avaliados foram os seguintes: (a) Apenas unigramas, sem pré-processamento, (b) Apenas unigramas, com remoção de stopwords e lematização, (c) Unigramas e bigramas, sem pré-processamento, (d) Unigramas e bigramas, com remoção de stopwords e lematização, (e) Unigramas, bigramas e trigramas, sem pré-processamento, e (f) Unigramas, bigramas e trigramas, com remoção de stopwords e lematização.

Os resultados obtidos com o conjunto de dados PrejudiceTelegram.Br estão sintetizados nas Tabelas 8 e 9. A Tabela 8 apresenta o desempenho dos modelos utilizando o método Bag-of-Words (BoW), enquanto a Tabela 9 apresenta os resultados obtidos com TF-IDF (Term Frequency–Inverse Document Frequency). A análise conjunta dessas tabelas revela que os classificadores Gradient Boosting (GB) e Support Vector Machine (SVM) destacaram-se consistentemente como os de melhor desempenho, considerando o F1-score como métrica principal. Em contraste, os métodos Bernoulli Naive Bayes (BNB) e K-Nearest Neighbors (KNN) apresentaram os menores valores médios de F1, indicando menor capacidade discriminativa nesse conjunto de dados. Os demais classificadores mantiveram desempenho estável e intermediário entre esses extremos. Outro aspecto relevante é a similaridade entre os resultados obtidos com BoW e TF-IDF, indicando que ambos os métodos de representação textual são eficazes para a tarefa de detecção de linguagem preconceituosa no Telegram, sem diferenças significativas de desempenho entre si.

Os resultados dos experimentos realizados com o conjunto de dados PrejudiceWhatsApp.Br encontram-se sintetizados nas Tabelas 10 e 11. A Tabela 10 apresenta o desempenho dos classificadores utilizando o método Bag-of-Words (BoW), enquanto a Tabela 11 apresenta os resultados obtidos com o método TF-IDF (Term Frequency–Inverse Document Frequency). A partir dessas tabelas, observamos que os classificadores Gradient Boosting (GB) e Linear Support Vector Machine (LSVM) se destacaram de forma consistente, apresentando os maiores valores de F1-score na maioria dos cenários avaliados. Em contraste, o classificador K-Nearest Neighbors (KNN) apresentou o pior desempenho entre todas as configurações testadas, indicando dificuldades claras em lidar com a natureza do problema e com a alta dimensionalidade das representações textuais. Os demais algoritmos mantiveram desempenho estável, reforçando que diversas abordagens de aprendizado de máquina conseguem capturar padrões linguísticos relevantes para a detecção de linguagem preconceituosa no WhatsApp. Além disso, constatamos que os métodos BoW e TF-IDF produziram resultados semelhantes, sugerindo que ambos são alternativas viáveis para essa tarefa, embora apresentem características distintas de representação textual.




Figura 2 – Curva de aprendizado para o melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceTelegram.Br.

Tabela 8 – Resultados para o PrejudiceTelegram.Br usando o método BoW

(a) BoW-1. Features: 14.491, Tempo: 313.0s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.90	0.82 ± 0.02	0.81 ± 0.01	0.820 ± 0.01
BNB	0.85	0.64 ± 0.02	0.90 ± 0.02	0.752 ± 0.01
MNB	0.87	0.73 ± 0.01	0.89 ± 0.02	0.808 ± 0.01
LSVM	0.89	0.82 ± 0.02	0.81 ± 0.01	0.820 ± 0.01
KNN	0.70	0.59 ± 0.02	0.80 ± 0.01	0.686 ± 0.01
SGD	0.89	0.83 ± 0.04	0.80 ± 0.05	0.812 ± 0.01
RF	0.90	0.83 ± 0.02	0.79 ± 0.02	0.813 ± 0.01
GB	0.93	0.92 ± 0.01	0.80 ± 0.01	0.860 ± 0.00
MLP	0.87	0.80 ± 0.02	0.79 ± 0.03	0.796 ± 0.02

(b) BoW-1 C/Pré. Features: 15.218, Tempo: 141.3s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.90	0.82 ± 0.02	0.81 ± 0.01	0.818 ± 0.01
BNB	0.85	0.63 ± 0.01	0.92 ± 0.01	0.755 ± 0.01
MNB	0.86	0.73 ± 0.02	0.89 ± 0.01	0.808 ± 0.01
LSVM	0.88	0.81 ± 0.03	0.79 ± 0.01	0.801 ± 0.02
KNN	0.71	0.64 ± 0.01	0.71 ± 0.03	0.680 ± 0.02
SGD	0.87	0.81 ± 0.02	0.77 ± 0.02	0.794 ± 0.01
RF	0.90	0.84 ± 0.01	0.78 ± 0.01	0.812 ± 0.00
GB	0.91	0.89 ± 0.03	0.78 ± 0.03	0.834 ± 0.01
MLP	0.87	0.79 ± 0.03	0.81 ± 0.01	0.805 ± 0.01

(c) BoW-1,2. Features: 102.297, Tempo: 872.5s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.90	0.82 ± 0.02	0.81 ± 0.01	0.822 ± 0.01
BNB	0.85	0.59 ± 0.01	0.96 ± 0.00	0.735 ± 0.01
MNB	0.86	0.72 ± 0.02	0.89 ± 0.02	0.801 ± 0.01
LSVM	0.90	0.83 ± 0.01	0.81 ± 0.01	0.825 ± 0.00
KNN	0.60	0.50 ± 0.00	0.98 ± 0.00	0.670 ± 0.00
SGD	0.88	0.81 ± 0.02	0.79 ± 0.03	0.804 ± 0.02
RF	0.87	0.79 ± 0.03	0.78 ± 0.01	0.789 ± 0.01
GB	0.93	0.92 ± 0.01	0.80 ± 0.01	0.859 ± 0.00
MLP	0.88	0.78 ± 0.02	0.81 ± 0.02	0.801 ± 0.02

(d) BoW-1,2 C/Pré. Features: 70.176, Tempo: 1647.4s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.89	0.80 ± 0.02	0.81 ± 0.01	0.813 ± 0.01
BNB	0.85	0.58 ± 0.00	0.97 ± 0.01	0.727 ± 0.00
MNB	0.84	0.70 ± 0.01	0.91 ± 0.01	0.793 ± 0.01
LSVM	0.89	0.81 ± 0.02	0.80 ± 0.01	0.806 ± 0.01
KNN	0.59	0.51 ± 0.01	0.94 ± 0.03	0.668 ± 0.00
SGD	0.87	0.79 ± 0.01	0.77 ± 0.01	0.784 ± 0.01
RF	0.87	0.78 ± 0.04	0.78 ± 0.02	0.784 ± 0.02
GB	0.91	0.91 ± 0.01	0.75 ± 0.01	0.826 ± 0.00
MLP	0.87	0.79 ± 0.02	0.80 ± 0.01	0.798 ± 0.01

(e) BoW-1,2,3.

2134.5s

Features: 222.563, Tempo:

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.89	0.81 ± 0.02	0.80 ± 0.02	0.809 ± 0.01
BNB	0.83	0.56 ± 0.00	0.98 ± 0.00	0.715 ± 0.00
MNB	0.83	0.70 ± 0.01	0.91 ± 0.01	0.794 ± 0.01
LSVM	0.89	0.82 ± 0.01	0.79 ± 0.00	0.812 ± 0.01
KNN	0.56	0.50 ± 0.00	0.99 ± 0.00	0.669 ± 0.00
SGD	0.87	0.80 ± 0.02	0.79 ± 0.04	0.795 ± 0.02
RF	0.86	0.75 ± 0.02	0.80 ± 0.02	0.780 ± 0.02
GB	0.93	0.92 ± 0.01	0.79 ± 0.01	0.857 ± 0.00
MLP	0.86	0.76 ± 0.01	0.82 ± 0.04	0.793 ± 0.02

(f) BoW-1,2,3 C/Pré. Features: 164.396, Tempo:

1458.8s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.89	0.81 ± 0.02	0.80 ± 0.02	0.806 ± 0.01
BNB	0.84	0.54 ± 0.00	0.98 ± 0.01	0.706 ± 0.00
MNB	0.83	0.68 ± 0.00	0.93 ± 0.01	0.787 ± 0.00
LSVM	0.89	0.82 ± 0.01	0.79 ± 0.02	0.808 ± 0.00
KNN	0.59	0.51 ± 0.01	0.95 ± 0.00	0.669 ± 0.00
SGD	0.87	0.80 ± 0.02	0.79 ± 0.02	0.798 ± 0.01
RF	0.86	0.77 ± 0.03	0.79 ± 0.03	0.784 ± 0.02
GB	0.91	0.90 ± 0.03	0.77 ± 0.01	0.830 ± 0.00
MLP	0.86	0.75 ± 0.02	0.84 ± 0.03	0.798 ± 0.01

6.2 Avaliação de Modelos de Linguagem Pré-treinados

Os resultados apresentados nas Tabelas 12 (PrejudiceTelegram.Br) e 13 (PrejudiceWhatsApp.Br) evidenciam um desempenho consistentemente elevado das diferentes variantes de BERT em ambos os conjuntos de dados, ainda que haja variações relevantes entre os modelos pré-treinados e os classificadores aplicados sobre seus embeddings.

Tabela 9 – Resultados para o PrejudiceTelegram.Br usando o método TF-IDF

(a) TF-IDF-1. Features: 16.371, Tempo: 238.3s (b) TF-IDF-1 C/Pré. Features: 15.218, Tempo: 164.1s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.85	0.78±0.02	0.73±0.02	0.763±0.02	LR	0.85	0.78±0.01	0.74±0.01	0.762±0.00
BNB	0.85	0.64±0.02	0.90±0.02	0.752±0.01	BNB	0.85	0.63±0.01	0.92±0.01	0.755±0.01
MNB	0.85	0.75±0.01	0.79±0.02	0.773±0.01	MNB	0.85	0.75±0.01	0.80±0.02	0.773±0.01
LSVM	0.89	0.81±0.01	0.79±0.02	0.807±0.01	LSVM	0.89	0.81±0.02	0.79±0.02	0.808±0.02
KNN	0.78	0.74±0.01	0.69±0.07	0.716±0.00	KNN	0.78	0.73±0.01	0.69±0.02	0.713±0.00
SGD	0.89	0.80±0.02	0.79±0.06	0.795±0.02	SGD	0.88	0.81±0.03	0.78±0.03	0.796±0.02
RF	0.88	0.81±0.03	0.77±0.02	0.796±0.01	RF	0.89	0.82±0.01	0.77±0.01	0.800±0.01
GB	0.93	0.91±0.01	0.79±0.00	0.853±0.00	GB	0.91	0.88±0.02	0.76±0.02	0.820±0.01
MLP	0.86	0.78±0.02	0.77±0.02	0.776±0.02	MLP	0.86	0.77±0.01	0.78±0.03	0.779±0.01

(c) TF-IDF-1,2. Features: 102.297, Tempo: 954.8s (d) TF-IDF-1,2 C/Pré. Features: 84.810, Tempo: 951.3s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.80	0.76±0.02	0.67±0.02	0.713±0.02	LR	0.80	0.76±0.02	0.66±0.02	0.711±0.01
BNB	0.85	0.59±0.01	0.96±0.00	0.735±0.01	BNB	0.85	0.58±0.00	0.97±0.01	0.729±0.00
MNB	0.83	0.76±0.01	0.74±0.04	0.753±0.02	MNB	0.83	0.74±0.01	0.75±0.02	0.750±0.01
LSVM	0.87	0.80±0.02	0.76±0.01	0.783±0.01	LSVM	0.87	0.80±0.02	0.76±0.01	0.787±0.00
KNN	0.79	0.74±0.01	0.68±0.01	0.713±0.00	KNN	0.78	0.72±0.01	0.69±0.03	0.708±0.01
SGD	0.88	0.78±0.00	0.79±0.03	0.793±0.01	SGD	0.88	0.78±0.02	0.81±0.03	0.799±0.01
RF	0.87	0.78±0.01	0.78±0.03	0.783±0.02	RF	0.87	0.79±0.01	0.78±0.01	0.790±0.01
GB	0.93	0.91±0.00	0.79±0.01	0.855±0.00	GB	0.91	0.89±0.02	0.76±0.01	0.820±0.01
MLP	0.84	0.76±0.03	0.73±0.06	0.746±0.03	MLP	0.85	0.76±0.01	0.77±0.02	0.768±0.01

(e) TF-IDF-1,2,3. Features: 222.563, Tempo: 2231.7s (f) TF-IDF-1,2,3 C/Pré. features: 164.396, Tempo: 2193.2s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.78	0.76±0.03	0.62±0.02	0.687±0.02	LR	0.78	0.75±0.02	0.62±0.02	0.683±0.02
BNB	0.83	0.56±0.00	0.98±0.00	0.715±0.00	BNB	0.84	0.54±0.00	0.98±0.00	0.706±0.00
MNB	0.81	0.75±0.01	0.71±0.04	0.734±0.02	MNB	0.81	0.73±0.00	0.73±0.03	0.735±0.01
LSVM	0.85	0.78±0.02	0.73±0.01	0.755±0.01	LSVM	0.85	0.79±0.01	0.73±0.02	0.764±0.01
KNN	0.79	0.73±0.01	0.67±0.02	0.703±0.01	KNN	0.78	0.72±0.01	0.68±0.02	0.705±0.01
SGD	0.86	0.80±0.03	0.73±0.05	0.761±0.02	SGD	0.85	0.79±0.02	0.72±0.06	0.755±0.02
RF	0.85	0.75±0.01	0.79±0.04	0.776±0.01	RF	0.86	0.76±0.03	0.79±0.01	0.777±0.02
GB	0.93	0.91±0.01	0.79±0.01	0.851±0.00	GB	0.91	0.88±0.02	0.76±0.02	0.818±0.01
MLP	0.83	0.74±0.02	0.74±0.04	0.745±0.02	MLP	0.83	0.75±0.01	0.77±0.02	0.760±0.01

No conjunto PrejudiceTelegram.Br, o modelo HateBR destacou-se como a melhor opção, alcançando os maiores valores de F1-score especialmente em combinação com o classificador Logistic Regression (LR), que atingiu aproximadamente F1 de 0.807. Os modelos TupiBERTBase e BERTweetBR também apresentaram resultados sólidos e estáveis, embora ligeiramente inferiores. Além disso, a comparação entre versões com e sem pré-processamento

Tabela 10 – Resultados para o PrejudiceWhatsApp.Br usando o método BoW

(a) BoW-1. Features: 10.924, Tempo: 319.2s

(b) BoW-1 C/Pré. Features: 9.820, Tempo: 308.3s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.93	0.88±0.00	0.84±0.01	0.863 ±0.00
BNB	0.90	0.70±0.01	0.92±0.01	0.801±0.01
MNB	0.91	0.77±0.00	0.90±0.01	0.834±0.01
LSVM	0.92	0.87±0.01	0.83±0.00	0.855±0.00
KNN	0.76	0.81±0.05	0.44±0.07	0.566±0.05
SGD	0.92	0.85±0.01	0.83±0.02	0.844±0.00
RF	0.92	0.87±0.02	0.81±0.01	0.836±0.00
GB	0.94	0.94±0.01	0.79±0.02	0.862±0.01
MLP	0.90	0.84±0.03	0.83±0.02	0.846±0.00

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.92	0.86±0.01	0.82±0.01	0.841 ±0.01
BNB	0.90	0.69±0.01	0.92±0.01	0.793±0.00
MNB	0.91	0.77±0.01	0.89±0.01	0.830±0.00
LSVM	0.91	0.85±0.00	0.82±0.01	0.837±0.00
KNN	0.77	0.81±0.06	0.52±0.08	0.629±0.04
SGD	0.90	0.86±0.01	0.80±0.02	0.835±0.01
RF	0.92	0.86±0.02	0.79±0.02	0.831±0.00
GB	0.93	0.94±0.01	0.76±0.02	0.840±0.02
MLP	0.91	0.84±0.02	0.82±0.01	0.837±0.01

(c) BoW-1,2. Features: 60.344, Tempo: 1504.7s

(d) BoW-1,2 C/Pré. Features: 48.576, Tempo: 1421.5s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.92	0.86±0.01	0.84±0.00	0.850±0.00
BNB	0.89	0.65±0.01	0.93±0.01	0.773±0.01
MNB	0.89	0.76±0.01	0.88±0.01	0.823±0.01
LSVM	0.92	0.87±0.01	0.83±0.01	0.853±0.01
KNN	0.69	0.85±0.11	0.28±0.2	0.372±0.02
SGD	0.91	0.85±0.01	0.82±0.01	0.835±0.01
RF	0.91	0.82±0.03	0.83±0.01	0.829±0.01
GB	0.94	0.94±0.01	0.78±0.02	0.860±0.01
MLP	0.90	0.84±0.01	0.83±0.01	0.838±0.01

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.92	0.85±0.01	0.82±0.01	0.837±0.00
BNB	0.89	0.63±0.00	0.94±0.01	0.761±0.00
MNB	0.89	0.76±0.01	0.89±0.01	0.822±0.01
LSVM	0.92	0.87±0.00	0.81±0.00	0.841±0.00
KNN	0.67	0.75±0.07	0.38±0.17	0.484±0.11
SGD	0.91	0.86±0.02	0.80±0.01	0.834±0.00
RF	0.90	0.83±0.03	0.81±0.01	0.827±0.01
GB	0.93	0.94±0.01	0.75±0.02	0.842±0.01
MLP	0.90	0.83±0.03	0.82±0.01	0.828±0.01

(e) BoW-1,2,3. Features: 125.729, Tempo: 3716.1s

(f) BoW-1,2,3 C/Pré. Features: 113.634, Tempo: 1150.4s

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.91	0.84±0.02	0.83±0.00	0.844±0.01
BNB	0.88	0.61±0.00	0.94±0.00	0.748±0.00
MNB	0.88	0.75±0.01	0.90±0.01	0.820±0.01
LSVM	0.92	0.86±0.02	0.83±0.00	0.847 ±0.01
KNN	0.64	0.84±0.15	0.30±0.34	0.304±0.30
SGD	0.91	0.84±0.02	0.84±0.01	0.836±0.00
RF	0.89	0.78±0.01	0.84±0.01	0.810±0.01
GB	0.94	0.94±0.01	0.78±0.02	0.858±0.02
MLP	0.90	0.83±0.01	0.84±0.01	0.838±0.00

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.92	0.87±0.01	0.82±0.00	0.848±0.01
BNB	0.88	0.60±0.00	0.96±0.01	0.743±0.00
MNB	0.89	0.75±0.01	0.90±0.01	0.822±0.01
LSVM	0.92	0.87±0.01	0.83±0.00	0.853 ±0.00
KNN	0.70	0.87±0.10	0.28±0.22	0.374±0.17
SGD	0.91	0.86±0.02	0.82±0.01	0.842±0.00
RF	0.91	0.83±0.03	0.80±0.02	0.822±0.01
GB	0.93	0.92±0.00	0.78±0.02	0.846±0.01
MLP	0.91	0.85±0.02	0.83±0.02	0.842±0.01

(C/Pre.) sugere que o pré-processamento adicional não proporcionou ganhos significativos, indicando que os modelos pré-treinados já são suficientemente robustos para lidar com ruídos característicos de mensagens instantâneas.

Tabela 11 – Resultados para o PrejudiceWhatsApp.Br usando o método TF-IDF

(a) TF-IDF-1. Features: 12.549, Tempo: 130.0s (b) TF-IDF-1 C/Pré. Features: 11.344, Tempo: 146.1s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.89	0.83±0.02	0.78±0.01	0.810±0.01	LR	0.89	0.84±0.02	0.78±0.01	0.809±0.01
BNB	0.90	0.71±0.01	0.91±0.01	0.804±0.01	BNB	0.90	0.70±0.01	0.91±0.01	0.800±0.00
MNB	0.88	0.79±0.01	0.81±0.02	0.803±0.01	MNB	0.88	0.80±0.01	0.81±0.02	0.806±0.01
LSVM	0.92	0.88±0.01	0.83±0.01	0.855±0.01	LSVM	0.92	0.87±0.02	0.82±0.01	0.850±0.01
KNN	0.87	0.81±0.03	0.78±0.01	0.800±0.01	KNN	0.86	0.81±0.02	0.78±0.02	0.797±0.02
SGD	0.92	0.86±0.02	0.83±0.01	0.848±0.01	SGD	0.91	0.86±0.01	0.82±0.02	0.844±0.01
RF	0.92	0.86±0.02	0.81±0.01	0.837±0.00	RF	0.92	0.86±0.01	0.79±0.01	0.831±0.00
GB	0.94	0.92±0.00	0.80±0.02	0.861±0.01	GB	0.93	0.92±0.01	0.78±0.02	0.850±0.01
MLP	0.91	0.85±0.01	0.82±0.01	0.841±0.00	MLP	0.90	0.84±0.02	0.82±0.01	0.831±0.01

(c) TF-IDF-1,2. Features: 72.560, Tempo: 944.0s (d) TF-IDF-1,2 C/Pré. Features: 59.134, Tempo: 1012.8s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.85	0.82±0.02	0.74±0.02	0.779±0.02	LR	0.85	0.82±0.02	0.74±0.02	0.782±0.01
BNB	0.89	0.66±0.01	0.94±0.01	0.781±0.01	BNB	0.89	0.64±0.00	0.95±0.01	0.770±0.00
MNB	0.86	0.79±0.02	0.77±0.02	0.786±0.01	MNB	0.85	0.79±0.01	0.77±0.03	0.784±0.02
LSVM	0.90	0.85±0.02	0.79±0.01	0.826±0.01	LSVM	0.90	0.86±0.02	0.79±0.01	0.828±0.01
KNN	0.86	0.80±0.02	0.77±0.01	0.791±0.01	KNN	0.86	0.81±0.02	0.78±0.02	0.798±0.02
SGD	0.90	0.85±0.02	0.80±0.01	0.831±0.00	SGD	0.90	0.86±0.02	0.79±0.02	0.828±0.01
RF	0.91	0.84±0.01	0.82±0.01	0.833±0.01	RF	0.90	0.83±0.03	0.81±0.02	0.827±0.01
GB	0.94	0.92±0.01	0.81±0.02	0.868±0.01	GB	0.93	0.92±0.00	0.79±0.01	0.853±0.01
MLP	0.89	0.83±0.03	0.81±0.01	0.825±0.01	MLP	0.90	0.83±0.02	0.80±0.01	0.821±0.00

(e) TF-IDF-1,2,3. Features: 153.813, Tempo: 1603.3s (f) TF-IDF-1,2,3 C/Pré. Features: 113.634, Tempo: 1451.7s

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.84	0.81±0.03	0.71±0.02	0.761±0.02	LR	0.84	0.81±0.03	0.72±0.02	0.765±0.01
BNB	0.89	0.62±0.00	0.94±0.11	0.751±0.00	BNB	0.88	0.60±0.00	0.96±0.01	0.743±0.00
MNB	0.84	0.79±0.02	0.76±0.01	0.780±0.01	MNB	0.84	0.78±0.01	0.77±0.03	0.780±0.01
LSVM	0.89	0.84±0.02	0.77±0.02	0.810±0.01	LSVM	0.89	0.85±0.02	0.77±0.01	0.812±0.01
KNN	0.86	0.80±0.01	0.77±0.01	0.789±0.01	KNN	0.86	0.81±0.02	0.78±0.02	0.797±0.02
SGD	0.89	0.84±0.02	0.80±0.01	0.819±0.01	SGD	0.89	0.84±0.02	0.78±0.01	0.815±0.01
RF	0.90	0.81±0.02	0.82±0.02	0.818±0.01	RF	0.90	0.81±0.03	0.80±0.03	0.811±0.02
GB	0.94	0.92±0.01	0.81±0.01	0.866±0.00	GB	0.93	0.91±0.00	0.79±0.02	0.851±0.01
MLP	0.88	0.81±0.04	0.80±0.00	0.806±0.02	MLP	0.88	0.82±0.03	0.78±0.02	0.808±0.02

No conjunto PrejudiceWhatsApp.Br, o padrão se mantém, mas o desempenho geral ainda é mais elevado. O modelo TupiBERTBase destacou-se como o melhor neste cenário, atingindo F1 de 0.855 quando combinado com Logistic Regression o melhor resultado entre todos os experimentos conduzidos. O HateBR também apresentou desempenho altamente competitivo, reforçando sua adequação à tarefa de detecção de linguagem preconceituosa. Assim como




Figura 3 – Matriz de confusão do melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceTelegram.Br.




Figura 4 – Curva de aprendizado para o melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceWhatsApp.Br.

observado no Telegram, o pré-processamento adicional mostrou impacto limitado, sugerindo que a qualidade intrínseca das representações produzidas pelos modelos pré-treinados é o principal fator responsável pelo desempenho observado.

Matriz de Confusão — Gradient Boosting (TF-IDF Bigrama)




Figura 5 – Matriz de confusão do melhor modelo usando vetorizadores (BoW/TF-IDF) para o PrejudiceWhatsApp.Br.

De modo geral, os resultados demonstram que:

- (i) modelos pré-treinados específicos para língua portuguesa e/ou discurso de ódio (como HateBR e TupiBERTBase) apresentam vantagem clara sobre modelos genéricos;
- (ii) classificadores lineares, especialmente *Logistic Regression* e *Linear SVM*, são particularmente eficazes quando acoplados aos embeddings BERT;
- (iii) modelos probabilísticos simples, como BNB e MNB, apresentam desempenho inferior, indicando que não capturam adequadamente a estrutura das representações contextualizadas;
- (iv) há um padrão de estabilidade entre os diferentes classificadores, evidenciando que a informação fornecida pelos embeddings BERT é altamente discriminativa.

Por fim, as curvas de aprendizado e as matrizes de confusão dos melhores modelos reforçam a capacidade de generalização observada nas tabelas: as curvas evidenciam a ausência de sobreajuste significativo, enquanto as matrizes de confusão mostram boa capacidade de distinguir ambas as classes, com baixa taxa de falsos positivos e falsos negativos. Esses achados consolidam os modelos baseados em BERT como as abordagens mais eficientes para detecção automática de linguagem preconceituosa nos dois ambientes analisados.

Tabela 12 – Resultados utilizando modelos pré treinados - BERT - no conjunto de dados PrejudiceTelegram.Br.

(a) BERT (BERTweetBR), Tempo: 3449.4s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.83	0.75 ± 0.02	0.76 ± 0.02	0.760 ± 0.01
BNB	0.64	0.60 ± 0.02	0.38 ± 0.03	0.468 ± 0.02
MNB	0.65	0.60 ± 0.02	0.38 ± 0.03	0.467 ± 0.02
LSVM	0.83	0.75 ± 0.01	0.75 ± 0.03	0.756 ± 0.02
KNN	0.72	0.63 ± 0.01	0.75 ± 0.01	0.688 ± 0.01
SGD	0.82	0.69 ± 0.05	0.84 ± 0.09	0.756 ± 0.01
RF	0.80	0.71 ± 0.02	0.73 ± 0.01	0.723 ± 0.01
GB	0.82	0.72 ± 0.02	0.76 ± 0.02	0.743 ± 0.01
MLP	0.82	0.74 ± 0.03	0.75 ± 0.06	0.748 ± 0.02

(b) BERT (BERTweetBR) C/Pré., Tempo: 2525.8s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.82	0.75 ± 0.02	0.72 ± 0.02	0.741 ± 0.01
BNB	0.66	0.59 ± 0.02	0.55 ± 0.01	0.571 ± 0.01
MNB	0.65	0.59 ± 0.02	0.54 ± 0.01	0.567 ± 0.01
LSVM	0.79	0.73 ± 0.01	0.70 ± 0.03	0.720 ± 0.02
KNN	0.71	0.61 ± 0.01	0.77 ± 0.02	0.682 ± 0.00
SGD	0.79	0.74 ± 0.05	0.66 ± 0.01	0.693 ± 0.04
RF	0.78	0.71 ± 0.01	0.69 ± 0.02	0.702 ± 0.01
GB	0.80	0.72 ± 0.02	0.71 ± 0.02	0.718 ± 0.02
MLP	0.82	0.73 ± 0.02	0.75 ± 0.03	0.744 ± 0.01

(c) BERT (TupiBERTBase), Tempo: 3661.0s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.86	0.78 ± 0.02	0.78 ± 0.02	0.783 ± 0.01
BNB	0.79	0.76 ± 0.01	0.67 ± 0.01	0.713 ± 0.01
MNB	0.81	0.76 ± 0.01	0.68 ± 0.01	0.719 ± 0.01
LSVM	0.84	0.76 ± 0.01	0.76 ± 0.03	0.764 ± 0.01
KNN	0.82	0.75 ± 0.02	0.75 ± 0.00	0.752 ± 0.00
SGD	0.85	0.76 ± 0.05	0.77 ± 0.08	0.761 ± 0.02
RF	0.84	0.76 ± 0.01	0.76 ± 0.02	0.762 ± 0.01
GB	0.85	0.77 ± 0.02	0.78 ± 0.01	0.779 ± 0.01
MLP	0.86	0.77 ± 0.01	0.78 ± 0.03	0.777 ± 0.01

(d) BERT (TupiBERTBase) C/Pré., Tempo: 1600.3s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.84	0.76 ± 0.01	0.74 ± 0.00	0.752 ± 0.00
BNB	0.74	0.74 ± 0.01	0.57 ± 0.02	0.645 ± 0.01
MNB	0.76	0.73 ± 0.01	0.58 ± 0.02	0.654 ± 0.01
LSVM	0.82	0.75 ± 0.00	0.73 ± 0.01	0.745 ± 0.00
KNN	0.77	0.71 ± 0.01	0.71 ± 0.02	0.711 ± 0.01
SGD	0.83	0.80 ± 0.05	0.61 ± 0.18	0.674 ± 0.09
RF	0.80	0.73 ± 0.01	0.71 ± 0.01	0.721 ± 0.01
GB	0.82	0.74 ± 0.01	0.74 ± 0.02	0.744 ± 0.02
MLP	0.83	0.72 ± 0.01	0.79 ± 0.04	0.760 ± 0.01

(e) BERT (HateBR), Tempo: 4555.4s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.88	0.79 ± 0.02	0.82 ± 0.00	0.807 ± 0.01
BNB	0.77	0.72 ± 0.01	0.80 ± 0.02	0.764 ± 0.00
MNB	0.78	0.72 ± 0.01	0.81 ± 0.02	0.764 ± 0.00
LSVM	0.86	0.78 ± 0.02	0.82 ± 0.01	0.800 ± 0.01
KNN	0.82	0.73 ± 0.02	0.82 ± 0.02	0.776 ± 0.01
SGD	0.87	0.79 ± 0.07	0.77 ± 0.12	0.769 ± 0.03
RF	0.85	0.77 ± 0.02	0.78 ± 0.02	0.780 ± 0.00
GB	0.86	0.77 ± 0.03	0.78 ± 0.01	0.783 ± 0.01
MLP	0.87	0.78 ± 0.03	0.80 ± 0.01	0.798 ± 0.01

(f) BERT (HateBR) C/Pré., Tempo: 4555.4s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.86	0.76 ± 0.02	0.81 ± 0.02	0.784 ± 0.01
BNB	0.72	0.67 ± 0.01	0.80 ± 0.01	0.736 ± 0.00
MNB	0.76	0.67 ± 0.01	0.80 ± 0.01	0.736 ± 0.01
LSVM	0.84	0.74 ± 0.02	0.80 ± 0.02	0.776 ± 0.00
KNN	0.79	0.69 ± 0.01	0.78 ± 0.01	0.738 ± 0.00
SGD	0.85	0.76 ± 0.04	0.77 ± 0.07	0.738 ± 0.01
RF	0.83	0.76 ± 0.02	0.72 ± 0.03	0.766 ± 0.01
GB	0.83	0.75 ± 0.01	0.77 ± 0.02	0.765 ± 0.01
MLP	0.84	0.74 ± 0.03	0.80 ± 0.02	0.773 ± 0.02

6.3 Avaliação de Grandes Modelos de Linguagem

Os resultados apresentados nas Tabelas 14 e 15 revelam que tanto o GPT-4o-mini quanto o Gemini-2.0-Flash alcançam desempenho competitivo na tarefa de detecção de linguagem preconceituosa, ainda que haja variações significativas entre as abordagens de prompting

Tabela 13 – Resultados utilizando modelos pré treinados - BERT - no conjunto de dados PrejudiceWhatsApp.Br.

(a) BERT (BERTweetBR), Tempo: 2070.9s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.89	0.82 ± 0.01	0.81 ± 0.01	0.818 ± 0.00
BNB	0.68	0.60 ± 0.03	0.51 ± 0.02	0.558 ± 0.02
MNB	0.68	0.60 ± 0.03	0.51 ± 0.02	0.560 ± 0.02
LSVM	0.89	0.82 ± 0.01	0.81 ± 0.00	0.820 ± 0.00
KNN	0.79	0.66 ± 0.00	0.85 ± 0.01	0.744 ± 0.01
SGD	0.89	0.81 ± 0.05	0.79 ± 0.06	0.800 ± 0.01
RF	0.86	0.78 ± 0.01	0.77 ± 0.01	0.778 ± 0.01
GB	0.88	0.79 ± 0.00	0.80 ± 0.00	0.799 ± 0.00
MLP	0.88	0.80 ± 0.02	0.83 ± 0.02	0.816 ± 0.00

(b) BERT (BERTweetBR) C/Pré., Time: 1142.7s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.88	0.81 ± 0.01	0.78 ± 0.01	0.802 ± 0.01
BNB	0.71	0.61 ± 0.01	0.65 ± 0.02	0.637 ± 0.01
MNB	0.70	0.64 ± 0.01	0.63 ± 0.02	0.640 ± 0.01
LSVM	0.87	0.80 ± 0.01	0.79 ± 0.02	0.802 ± 0.01
KNN	0.80	0.67 ± 0.00	0.83 ± 0.00	0.749 ± 0.00
SGD	0.87	0.79 ± 0.04	0.79 ± 0.05	0.791 ± 0.01
RF	0.86	0.77 ± 0.01	0.75 ± 0.00	0.764 ± 0.01
GB	0.87	0.78 ± 0.00	0.76 ± 0.01	0.774 ± 0.01
MLP	0.87	0.79 ± 0.02	0.80 ± 0.01	0.801 ± 0.01

(c) BERT (TupiBERTBase), Tempo: 1359.3s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.92	0.86 ± 0.03	0.85 ± 0.02	0.855 ± 0.02
BNB	0.87	0.85 ± 0.01	0.76 ± 0.01	0.806 ± 0.01
MNB	0.89	0.85 ± 0.01	0.77 ± 0.01	0.810 ± 0.01
LSVM	0.90	0.84 ± 0.02	0.82 ± 0.02	0.833 ± 0.00
KNN	0.89	0.83 ± 0.01	0.85 ± 0.00	0.848 ± 0.02
SGD	0.91	0.86 ± 0.04	0.80 ± 0.05	0.831 ± 0.01
RF	0.91	0.84 ± 0.02	0.83 ± 0.01	0.842 ± 0.01
GB	0.91	0.84 ± 0.02	0.83 ± 0.00	0.844 ± 0.01
MLP	0.91	0.84 ± 0.02	0.83 ± 0.02	0.840 ± 0.01

(d) BERT (TupiBERTBase) C/Pré., Tempo: 1299.2s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.90	0.83 ± 0.01	0.79 ± 0.01	0.813 ± 0.00
BNB	0.83	0.81 ± 0.02	0.65 ± 0.00	0.724 ± 0.01
MNB	0.84	0.81 ± 0.02	0.66 ± 0.01	0.733 ± 0.01
LSVM	0.88	0.81 ± 0.01	0.79 ± 0.01	0.805 ± 0.01
KNN	0.85	0.79 ± 0.02	0.78 ± 0.00	0.789 ± 0.01
SGD	0.88	0.78 ± 0.09	0.79 ± 0.17	0.764 ± 0.06
RF	0.87	0.79 ± 0.02	0.78 ± 0.01	0.791 ± 0.01
GB	0.88	0.79 ± 0.02	0.80 ± 0.01	0.801 ± 0.01
MLP	0.88	0.80 ± 0.01	0.80 ± 0.01	0.802 ± 0.00

(e) BERT (HateBR), Tempo: 1330.3s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.90	0.81 ± 0.01	0.84 ± 0.01	0.832 ± 0.01
BNB	0.78	0.74 ± 0.01	0.80 ± 0.02	0.769 ± 0.01
MNB	0.79	0.74 ± 0.01	0.80 ± 0.02	0.770 ± 0.01
LSVM	0.89	0.81 ± 0.01	0.85 ± 0.00	0.834 ± 0.01
KNN	0.85	0.77 ± 0.01	0.83 ± 0.01	0.800 ± 0.01
SGD	0.90	0.80 ± 0.05	0.85 ± 0.05	0.824 ± 0.00
RF	0.87	0.81 ± 0.01	0.77 ± 0.01	0.791 ± 0.01
GB	0.88	0.81 ± 0.01	0.79 ± 0.01	0.801 ± 0.00
MLP	0.89	0.80 ± 0.02	0.85 ± 0.02	0.825 ± 0.01

(f) BERT (HateBR) C/Pré., Tempo: 4555.4s

Metódo	Auc	Precisão	Revocação	F1-score
LR	0.88	0.81 ± 0.02	0.82 ± 0.01	0.818 ± 0.01
BNB	0.75	0.70 ± 0.01	0.80 ± 0.03	0.754 ± 0.02
MNB	0.77	0.70 ± 0.02	0.81 ± 0.03	0.755 ± 0.02
LSVM	0.88	0.80 ± 0.01	0.83 ± 0.01	0.817 ± 0.00
KNN	0.82	0.74 ± 0.02	0.79 ± 0.01	0.769 ± 0.01
SGD	0.87	0.84 ± 0.05	0.70 ± 0.12	0.759 ± 0.04
RF	0.85	0.80 ± 0.01	0.72 ± 0.02	0.764 ± 0.01
GB	0.85	0.79 ± 0.02	0.76 ± 0.01	0.777 ± 0.00
MLP	0.87	0.79 ± 0.02	0.81 ± 0.00	0.802 ± 0.01

e entre os próprios modelos. No conjunto PrejudiceTelegram.Br, o GPT-4o-mini apresentou melhor desempenho geral, com destaque para a estratégia de prompting por papel, que atingiu F1 de 0.808, superando as configurações Zero-Shot e Few-Shot. A estratégia baseada em dicionário também obteve resultados sólidos, sugerindo que fornecer pistas semânticas explícitas pode auxiliar o modelo. Para o Gemini-2.0-Flash, o melhor desempenho foi obtido com o uso de




Figura 6 – Curva de aprendizado para o melhor modelo pré treinado (HATEBr) para o PrejudiceTelegram.Br.




Figura 7 – Matrix de confusão para o melhor modelo pré treinado (HATEBr) para o PrejudiceTelegram.Br.

dicionário (F1 de 0.793), enquanto o Few-Shot apresentou queda acentuada, indicando maior sensibilidade à seleção dos exemplos.




Figura 8 – Curva de aprendizado para o melhor modelo pré treinado (TupiBert) para o PrejudiceWhatsApp.Br




Figura 9 – Matrix de confusão para o melhor modelo pré treinado (TupiBert) para o PrejudiceWhatsApp.Br

No conjunto PrejudiceWhatsApp.Br, observa-se uma melhora geral do desempenho em comparação ao Telegram, refletindo a maior regularidade e menor ruído das mensagens desse corpus. O GPT-4o-mini novamente se destacou, alcançando seu melhor resultado com prompting por papel (F1 de 0.838), demonstrando que a instrução explícita de assumir o papel de

um especialista reforça a capacidade do modelo de identificar nuances linguísticas associadas ao preconceito. Já o Gemini-2.0-Flash obteve seu melhor desempenho com a abordagem baseada em dicionário (F1 de 0.825), apresentando padrão semelhante ao observado no Telegram.

De forma geral, os resultados permitem identificar três tendências principais: (i) o prompting por papel e o uso de dicionário são as abordagens mais estáveis e eficazes entre os LLMs avaliados; (ii) o GPT-4o-mini apresenta desempenho superior ao do Gemini-2.0-Flash na maioria dos cenários, especialmente em tarefas com maior ambiguidade contextual; e (iii) o conjunto PrejudiceWhatsApp.Br possibilita métricas mais elevadas para ambos os modelos, possivelmente devido à maior homogeneidade linguística das mensagens. Esses achados reforçam o potencial dos LLMs como ferramentas eficazes para detecção de discurso preconceituoso, desde que acompanhados de estratégias adequadas de prompting.

Tabela 14 – Melhores resultados dos LLMs utilizando o PrejudiceTelegram.Br

(a) GPT-4o-mini — Tempo: 411s

Abordagem	AUC	Precisão	Revocação	F1-score
Zero-Shot	0.76	0.71 ± 0.02	0.90 ± 0.01	0.796 ± 0.01
Few-Shot	0.76	0.71 ± 0.02	0.86 ± 0.02	0.783 ± 0.01
Prompting por Papel	0.79	0.74 ± 0.02	0.87 ± 0.01	0.808 ± 0.01
Uso de Dicionário	0.79	0.78 ± 0.02	0.82 ± 0.02	0.801 ± 0.01

(b) Gemini-2.0-Flash — Tempo: 159s

Abordagem	AUC	Precisão	Revocação	F1-score
Zero-Shot	0.75	0.75 ± 0.02	0.74 ± 0.02	0.752 ± 0.01
Few-Shot	0.69	0.74 ± 0.02	0.59 ± 0.02	0.664 ± 0.02
Prompting por Papel	0.75	0.84 ± 0.02	0.63 ± 0.02	0.721 ± 0.02
Uso de Dicionário	0.77	0.73 ± 0.01	0.86 ± 0.01	0.793 ± 0.01

Tabela 15 – Melhores resultados dos LLMs utilizando o PrejudiceWhatsApp.Br

(a) GPT-4o-mini — Tempo: 399,6s

Abordagem	AUC	Precisão	Revocação	F1-score
Zero-Shot	0.80	0.76 ± 0.02	0.86 ± 0.01	0.811 ± 0.01
Few-Shot	0.79	0.78 ± 0.02	0.80 ± 0.02	0.792 ± 0.01
Prompting por Papel	0.83	0.83 ± 0.02	0.84 ± 0.02	0.838 ± 0.01
Uso de Dicionário	0.83	0.81 ± 0.01	0.84 ± 0.02	0.831 ± 0.01

(b) Gemini-2.0-Flash — Tempo: 137,8s

Abordagem	AUC	Precisão	Revocação	F1-score
Zero-Shot	0.80	0.83 ± 0.02	0.75 ± 0.02	0.795 ± 0.01
Few-Shot	0.73	0.82 ± 0.04	0.57 ± 0.05	0.673 ± 0.04
Prompting por Papel	0.77	0.88 ± 0.02	0.62 ± 0.02	0.731 ± 0.02
Uso de Dicionário	0.82	0.82 ± 0.02	0.82 ± 0.02	0.825 ± 0.01

6.4 Resultados Obtidos Usando o Dicionário

Nesta seção, investigamos o uso do dicionário Prejudice.Br, em conjunto com diferentes estratégias de representação textual: BoW, TF-IDF e BERT. Inicialmente, apresentamos abordagens que combinam o dicionário com essas técnicas de vetorização. Em seguida, analisamos um cenário alternativo em que a detecção de linguagem preconceituosa é realizada com base apenas nas categorias do dicionário como atributos. Por fim, avaliamos um terceiro cenário, no qual somente as palavras presentes no dicionário são utilizadas como *features*, discutindo, de forma comparativa, o impacto de cada configuração no desempenho dos modelos.

Matriz de Confusão — Prompting por papel (LLM vs Anotadores)




Figura 10 – Matriz de confusão do modelo GPT-4 Mini usando a estratégia de *role prompting* no PrejudiceTelegram.Br

Matriz de Confusão — Prompting por papel (LLM vs Anotadores)




Figura 11 – Matriz de confusão para o modelo GPT-4 Mini usando a estratégia prompting por papel no PrejudiceWhatsApp.Br

6.4.1 *Resultados Obtidos com Dicionários e Métodos de Vetorização*

Inicialmente, avaliamos a estratégia de integrar as nove categorias do dicionário PrejudicePT-br aos métodos tradicionais de extração de características Bag-of-Words (BoW) e TF-IDF, considerando diferentes granularidades textuais (unigramas, bigramas e trigramas) e o pré-processamento. Os resultados dessa configuração são apresentados na Tabela 16. Em seguida, investigamos uma segunda estratégia baseada no uso direto das 842 palavras do dicionário PrejudicePT-br como características, novamente combinadas com BoW e TF-IDF, diferentes n-gramas e pré-processamento. Os resultados correspondentes encontram-se na Tabela 17.

No conjunto PrejudiceTelegram.Br, o melhor resultado da linha de base isto é, sem o uso do dicionário foi obtido com o classificador Gradient Boosting (GB) utilizando unigramas, sem pré-processamento, alcançando um F1-score de 0,855, tanto com BoW quanto com TF-IDF. Ao incorporar o dicionário PrejudicePT-br por meio de suas categorias, observou-se uma leve melhora no desempenho, com F1-score de 0,857. Esse resultado foi alcançado com o classificador GB, utilizando unigramas, bigramas e trigramas, com pré-processamento e o método BoW, o que indica que a informação semântica agregada pelas categorias do dicionário pode contribuir positivamente para a detecção de preconceito.

Para o conjunto PrejudiceWhatsApp.Br, o melhor desempenho da linha de base apresentou um F1-score de 0,866, obtido com o classificador GB, utilizando unigramas e bigramas, sem pré-processamento e com o método TF-IDF. De forma semelhante ao observado no Telegram, a incorporação das categorias do PrejudicePT-br manteve o desempenho máximo, com F1-score = 0,866, agora utilizando unigramas, bigramas e trigramas, com pré-processamento e TF-IDF. Esses resultados sugerem que, nesse cenário, o dicionário atua mais como um reforço interpretativo do modelo do que como um fator decisivo para ganhos expressivos de desempenho.

Por fim, ao utilizar diretamente as 842 palavras do dicionário PrejudicePT-br como características, observamos ganhos adicionais em ambos os conjuntos de dados. No PrejudiceTelegram.Br, o melhor resultado foi um F1-score de 0,856, obtido com o classificador GB, empregando unigramas, bigramas e trigramas com o vetorizador BoW. Já no PrejudiceWhatsApp.Br, o melhor desempenho geral foi alcançado, com F1-score de 0,88, utilizando o modelo pré-treinado TupiBERTBase, evidenciando o potencial das representações contextualizadas quando combinadas com conhecimento lexical especializado.

Tabela 16 – Resultados da utilização das 9 categorias do dicionário PrejudicePT-br com BoW, TF-IDF e BERT

(a) PrejudicePT-br + BoW-1,2,3. Features: 153.813, Tempo: 1446.0s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.91	0.84±0.02	0.83±0.00	0.851±0.01
BNB	0.88	0.61±0.00	0.94±0.00	0.751±0.00
MNB	0.88	0.75±0.01	0.90±0.01	0.823±0.01
LSVM	0.92	0.86±0.02	0.83±0.00	0.860±0.01
KNN	0.64	0.84±0.15	0.30±0.34	0.372±0.30
SGD	0.91	0.84±0.02	0.84±0.01	0.842±0.01
RF	0.89	0.78±0.01	0.84±0.01	0.822±0.00
GB	0.94	0.94±0.01	0.78±0.02	0.858±0.01
MLP	0.90	0.83±0.01	0.84±0.01	0.837±0.00

(b) PrejudicePT-br + BoW-1,2,3. Features: 222.563, Tempo: 2134.6s - PrejudiceTelegram.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.89	0.80±0.02	0.81±0.02	0.809±0.02
BNB	0.83	0.56±0.00	0.98±0.00	0.715±0.00
MNB	0.83	0.68±0.01	0.93±0.01	0.794±0.00
LSVM	0.89	0.81±0.03	0.81±0.01	0.812±0.01
KNN	0.54	0.50±0.00	0.99±0.00	0.669±0.00
SGD	0.87	0.80±0.01	0.78±0.04	0.795±0.02
RF	0.85	0.74±0.03	0.81±0.02	0.780±0.03
GB	0.93	0.93±0.01	0.78±0.01	0.857±0.00
MLP	0.86	0.79±0.03	0.82±0.02	0.793±0.01

(c) PrejudicePT-br + TF-IDF-1,2,3. Features: 153.813, Tempo: 1603.3s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.87	0.77±0.02	0.85±0.01	0.761±0.02
BNB	0.88	0.61±0.00	0.94±0.00	0.751±0.00
MNB	0.86	0.80±0.02	0.83±0.01	0.780±0.01
LSVM	0.90	0.81±0.03	0.83±0.00	0.810±0.01
KNN	0.79	0.74±0.02	0.71±0.02	0.789±0.01
SGD	0.90	0.83±0.03	0.82±0.01	0.819±0.01
RF	0.88	0.77±0.03	0.83±0.01	0.818±0.01
GB	0.94	0.94±0.01	0.79±0.02	0.866±0.00
MLP	0.87	0.78±0.03	0.82±0.01	0.806±0.02

(d) PrejudicePT-br + TF-IDF-1,2,3. Features: 222.563, Tempo: 2231.8s - PrejudiceTelegram.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.85	0.76±0.02	0.81±0.03	0.687±0.02
BNB	0.83	0.56±0.00	0.98±0.00	0.715±0.00
MNB	0.85	0.77±0.02	0.79±0.04	0.734±0.02
LSVM	0.87	0.78±0.02	0.81±0.02	0.755±0.01
KNN	0.72	0.70±0.02	0.54±0.05	0.703±0.01
SGD	0.88	0.79±0.02	0.80±0.03	0.761±0.02
RF	0.85	0.74±0.02	0.79±0.03	0.776±0.01
GB	0.93	0.92±0.01	0.79±0.02	0.851±0.00
MLP	0.84	0.76±0.03	0.76±0.08	0.745±0.02

(e) PrejudicePT-br + TupiBERTBase, Tempo: 2098,2s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.93	0.87±0.02	0.86±0.02	0.866±0.01
BNB	0.87	0.85±0.00	0.76±0.00	0.806±0.01
MNB	0.89	0.85±0.00	0.77±0.00	0.812±0.01
LSVM	0.91	0.85±0.01	0.84±0.01	0.846±0.01
KNN	0.91	0.86±0.01	0.85±0.01	0.856±0.01
SGD	0.92	0.86±0.05	0.81±0.05	0.835±0.01
RF	0.91	0.84±0.01	0.83±0.01	0.843±0.01
GB	0.92	0.87±0.01	0.84±0.01	0.860±0.01
MLP	0.92	0.86±0.02	0.85±0.02	0.860±0.01

(f) PrejudicePT-br + HateBR Tempo: 777s - PrejudiceTelegram.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.88	0.79±0.02	0.83±0.01	0.810±0.01
BNB	0.77	0.72±0.01	0.81±0.02	0.764±0.00
MNB	0.78	0.72±0.01	0.81±0.02	0.764±0.00
LSVM	0.87	0.79±0.02	0.82±0.01	0.805±0.01
KNN	0.82	0.74±0.02	0.82±0.02	0.779±0.01
SGD	0.87	0.74±0.13	0.77±0.22	0.716±0.07
RF	0.85	0.78±0.02	0.78±0.02	0.782±0.00
GB	0.86	0.79±0.04	0.79±0.01	0.790±0.02
MLP	0.87	0.79±0.05	0.79±0.03	0.792±0.02

Tabela 17 – Resultados da utilização das 842 palavras do dicionário PrejudicePT-br com BoW, TF-IDF e BERT

(a) PrejudicePT-br + BoW-1,2. Features: 73.402, Tempo: 849.4s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.93	0.88±0.02	0.84±0.01	0.863±0.01
BNB	0.90	0.68±0.02	0.94±0.01	0.790±0.01
MNB	0.91	0.79±0.02	0.88±0.01	0.839±0.01
LSVM	0.93	0.88±0.02	0.84±0.01	0.865±0.02
KNN	0.76	0.85±0.08	0.41±0.08	0.546±0.06
SGD	0.92	0.86±0.02	0.84±0.01	0.854±0.01
RF	0.92	0.85±0.02	0.81±0.02	0.836±0.01
GB	0.93	0.94±0.01	0.78±0.02	0.858±0.01
MLP	0.92	0.86±0.03	0.84±0.01	0.853±0.01

(b) PrejudicePT-br + BoW-1,2,3. Features: 17.204, Tempo: 247.9s - PrejudiceTelegram.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.91	0.84±0.02	0.81±0.02	0.829±0.01
BNB	0.86	0.65±0.00	0.91±0.02	0.763±0.01
MNB	0.89	0.75±0.01	0.89±0.03	0.815±0.01
LSVM	0.89	0.83±0.03	0.80±0.01	0.819±0.01
KNN	0.72	0.64±0.00	0.77±0.03	0.703±0.03
SGD	0.89	0.81±0.01	0.79±0.01	0.803±0.01
RF	0.90	0.84±0.03	0.77±0.01	0.807±0.01
GB	0.93	0.93±0.01	0.79±0.01	0.856±0.00
MLP	0.88	0.81±0.03	0.80±0.02	0.809±0.02

(c) PrejudicePT-br + TF-IDF-1. Features: 13.381, Tempo: 312.8s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.93	0.93±0.01	0.78±0.02	0.853±0.01
BNB	0.92	0.74±0.01	0.91±0.01	0.819±0.01
MNB	0.92	0.83±0.02	0.87±0.02	0.850±0.00
LSVM	0.94	0.92±0.01	0.82±0.01	0.875±0.01
KNN	0.88	0.86±0.00	0.76±0.03	0.815±0.01
SGD	0.94	0.91±0.01	0.84±0.01	0.876±0.01
RF	0.93	0.89±0.02	0.79±0.00	0.841±0.01
GB	0.94	0.94±0.01	0.79±0.02	0.862±0.01
MLP	0.93	0.88±0.02	0.82±0.02	0.854±0.01

(d) PrejudicePT-br + TF-IDF-1,2,3. Features: 223.396, Tempo: 3458.6s - PrejudiceTelegram.Br

Method	Auc	Precisão	Revocação	F1-score
LR	0.85	0.85±0.02	0.63±0.01	0.724±0.00
BNB	0.85	0.56±0.00	0.98±0.00	0.718±0.00
MNB	0.84	0.77±0.02	0.78±0.03	0.783±0.02
LSVM	0.88	0.84±0.02	0.68±0.01	0.753±0.01
KNN	0.82	0.81±0.02	0.65±0.02	0.723±0.01
SGD	0.87	0.83±0.03	0.70±0.01	0.767±0.01
RF	0.86	0.77±0.02	0.79±0.03	0.786±0.03
GB	0.93	0.92±0.01	0.79±0.02	0.851±0.01
MLP	0.87	0.80±0.02	0.76±0.04	0.780±0.02

(e) PrejudicePT-br + TupiBERTBase, Tempo: 971s - PrejudiceWhatsApp.Br

Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.94	0.89±0.01	0.86±0.02	0.880±0.01
BNB	0.87	0.85±0.00	0.76±0.01	0.807±0.01
MNB	0.89	0.85±0.00	0.77±0.01	0.812±0.01
LSVM	0.93	0.86±0.01	0.85±0.01	0.862±0.01
KNN	0.91	0.86±0.01	0.80±0.02	0.831±0.01
SGD	0.91	0.88±0.01	0.84±0.03	0.863±0.01
RF	0.91	0.84±0.01	0.83±0.01	0.840±0.00
GB	0.93	0.87±0.01	0.85±0.01	0.866±0.00
MLP	0.93	0.87±0.01	0.86±0.01	0.872±0.01

(f) PrejudicePT-br + HateBR, Tempo: 1114,6s - PrejudiceTelegram.Br

Method	Auc	Precisão	Revocação	F1-score
LR	0.87	0.80±0.01	0.80±0.01	0.807±0.01
BNB	0.77	0.72±0.02	0.81±0.02	0.764±0.00
MNB	0.78	0.72±0.02	0.81±0.02	0.765±0.00
LSVM	0.87	0.80±0.01	0.79±0.01	0.800±0.01
KNN	0.82	0.75±0.02	0.77±0.02	0.764±0.02
SGD	0.83	0.79±0.03	0.72±0.08	0.749±0.03
RF	0.86	0.78±0.02	0.78±0.02	0.785±0.01
GB	0.89	0.81±0.03	0.81±0.02	0.812±0.01
MLP	0.85	0.77±0.02	0.80±0.02	0.786±0.01

6.4.2 Resultados Obtidos Usando Somente as Categorias do Dicionário

Em seguida, realizamos experimentos para avaliar o uso das nove categorias do dicionário PrejudicePT-br como características isoladas, sem combiná-las com os métodos de

extração de características BoW ou TF-IDF. Os resultados desses experimentos são apresentados na Tabela 18.

Para o conjunto de dados PrejudiceTelegram.Br, o melhor resultado, utilizando apenas as nove categorias do dicionário PrejudicePT-br como características, alcançou um F1-score de 0,640, com um tempo de treinamento de apenas 5,8 segundos. Esse desempenho foi significativamente inferior ao obtido pela abordagem combinada, que integrou o dicionário ao método BoW, com F1-score de 0,857. Entretanto, essa melhoria ocorreu ao custo de um aumento substancial na complexidade do modelo, que passou a utilizar 222.563 características e a demandar 2.134,6 segundos de treinamento.

De forma semelhante, no conjunto PrejudiceWhatsApp.Br, a utilização exclusiva das categorias do dicionário resultou em um F1-score de 0,733, com apenas 9 características e um tempo de treinamento reduzido (5,7 segundos). Embora esse resultado seja inferior ao obtido pela abordagem mais sofisticada, que combinou o dicionário com o modelo TupiBERTBase e alcançou um F1-score de 0,88, esta última exigiu um tempo de processamento consideravelmente maior (971 segundos).

Esses resultados evidenciam um trade-off claro entre desempenho e eficiência computacional. Enquanto abordagens baseadas exclusivamente nas categorias do dicionário apresentam menor capacidade discriminativa, destacam-se pela simplicidade, rapidez e baixo custo computacional, tornando-se atrativas em cenários com restrições de recursos ou que demandam respostas em tempo quase real. Por outro lado, abordagens combinadas com métodos de vetorização tradicionais ou com modelos pré-treinados oferecem ganhos expressivos no desempenho, especialmente em termos de F1-score, mas à custa de maior complexidade e tempo de processamento.

Tabela 18 – Resultados da utilização das 9 categorias do dicionário PrejudicePT-br

(a) PrejudicePT-br. Features: 9, Tempo: 5.7s - Pre-judiceWhatsApp.Br (b) PrejudicePT-br. Features: 9, Tempo: 5.8s - PrejudiceTelegram.br

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.77	0.79±0.03	0.67±0.03	0.730±0.03	LR	0.67	0.72±0.03	0.53±0.04	0.615±0.03
BNB	0.73	0.63±0.01	0.82±0.01	0.719±0.00	BNB	0.66	0.73±0.04	0.52±0.03	0.612±0.03
MNB	0.72	0.75±0.03	0.49±0.01	0.594±0.07	MNB	0.65	0.71±0.04	0.52±0.03	0.607±0.03
LSVM	0.77	0.79±0.03	0.66±0.03	0.726±0.03	LSVM	0.67	0.72±0.03	0.53±0.04	0.614±0.03
KNN	0.74	0.72±0.01	0.65±0.15	0.664±0.08	KNN	0.65	0.65±0.05	0.61±0.08	0.627±0.02
SGD	0.75	0.78±0.03	0.65±0.04	0.714±0.03	SGD	0.66	0.69±0.06	0.54±0.09	0.598±0.02
RF	0.79	0.80±0.04	0.67±0.03	0.732±0.03	RF	0.70	0.71±0.04	0.58±0.02	0.640±0.02
GB	0.79	0.80±0.05	0.67±0.03	0.733±0.04	GB	0.70	0.71±0.04	0.56±0.04	0.630±0.03
MLP	0.78	0.79±0.03	0.67±0.03	0.729±0.03	MLP	0.67	0.68±0.04	0.53±0.05	0.597±0.02

6.4.3 Resultados Obtidos Usando Somente as Palavras do Dicionário

Por fim, realizamos experimentos para avaliar o uso das 842 palavras do dicionário PrejudicePT-br como características isoladas, sem combiná-las com os métodos de extração de características BoW ou TF-IDF. Os resultados desses experimentos são apresentados na Tabela 19.

Nesse experimento final, o melhor resultado para PrejudiceTelegram.Br alcançou um F1-score de 0.713, utilizando apenas 842 características e um tempo de treinamento de 1,49 segundos. Esse desempenho foi inferior ao obtido com a abordagem combinada (PrejudicePT-br + BoW), que atingiu um F1-score de 0.857. No entanto, a abordagem combinada utilizou 222.563 características e exigiu 2.134,6 segundos de tempo de treinamento. Para o conjunto de dados PrejudiceWhatsApp.Br, o uso apenas das palavras do dicionário PrejudicePT-br como características resultou em um F1-score de 0.812, com apenas 842 características e um tempo de treinamento de 1,65 segundos. Esse desempenho também foi inferior ao da abordagem combinada (PrejudicePT-br + TupiBERTBase), que obteve um F1-score de 0.88. No entanto, a abordagem combinada exigiu 971 segundos de processamento.

Esses resultados evidenciam um trade-off claro entre desempenho e eficiência computacional. Enquanto abordagens baseadas exclusivamente nas palavras do dicionário apresentam menor capacidade discriminativa, destacam-se pela simplicidade, rapidez e baixo custo computacional, tornando-se atrativas em cenários com restrições de recursos ou que demandam respostas em tempo quase real. Por outro lado, abordagens combinadas com métodos de vetorização tradicionais ou com modelos pré-treinados oferecem ganhos expressivos no desempenho, especialmente em termos de F1-score, mas à custa de maior complexidade e tempo de processamento.

Tabela 19 – Resultados da utilização das 842 palavras do dicionário PrejudicePT-br

(a) PrejudicePT-br. Features: 842, Tempo: 34.71s - (b) PrejudicePT-br. Features: 842, Tempo: 24.8s - PrejudiceWhatsApp.Br PrejudiceTelegram.br

Abordagem	Auc	Precisão	Revocação	F1-score	Abordagem	Auc	Precisão	Revocação	F1-score
LR	0.90	0.92±0.00	0.71±0.04	0.804±0.02	LR	0.80	0.83±0.03	0.60±0.02	0.701±0.02
BNB	0.90	0.89±0.00	0.74±0.03	0.809±0.02	BNB	0.79	0.80±0.03	0.63±0.02	0.709±0.02
MNB	0.89	0.88±0.00	0.75±0.04	0.812±0.02	MNB	0.80	0.80±0.03	0.64±0.02	0.713±0.02
LSVM	0.89	0.91±0.02	0.72±0.04	0.812±0.03	LSVM	0.80	0.82±0.02	0.61±0.02	0.703±0.02
KNN	0.83	0.84±0.10	0.70±0.09	0.753±0.01	KNN	0.74	0.74±0.09	0.64±0.07	0.680±0.01
RF	0.89	0.90±0.01	0.72±0.04	0.802±0.03	RF	0.78	0.80±0.02	0.61±0.02	0.695±0.01
SGD	0.89	0.94±0.01	0.69±0.05	0.797±0.03	SGD	0.79	0.86±0.03	0.56±0.01	0.682±0.01
MLP	0.89	0.91±0.00	0.72±0.04	0.809±0.02	MLP	0.79	0.81±0.01	0.63±0.01	0.713±0.01

6.5 Resultados Obtidos Usando o LIWC

As Tabelas 20 e 21 apresentam as diferenças nas categorias do LIWC entre mensagens preconceituosas e não preconceituosas nos corpora PrejudiceWhatsApp.Br e PrejudiceTelegram.Br. Em ambas as plataformas, o discurso preconceituoso apresentou maior carga emocional negativa, especialmente relacionada à raiva e à tristeza, e menor uso de emoções positivas, o que revela um padrão linguístico de hostilidade.

A categoria *relig* foi mais frequente em mensagens não preconceituosas, enquanto os processos cognitivos (*cogmech*) apresentaram diferença significativa apenas no Telegram, sugerindo maior elaboração argumentativa nesse contexto. No WhatsApp, diferenças nas conjunções e preposições indicam maior complexidade sintática em mensagens neutras. Outras categorias, como *work*, *leisure* e *death*, também variaram entre os grupos, sobretudo no Telegram.

De modo geral, o WhatsApp apresentou mais categorias com diferenças significativas, indicando maior polarização lexical, enquanto o Telegram apresentou um discurso mais homogêneo. Assim, o conteúdo preconceituoso em ambas as plataformas caracteriza-se por maior negatividade emocional e menor diversidade lexical.

Tabela 20 – Diferenças nas categorias LIWC entre mensagens com e sem preconceito (PrejudiceWhatsApp.Br)

Categoria	Preconceito	Não Preconceito	Dif.	Prec.(%)	Não Prec.(%)	Dif.(%)	Sig. Dif.(%)
we	0.003	0.007	0.004	0.308	0.749	0.441	Yes
assent	0.004	0.003	0.000	0.438	0.347	0.090	No
work	0.022	0.029	0.006	2.234	2.923	0.689	Yes
money	0.018	0.019	0.000	1.894	1.940	0.046	No
leisure	0.010	0.010	0.000	1.087	1.009	0.077	No
home	0.002	0.003	0.000	0.285	0.346	0.061	No
health	0.006	0.006	8.516	0.652	0.643	0.008	No
death	0.003	0.003	0.000	0.382	0.317	0.064	No
relig	0.014	0.044	0.030	1.434	4.476	3.041	Yes
anger	0.031	0.015	0.015	3.158	1.568	1.589	Yes
sad	0.014	0.012	0.002	1.414	1.203	0.211	Yes
anx	0.006	0.008	0.002	0.628	0.884	0.256	Yes
negemo	0.059	0.039	0.020	5.998	3.903	2.094	Yes
posemo	0.045	0.067	0.021	4.549	6.708	2.159	Yes
excl	0.068	0.058	0.010	6.874	5.873	1.001	Yes
conj	0.086	0.076	0.009	8.640	7.692	0.948	Yes
preps	0.119	0.125	0.005	11.991	12.588	0.597	Yes
cogmech	0.304	0.309	0.005	30.400	30.990	0.589	No

Tabela 21 – Diferenças nas categorias LIWC entre mensagens com e sem preconceito (PrejudiceTelegram.Br)

Categoria	Preconceito	Não Preconceito	Dif.	Prec.(%)	Não Prec.(%)	Dif.(%)	Sig. Dif.
we	0.003	0.004	0.000	0.346	0.407	0.061	No
assent	0.003	0.003	4.998	0.382	0.382	0.000	No
work	0.025	0.029	0.004	2.512	2.998	0.486	Yes
money	0.017	0.018	0.000	1.770	1.830	0.059	No
leisure	0.012	0.010	0.002	1.234	1.032	0.202	Yes
home	0.002	0.002	0.000	0.262	0.273	0.010	No
health	0.006	0.005	0.000	0.642	0.575	0.066	No
death	0.003	0.002	0.000	0.359	0.266	0.093	Yes
relig	0.018	0.036	0.018	1.875	3.684	1.808	Yes
anger	0.024	0.018	0.006	2.473	1.821	0.652	Yes
sad	0.015	0.013	0.002	1.584	1.332	0.252	Yes
anx	0.007	0.007	0.000	0.701	0.784	0.083	No
negemo	0.058	0.043	0.015	5.854	4.329	1.525	Yes
posemo	0.048	0.057	0.009	4.834	5.769	0.934	Yes
excl	0.069	0.068	0.001	6.961	6.836	0.124	No
conj	0.084	0.087	0.002	8.432	8.708	0.275	No
preps	0.125	0.131	0.006	12.533	13.166	0.633	Yes
cogmech	0.314	0.331	0.016	31.484	33.175	1.691	Yes

6.6 Resultados Obtidos Usando SHAP e LIME

As Tabelas 22 e 23 indicam que tanto o LIME quanto o SHAP identificaram termos politicamente polarizados como os principais indicadores de mensagens preconceituosas no corpus *PrejudiceWhatsApp.Br*. O LIME destacou o termo *luladrão* como o mais influente para a classe *prejudice*, refletindo seu forte caráter ofensivo e ideologicamente carregado, enquanto palavras semanticamente neutras, como *claro* e *bem*, foram associadas à classe *non-prejudice*. Por sua vez, o SHAP atribuiu maior relevância a termos como *contra* e *cara*, frequentemente presentes em discursos de oposição e de confrontação política. De modo geral, observou-se que o LIME produziu explicações mais estáveis e semanticamente coerentes, ao passo que o SHAP apresentou maior variação nos pesos atribuídos, demonstrando maior sensibilidade a nuances contextuais mais sutis.

A Tabela 24 apresenta os resultados das métricas de fidelidade para o conjunto *PrejudiceWhatsApp.Br*. Novamente, o LIME apresentou desempenho superior em termos de consistência e clareza interpretativa. Os maiores valores de (Comprehensiveness) foram obtidos pelos modelos BoW Bigram + PrejudicePT-br [Palavras] (LR) (0.705) e BoW Unigram (LR) (0.681), seguidos por TF-IDF Unigram + PrejudicePT-br [Palavras] (SGD) (0.629). Esses resultados sugerem que o LIME foi capaz de identificar, de forma eficaz, os termos mais decisivos para a predição dos modelos. Representações lexicais mais simples, como unigramas e bigra-

mas, mostraram-se mais interpretáveis, enquanto modelos baseados em trigramas associados às categorias do dicionário apresentaram menor fidelidade e explicações menos transparentes. Em contraste, o SHAP exibiu desempenho mais instável: embora alguns modelos, como BoW Unigram (LR) e TF-IDF Bigram (GB), tenham alcançado níveis razoáveis de fidelidade, outros, especialmente aqueles que incorporaram n-gramas mais longos e variáveis categóricas, apresentaram valores negativos de *Comprehensiveness* e *Sufficiency*, evidenciando menor confiabilidade nas explicações geradas.

Entre os termos mais frequentemente destacados como variáveis explicativas no WhatsApp, predominam termos com forte conotação ofensiva e política, como *idiota*, *bandido*, *imbecil*, *burro*, *luladrão* e *esquerdopata*. As categorias de preconceito mais recorrentes foram Preconceito Político e Intolerância Religiosa, o que reflete o foco temático predominante do corpus. Em síntese, o LIME demonstrou maior estabilidade e coerência interpretativa, especialmente em modelos lineares e com representações lexicais simples, enquanto o SHAP mostrou-se mais sensível à complexidade dos modelos e das representações, resultando em maior variabilidade explicativa.

De forma análoga, as Tabelas 25 e 26 mostram que, no corpus *PrejudiceTelegram.Br*, tanto o LIME quanto o SHAP enfatizaram termos politicamente orientados como principais indicadores de mensagens preconceituosas. O LIME identificou *ladrão* como o termo mais influente para a classe *prejudice*, evidenciando seu caráter ofensivo e polarizador, enquanto palavras mais neutras, como *dia* e *sou*, caracterizaram a classe *non-prejudice*. O SHAP, por sua vez, atribuiu maior relevância a termos como *comunistas*, *brasil* e *bolsonaro*, reforçando a dimensão ideológica do discurso analisado. De maneira geral, o LIME produziu explicações mais consistentes e interpretáveis, enquanto o SHAP apresentou maior dispersão nos pesos atribuídos e maior dependência do contexto lexical.

A Tabela 27 apresenta as métricas de fidelidade para o conjunto *PrejudiceTelegram.Br*. Em consonância com os resultados observados no WhatsApp, o LIME apresentou desempenho superior quanto à estabilidade e à coerência semântica. Os maiores valores de *Comprehensiveness* foram obtidos pelos modelos TF-IDF Trigram + PrejudicePT-br [Palavras] (GB) (0.579) e BoW Unigram + PrejudicePT-br [Palavras] (GB) (0.564), indicando que o método conseguiu capturar, de forma confiável, os *tokens* mais relevantes para a identificação de conteúdo preconceituoso. Assim como observado anteriormente, representações lexicais mais simples favoreceram explicações mais fiéis, enquanto modelos baseados em trigramas associados a

categorias do dicionário apresentaram menor interpretabilidade e valores ligeiramente negativos de *Sufficiency*, sugerindo perda de clareza explicativa com o aumento da complexidade das representações.

Em contraste, o SHAP apresentou resultados mais heterogêneos. Embora alguns modelos, como TF-IDF Bigram (GB) (0.575) e PrejudicePT-br [Categoria] (RF) (0.489), tenham alcançado níveis razoáveis de fidelidade, outros apresentaram valores baixos ou negativos de *Comprehensiveness*, o que reflete instabilidade nas explicações. Destaca-se novamente o comportamento extremo do modelo PrejudicePT-br [Palavras] (MNB), que apresentou *Comprehensiveness* igual a 0.000 e *Sufficiency* igual a 1.000, indicando forte dependência de tokens altamente discriminativos, como *judeus* e *judeu*, sem considerar adequadamente o contexto discursivo mais amplo.

Entre as variáveis explicativas mais relevantes no Telegram, sobressaem termos ofensivos e politicamente carregados, como *ladrão*, *comunista*, *esquerdalha*, *esquerdopata* e *bolsonaro*, o que evidencia a natureza polarizada e ideologicamente orientada do discurso preconceituoso nessa plataforma. As categorias de Preconceito Político e Intolerância Religiosa voltam a se destacar como predominantes. De forma geral, o LIME apresentou explicações mais fiéis, estáveis e semanticamente coerentes, especialmente em modelos lineares e com representações lexicais simples, enquanto o SHAP demonstrou maior sensibilidade à complexidade dos modelos e das representações, resultando em maior variabilidade e menor estabilidade interpretativa.

Tabela 22 – As 5 palavras mais influentes identificadas pelo LIME para as classes *preconceito* e *não preconceito* (BoW Bigram + Palavras [LR]) para o *PrejudiceWhatsApp.Br*.

Preconceito						Não Preconceito				
Palavra	luladrão	esses	da	nunca	tudo	claro	bem	presidente	maior	eleições
Peso	+0.639	+0.050	+0.042	+0.027	+0.027	-0.117	-0.031	-0.030	-0.028	-0.024

Tabela 23 – As 5 palavras mais influentes identificadas pelo SHAP para as classes *preconceito* e *não preconceito* (BoW Unigram [LR]) para o *PrejudiceWhatsApp.Br*.

Preconceito						Não Preconceito				
Palavra	contra	cara	isto	os	mesmo	pesquisas	mito	acontecer	stf	esquerda
Peso	+1.171	+0.789	+0.375	+0.350	+0.312	-0.510	-0.308	-0.260	-0.225	-0.218

Tabela 24 – Resultados das métricas de fidelidade para o PrejudiceWhatsApp.Br

Embedding	Compreh.	Suff.	Probabilidade sem variáveis	Probabilidade com as variáveis	Variáveis explicativas
LIME					
BoW Unigram (LR)	0.681	-0.001	0.314	0.996	idiota, bandido, bando, desse, as
TF-IDF Bigram (GB)	0.487	0.010	0.330	0.807	esquerdopata, normal, você, esse, que
BoW Trigram + Categorias (LSVM)	0.446	0.017	0.535	0.949	ladrão, satanás, do, lula, bando, não, os, povo, contra, vagabundos
TF-IDF Trigram + Categorias (LSVM)	0.157	-0.055	0.594	0.743	ladrão, satanás, bando, lula, do, trilogia, povo, vagabundos, contra, fatos
BoW Bigram + Palavras (LR)	0.705	0.000	0.295	1.000	luladrão, claro, esses, da, bem, presidente, maior, nunca, tudo, isso
TF-IDF Unigram + Palavras (SGD)	0.629	-0.000	0.371	1.000	burro, bolsominion, vc, tão, mais, que, tenta, na, tem, só
Categorias do PrejudicePt-br	0.506	0.000	0.369	0.748	Prec.Politico
Palavras do PrejudicePt-br	0.662	0.000	0.312	0.924	imbecil
SHAP					
BoW Unigram (LR)	0.699	-0.031	0.272	0.930	contra, cara, pesquisas, isto, os, mesmo, mito, fico, todas, dos
TF-IDF Bigram (GB)	0.670	-0.000	0.330	0.999	lulaladrão, imbecil, idiota, brasil, os, do, brasil, por, asseclas, raised eyebrow
BoW Trigram + Categorias (LSVM)	-0.099	-0.811	0.338	0.557	esquerda, não, golpe, dos, pelo, lula, lula não, xandão, para, dia
TF-IDF Trigram + Categorias (LSVM)	0.414	-0.576	0.345	0.928	esquerdopata, ódio, merda, você, opiniões, não, eu sou, of joy face, joy face with, que mesmo
BoW Bigram + Palavras (LR)	0.650	-0.001	0.346	0.991	luladrão, luladrão, do luladrão, foi, do, isso, do governo, ministro, governo do, quem
TF-IDF Unigram + Palavras (SGD)	0.694	0.004	0.285	0.928	retardado, igual, retardado, eu, meu, amigo, você, isso, de, coisa
Categorias do PrejudicePt-br (GB)	0.354	0.000	0.369	0.571	Int.Religiosa, Racismo
Palavras do PrejudicePt-br (LSVM)	0.000	1.000	0.312	0.000	gay, deus, aberrações, cheio, aberração, rachada, provocante, puara, put, puta

6.7 Análise de Erros do Melhor Resultado

O melhor desempenho foi alcançado pela combinação do modelo pré-treinado TupiBERTBase com as 842 palavras do dicionário PrejudicePT-br, evidenciando a capacidade dessa abordagem híbrida de capturar tanto padrões semânticos contextuais quanto sinais léxicos

Tabela 25 – As 5 palavras mais influentes identificadas pelo LIME para as classes *preconceito* e *não preconceito* (TF-IDF Trigram + Palavras[GB]) para o *PrejudiceTelegram.Br*.

	Preconceito					Não Preconceito				
Palavra	ladrão	do	vocês	igreja		em	dia	22	sou	heart
Peso	+0.542	+0.016	+0.003	+0.000		-0.023	-0.019	-0.012	-0.010	-0.009

Tabela 26 – As 5 palavras mais influentes identificadas pelo SHAP para as classes *preconceito* e *não preconceito* (bigrama TF-IDF [GB]) para o *PrejudiceTelegram.Br*.

	Preconceito						Não Preconceito		
Palavra	comunistas	sem	os brasileiros	brasil	bolsonaro		os	esquerda	da
Peso	+2.043	+0.448	+0.002	+0.001	+0.000		-0.116	-0.090	-0.003

explícitos de preconceito. No entanto, a análise detalhada dos erros revela assimetrias importantes no comportamento do modelo. A análise quantitativa dos erros, acumulados ao longo de todos os folds da validação cruzada, indica predominância de Falsos Negativos (FN) em relação a Falsos Positivos (FP), sugerindo que o modelo tende a ser mais conservador ao atribuir o rótulo de preconceito. Esse comportamento indica que, embora o modelo apresente bom desempenho global, ele ainda enfrenta dificuldades para reconhecer manifestações de preconceito mais sutis, implícitas ou dependentes de conhecimento sociocultural.

A análise qualitativa, exemplificada na Tabela 28, reforça essa interpretação. Os casos de Falsos Negativos frequentemente envolvem mensagens com linguagem coloquial, ironia, generalizações regionais ou termos potencialmente ofensivos utilizados de forma implícita, como nos exemplos associados a preconceitos regionais ou políticos. Nessas situações, o preconceito não se manifesta exclusivamente por meio de palavras do léxico, mas também emerge do contexto discursivo, o que dificulta sua detecção automática, mesmo com o uso de *embeddings* contextualizados. Por outro lado, os Falsos Positivos observados tendem a ocorrer em mensagens que contêm termos associados a discursos políticos, religiosos ou patrióticos, mas que não apresentam, de fato, conteúdo preconceituoso. Esses erros sugerem que o modelo pode superestimar a presença de preconceito quando certos padrões lexicais ou semânticos ocorrem fora de um contexto discriminatório, refletindo uma sensibilidade excessiva a palavras ou construções frequentemente associadas à classe positiva durante o treinamento.

Tabela 27 – Resultados das métricas de Fidelidade para o PrejudiceTelegram.Br

Embedding	Compreh.	Suff.	Probabilidade sem variáveis	Probabilidade com as variáveis	Variáveis explicativas
LIME					
BoW Unigram (GB)	0.518	0.000	0.388	0.906	esquerdalha, vai, de, para, desconsiderar
TF-IDF Bigram (GB)	0.534	0.000	0.393	0.927	ladrão, vai, em, esse, comunismo
BoW Trigram + Categorias (LSVM)	0.173	0.044	0.646	0.746	ladrão, em, presidente, do, tá, sabem, eleger, oração, cair, tem
TF-IDF Trigram + Categorias (LSVM)	0.035	-0.063	0.489	0.539	traidor, cristão, dia, maçom, loja, suas, esquerda, deve, brasil, se
BoW Unigram + Palavras (GB)	0.564	0.000	0.394	0.902	ladrão, de, satanás, para, analfabeto, caráter, anos, obra, gente, fosse
TF-IDF Trigram + Palavras (GB)	0.579	0.007	0.349	0.822	ladrão, em, dia, do, 22, sou, heart, para, yellow, vocês
Categorias do PrejudicePT-br (RF)	0.531	0.000	0.392	0.836	Prec.Politico, Capacitismo
Palavras do PrejudicePT-br (MNB)	0.308	0.000	0.500	0.722	traidor
SHAP					
BoW Unigram (GB)	0.240	0.000	0.391	0.514	ladrão, daniel, pt, em, de, não, lula, para, quer, tá
TF-IDF Bigram (GB)	0.575	0.000	0.369	0.868	comunistas, sem, os, esquerda, da, os brasileiros, que, brasil, bolsonaro, cai
BoW Trigram + Categorias (LSVM)	0.300	-0.063	0.549	0.834	comunista, direita, lula, como, de direita, todo, assim, não, assim como, lula não
TF-IDF Trigram + Categorias (LSVM)	0.122	-0.027	0.784	0.918	esquerdalha, lugar de, do, mensagem, postagem, onde tem, primeira, que fazer, na, uma
BoW Bigram + Palavras (LR)	0.260	0.006	0.739	0.993	luladrão, luladrão, comunistas, brasil, collision, hands clapping, clapping, clapping hands, fora, do luladrão
TF-IDF Bigram + Palavras (LR)	0.452	0.021	0.392	0.701	esquerdopata, deus, light police, police car, car, car light, police, light, de, esquerdopata
Categorias do PrejudicePT-br (RF)	0.489	0.000	0.392	0.768	Prec.Politico
Palavras do PrejudicePT-br (MNB)	0.000	1.000	0.500	0.000	judeus, judeu

6.8 Conclusão

Neste capítulo, apresentamos e analisamos os resultados obtidos com três abordagens para a detecção de linguagem preconceituosa: modelos clássicos de aprendizado de máquina,

Tabela 28 – Análise dos erros da melhor abordagem - PrejudicePT-br (palavras) + TupiBERT-Base

Modelo	Texto	y_true	y_pred	Tipo de Erro
LR	<i>A blogueira nem apagou a calúnia e olha só a virgem no puteiro</i>	1	0	FN
BNB	<i>Tão tudo caladinho os Bolsominion</i>	1	0	FN
KNN	<i>Eu sou Nordestina e moro na Bahia, mas a culpa é do Nordeste mesmo. Por isso que vive no atraso.</i>	1	0	FN
MLP	<i>O mais importante será nossa vitória meus irmão patriotas. Deus a frente sempre</i>	0	1	FP
RF	Jornalista toma uma invertida de uma senhora nordestina	0	1	FP
SGD	<i>Isso é no Espírito Santo a terceira ponte no 7 de setembro</i>	0	1	FP

modelos pré-treinados baseados em *embeddings* contextualizados e grandes modelos de linguagem (LLMs) aplicados por meio de diferentes estratégias de *prompting*. Foram discutidos os cenários experimentais, destacando as combinações que apresentaram os melhores e os piores desempenhos, tendo o F1-score como principal métrica de avaliação, o que evidencia a viabilidade e os trade-offs entre desempenho, custo computacional e complexidade das abordagens. Adicionalmente, analisamos as categorias do LIWC que apresentaram diferenças relevantes entre os conjuntos PrejudiceWhatsApp.Br e PrejudiceTelegram.Br, revelando padrões linguísticos específicos de cada plataforma. Por fim, empregamos métodos de explicabilidade, como LIME e SHAP, para interpretar as decisões dos modelos de melhor desempenho e compreender as características linguísticas mais influentes nas predições. No próximo capítulo, apresentam-se as conclusões desta dissertação, retomando os desafios iniciais, sintetizando as principais contribuições e apontando direções para trabalhos futuros.

7 CONCLUSÕES E TRABALHOS FUTUROS

Esta dissertação investigou o problema da detecção automática de linguagem preconceituosa em mensagens provenientes de aplicativos de comunicação instantânea, com foco nas plataformas WhatsApp e Telegram. Entre as principais contribuições, desenvolvemos o dicionário léxico PrejudicePT-br, composto por 842 palavras, organizadas em nove categorias de preconceito: Capacitismo, Gordofobia, Intolerância Religiosa, LGBTQIA+fobia, Misoginia, Xenofobia, Racismo, Etarismo e Preconceito Político. Além disso, construímos dois conjuntos de dados rotulados e publicamente disponíveis, PrejudiceWhatsApp.Br e PrejudiceTelegram.Br, extraídos de grupos públicos dessas plataformas. Esses conjuntos foram cuidadosamente explorados, balanceados e anotados, o que viabilizou a realização de uma série abrangente de experimentos de classificação de texto.

A partir desses recursos, conduzimos análises empíricas com diferentes abordagens de detecção, permitindo avaliar o comportamento de modelos clássicos de aprendizado de máquina, modelos pré-treinados baseados em *embeddings* contextualizados e grandes modelos de linguagem (LLMs) alcançando então um *F1-score* 0,88. Dessa forma, buscamos traçar diretrizes sobre o problema da detecção de linguagem preconceituosa em ambientes de comunicação informal, fornecendo novos conhecimentos e subsídios para responder às questões de pesquisa propostas.

Q1. Quão desafiadora é a detecção de linguagem preconceituosa no WhatsApp e no Telegram utilizando técnicas de NLP e métodos supervisionados e não supervisionados de aprendizado de máquina? Os resultados obtidos indicam que essa tarefa permanece altamente desafiadora. Foram realizados diversos experimentos de classificação com modelos clássicos, pré-treinados e LLMs, alcançando-se um F1-score máximo de 0,88. Embora esse valor represente um desempenho competitivo e possa servir como *baseline* para trabalhos futuros, ele evidencia que a detecção robusta de linguagem preconceituosa nessas plataformas ainda é um problema em aberto, especialmente devido à informalidade da linguagem, ao uso de ironia, sarcasmo e referências contextuais implícitas.

Q2. Quais combinações de pré-processamento, estratégias de extração de atributos e algoritmos de classificação apresentam melhor desempenho na detecção de mensagens preconceituosas nessas plataformas? Os experimentos demonstraram que a combinação de modelos pré-treinados com as palavras do dicionário PrejudicePT-br resulta em ganhos consistentes de desempenho. O melhor resultado foi obtido com o modelo TupiBERTBase, combinado

com 842 palavras do dicionário, alcançando um F1-score de 0,88. Por outro lado, a utilização exclusiva do dicionário também apresentou vantagens relevantes, como a redução significativa do número de características e do tempo de treinamento, resultando em resultados próximos, com F1-score em torno de 0,81. Esses achados indicam um *trade-off* claro entre desempenho máximo e eficiência computacional, o que pode orientar a escolha da abordagem conforme o contexto de aplicação.

Q3. Quais são as limitações das melhores abordagens identificadas e quais aspectos específicos das plataformas dificultam a detecção automática desse tipo de linguagem?

A análise dos erros revelou que a maior parte das falhas está concentrada em falsos negativos, ou seja, mensagens preconceituosas incorretamente classificadas como não preconceituosas. Uma análise qualitativa mais aprofundada mostrou que esses casos tendem a envolver preconceito implícito, construções discursivas sutis, uso de humor, ironia ou referências culturais e políticas específicas do contexto brasileiro. Já os falsos positivos, embora menos frequentes, geralmente estão associados a mensagens com vocabulário politicamente carregado ou a termos sensíveis utilizados em contextos neutros ou informativos. Esses resultados evidenciam limitações relacionadas à compreensão semântica profunda e ao contexto discursivo das mensagens, reforçando a necessidade de abordagens mais sensíveis ao contexto e, possivelmente, híbridas.

Além das questões de pesquisa investigadas, este trabalho apresenta contribuições e inovações relevantes para a área de Processamento de Linguagem Natural aplicado à detecção de discurso preconceituoso, das quais destacam-se:

- A criação do **dicionário léxico PrejudicePT-br**, composto por 842 palavras organizadas em nove categorias distintas de preconceito. Até onde sabemos, trata-se do primeiro dicionário léxico em Português brasileiro (PT-BR) que sistematiza, de forma explícita e estruturada, diferentes tipos de preconceito, constituindo um recurso inédito para pesquisas em linguística computacional e processamento de linguagem natural;
- A construção de dois conjuntos de dados rotulados, **PrejudiceWhatsApp.Br** e **PrejudiceTelegram.Br**, extraídos de grupos públicos dessas plataformas. Até onde temos conhecimento, estes são os primeiros datasets em Português brasileiro voltados especificamente à detecção de linguagem preconceituosa no WhatsApp e no Telegram, contribuindo para suprir uma lacuna relevante na literatura;
- A realização de uma **análise comparativa inédita** entre duas plataformas de comunicação instantânea amplamente utilizadas no Brasil, WhatsApp e Telegram;

- A avaliação sistemática de **três abordagens distintas** para a detecção de linguagem preconceituosa: (i) modelos clássicos de aprendizado de máquina, (ii) modelos pré-treinados baseados em *embeddings* contextualizados e (iii) grandes modelos de linguagem (LLMs), permitindo uma análise abrangente de desempenho, custo computacional e robustez;
- A proposta e validação empírica de uma **abordagem híbrida**, que combina *embeddings* contextualizados com características léxicas derivadas de um dicionário especializado, demonstrando ganhos consistentes tanto em desempenho quanto em interpretabilidade dos modelos;
- A incorporação de **métodos de explicabilidade** (LIME e SHAP) para analisar as decisões dos modelos, contribuindo para uma compreensão mais transparente dos fatores linguísticos que influenciam a detecção de linguagem preconceituosa;
- A disponibilização de recursos (dicionário, *datasets* e protocolos experimentais) que podem servir como **baseline e ponto de partida** para pesquisas futuras na área de detecção de discurso preconceituoso em língua portuguesa.

7.1 Trabalhos Futuros

Os resultados desta dissertação evidenciam diversas possibilidades de pesquisas futuras, tanto a partir dos conjuntos de dados aqui construídos quanto por meio da incorporação de novos dados provenientes do WhatsApp e do Telegram. Nesse sentido, destacam-se as seguintes direções promissoras de investigação:

- Ampliar a avaliação experimental por meio da inclusão de modelos contextuais pré-treinados amplamente adotados na literatura, como BERT, RoBERTa e DeBERTa, bem como de suas variantes compactas (por exemplo, DistilBERT e TinyBERT), aplicados via *fine-tuning* a tarefas de classificação de texto. Além do desempenho preditivo, pretende-se analisar aspectos relacionados ao custo computacional, como número de parâmetros, tempo de treinamento e tempo de inferência, permitindo uma comparação mais abrangente dos *trade-offs* entre acurácia, eficiência e interpretabilidade;
- Expandir a coleta de dados para incluir grupos do WhatsApp e do Telegram com diferentes temáticas centrais, como religião, esportes, saúde, economia e entretenimento, possibilitando a análise do comportamento da linguagem preconceituosa em distintos contextos discursivos;

- Investigar abordagens de classificação multirrótulo, permitindo identificar simultaneamente múltiplos tipos de preconceito em uma mesma mensagem (por exemplo, xenofobia e preconceito político);
- Investigar a capacidade de generalização dos modelos entre plataformas distintas, avaliando cenários de *cross-domain* e *cross-platform learning*.

REFERÊNCIAS

- ALLPORT, G. W.; CLARK, K.; PETTIGREW, T. F. **The nature of prejudice**. [S.l.]: Addison-wesley Reading, MA, 1954. v. 2.
- AMUNDSON, R.; TAIRA, G. Our lives and ideologies: The effect of life experience on the perceived morality of the policy of physician-assisted suicide. **Journal of Disability Policy Studies**, Sage Publications Sage CA: Los Angeles, CA, v. 16, n. 1, p. 53–57, 2005.
- ARONSON, E.; WILSON, T. D.; SOMMERS, S. R. **Social psychology**. [S.l.]: Pearson Education India, 2010.
- BAHGAT, M.; WILSON, S.; MAGDY, W. Liwc-ud: Classifying online slang terms into liwc categories. In: **Proceedings of the 14th ACM Web Science Conference 2022**. New York, NY, USA: Association for Computing Machinery, 2022. (WebSci '22), p. 422–432. ISBN 9781450391917. Disponível em: <<https://doi.org/10.1145/3501247.3531572>>.
- BARBOSA, J.; VIEIRA, J. P. A.; SANTOS, R.; JUNIOR, G. V. M.; MUNIZ, M. d. S.; MOURA, R. S. Introdução ao processamento de linguagem natural usando python. **III Escola Regional de Informatica do Piauí**, v. 1, p. 336–360, 2017.
- BIAU, G.; CADRE, B. Optimization by gradient boosting. In: **Advances in Contemporary Statistics and Econometrics: Festschrift in Honor of Christine Thomas-Agnan**. [S.l.]: Springer, 2021. p. 23–44.
- BISHOP, C. M.; NASRABADI, N. M. **Pattern recognition and machine learning**. [S.l.]: Springer, 2006. v. 4.
- BOLUKBASI, T.; CHANG, K.-W.; ZOU, J. Y.; SALIGRAMA, V.; KALAI, A. T. Man is to computer programmer as woman is to homemaker? debiasing word embeddings. **Advances in neural information processing systems**, v. 29, 2016.
- BORIOLA, M. A. H.; PAETZOLD, G. H. Detectando linguagem ofensiva em tweets utilizando modelos transformer. In: **XXVI Seminário de Iniciação Científica e Tecnológica da UTFPR**. [S.l.: s.n.], 2021.
- BOYKIS, V. What are embeddings. **10.5281/zenodo**, v. 8015029, 2023.
- BROWN, T.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J. D.; DHARIWAL, P.; NEELAKANTAN, A.; SHYAM, P.; SASTRY, G.; ASKELL, A. *et al.* Language models are few-shot learners. **Advances in neural information processing systems**, v. 33, p. 1877–1901, 2020.
- CAMPBELL, F. A. K. Exploring internalized ableism using critical race theory. **Disability & society**, Taylor & Francis, v. 23, n. 2, p. 151–162, 2008.
- CARDOSO, J. G.; ROCHA, R. A. d.; IWAYA, G. H.; JÚNIOR, J. H. d. S. Discriminação percebida e consequências emocionais da lgbtqi+ fobia no consumo no brasil. **Inovar**, Revista INNOVAR, Escuela de Administración de Empresas y Contaduría Pública ..., v. 32, n. 85, p. 33–47, 2022.
- CARNUT LEONARDO, C. Z.; AGRIPINO., N. A. Preconceito político como conteúdo na percepção de estudantes de uma graduação na área da saúde. **Revista Educación, Política y Sociedad** **10.1**, 2025.

CARVALHO, F.; JUNIOR, F. P.; OGASAWARA, E.; FERRARI, L.; GUEDES, G. Evaluation of the brazilian portuguese version of linguistic inquiry and word count 2015 (bp-liwc2015). **Lang. Resour. Eval.**, Springer-Verlag, Berlin, Heidelberg, v. 58, n. 1, p. 203–222, may 2023. ISSN 1574-020X. Disponível em: <<https://doi.org/10.1007/s10579-023-09647-2>>.

CARVALHO, F.; SANTOS, G.; GUEDES, G. P. Affectpt-br: an affective lexicon based on liwc 2015. In: **2018 37th International Conference of the Chilean Computer Science Society (SCCC)**. [S.l.: s.n.], 2018. p. 1–5.

CARVALHO, F.; SANTOS, G.; GUEDES, G. P. Affectpt-br: an affective lexicon based on liwc 2015. In: IEEE. **2018 37th International Conference of the Chilean Computer Science Society (SCCC)**. [S.l.], 2018. p. 1–5.

CARVALHO, F. M. D. de. **DESENVOLVIMENTO DO DICCIONÁRIO LIWC 2015 EM PORTUGUÊS DO BRASIL**. Tese (Doutorado) — Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, 2019.

CERQUEIRA, D. R. D. C.; MOURA, R. L. de. Vidas perdidas e racismo no brasil. **Publicatio UEPG: Ciências Sociais Aplicadas**, v. 22, n. 1, p. 73–90, 2014.

ÇÖLTEKIN, Ç. A corpus of turkish offensive language on social media. In: **Proceedings of the twelfth language resources and evaluation conference**. [S.l.: s.n.], 2020. p. 6174–6184.

CUNHA, L. C. C. d. Fakewhatsapp. br: detecção de desinformação e desinformadores em grupos públicos do whatsapp em pt-br. 2021.

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)**. [S.l.: s.n.], 2019. p. 4171–4186.

DINU, L. P.; IORDACHE, I.-B.; UBAN, A. S.; ZAMPIERI, M. A computational exploration of pejorative language in social media. In: MOENS, M.-F.; HUANG, X.; SPECIA, L.; YIH, S. W.-t. (Ed.). **Findings of the Association for Computational Linguistics: EMNLP 2021**. Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021. p. 3493–3498. Disponível em: <<https://aclanthology.org/2021.findings-emnlp.296>>.

ECONOMICS, L. S. of; SCIENCE, P. **Prejudice rather than digital illiteracy behind the spread of fake news on WhatsApp in India**. 2019. Accessed: 2025-02-08. Disponível em: <<https://www.lse.ac.uk/news/latest-news-from-lse/j-october-2019/prejudice-rather-than-digital-illiteracy-behind-the-spread-of-fake-news-on-whatsapp-in-india>>.

FGV, D. . Ódio contra mulheres reúne 220 mil no telegram e é ponte para grupos conspiracionistas e neonazistas. **Estadão Verifica**, 2025. Acessado em 26 nov. 2025. Disponível em: <https://www.estadao.com.br/estadao-verifica/odio-contra-mulheres-220-mil-telegram-ponte-grupos-conspiracionistas-neonazistas/?srsltid=AfmBOoo8YPZrt_DnVSNdDIIqTFjSPw7dq0OuB0MKf9eY8xLU643TcSiB>.

GARREAU, D.; LUXBURG, U. Explaining the explainer: A first theoretical analysis of lime. In: PMLR. **International conference on artificial intelligence and statistics**. [S.l.], 2020. p. 1287–1296.

GARZA, C. D. L. Xenofobia. **Laboreal**, Universidade do Porto, v. 7, n. N°2, 2011.

HOLTZMAN, A.; BUYS, J.; DU, L.; FORBES, M.; CHOI, Y. The curious case of neural text degeneration. **arXiv preprint arXiv:1904.09751**, 2019.

IBRAHIM, I. From ancient greco-roman culture the contemporary lgbtq community: The transfer of sex and power dynamics. **Denison Journal of Religion**, v. 15, n. 1, p. 4, 2016.

IVANOVICH, A. C. C. F.; MARIVETE, M. G. Discapacidad y capacitismo: corrección de los cuerpos y producción de sujetos (a) políticos. **Quaderns de psicologia. International journal of psychology**, v. 22, n. 3, p. e1618–e1618, 2020.

KONG, A.; ZHAO, S.; CHEN, H.; LI, Q.; QIN, Y.; SUN, R.; ZHOU, X.; WANG, E.; DONG, X. Better zero-shot reasoning with role-play prompting. In: **Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)**. [S.l.: s.n.], 2024. p. 4099–4113.

LEITE, J. A.; SILVA, D.; BONTCHEVA, K.; SCARTON, C. Toxic language detection in social media for Brazilian Portuguese: New dataset and multilingual analysis. In: WONG, K.-F.; KNIGHT, K.; WU, H. (Ed.). **Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing**. Suzhou, China: Association for Computational Linguistics, 2020. p. 914–924. Disponível em: <<https://aclanthology.org/2020.aacl-main.91>>.

LIU, Y.; RAHIMIAN, M. A.; GARIMELLA, K. Structural dynamics of harmful content dissemination on whatsapp. **arXiv preprint arXiv:2505.18099**, 2025.

LIYANAGE, U. P.; RANAWEERA, N. D. Ethical considerations and potential risks in the deployment of large language models in diverse societal contexts. **Journal of Computational Social Dynamics**, v. 8, n. 11, p. 15–25, 2023.

LOTH, G. B.; SILVEIRA, N. Etarismo nas organizações: um estudo dos estereótipos em trabalhadores envelhecidos. **Revista de Ciências da Administração**, Universidade Federal de Santa Catarina, v. 16, n. 39, p. 65–82, 2014.

MARTINS, A. D. F.; MONTEIRO, J. M.; MACHADO, J. C. Understanding misinformation about covid-19 in whatsapp messages. In: **Proceedings of the European Conference on Advances in Databases and Information Systems**. [S.l.: s.n.], 2022. p. 14–23.

MATHEW, B.; DUTT, R.; GOYAL, P.; MUKHERJEE, A. Spread of hate speech in online social media. In: **Proceedings of the 10th ACM conference on web science**. [S.l.: s.n.], 2019. p. 173–182.

MATOS, E.; TOMAZ, R.; MAIA, A.; SANCHES, D.; BENTES, A.; FOLETTTO, L.; SANTOS, L. Online hate speech and instant messaging apps: An emerging research agenda. **First Monday**, 2024.

MATSUBARA EDSON TAKASHI, C. A. M.; MONARD, M. C. Pretext: Uma ferramenta para pré-processamento de textos utilizando a abordagem bag-of-words. 2003.

MCARTHUR, T. B.; MCARTHUR, R. **Concise Oxford companion to the English language**. [S.l.]: Oxford University Press, USA, 2005.

MEZAN, R. **Tempo de muda: ensaios de psicanálise**. [S.l.]: Editora Blucher, 2021.

MOTERANI, G. M. B.; CARVALHO, F. M. d. Misoginia: a violência contra a mulher numa visão histórica e psicanalítica. **Aveso do avesso**, v. 14, n. 14, p. 167–178, 2016.

MUMINOVIC, A.; MUMINOVIC, A. K. Large language models for toxic language detection in low-resource balkan languages. **arXiv preprint arXiv:2506.09992**, 2025.

NEWTON, D.; YOUSEFIAN, F.; PASUPATHY, R. Stochastic gradient descent: Recent trends. **Recent advances in optimization and modeling of contemporary problems**, INFORMS, p. 193–220, 2018.

NOGUEIRA, S. **Intolerância Religiosa**. [S.l.]: Pòlen Livros, 2020.

NORDQUIST, R. **Pejorative Language**. 2019. Disponível em: <https://www-thoughtco-com.translate.google/pejorative-language-1691495?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc>. Acesso em: 11 Ago. 2025.

PALMORE, E. Ageism: Negative and positive. Springer Publishing Company, 1999.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COUNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, E. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PÉREZ, V. A. F.; FIOL, E. B. Violencia de género y misoginia: reflexiones psicosociales sobre un posible factor explicativo. **Papeles del psicólogo**, Consejo General de Colegios Oficiales de Psicólogos, n. 75, p. 13–19, 2000.

POMPEU, I. M. T. Classificação automática de marcas utilizando algoritmos de aprendizado de máquina. 2025.

POPESCU, M.-C.; BALAS, V. E.; PERESCU-POPESCU, L.; MASTORAKIS, N. Multilayer perceptron and neural networks. **WSEAS Transactions on Circuits and Systems**, v. 8, n. 7, p. 579–588, 2009.

QAISER, S.; ALI, R. Text mining: use of tf-idf to examine the relevance of words to documents. **International journal of computer applications**, v. 181, n. 1, p. 25–29, 2018.

QUIXADÁ, C. M. d. S. Classificação de texto: multinomial x bernoulli utilizando reviews de e-commerces. 2019.

RANGEL, N. F. de A. **O ativismo gordo em campo: política, identidade e construção de significados**. Tese (Doutorado) — Universidade Federal de Santa Catarina, 2018.

REGIÃO, T. R. do Trabalho da Racismo recreativo: Juíza mantém justa causa e usa protocolo do cnj para derrubar “piadas” de grupo do whatsapp. **Portal TRT-MG – Notícias Jurídicas**, 2025. Acessado em 26 nov. 2025. Disponível em: <<https://portal.trt3.jus.br/internet/conheca-o-trt/comunicacao/noticias-juridicas/racismo-recreativo-juiza-mantem-justa-causa-e-usa-protocolo-do-cnj-para-derrubar-201cpiadass201d-de-gru>>

ROBINSON, B. E.; BACON, L. C.; O'REILLY, J. Fat phobia: Measuring, understanding, and changing anti-fat attitudes. **International Journal of Eating Disorders**, Wiley Online Library, v. 14, n. 4, p. 467–480, 1993.

ROSENFELD, A.; SINA, S.; SARNE, D.; AVIDOV, O.; KRAUS, S. A study of whatsapp usage patterns and prediction models without message content. **arXiv preprint arXiv:1802.03393**, 2018.

ROY, S.; HARSHAVARDHAN, A.; MUKHERJEE, A.; SAHA, P. Probing llms for hate speech detection: strengths and vulnerabilities. **arXiv preprint arXiv:2310.12860**, 2023.

RUBIN, V. L.; CHEN, Y.; CONROY, N. K. Deception detection for news: three types of fakes. **Proceedings of the Association for Information Science and Technology**, Wiley Online Library, v. 52, n. 1, p. 1–4, 2015.

SÁ, I. C. de; GADELHA, T.; VINUTO, T.; SILVA, J. W. F. da; MONTEIRO, J. M.; MACHADO, J. C. A real-time platform to monitoring misinformation on telegram. In: FILIPE, J.; SMIALEK, M.; BRODSKY, A.; HAMMOUDI, S. (Ed.). **Proceedings of the 25th International Conference on Enterprise Information Systems, ICEIS 2023, Volume 1, Prague, Czech Republic, April 24-26, 2023**. SCITEPRESS, 2023. p. 271–278. Disponível em: <<https://doi.org/10.5220/0012039100003467>>.

SÁ, I. C. de; GALIC, L.; FRANCO, W.; GADELHA, T.; MONTEIRO, J. M.; MACHADO, J. C. BATMAN: A big data platform for misinformation monitoring. In: FILIPE, J.; SMIALEK, M.; BRODSKY, A.; HAMMOUDI, S. (Ed.). **Proceedings of the 25th International Conference on Enterprise Information Systems, ICEIS 2023, Volume 1, Prague, Czech Republic, April 24-26, 2023**. SCITEPRESS, 2023. p. 237–246. Disponível em: <<https://doi.org/10.5220/0011995500003467>>.

SAID, T. O. R.; AMBRÓSIO, F. T. A. M.; LEAL, G. de O.; SILVA, J. C. S. da. Diversas formas de preconceito e seus impactos na liberdade individual e coletiva. In: **Anais do Congresso Nacional Universidade, EAD e Software Livre**. [S.l.: s.n.], 2023. v. 1, n. 15.

SALLES, T.; FONSECA, E.; CASTRO, M.; OLIVEIRA, W.; PARDO, T. A. S.; ALUÍSIO, S. M. Hatebrxplain: A benchmark dataset with human-annotated rationales for explainable hate speech detection in brazilian portuguese. In: **Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025)**. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2025. p. 6422–6437.

SCHONLAU, M.; ZOU, R. Y. The random forest algorithm for statistical learning. **The Stata Journal**, SAGE Publications Sage CA: Los Angeles, CA, v. 20, n. 1, p. 3–29, 2020.

Scikit-learn Learner. **Scikit-learn LinearSVC**. 2023. <https://sklearn.com/scikit-learn-linearsvc/?utm_source=chatgpt.com>. Accessed: 2025-08-18.

SERT, B.; ÜLKER, S. V. A review of liwc and machine learning approaches on mental health diagnosis. **Social Review of Technology and Change**, Işık Üniversitesi Yayınları, v. 1, n. 2, p. 71–92, 2023.

SU QI, e. a. Motivations, methods and metrics of misinformation detection: an nlp perspective. **Natural Language Processing Research 1.1**, 2020.

SUN, X.; LI, X.; LI, J.; WU, F.; GUO, S.; ZHANG, T.; WANG, G. Text classification via large language models. In: BOUAMOR, H.; PINO, J.; BALI, K. (Ed.). **Findings of the Association for Computational Linguistics: EMNLP 2023**. Singapore: Association for Computational Linguistics, 2023. p. 8990–9005. Disponível em: <<https://aclanthology.org/2023.findings-emnlp.603/>>.

SUYAL, M.; GOYAL, P. A review on analysis of k-nearest neighbor classification machine learning algorithms based on supervised learning. **International Journal of Engineering Trends and Technology**, Seventh Sense Research Group, v. 70, n. 7, p. 43–48, 2022.

TASO, F.; REIS, V.; MARTINEZ, F. Sexismo no brasil: análise de um word embedding por meio de testes baseados em associação implícita. In: **Anais do XIV Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana**. Porto Alegre, RS, Brasil: SBC, 2023. p. 53–62. ISSN 0000-0000. Disponível em: <<https://sol.sbc.org.br/index.php/stil/article/view/25437>>.

VARGAS, F.; CARVALHO, I.; GÓES, F. Rodrigues de; PARDO, T.; BENEVENUTO, F. HateBR: A large expert annotated corpus of Brazilian Instagram comments for offensive language and hate speech detection. In: CALZOLARI, N.; BÉCHET, F.; BLACHE, P.; CHOUKRI, K.; CIERI, C.; DECLERCK, T.; GOGGI, S.; ISAHARA, H.; MAEGAARD, B.; MARIANI, J.; MAZO, H.; ODIJK, J.; PIPERIDIS, S. (Ed.). **Proceedings of the Thirteenth Language Resources and Evaluation Conference**. Marseille, France: European Language Resources Association, 2022. p. 7174–7183. Disponível em: <<https://aclanthology.org/2022.lrec-1.777>>.

VARGAS, F.; GÓES, F. R. de; CARVALHO, I.; BENEVENUTO, F.; PARDO, T. Contextual-lexicon approach for abusive language detection. In: **Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2021)**. [S.l.: s.n.], 2021. p. 1438–1447.

VARGAS, F.; GÓES, F. Rodrigues de; CARVALHO, I.; BENEVENUTO, F.; PARDO, T. Contextual-lexicon approach for abusive language detection. In: MITKOV, R.; ANGELOVA, G. (Ed.). **Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2021)**. Held Online: INCOMA Ltd., 2021. p. 1438–1447. Disponível em: <<https://aclanthology.org/2021.ranlp-1.161>>.

VARGAS, F. A.; CARVALHO, I.; GÓES, F. R. de; BENEVENUTO, F.; PARDO, T. A. S. Hatebr: A large expert annotated corpus of brazilian instagram comments for offensive language and hate speech detection. **arXiv preprint arXiv:2103.14972**, 2021.

VAZ, J. V.; BENEVENUTO, F.; ALMEIDA, J. M.; GONÇALVES, M. A.; VASCONCELOS, M. Detecção de discursos racistas em português na rede social x. In: SBC. **Brazilian Workshop on Social Network Analysis and Mining (BraSNAM)**. [S.l.], 2025. p. 228–241.

WATANABE, H.; BOUAZIZI, M.; OHTSUKI, T. Hate speech on twitter: A pragmatic approach to collect hateful and offensive expressions and perform hate speech detection. **IEEE access**, IEEE, v. 6, p. 13825–13835, 2018.

WEI, J.; TAY, Y.; BOMMASANI, R.; RAFFEL, C.; ZOPH, B.; BORGEAUD, S.; YOGATAMA, D.; BOSMA, M.; ZHOU, D.; METZLER, D. *et al.* Emergent abilities of large language models. **arXiv preprint arXiv:2206.07682**, 2022.

WELLECK, S.; KULIKOV, I.; ROLLER, S.; DINAN, E.; CHO, K.; WESTON, J. Neural text generation with unlikelihood training. **arXiv preprint arXiv:1908.04319**, 2019.

WIDMANN, T.; WICH, M. Creating and comparing dictionary, word embedding, and transformer-based models to measure discrete emotions in german political text. **Political Analysis**, v. 31, n. 4, p. 626–641, 2023.

WIGGINS, W. F.; TEJANI, A. S. On the opportunities and risks of foundation models for natural language processing in radiology. **Radiology: Artificial Intelligence**, Radiological Society of North America, v. 4, n. 4, p. e220119, 2022.

Wiktionary contributors. **Wiktionary: A Free Dictionary**. 2025. Accessed: 2025-01-15. Disponível em: <<https://www.wiktionary.org/>>.

WILLIAMS, D. R.; LAWRENCE, J. A.; DAVIS, B. A. Racism and health: evidence and needed research. **Annual review of public health**, Annual Reviews, v. 40, n. 1, p. 105–125, 2019.

YU, M.; CHANG, S.; ZHANG, Y.; JAAKKOLA, T. Rethinking cooperative rationalization: Introspective extraction and complement control. In: **Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)**. [S.l.: s.n.], 2019. p. 4094–4103.

ZAHID, A. H.; ROY, M. K.; DAS, S. Evaluation of hate speech detection using large language models and geographical contextualization. **arXiv preprint arXiv:2502.19612**, 2025.

ZAMPIERI, M.; MALMASI, S.; NAKOV, P.; ROSENTHAL, S.; FARRA, N.; KUMAR, R. Predicting the type and target of offensive posts in social media. In: BURSTEIN, J.; DORAN, C.; SOLORIO, T. (Ed.). **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)**. Minneapolis, Minnesota: Association for Computational Linguistics, 2019. p. 1415–1420. Disponível em: <<https://aclanthology.org/N19-1144/>>.

ZHANG, Y.; CHEN, L.; TIAN, Y. A method for evaluating the interpretability of machine learning models in predicting bond default risk based on lime and shap. **arXiv preprint arXiv:2502.19615**, 2025.

ZHAO, H.; CHEN, H.; YANG, F.; LIU, N.; DENG, H.; CAI, H.; WANG, S.; YIN, D.; DU, M. Explainability for large language models: A survey. **ACM Transactions on Intelligent Systems and Technology**, ACM New York, NY, v. 15, n. 2, p. 1–38, 2024.

ZHAO, W. X.; ZHOU, K.; LI, J.; TANG, T.; WANG, X.; HOU, Y.; MIN, Y.; ZHANG, B.; ZHANG, J.; DONG, Z. *et al.* A survey of large language models. **arXiv preprint arXiv:2303.18223**, v. 1, n. 2, 2023.

ZHU, J.; ZHANG, Z.; GUO, Z.; LI, Z. Sentiment classification of anxiety-related texts in social media via fusing linguistic and semantic features. **IEEE Transactions on Computational Social Systems**, p. 1–11, 2024.