

Métodos em Tempo Discreto para a Análise de Histórias de Eventos

Paul D. Allison

UNIVERSIDADE DA PENSILVÂNIA

Fonte: Sociological Methodology, Vol. 13, (1982), pp. 61-98

A história de um indivíduo ou grupo pode sempre ser caracterizada como uma sequência de eventos. As pessoas concluem os estudos, entram no mercado de trabalho, casam-se, têm filhos, são promovidas, mudam de empregador, aposentam-se e, por fim, morrem. Organizações formais fundem-se, adotam inovações e vão à falência. Nações experimentam guerras, revoluções e mudanças pacíficas de governo. É certamente tarefa da sociologia explicar e prever a ocorrência de tais eventos. Por que, por exemplo, alguns indivíduos experimentam maconha enquanto outros não? Por que algumas pessoas casam cedo enquanto outras casam tarde? Programas de enriquecimento educacional reduzem a probabilidade de abandono escolar? O que distingue empresas que adotaram sistemas de contabilidade informatizados daquelas que não o fizeram? Quais são as causas das revoluções?

Talvez a melhor forma de dados para responder a questões como essas seja uma história de eventos. Simplesmente, uma história de eventos é um registro de quando os eventos ocorreram a uma amostra de indivíduos (Tuma e Hannan, 1978). Se a amostra consiste em mulheres em idade fértil, por exemplo, a história de eventos de cada mulher pode consistir nas datas de nascimento de seus filhos, se houver. Se há interesse nas causas dos eventos, a história de eventos também deve incluir dados sobre variáveis explicativas relevantes. Algumas delas, como a raça, podem ser constantes ao longo do tempo, enquanto outras, como a renda, podem variar.

Embora as histórias de eventos sejam quase ideais para estudar as causas dos eventos, elas tipicamente possuem duas características — censura e variáveis explicativas que variam com o tempo — que criam dificuldades importantes para os procedimentos estatísticos convencionais. De fato, a tentativa de aplicar métodos convencionais a tais dados pode levar a viés grave ou perda de informação. Essas dificuldades são discutidas em detalhe nas páginas seguintes. Na última década, no entanto, vários métodos inovadores para a análise de histórias de eventos foram propostos. Os sociólogos estão mais familiarizados com os métodos de máxima verossimilhança de Tuma e seus colaboradores (Tuma, 1976; Tuma e Hannan, 1978; Tuma, Hannan e Groeneveld, 1979). Procedimentos similares foram desenvolvidos por bioestatísticos interessados na análise de dados de sobrevivência (Gross e Clark, 1975; Elandt-Johnson e Johnson, 1980; Kalbfleisch e Prentice, 1980). Uma abordagem relacionada, conhecida como verossimilhança parcial, oferece vantagens importantes sobre os métodos de máxima verossimilhança e está atualmente em uso generalizado nas ciências biomédicas (Cox, 1972; Kalbfleisch e Prentice, 1980; Tuma, volume atual, Capítulo 1).

A maioria dos métodos para analisar histórias de eventos pressupõe que o tempo é medido como uma variável contínua — ou seja, pode assumir qualquer valor não negativo. Em algumas circunstâncias, modelos e métodos em tempo discreto podem ser mais apropriados ou, se menos apropriados, altamente úteis.

Primeiro, em algumas situações os eventos só podem ocorrer em pontos regulares e discretos no tempo. Por exemplo, nos Estados Unidos, uma mudança no partido que controla a presidência só ocorre quadrienalmente no mês de janeiro. Nesses casos, um modelo em tempo discreto é claramente mais apropriado do que um modelo em tempo contínuo.

Segundo, em outras situações os eventos podem ocorrer em qualquer ponto no tempo, mas os dados disponíveis registram apenas o intervalo de tempo específico em que cada evento ocorre. Por exemplo, a maioria das pesquisas pergunta apenas pelo ano do casamento de uma pessoa, e não pela data exata. Seria claramente inadequado tratar esses dados como se fossem contínuos. Duas abordagens alternativas estão disponíveis. Uma é assumir que existe um modelo subjacente em tempo contínuo e, em seguida, estimar os parâmetros do modelo por métodos que levem em conta o caráter discreto dos dados. A outra abordagem é simplesmente assumir que os eventos só podem ocorrer nos pontos de tempo discretos medidos nos dados e, em seguida, aplicar modelos e métodos em tempo discreto. Na prática, essas duas abordagens levam a procedimentos de estimação muito semelhantes e, portanto, ambas podem ser descritas como métodos em tempo discreto.

Os métodos em tempo discreto têm várias características desejáveis. É fácil, por exemplo, incorporar variáveis explicativas que variam com o tempo em uma análise em tempo discreto. Além disso, quando as variáveis explicativas são categóricas (ou podem ser tratadas como tal), os modelos em tempo discreto podem ser estimados usando métodos log-lineares para analisar tabelas de contingência. Com essa abordagem, é possível analisar grandes amostras a custo muito baixo. Quando as variáveis explicativas não são categóricas, os procedimentos de estimação podem frequentemente ser bem aproximados usando regressão de mínimos quadrados ordinários. Por fim, os métodos em tempo discreto são mais facilmente compreendidos pelos metodologicamente menos experientes.

Por todas essas razões, os métodos em tempo discreto para a análise de histórias de eventos são frequentemente bem adequados aos tipos de dados, recursos computacionais e habilidades quantitativas dos cientistas sociais. O objetivo deste capítulo é examinar de perto a abordagem em tempo discreto e compará-la com os métodos em tempo contínuo. Antes de realizar essa tarefa, discutirei primeiro os problemas que surgem na análise de histórias de eventos e, em seguida, resumirei a abordagem em tempo contínuo.

PROBLEMAS NA ANÁLISE DE HISTÓRIAS DE EVENTOS

Seja o tempo medido em uma escala contínua ou discreta, as técnicas analíticas convencionais não são bem adequadas à análise de dados de histórias de eventos. Como exemplo dessas dificuldades, considere o estudo de reincidência criminal relatado por Rossi, Berk e Lenihan (1980). Aproximadamente 430 detentos liberados de presídios estaduais de Maryland foram acompanhados por um ano após sua liberação. Os eventos de interesse eram as prisões; o objetivo era determinar como a probabilidade de uma prisão dependia de diversas variáveis explicativas.

Embora a data de cada prisão fosse conhecida, Rossi e colaboradores simplesmente criaram uma variável binária indicando se a pessoa foi ou não presa durante o período de acompanhamento de 12 meses. Em seguida, regrediram essa variável binária sobre as possíveis variáveis explicativas, incluindo idade na liberação, raça, escolaridade e experiência de trabalho anterior. Embora esse não seja um método exploratório irrazoável, está longe de ser ideal. Além das limitações bem conhecidas

do uso de uma variável dependente binária em uma regressão múltipla (Goldberger, 1964), a dicotomização da variável dependente é tanto arbitrária quanto desperdiçadora de informação. É arbitrária porque não havia nada de especial no intervalo de 12 meses, exceto que o estudo terminou nesse ponto. Usando os mesmos dados, poder-se-ia igualmente comparar os presos antes e após uma linha divisória de 6 meses. Desperdiça informação porque ignora a variação em ambos os lados do ponto de corte. Poder-se-ia suspeitar, por exemplo, que uma pessoa presa imediatamente após a liberação tivesse uma propensão maior à reincidência do que uma presa 11 meses depois.

Para evitar essas dificuldades, é tentador usar o tempo decorrido desde a liberação até a primeira prisão como variável dependente em uma regressão múltipla. Mas essa estratégia apresenta dois novos problemas. Primeiro, o valor da variável dependente é desconhecido ou "censurado" para as pessoas que não foram presas durante o período de um ano. Uma solução ad hoc para esse dilema seria excluir todas as observações censuradas e analisar apenas os casos para os quais uma prisão é observada. Mas o número de casos censurados pode ser grande (47% foram censurados nessa amostra), e foi demonstrado que sua exclusão pode levar a grandes vieses (Sørensen, 1977; Tuma e Hannan, 1978). Uma abordagem alternativa ad hoc é atribuir o tempo máximo de observação, neste caso um ano, como o valor da variável dependente para os casos censurados. Obviamente, essa estratégia subestima o valor verdadeiro, e novamente podem resultar vieses substanciais (Tuma e Hannan, 1978).

Mesmo que nenhuma das observações fosse censurada, haveria outro problema: como incorporar variáveis explicativas que mudam de valor durante o período de observação na regressão linear. Neste estudo, por exemplo, os indivíduos foram entrevistados em intervalos mensais para obter informações sobre mudanças na renda, estado civil, situação de emprego e similares. Poder-se-ia parecer razoável incluir 12 diferentes medidas de renda na regressão múltipla, uma para cada mês de acompanhamento. Embora esse método possa fazer sentido para a pessoa que não é presa até o décimo primeiro mês, é certamente inadequado para a pessoa presa durante o primeiro mês após a liberação; sua renda posterior deveria ser irrelevante para a análise. De fato, a pessoa pode ter estado encarcerada durante o restante do período de acompanhamento, de modo que a renda se torna uma consequência, em vez de uma causa, da reincidência. Também é perigoso usar a renda durante o mês da prisão como única variável independente. Se a renda tiver uma tendência exógena a aumentar com o tempo, esse procedimento poderia erroneamente fazer parecer que rendas mais altas estão associadas a tempos mais longos até a prisão. Como Flinn e Heckman (1980) demonstraram, esforços ad hoc para introduzir variáveis exógenas que variam com o tempo em regressões que predizem duração geralmente têm a consequência não intencional de tornar essas mesmas variáveis endógenas.

Esses dois problemas — censura e variáveis explicativas que variam com o tempo — ocorrem tipicamente na análise de histórias de eventos. Ambos os problemas foram resolvidos pelos métodos em tempo contínuo de máxima verossimilhança e verossimilhança parcial, revisados na próxima seção.

MÉTODOS EM TEMPO CONTÍNUO

Em muitas histórias de eventos, cada indivíduo pode experimentar múltiplos eventos de vários tipos diferentes. Embora os métodos em tempo contínuo e em tempo discreto possam lidar com esses dados, a discussão é bastante simplificada se começarmos com um tipo de dados muito mais restrito.

Especificamente, vamos assumir que cada indivíduo experimenta no máximo um evento e que todos os eventos são idênticos, ou pelo menos podem ser tratados como idênticos para fins de análise.

A configuração para modelos em tempo contínuo é a seguinte. Temos uma amostra de n indivíduos independentes ($i = 1, \dots, n$), e começamos a observar cada indivíduo em algum ponto de partida natural $t = 0$. Em muitos casos, o ponto de partida apropriado será evidente. Se o evento de interesse é o divórcio, o ponto de partida óbvio é a data do casamento. No exemplo da reincidência, o ponto de partida natural é a data de liberação da reclusão. Às vezes, a escolha dos pontos de partida não é tão óbvia, no entanto, um problema que será discutido mais adiante quando considerarmos eventos repetidos.

Assumindo que existe um ponto de partida observado para cada indivíduo, a observação continua até o tempo t_i , no qual ou um evento ocorre ou a observação é censurada. Censura significa que o indivíduo não é observado além de t_i , seja porque o estudo termina nesse ponto ou porque o indivíduo se perde para o acompanhamento por algum motivo.¹ Para uma discussão sobre mecanismos alternativos de censura e suas implicações, veja Kalbfleisch e Prentice (1980) ou Lagakos (1979). Praticamente todos os modelos assumem que a censura é independente da ocorrência de eventos — ou seja, os indivíduos não são seletivamente retirados da amostra por serem mais ou menos propensos a experimentar um evento. Embora essa suposição nem sempre seja realista, ainda não parece existir uma alternativa satisfatória.

Definimos uma variável binária δ_i , que é igual a 1 se a observação é não censurada e zero se censurada. Também observamos x_i , um vetor $K \times 1$ de variáveis explicativas constantes ao longo do tempo. A generalização para variáveis explicativas que variam com o tempo é considerada posteriormente. O problema é especificar como a ocorrência de um evento depende de x , o vetor de variáveis explicativas. De longe, a abordagem mais comum é definir uma variável não observável ou latente que controla a ocorrência ou não ocorrência do evento, bem como a duração até que um evento ocorra (Tuma, Hannan e Groeneveld, 1979; Kalbfleisch e Prentice, 1980). Essa variável, comumente chamada de taxa de risco (hazard rate), é definida como segue. Primeiro, seja T uma variável aleatória denotando o tempo não censurado de ocorrência do evento (que pode não ser observado), e denote a taxa de risco por $\lambda(t)$. Então:

$$\lambda(t) = \lim \Pr(t < T < t + \Delta \mid T > t) / \Delta \quad (1)$$

Aqui $\lambda(t)$ pode ser pensado como a probabilidade instantânea de que um evento ocorra no tempo t , dado que ainda não ocorreu. Não é realmente uma probabilidade, no entanto, pois pode ser maior que 1. Alternativamente, pode ser pensado como o número esperado de eventos em um intervalo de tempo com 1 unidade de comprimento. Deixamos $\lambda(t)$ ser uma função do tempo para indicar que a probabilidade de um evento pode variar com o tempo. Às vezes, no entanto, supõe-se que $\lambda(t) = \lambda$, uma constante ao longo do tempo. Isso implica que T , o tempo até a ocorrência de um evento, tem uma distribuição exponencial. De forma mais geral, a função $\lambda(t)$ determina completamente a distribuição de probabilidade de T . Também pode ser demonstrado que:

$$\lambda(t) = f(t) / [1 - F(t)] \quad (2)$$

onde $f(t)$ é a densidade de probabilidade para T e $F(t)$ é a função de distribuição acumulada para T .

O próximo passo é expressar a taxa de risco como uma função tanto do tempo quanto das variáveis explicativas. A forma funcional mais amplamente utilizada é o chamado modelo de riscos proporcionais:

$$\log \lambda(t, x) = \alpha(t) + \beta'x \quad (3)$$

onde $\alpha(t)$ é uma função não especificada do tempo e β é um vetor $K \times 1$ de constantes.² É chamado de modelo de riscos proporcionais porque a razão das taxas de risco para quaisquer dois indivíduos em qualquer ponto no tempo é uma constante ao longo do tempo. O vetor β representa os efeitos das variáveis explicativas sobre a probabilidade instantânea de um evento. Assim, se x_1 tem um coeficiente positivo β_1 , um aumento em x_1 produz um aumento na probabilidade de que um evento ocorra. Por suposição, esses efeitos são constantes ao longo do tempo no modelo de riscos proporcionais.

Casos especiais desse modelo são obtidos especificando ainda mais a função $\alpha(t)$. A suposição mais simples é que $\alpha(t) = \alpha$, o que novamente implica que T tem uma distribuição exponencial. Se, no entanto, assume-se que:

$$\alpha(t) = \alpha_0 + \alpha_1 \log t \quad (4)$$

obtém-se uma distribuição de Weibull para T (Kalbfleisch e Prentice, 1980). Alternativamente, a especificação

$$\alpha(t) = \alpha_0 + \alpha_1 t \quad (5)$$

produz uma distribuição de Gompertz para T (Tuma e Crockford, 1976). Em geral, especificar a função $\alpha(t)$ é equivalente a especificar a distribuição de probabilidade para T .

O problema, claro, é que não observamos T para os casos censurados. No entanto, o método de máxima verossimilhança (MV) permite fazer uso completo das informações disponíveis para esses casos. A equação de verossimilhança geral para dados censurados é:³

$$L = \prod_{i=1}^n [f(t_i)]^{\delta_i} [1 - F(t_i)]^{1-\delta_i} \quad (6)$$

Em palavras: cada membro da amostra contribui com um fator que é a função de densidade para T se T é observado, e 1 menos a função de distribuição cumulativa se o indivíduo é censurado em t_i . O último é a probabilidade de que um evento ocorra em algum momento além de t_i . Substituindo de (2) e também deixando as funções dependerem de x , obtemos:

$$L = \prod_{i=1}^n [\lambda(t_i, x_i)]^{\delta_i} [1 - F(t_i, x_i)] \quad (7)$$

A Equação (2) implica que:

$$F(t_i, x_i) = 1 - \exp[-\int_0^{t_i} \lambda(u, x_i) du] \quad (8)$$

o que permite que a função de verossimilhança seja expressa inteiramente em termos da taxa de risco:

$$L = \prod_{i=1}^n [\lambda(t_i, x_i)]^{\delta_i} \exp[-\int_0^{t_i} \lambda(u, x_i) du] \quad (9)$$

As estimativas de máxima verossimilhança são então obtidas substituindo em (9) a expressão apropriada para $\lambda(t, x)$ e, em seguida, escolhendo as estimativas dos parâmetros para maximizar L .

Geralmente, a solução requer um algoritmo iterativo; para um exemplo, veja Kalbfleisch e Prentice (1980, pp. 55-56).

Embora a estimação por MV represente um grande avanço sobre os métodos de regressão ad hoc, ela tem a desvantagem de exigir que se especifique a forma de $\alpha(t)$ para usar o método. Tipicamente, não existe base teórica ou empírica suficiente para escolher entre especificações alternativas, mas os resultados podem variar consideravelmente dependendo da especificação escolhida. Em um artigo extremamente influente, Cox (1972) propôs um método pelo qual β poderia ser estimado sem impor restrições sobre $\alpha(t)$. Posteriormente chamado de verossimilhança parcial (VP), este método foi demonstrado ser altamente eficiente (Efron, 1977) e tem sido amplamente utilizado na análise de experimentos médicos. Para mais detalhes, veja Kalbfleisch e Prentice (1980).

Tanto os métodos de MV quanto de VP podem ser estendidos para lidar com múltiplos tipos de eventos e eventos repetidos (Tuma, Hannan e Groeneveld, 1979; Kalbfleisch e Prentice, 1980; Tuma, volume atual, Capítulo 1). O modelo de riscos proporcionais também pode ser generalizado para permitir que as variáveis explicativas mudem com o tempo, simplesmente substituindo $x(t)$ por x em (3). Tal modelo pode ser prontamente estimado pelo método de VP (veja, por exemplo, Crowley e Hu, 1977). Variáveis explicativas que dependem do tempo também podem ser incorporadas na estimação por MV, mas essa estratégia frequentemente leva a procedimentos computacionais bastante trabalhosos. Tuma, Hannan e Groeneveld (1979), por exemplo, permitem tais variáveis dividindo o tempo em vários intervalos disjuntos e assumindo que as variáveis explicativas têm valores constantes dentro de cada intervalo.

MÉTODOS EM TEMPO DISCRETO

Embora os modelos em tempo contínuo sejam geralmente representações plausíveis dos processos que geram eventos, na prática o tempo é sempre observado em unidades discretas, por menores que sejam. Quando essas unidades discretas são muito pequenas, em relação à taxa de ocorrência de eventos, geralmente é aceitável ignorar a discreticidade e tratar o tempo como se fosse medido de forma contínua. Quando as unidades de tempo são muito grandes — meses, anos ou décadas — esse tratamento se torna problemático.

No caso dos métodos de MV em tempo contínuo, o caráter discreto dos dados pode ser facilmente ignorado. O procedimento de estimação requer apenas que haja um valor numérico para o tempo de ocorrência do evento ou censura para cada indivíduo, e os programas disponíveis não têm como distinguir dados discretos de dados (quase) contínuos. Para o método de VP de Cox, por outro lado, o uso de grandes intervalos de tempo pode levar a problemas computacionais extremamente difíceis. Esses problemas surgem quando os intervalos de tempo são suficientemente grandes para que mais de um indivíduo experimente um evento no mesmo intervalo de tempo. Embora tais dados empatados possam ser tratados em teoria, os requisitos computacionais podem facilmente se tornar tão grandes a ponto de superar o hardware atualmente disponível. Fórmulas aproximadas que reduzem o custo computacional estão em uso generalizado, mas sua adequação foi recentemente questionada (Farewell e Prentice, 1980).

Entre os bioestatísticos, essas dificuldades foram um grande impulso para o desenvolvimento de modelos em tempo discreto e métodos de estimação que possuem as virtudes do método de VP. Como observado anteriormente, existem duas abordagens gerais para esse problema. A mais simples

é tratar o tempo como se fosse verdadeiramente discreto, abordagem adotada por Myers, Hankey e Mantel (1973), Byar e Mantel (1975), Brown (1975) e Mantel e Hankey (1978). A alternativa é começar com um modelo em tempo contínuo, geralmente o modelo de riscos proporcionais de (3), e, em seguida, derivar estimadores desse modelo que sejam apropriados para dados agrupados em intervalos. Essa abordagem foi usada por Holford (1976, 1980), Thompson (1977) e Prentice e Gloeckler (1978). Qualquer que seja a direção tomada, os resultados são notavelmente semelhantes. Portanto, farei uma apresentação integrada de todos os métodos, observando quaisquer variações onde for apropriado.

A notação para modelos em tempo discreto é similar à do tempo contínuo. Assume-se que o tempo só pode assumir valores inteiros positivos ($t = 1, 2, 3, \dots$) e que observamos um total de n indivíduos independentes ($i = 1, \dots, n$) a partir de algum ponto de partida natural $t = 1$. A observação continua até o tempo t_i , no qual ou um evento ocorre ou a observação é censurada. Censura significa que o indivíduo é observado em t_i mas não em $t_i + 1$.⁴ Como de costume, assume-se que o tempo de censura é independente da taxa de risco para a ocorrência de eventos. A variável δ_i é definida como igual a 1 se i é não censurado; caso contrário, é zero. Também é observado um vetor $K \times 1$ de variáveis explicativas x_i , que podem assumir valores diferentes em diferentes tempos discretos.⁵

Começamos definindo uma taxa de risco em tempo discreto:

$$p_{it} = \Pr[T_i = t \mid T_i \geq t, x_i] \quad (10)$$

onde T é a variável aleatória discreta que fornece o tempo não censurado de ocorrência do evento. Esta é apenas a analogia em tempo discreto da taxa de risco definida em (1). É também a probabilidade condicional de que um evento ocorra no tempo t , dado que ainda não ocorreu.

O próximo passo é especificar como essa taxa de risco depende do tempo e das variáveis explicativas. A escolha mais popular (Cox, 1972; Myers, Hankey e Mantel, 1973; Byar e Mantel, 1975; Brown, 1975; Thompson, 1977; Mantel e Hankey, 1978) é a função de regressão logística:

$$p_{it} = 1 / [1 + \exp(-\alpha_t - \beta'x_{it})] \quad (11)$$

que também pode ser escrita na forma logit:

$$\log[p_{it} / (1 - p_{it})] = \alpha_t + \beta'x_{it} \quad (12)$$

Note que α_t ($t = 1, 2, \dots$) é apenas um conjunto de constantes. Deixá-las não especificadas é análogo a deixar a função $\alpha(t)$ não especificada no modelo de riscos proporcionais (3).

Embora o modelo de regressão logística seja uma escolha um tanto arbitrária, tem várias virtudes: restringe p_{it} ao intervalo unitário para quaisquer valores de β e x ; é computacionalmente conveniente; e implica que existem estatísticas suficientes. Por outro lado, se assume-se que os dados são realmente gerados pelo modelo de riscos proporcionais em tempo contínuo (3), foi demonstrado (Holford, 1976; Prentice e Gloeckler, 1978) que a função de taxa de risco correspondente em tempo discreto é dada por:

$$p_{it} = 1 - \exp[-\exp(\alpha_t + \beta'x_{it})] \quad (13)$$

onde o vetor de coeficientes β é identicamente igual a β no modelo de riscos proporcionais (3). A Equação (13) pode ser resolvida para produzir a chamada função log-log complementar:

$$\log[-\log(1 - p_{it})] = \alpha_t + \beta'x_{it} \quad (14)$$

O fato de que β é o mesmo em (3) e (13) implica que as estimativas em tempo discreto baseadas em (13) são também estimativas do modelo subjacente em tempo contínuo. Segue também que o vetor de coeficientes do modelo log-log complementar é invariante ao comprimento dos intervalos de tempo.⁶ Essa propriedade não é compartilhada pelo modelo logístico.⁷ Na prática, no entanto, a diferença entre os dois modelos tende a ser trivial. Quanto menor o intervalo de tempo, menor será essa diferença, pois à medida que a largura do intervalo diminui, o modelo logístico converge para o modelo de riscos proporcionais (Thompson, 1977).

Alguns casos especiais desses modelos são obtidos impondo restrições ao conjunto de constantes α_t . Por exemplo:

$$\alpha_t = \alpha \quad (15) \quad \alpha_t = \alpha_0 + \alpha_1 t \quad (16) \quad \alpha_t = \alpha_0 + \alpha_1 \log t \quad (17)$$

Mantel e Hankey (1978) propõem que α_t seja expresso como um polinômio em t . Também é possível generalizar os modelos de modo que os efeitos das variáveis explicativas possam variar com o tempo, simplesmente substituindo β_t por β em (11) ou (13).

Como esses modelos podem ser estimados? Para o modelo logit (11), Cox (1972) propôs um estimador de VP análogo ao de dados em tempo contínuo. Como observado anteriormente, esse método se torna extremamente exigente computacionalmente se eventos ocorrem a muitos indivíduos durante a mesma unidade de tempo. Felizmente, a estimação convencional por MV dos modelos (11) e (13) é possível em tempo discreto sem quaisquer restrições sobre α_t . A construção da função de verossimilhança merece exame detalhado, pois tem importantes implicações conceituais e computacionais.

Para (11) ou (13), a verossimilhança dos dados pode ser escrita como:

$$L = \prod_{i=1}^n [\Pr(T_i = t_i)]^{\delta_i} [\Pr(T_i > t_i)]^{1-\delta_i} \quad (18)$$

que é análoga à verossimilhança em tempo contínuo em (6). Cada uma das probabilidades em (18) pode ser expressa como uma função da taxa de risco. Usando propriedades elementares de probabilidades condicionais, pode-se demonstrar que:

$$\Pr(T_i = t) = p_{it} \prod_{j=1}^{t-1} (1 - p_{ij}) \quad (19) \quad \Pr(T_i > t) = \prod_{j=1}^t (1 - p_{ij}) \quad (20)$$

Substituindo (19) e (20) em (18) e tomando o logaritmo, obtém-se a função de log-verossimilhança:

$$\log L = \sum_{i=1}^n \delta_i \log\{p_{it_i} / (1 - p_{it_i})\} + \sum_{i=1}^n \sum_{j=1}^{t_i} \log(1 - p_{ij}) \quad (21)$$

Neste ponto, pode-se substituir o modelo de regressão apropriado para p_{it} (seja a Equação 11 ou 13) e, em seguida, proceder para maximizar $\log L$ em relação a α_t ($t = 1, 2, \dots$) e β . A maioria dos investigadores para nesse ponto. Uma manipulação adicional, no entanto, leva a algo mais familiar. Se definirmos uma variável binária y_{it} igual a 1 se a pessoa i experimenta um evento no tempo t , e zero caso contrário, então (21) pode ser reescrita como:

$$\log L = \sum_{i=1}^n \sum_{j=1}^{t_i} y_{ij} \log\{p_{ij} / (1 - p_{ij})\} + \sum_{i=1}^n \sum_{j=1}^{t_i} \log(1 - p_{ij}) \quad (22)$$

Mas isso é apenas o log-verossimilhança para a análise de regressão de variáveis dependentes dicotômicas (Cox, 1970; Nerlove e Press, 1973; Hanushek e Jackson, 1977). Essa identidade implica

que modelos de taxa de risco em tempo discreto podem ser estimados usando programas para a análise de dados dicotômicos — uma abordagem de estimação notada pela primeira vez por Brown (1975), mas geralmente ignorada por outros.

Na prática, o procedimento é o seguinte: cada unidade de tempo discreto para cada indivíduo é tratada como uma observação separada ou unidade de análise. Para cada uma dessas observações, a variável dependente é codificada 1 se um evento ocorreu a esse indivíduo nessa unidade de tempo; caso contrário, é codificada zero. Assim, se um indivíduo experimentou um evento no tempo 5, cinco observações diferentes seriam criadas. Para a quinta observação, a variável dependente seria codificada 1. Para as outras quatro observações, a variável dependente seria codificada zero. As variáveis explicativas para cada uma dessas novas observações receberiam os valores que tinham naquela unidade de tempo específica. Valores defasados também poderiam ser incluídos. Para estimar as constantes α_t ($t = 1, 2, \dots$), uma variável independente binária seria criada para cada uma das possíveis unidades de tempo menos 1. Para estimar modelos como (16) ou (17), que impõem restrições sobre α_t , o próprio tempo (ou alguma função do tempo) pode ser incluído como variável explicativa.

O passo final é agrupar essas observações e computar as estimativas de MV do modelo de regressão apropriado, seja (11) ou (13), para uma variável dependente dicotômica. Até onde sei, o único programa publicamente disponível para estimar o modelo log-log complementar é o GLIM (Baker e Nelder, 1978).⁸ O modelo de regressão logística pode ser estimado usando qualquer programa logit de MV. Além disso, se as variáveis explicativas forem todas categóricas (ou puderem ser tratadas como tal), o modelo de taxa de risco logit pode ser estimado a partir de uma tabela de contingência usando programas log-lineares como o ECTA. Finalmente, um modelo linear da forma $p_{it} = \alpha_t + \beta'x_{it}$ é frequentemente uma boa aproximação dos modelos em (11) ou (13), o que sugere que o método de mínimos quadrados ordinários com uma variável dependente binária seja aplicado às unidades de tempo agrupadas. Embora essa abordagem tenha limitações bem conhecidas (Goldberger, 1964; Nerlove e Press, 1973), pode ser bastante útil como método exploratório.

UM EXEMPLO

Para ilustrar os métodos em tempo discreto, analisei um conjunto de histórias de eventos em que o evento de interesse é uma mudança de empregador. A amostra consiste em 200 bioquímicos do sexo masculino que obtiveram doutorado no final da década de 1950 ou início da de 1960, e que em algum momento de suas carreiras ocuparam posições como professores assistentes em departamentos de pós-graduação universitários. Para uma descrição detalhada da amostra, veja Long, Allison e McGinnis (1979). Foram observados por um máximo de 5 anos a partir do primeiro ano em seus primeiros cargos como professores assistentes. A Tabela 1 mostra o número de bioquímicos que mudaram de empregador em cada um dos 5 anos de observação. Dos 200 casos, 129 não mudaram de empregador durante o período de observação e são considerados censurados.

Começamos com um modelo simples em que a taxa de risco varia em cada um dos 5 anos, mas não depende de variáveis explicativas. Pode-se demonstrar que, nesse caso, a estimativa de MV da taxa de risco é obtida tomando a razão do número de mudanças de empregador no ano t pelo número em risco no ano t . A terceira coluna da Tabela 1 fornece o número em risco de mudança de empregador em cada um dos 5 anos. No ano 1, todos os 200 casos estão em risco. No ano 2, o número em risco é diminuído por 11, o número que mudou de empregador no ano 1. (Essas 11 pessoas obviamente

poderiam mudar de empregador novamente, mas essa análise se restringe à primeira tal mudança.) A taxa de risco estimada para cada ano é mostrada na última coluna da Tabela 1. Como o número em risco diminui constantemente, é possível que a taxa de risco aumente mesmo quando o número de mudanças de empregador diminui. A taxa de risco no ano 3, por exemplo, é maior do que a taxa de risco no ano 1, mesmo que mais pessoas tenham mudado de empregador no ano 1.

TABELA 1
Distribuição do Ano de Mudança de Empregador para 200 Bioquímicos

Ano	Número com Mudança de Empregador	Número em Risco	Taxa de Risco Estimada
1	11	200	0,055
2	25	189	0,132
3	10	164	0,061
4	13	154	0,084
5	12	141	0,085
>5	129		
Total	200	848	

Esses cálculos pressupuseram que, dentro de cada ano, a taxa de risco de todos é a mesma. Voltamo-nos agora para modelos em que a taxa de risco não observada depende de variáveis explicativas. Cinco variáveis independentes foram consideradas. Duas delas descrevem a instituição empregadora e são assumidas como constantes ao longo do tempo: uma medida do prestígio do departamento empregador (Roose e Andersen, 1970) e uma medida dos fundos federais alocados à instituição para pesquisa biomédica. Três variáveis descrevendo os bioquímicos individualmente foram medidas anualmente: número cumulativo de artigos publicados; número de citações feitas por outros cientistas à obra de cada indivíduo; e posto acadêmico codificado como 1 para professor associado e zero para professor assistente. (Embora todos os bioquímicos tenham iniciado o período de observação como professores assistentes, alguns foram promovidos posteriormente.) O objetivo é descobrir como a probabilidade de mudança de empregador depende dessas cinco variáveis.

Para implementar o método descrito acima, o primeiro passo foi criar uma observação separada para cada ano em que cada pessoa foi observada, até o ano em que ocorreu uma mudança de empregador. Assim, as pessoas que mudaram de empregador no ano 1 contribuíram com 1 pessoa-ano cada; as que mudaram de emprego no ano 3 contribuíram com 3 pessoas-ano. Os indivíduos censurados — aqueles que ainda estavam com o mesmo empregador no quinto ano — contribuíram com o máximo de 5 pessoas-ano. Para os 200 bioquímicos, havia um total de 848 pessoas-ano. Da Tabela 1, pode-se ver que esse total pode ser obtido somando o número em risco em cada um dos 5 anos.

A variável dependente para cada pessoa-ano foi codificada 1 se a pessoa mudou de empregador naquele ano; caso contrário, foi codificada zero. As variáveis independentes foram simplesmente atribuídas com os valores que tinham no determinado pessoa-ano. Tomando as 848 pessoas-ano como uma única amostra, vários modelos logit foram ajustados pelo método de MV usando o programa GLIM (Baker e Nelder, 1978). Os resultados para dois dos modelos são mostrados na

Tabela 2.

O Modelo 1 impõe a restrição de que $\alpha_t = \alpha$. Isso é equivalente a assumir que a taxa de risco de cada pessoa não muda autonomamente ao longo do tempo — quaisquer mudanças devem ocorrer em resposta a mudanças nas variáveis explicativas. A Tabela 2 fornece estimativas de coeficientes e estatísticas t de grandes amostras para a hipótese nula de que cada coeficiente é igual a zero. As estimativas dos coeficientes são como coeficientes de regressão não padronizados, pois dependem da métrica de cada variável independente. Para nossos propósitos, é mais instrutivo focar nas estatísticas t, que são livres de métrica e dão alguma indicação de importância relativa.

Os resultados para o Modelo 1 indicam que três das variáveis têm impacto significativo sobre a taxa de risco de mudança de empregador. Especificamente, as pessoas com muitas citações são mais propensas a mudar de empregador. As pessoas empregadas por instituições que recebem altos níveis de financiamento são menos propensas a mudar de empregador. E, finalmente, professores associados são menos propensos a mudar de empregador do que professores assistentes. O prestígio do departamento e o número de publicações parecem fazer pouca diferença.

TABELA 2

Estimativas para Modelos Logit Predizendo a Probabilidade de Mudança de Empregador em 848 Pessoas-Ano

Variáveis Independentes	Modelo 1 β	Modelo 1 t	Modelo 1 MQO t	Modelo 2 β	Modelo 2 t	Modelo 2 MQO t
Prestígio do departamento	0,045	0,21	0,22	0,056	0,26	0,25
Financiamento	-0,077	-2,45	-2,34	-0,078	-2,47	-2,36
Publicações	-0,021	-0,75	-0,86	-0,023	-0,79	-0,91
Citações	0,0072	2,44	2,36	0,0069	2,33	2,23
Posto	-1,4	-2,86	-2,98	-1,6	-3,12	-3,26
Ano 1				-0,96	-2,11	-2,07
Ano 2				-0,025	-0,06	0,18
Ano 3				-0,74	-1,60	-1,54
Ano 4				-0,18	-0,42	-0,38
Constante			4,95			2,35
Qui-quadrado	461,9			452,5		
GL	842			838		

O Modelo 2 relaxa a restrição imposta no Modelo 1, permitindo que a taxa de risco seja diferente em cada um dos 5 anos, mesmo quando as outras variáveis são mantidas constantes. Isso foi realizado criando-se um conjunto de quatro variáveis binárias, uma para cada um dos primeiros 4 anos de observação. Estimativas de coeficientes e estatísticas de teste são mostradas na Tabela 2. O coeficiente para cada variável binária fornece a diferença no logaritmo das chances de mudança de empregador naquele ano específico e o log das chances de mudança de empregador no ano 5, líquido de outras variáveis. Nenhum padrão claro emerge desses coeficientes, embora haja alguma tendência

para a taxa de risco aumentar com o tempo. Observe que a introdução das quatro variáveis binárias faz pouca diferença nas estimativas de efeito das outras variáveis independentes. Isso nem sempre será o caso, no entanto.

Ao comparar o ajuste dos Modelos 1 e 2, pode-se testar a hipótese nula de que a taxa de risco de mudança de empregador não varia com o tempo, líquido de outras variáveis. Para cada modelo logit ajustado, obtém-se uma estatística qui-quadrado de razão de verossimilhança com um número associado de graus de liberdade. Os valores para os Modelos 1 e 2 são mostrados na parte inferior da Tabela 2. Se um modelo é um caso especial de outro modelo, seu ajuste pode ser comparado usando a diferença em suas estatísticas de razão de verossimilhança. Sob a hipótese nula de que não há diferença, a diferença entre as estatísticas de razão de verossimilhança terá uma distribuição qui-quadrado. Os graus de liberdade associados serão a diferença nos graus de liberdade dos dois modelos. Neste caso, a diferença é 9,4 com 4 graus de liberdade, o que é apenas abaixo do valor crítico para o nível de significância de 0,05. Assim, a evidência é marginal de que a taxa de risco varia com o tempo.

O próximo passo foi testar se os efeitos das variáveis independentes mudaram ao longo do tempo. Em vez de fazer isso para todas as variáveis simultaneamente, estimei cinco modelos diferentes, cada um dos quais permitia que os coeficientes de uma das variáveis explicativas variassem por ano. Em cada caso, isso foi realizado adicionando quatro novas variáveis ao Modelo 2. Essas variáveis foram construídas multiplicando uma variável explicativa por cada uma das quatro variáveis binárias que representam os quatro anos diferentes. Como nenhuma dessas diferenças se aproximou da significância estatística, os resultados detalhados não são reportados aqui. Assim, esses dados oferecem poucas evidências de que os efeitos das variáveis explicativas mudam ao longo do tempo.

Todos esses modelos foram reestimados sob a especificação log-log complementar de (14) usando o programa GLIM. Os resultados foram praticamente idênticos. Anteriormente também sugeri que uma função linear simples poderia servir como aproximação das funções logit ou log-log complementar e que tal modelo poderia ser estimado por mínimos quadrados ordinários (MQO) com uma variável dependente binária. Os Modelos 1 e 2 foram novamente reestimados com esse procedimento. Ou seja, as regressões de MQO foram executadas nas 848 pessoas-ano com a variável dependente codificada 1 se uma mudança ocorreu naquele pessoa-ano e zero caso contrário. As estatísticas t para essas regressões são fornecidas na Tabela 2, ao lado das estatísticas t para o modelo logit. Os resultados são notavelmente semelhantes.⁹ Obviamente, o fato de que a regressão de mínimos quadrados funcionou bem para esses dados não garante que funcionará para outros conjuntos de dados.

PROBLEMAS COM A ABORDAGEM EM TEMPO DISCRETO

Vimos que os modelos em tempo discreto para histórias de eventos podem ser estimados tratando a história de cada indivíduo como um conjunto de observações independentes, uma para cada unidade de tempo observada. Embora essa estratégia tenha vantagens conceituais e computacionais, ela também levanta duas questões sérias sobre a legitimidade e praticidade do procedimento. Ambas as questões são discutidas nesta seção.

É legítimo tratar as múltiplas unidades de tempo para cada indivíduo como se fossem independentes? No exemplo recém-considerado, começamos com apenas 200 observações, mas acabamos

analisando 848 observações. Para alguns, isso pode parecer uma inflação artificial do tamanho da amostra, levando a estatísticas de teste enganosamente altas. Para responder a essa objeção, suponhamos que o Modelo (11) ou (13) para a taxa de risco em tempo discreto seja uma descrição verdadeira de como os dados foram gerados. Se for esse o caso, então as derivações em (18) a (22) mostram que o procedimento de estimação proposto aqui é de fato o estimador de MV para o modelo correspondente. Assim, sob condições regulares fracas, as estimativas possuem as propriedades bem conhecidas de serem consistentes, assintoticamente eficientes e assintoticamente normalmente distribuídas. Além disso, os erros padrão estimados serão estimadores consistentes dos verdadeiros erros padrão.

Tudo isso depende, claro, da verdade do modelo original. Infelizmente, esses modelos tendem a ser irrealistas em um aspecto chave. Considere, por exemplo, o modelo log-log complementar de (14), que era:

$$\log[-\log(1 - p_{it})] = \alpha_t + \beta'x_{it} \quad (14)$$

Esse modelo afirma implicitamente que as variáveis no vetor x esgotam todas as fontes de variação individual na taxa de risco. Obviamente, isso raramente será o caso. Por analogia com modelos lineares, uma especificação mais plausível incluiria um termo de perturbação aleatória ε_{it} tal que:

$$\log[-\log(1 - p_{it})] = \alpha_t + \beta'x_{it} + \varepsilon_{it} \quad (23)$$

onde x_{it} e ε_{it} são assumidos como independentes para todos os i e t . Essa complicação seria relativamente inócua se não fosse pelo fato de que, para um determinado indivíduo, ε_t quase certamente será correlacionado com ε_{t+1} , ε_{t+2} , e assim por diante. Em outras palavras, as fontes não observadas de variação na taxa de risco terão alguma estabilidade ao longo do tempo. Embora as consequências exatas sejam difíceis de derivar, esse fato quase certamente criará dificuldades para o estimador em tempo discreto. Em particular, não será mais correto tratar as múltiplas unidades de tempo para cada indivíduo como se fossem independentes. Por analogia com a regressão de mínimos quadrados ordinários, esperaria-se que essa dependência entre as observações levasse a estimativas de coeficientes ineficientes e erros padrão estimados com viés para baixo.

Embora esse problema deva ser levado a sério, ele não deve levar ao abandono da abordagem em tempo discreto em favor dos métodos em tempo contínuo. Na verdade, os modelos em tempo contínuo sofrem exatamente da mesma dificuldade, embora seja um pouco menos conspícua. Por exemplo, o modelo de riscos proporcionais em tempo contínuo (3) também assume que a taxa de risco é completamente determinada pelas variáveis explicativas medidas. Novamente seria mais apropriado modificar o modelo introduzindo um termo de perturbação, de modo que:

$$\log \lambda(t) = \alpha(t) + \beta'x(t) + \varepsilon(t) \quad (24)$$

onde $\varepsilon(t)$ pode ser considerado como um processo estocástico em tempo contínuo. Embora essa complicação não induza dependência entre as observações originais, ela implica que a distribuição do tempo até a ocorrência do evento é diferente do que seria sem a perturbação aleatória. Se essa perturbação for ignorada no procedimento de estimação, pode novamente levar a viés, ineficiência e erros padrão inconsistentes (Fennell, Tuma e Hannan, 1977; Chamberlain, 1979). Além disso, para modelos análogos, as consequências devem ser virtualmente idênticas para os estimadores em tempo discreto e em tempo contínuo.

Em alguns casos, é possível modificar o procedimento de estimação para permitir explicitamente uma perturbação aleatória. Tuma (no prelo), por exemplo, propôs o modelo em tempo contínuo:

$$\log \lambda(t, x) = \alpha + \beta'x + \varepsilon$$

onde $\exp(\varepsilon)$ tem uma distribuição gama com média 1 e variância constante σ^2 . Ela então obteve estimadores de MV para α , β e σ^2 . Flinn e Heckman (1980) propuseram um modelo geral para a introdução de uma perturbação aleatória. Modificações similares podem ser feitas para modelos e métodos de estimação em tempo discreto. Por exemplo, um termo de perturbação pode ser adicionado a uma versão de taxa constante de (11) para produzir:¹⁰

$$p_{it} = [1 + \exp(-\alpha - \beta'x_i)]^{-1} + \varepsilon_i \quad (25)$$

Parece, então, que a possibilidade de dependência entre as unidades de tempo não confere nenhuma desvantagem especial aos estimadores em tempo discreto. A abordagem em tempo discreto pode se tornar impraticável, no entanto, quando as unidades de tempo são pequenas em relação ao período total de observação. Considere, por exemplo, as histórias de emprego dos bioquímicos. Se tivéssemos usado pessoa-dias em vez de pessoa-anos, o tamanho efetivo da amostra teria sido de mais de 300.000. E isso a partir de uma amostra original de apenas 200. O problema é ainda pior quando se estima modelos que permitem que a taxa de risco seja uma função arbitrária do tempo. Para tais modelos, uma variável binária deve ser incluída para cada ponto no tempo discreto (menos 1). Com muitos pontos de tempo, o número de variáveis binárias se torna impraticavelmente grande.¹¹

Pode-se sempre evitar esses problemas agregando os dados em intervalos maiores de tempo, mas essa tática necessariamente descarta alguma informação. Embora possa parecer claramente preferível usar os métodos de MV ou VP em tempo contínuo, a situação não é bem tão simples. Há vários casos em que, mesmo com unidades de tempo muito pequenas, o estimador de MV em tempo discreto se compara favoravelmente em custo com os estimadores de MV e VP em tempo contínuo.

Um tal caso ocorre quando as variáveis explicativas são constantes ao longo do tempo e a função de taxa de risco de linha de base $\alpha(t)$ também é constante ao longo do tempo. Sob essas suposições, as múltiplas unidades de tempo para cada indivíduo podem ser consideradas como um conjunto de tentativas independentes, todas com a mesma probabilidade de um "sucesso" (sendo o sucesso a ocorrência de um evento). A probabilidade de um sucesso depende por sua vez das variáveis explicativas de acordo com a Função (11) ou (13). O resultado é que pode-se usar métodos computacionais para dados binomiais agrupados em vez de computar sobre cada observação dicotômica separadamente.

Intervalos de tempo pequenos também representam pouca dificuldade para o estimador em tempo discreto quando todas as variáveis explicativas são categóricas (ou podem ser tratadas como tal). Considere um caso em que há observações sobre 500.000 pessoa-dias com cinco variáveis explicativas dicotômicas que variam com o tempo. Suponha também que a função de taxa de risco de linha de base seja uma constante — ou seja, $\alpha_t = \alpha$. Em vez de analisar esses dados no nível individual, é muito mais eficiente formar a tabela de contingência de 64 células e analisá-la, pois o custo da análise depende então do número de células na tabela e não do número de pessoa-dias. É bem sabido que os modelos logit como (11) são casos especiais de modelos log-lineares para tabelas de contingência. Portanto, as técnicas log-lineares padrão (Goodman, 1972; Fienberg, 1977) podem ser prontamente aplicadas.¹²

MÚLTIPLOS TIPOS DE EVENTOS

Até este ponto, assumimos que os eventos são de apenas um tipo. Frequentemente é útil distinguir entre diferentes tipos de eventos, no entanto, especialmente quando há razão para acreditar que os efeitos das variáveis explicativas diferem entre diferentes tipos de eventos. Por exemplo, as mudanças de empregador dos bioquímicos estudados anteriormente poderiam ser divididas em mudanças voluntárias e involuntárias. Seria razoável esperar que o prestígio do departamento tivesse um efeito negativo sobre a taxa de risco para mudanças voluntárias, mas um efeito positivo sobre a taxa de risco para mudanças involuntárias.

Os modelos de taxa de risco em tempo contínuo podem ser facilmente generalizados para permitir múltiplos tipos de eventos (Tuma, Hannan e Groeneveld, 1979; Kalbfleisch e Prentice, 1980). Essa generalização é realizada definindo uma taxa de risco separada para cada tipo diferente de evento, uma abordagem às vezes referida como modelagem de "riscos concorrentes." Suponha, por exemplo, que existam m tipos diferentes de eventos ($j = 1, \dots, m$), e seja J uma variável aleatória indicando qual dos m eventos ocorre. A taxa de risco¹³ para o evento j é então definida como:

$$\lambda_j(t) = \lim \Pr(t < T < t + \Delta, J = j \mid T \geq t) / \Delta \quad (26)$$

Segue-se que a taxa de risco global $\lambda(t)$, definida em (1), é apenas $\lambda(t) = \sum \lambda_j(t)$ (27). Em seguida, expressamos a dependência de cada uma das m taxas de risco nas variáveis explicativas. A especificação mais comum é, novamente, o modelo de riscos proporcionais:

$$\log \lambda_j(t) = \alpha_j(t) + \beta_j'x(t) \quad (28)$$

Observe que tanto α_j quanto β_j podem diferir entre diferentes tipos de eventos. A estimação por máxima verossimilhança dos β_j 's não envolve nada novo, devido ao fato de que a função de verossimilhança se fatoriza em um componente separado para cada tipo diferente de evento. Isso implica que cada β_j pode ser estimado separadamente. Além disso, o procedimento de estimação para cada β_j é o mesmo que se houvesse apenas um tipo de evento; eventos diferentes de j são tratados como se o indivíduo fosse censurado no momento em que o evento ocorreu.

Embora também seja simples desenvolver modelos em tempo discreto para múltiplos tipos de eventos, os resultados são um pouco diferentes. Como no modelo em tempo contínuo, o primeiro passo é definir uma taxa de risco em tempo discreto para cada tipo diferente de evento:

$$p_{tj} = \Pr(T = t, J = j \mid T \geq t) \quad (29)$$

Segue-se que $p_t = \sum_j p_{tj}$ é a taxa de risco global definida em (10). A coisa importante sobre (30) é que, ao contrário da função de verossimilhança para o modelo em tempo contínuo, a verossimilhança em tempo discreto não pode ser fatorizada em componentes separados para cada um dos m tipos de eventos. Portanto, a estimação por MV deve ser feita simultaneamente para todos os tipos de eventos.

Aqui considerarei uma generalização do modelo logístico (11). Especificamente, seja:

$$p_{tj} = \exp[\alpha_{jt} + \beta_j'x_t] / (1 + \sum_{j=1}^m \exp[\alpha_{jt} + \beta_j'x_t]) \quad (31)$$

que se reduz a (11) quando $m = 1$. Substituindo (31) em (30) e tomando o logaritmo, obtém-se o log-verossimilhança para um problema logit multinomial em que todas as unidades de tempo observadas para todos os indivíduos são tratadas como observações separadas e independentes.

Assim, assim como o modelo de evento único pode ser estimado com um programa logit binomial, o modelo de eventos múltiplos pode ser estimado usando um programa logit multinomial.

Quando todas as variáveis independentes são categóricas, a estimação do modelo logit multinomial é mais facilmente realizada por métodos log-lineares (Fienberg, 1977; Goodman, 1970). Como antes, o procedimento é primeiro dividir a história de eventos de cada indivíduo em um conjunto de unidades de tempo discretas. A variável dependente é uma politomia com $m + 1$ categorias. (A categoria extra é para a não ocorrência de nenhum dos m eventos.) Agrupando todas as unidades de tempo, o próximo passo é formar uma tabela de contingência para todas as variáveis categóricas. Por fim, ajustam-se modelos log-lineares correspondentes a modelos logit para a variável dependente de $m + 1$ categorias.¹⁵

Suponha que o evento de interesse seja uma morte resultante de câncer. Para o modelo em tempo contínuo, pode-se tratar uma morte devida a qualquer outra causa como se o indivíduo fosse censurado naquele ponto no tempo e, em seguida, proceder a aplicar os métodos usuais para analisar dados censurados para um único tipo de morte. Pareceria que, para o modelo em tempo discreto, por outro lado, deve-se especificar cuidadosamente cada tipo diferente de morte antes de estimar o modelo logit multinomial apropriado. Esse é de fato um procedimento complicado, mas há uma alternativa mais simples análoga à dos métodos em tempo contínuo. Suponha que se tratassem todas as mortes por causas não relacionadas ao câncer como se o indivíduo fosse censurado no início do intervalo em que a morte ocorreu. Essa tática equivaleria a descartar todas as unidades de tempo em que mortes por causas não relacionadas ao câncer ocorreram. Pode ser demonstrado que esse procedimento produz um estimador de MV condicional que possui as propriedades usuais de MV de consistência e normalidade assintótica (veja Andersen, 1980, para a prova de um caso especial).

EVENTOS REPETIDOS

Até agora foi assumido que cada indivíduo na amostra experimenta no máximo um evento. Embora essa suposição simplifique muito as coisas, frequentemente se encontram dados sobre eventos que se repetem, como nascimentos, casamentos, mudanças de empregador ou mudanças de residência, especialmente quando a observação continua por um longo período de tempo. Os métodos em tempo contínuo foram generalizados para lidar com eventos repetidos (Tuma, Hannan e Groeneveld, 1979; Gail, Santner e Brown, 1980; Kalbfleisch e Prentice, 1980), e generalizações similares podem ser feitas para os métodos em tempo discreto.

Antes de examinar essas generalizações, é essencial esclarecer qualquer confusão sobre a origem da escala de tempo. A escolha do tempo de partida é sempre problemática quando os dados contêm eventos repetidos. Em geral, o método de análise para eventos repetidos não é muito diferente do de eventos únicos: basta dividir a história de eventos de cada indivíduo em um conjunto de unidades de tempo discretas que são tratadas como observações independentes, e construir uma variável dependente dicotômica indicando se um evento ocorreu ou não em cada unidade de tempo.¹⁶

A diferença é que agora cada indivíduo pode contribuir com mais de um evento para a amostra. Como consequência, torna-se necessário considerar modelos mais complexos para a dependência da taxa de risco em relação ao tempo e à história de eventos anteriores do indivíduo.

Alguma notação adicional é necessária para discutir tais modelos. Seja T_k ($k = 1, 2, 3, \dots$) um conjunto de variáveis aleatórias denotando o tempo em que o k -ésimo evento ocorre a algum indivíduo, e seja t_k

o valor realizado de T_k . A taxa de risco em tempo discreto para o k-ésimo evento é então definida como:

$$P_k(t) = \Pr(T_k = t \mid T_k \geq t, T_1 = t_1, T_2 = t_2, \dots, T_{k-1} = t_{k-1}) \quad (32)$$

que é identicamente igual a zero se $t < t_{k-1}$. Um modelo muito simples é:

$$P_k(t) = G[\beta'x(t)] \quad (33)$$

onde G poderia ser a função logística em (11) ou o inverso da função log-log complementar como em (13). Esse modelo diz que a taxa de risco muda com o tempo apenas através de mudanças nas variáveis explicativas.

Se agora desejamos introduzir uma dependência explícita da taxa de risco em relação ao tempo, devemos escolher entre usar o mesmo ponto de partida para todos os eventos ou "reiniciar o relógio" cada vez que um evento ocorre. A primeira abordagem é simbolizada por:

$$P_k(t) = G[\alpha(t) + \beta'x(t)] \quad k = 1, 2, \dots \quad (34)$$

enquanto a última é representada por:

$$P_k(t) = G[\alpha(t - t_{k-1}) + \beta'x(t)] \quad k = 1, 2, \dots \quad (35)$$

Como de costume, $\alpha(t)$ é alguma função que pode ser especificada ou deixada arbitrária. Embora geralmente faça mais sentido escolher a especificação em (35), ainda se poderia permitir dependência tanto do tempo de partida inicial quanto do tempo desde o último evento. Em todos os casos, os modelos são facilmente estimados incluindo variáveis independentes apropriadas para representar as diferentes escalas de tempo.

Uma limitação dos Modelos (34) e (35) é a suposição de que os processos que afetam a ocorrência do primeiro evento são os mesmos que os do segundo, terceiro e eventos posteriores. Para permitir diferenças, pode-se simplesmente reescrever (35) como:

$$P_k(t) = G[\alpha_k(t - t_{k-1}) + \beta_k'x(t)] \quad k = 1, 2, \dots \quad (36)$$

Existem duas maneiras diferentes de estimar esse modelo. Uma é fazer uma análise separada para cada evento k, eliminando do conjunto agrupado todas as unidades de tempo após t_k ou antes de (e incluindo) t_{k-1} . Uma segunda abordagem é construir um conjunto de variáveis binárias representando os diferentes eventos na sequência. A vantagem desse método é que ele permite testar explicitamente se os α 's e β 's diferem para diferentes eventos na sequência.

Mais uma limitação de todos esses modelos é a suposição implícita de que, condicionado às variáveis explicativas, o tempo em que o k-ésimo evento de um indivíduo ocorre é independente da história de eventos anterior. A maneira mais fácil de relaxar a suposição é introduzir variáveis independentes adicionais representando a dependência da taxa de risco na história anterior do indivíduo (Tuma, 1976). Por exemplo, poder-se-ia estimar um modelo da forma:

$$P_k(t) = G[\alpha(t - t_{k-1}) + \beta'x(t) + (k-1)\gamma_1 + (t_{k-1} - t_{k-2})\gamma_2] \quad (37)$$

onde γ_1 e γ_2 são constantes fixas. Esse modelo diz que a taxa de risco para o k-ésimo evento depende do número de eventos anteriores (k-1) e da duração entre os últimos dois eventos ($t_{k-1} - t_{k-2}$).

CONCLUSÃO

Os problemas de censura e variáveis explicativas que variam com o tempo são grandes impedimentos à aplicação de técnicas analíticas convencionais a dados longitudinais sobre a ocorrência de eventos. Embora esses problemas tenham sido em grande parte resolvidos pelo desenvolvimento dos métodos de máxima verossimilhança e verossimilhança parcial, a ênfase tem sido em dados nos quais o momento dos eventos é precisamente medido. Nas ciências sociais, no entanto, grande parte dos dados disponíveis sobre histórias de eventos contém apenas a informação de que os eventos ocorreram dentro de certos intervalos de tempo. Para tais dados, frequentemente é desejável usar métodos em tempo discreto. Na prática, esses métodos têm considerável apelo intuitivo e são relativamente fáceis de aplicar. A essência dos métodos é dividir a história de eventos de cada indivíduo em um conjunto de unidades de tempo discretas em que um evento ocorreu ou não ocorreu. Agrupando essas unidades de tempo em todos os indivíduos, obtém-se então estimadores de máxima verossimilhança para modelos de regressão binária. Embora essa estratégia tenha o caráter de uma abordagem ad hoc, os estimadores resultantes são verdadeiros estimadores de máxima verossimilhança de modelos que são análogos exatos aos de dados em tempo contínuo. De fato, alguns dos modelos em tempo discreto podem ser derivados assumindo um modelo subjacente em tempo contínuo. Os métodos podem ser prontamente estendidos para a análise de eventos repetidos e múltiplos tipos de eventos.

REFERÊNCIAS

- ALLISON, P. D. 1977 "A confiabilidade de variáveis medidas como o número de eventos em um intervalo de tempo." Em K. F. Schuessler (ed.), *Sociological Methodology* 1978. San Francisco: Jossey-Bass.
- 1980 "Introduzindo uma perturbação em modelos de regressão logit e probit." Manuscrito não publicado, Universidade Cornell.
- ANDERSEN, E. B. 1973 *Conditional Inference and Models for Measuring*. Copenhagen: Mentalhygiejnisk Forlag.
- 1980 *Discrete Statistical Models with Social Science Applications*. Amsterdam: North-Holland.
- BAKER, R. J., AND NELDER, J. A. 1978 *The GLIM System*. Oxford: Numerical Algorithms Group.
- BLALOCK, H. M., JR. 1979 *Social Statistics*. 2ª ed. rev. New York: McGraw-Hill.
- BROWN, C. C. 1975 "Sobre o uso de variáveis indicadoras para estudar a dependência temporal de parâmetros em um modelo de tempo de resposta." *Biometrics* 31:863-872.
- BYAR, D. P., AND MANTEL, N. 1975 "Algumas inter-relações entre as estimativas de coeficientes de regressão decorrentes de uma classe de modelos apropriados a dados de tempo de resposta." *Biometrics* 31:943-947.
- CHAMBERLAIN, G. D. 1979 "Heterogeneidade, viés de variável omitida e dependência de duração." *Discussion Paper* 691. Harvard Institute of Economic Research.
- 1980 "Análise de covariância com dados qualitativos." *Review of Economic Studies* 47:225-238.
- COLEMAN, J. S. 1964 *Introduction to Mathematical Sociology*. New York: Free Press.
- COX, D. R. 1970 *The Analysis of Binary Data*. London: Methuen.
- 1972 "Modelos de regressão e tábuas de vida." *Journal of the Royal Statistical Society, Series B*, 34:187-202.
- COX, D. R., AND HINKLEY, D. B. 1974 *Theoretical Statistics*. London: Chapman & Hall.
- CROWLEY, J., AND HU, M. 1977 "Análise de covariância de dados de sobrevivência de transplante cardíaco." *Journal of the American Statistical Association* 72:27-36.
- EFRON, B. 1977 "A eficiência da função de verossimilhança de Cox para dados censurados." *Journal of the American Statistical Association* 72:557-565.

- ELANDT-JOHNSON, R. C., AND JOHNSON, N. L. 1980 *Survival Models and Data Analysis*. New York: Wiley.
- FAREWELL, V. T., AND PRENTICE, R. L. 1980 "A aproximação da verossimilhança parcial com ênfase em estudos caso-control." *Biometrika* 67:273-278.
- FENNEL, M. L., TUMA, N. B., AND HANNAN, M. T. 1977 "Qualidade das estimativas de máxima verossimilhança de parâmetros em um modelo de taxa log-linear." Technical Report 59. Laboratory for Social Research, Stanford University.
- FIENBERG, S. E. 1977 *The Analysis of Cross-Classified Categorical Data*. Cambridge, Mass.: M.I.T. Press.
- FIENBERG, S. E., AND MASON, W. M. 1978 "Identificação e estimação de modelos idade-período-coorte na análise de dados arquivados discretos." Em Karl Schuessler (ed.), *Sociological Methodology* 1979. San Francisco: Jossey-Bass.
- FLINN, C. J., AND HECKMAN, J. J. 1980 "Modelos para a análise da dinâmica da força de trabalho." Discussion Paper 80-3. Chicago: Economics Research Center, NORC.
- GAIL, M. H., SANTNER, T. J., AND BROWN, C. C. 1980 "Uma análise de experimentos de carcinogênese comparativa com base em múltiplos tempos até o tumor." *Biometrics* 36:255-266.
- GOLDBERGER, A. S. 1964 *Econometric Theory*. New York: Wiley.
- GOODMAN, L. A. 1970 "A análise multivariada de dados qualitativos: Interações entre múltiplas classificações." *Journal of the American Statistical Association* 65:226-256.
- 1972 "Uma abordagem de regressão múltipla modificada para a análise de variáveis dicotômicas." *American Sociological Review* 37:28-46.
- 1975 "A relação entre as abordagens de regressão múltipla modificada e usual para a análise de variáveis dicotômicas." Em D. R. Heise (ed.), *Sociological Methodology* 1976. San Francisco: Jossey-Bass.
- GROSS, A. J., AND CLARK, V. A. 1975 *Survival Distributions: Reliability Applications in the Biomedical Sciences*. New York: Wiley.
- HABERMAN, S. J. 1978 *Analysis of Qualitative Data*. Vol. 1. New York: Academic Press.
- HANUSHEK, E. A., AND JACKSON, J. E. 1977 *Statistical Methods for Social Scientists*. New York: Academic Press.
- HECKMAN, J. J., AND WILLIS, R. J. 1977 "Um modelo beta-logístico para a análise da participação sequencial na força de trabalho por mulheres casadas." *Journal of Political Economy* 85:27-58.
- HOLFORD, T. R. 1976 "Tábuas de vida com informações concomitantes." *Biometrics* 32:587-597.
- 1980 "A análise de taxas e sobrevivência usando modelos log-lineares." *Biometrics* 36:299-305.
- JOHNSON, W. D., AND KOCH, G. G. 1978 "Análise de modelos lineares de riscos concorrentes para tempos de sobrevivência agrupados." *International Statistical Review* 46:21-51.
- KALBFLEISCH, J. D., AND PRENTICE, R. L. 1980 *The Statistical Analysis of Failure Time Data*. New York: Wiley.
- LAGAKOS, S. W. 1979 "Censura à direita geral e seu impacto na análise de dados de sobrevivência." *Biometrics* 35:139-156.
- LONG, J. S., ALLISON, P. D., AND MCGINNIS, R. 1979 "Entrada na carreira acadêmica." *American Sociological Review* 44:816-830.
- MANTEL, N., AND HANKEY, B. 1978 "Uma análise de regressão logística de dados de tempo de resposta onde a função de risco é dependente do tempo." *Communications in Statistics-Theory and Methods* A7:333-347.
- MYERS, M. H., HANKEY, B. F., AND MANTEL, N. 1973 "Um modelo logístico-exponencial para uso com dados de tempo de resposta envolvendo variáveis de regressor." *Biometrics* 29:257-269.
- NERLOVE, M., AND PRESS, S. J. 1973 *Univariate and Multivariate Log-Linear and Logistic Models*. Santa Monica: Rand.
- PRENTICE, R. L., AND GLOECKLER, L. A. 1978 "Análise de regressão de dados de sobrevivência agrupados com aplicação a dados de câncer de mama." *Biometrics* 34:57-67.

ROOSE, K. D., AND ANDERSEN, C. J. 1970 A Rating of Graduate Programs. Washington, D.C.: American Council on Education.

ROSSI, P. H., BERK, R. A., AND LENIHAN, K. J. 1980 Money, Work and Crime: Some Experimental Results. New York: Academic Press.

SINGER, B., AND SPILERMAN, S. 1976 "Algumas questões metodológicas na análise de levantamentos longitudinais." *Annals of Economic and Social Measurement* 5:447-474.

SØRENSEN, A. B. 1977 "Estimando taxas a partir de questões retrospectivas." Em D. R. Heise (ed.), *Sociological Methodology* 1977. San Francisco: Jossey-Bass.

THOMPSON, W. A., JR. 1977 "Sobre o tratamento de observações agrupadas em estudos de vida." *Biometrics* 33:463-470.

TUMA, N. B. 1976 "Recompensas, recursos e taxa de mobilidade: Um modelo estocástico multivariado não estacionário." *American Sociological Review* 41:338-360.

"Efeitos da estrutura do mercado de trabalho sobre padrões de mudança de emprego." Em J. J. Heckman e B. Singer (eds.), *Longitudinal Studies of the Labor Market*. (No prelo)

TUMA, N. B., AND CROCKFORD, D. 1976 "Invocando RATE." Manual de programa não publicado.

TUMA, N. B., AND HANNAN, M. T. 1978 "Abordagens para o problema de censura na análise de histórias de eventos." Em K. F. Schuessler (ed.), *Sociological Methodology* 1979. San Francisco: Jossey-Bass.

TUMA, N. B., HANNAN, M. T., AND GROENEVELD, L. D. 1979 "Análise dinâmica de histórias de eventos." *American Journal of Sociology* 84:820-854.

TURNBULL, B. W. 1974 "Estimação não paramétrica de uma função de sobrevivência com dados duplamente censurados." *Journal of the American Statistical Association* 69:74-80.

1976 "A função de distribuição empírica com dados agrupados censurados e truncados arbitrariamente." *Journal of the Royal Statistical Society, Series B*, 38:290-295.

¹ Apenas a censura à direita é considerada neste capítulo. Os dados são censurados à direita se o tempo de ocorrência do evento é conhecido apenas como sendo maior do que algum valor. Muito menos comuns (mas muito mais problemáticos) são os dados censurados à esquerda, em que o tempo de ocorrência do evento é conhecido apenas como sendo menor do que algum valor.

² Logaritmos naturais são usados ao longo de todo o texto.

³ Esta verossimilhança é válida apenas para dados censurados à direita.

⁴ Se existe um processo subjacente em tempo contínuo gerando os dados, esta definição de censura pressupõe implicitamente que os dados são censurados no ponto final do intervalo correspondente a t_i .

⁵ Assume-se que em cada ponto no tempo discreto há um e apenas um valor para cada uma das variáveis explicativas.

⁶ Singer e Spilerman (1976) e Flinn e Heckman (1980) alertaram que análises em tempo discreto podem levar a inferências sensíveis à escolha arbitrária do comprimento do intervalo. No entanto, eles também observam que modelos em tempo discreto derivados de modelos em tempo contínuo não sofrem desse defeito.

⁷ Myers, Hankey e Mantel (1973) propuseram uma versão do modelo logístico que é invariante ao comprimento do intervalo, mas seu modelo tem a desvantagem de restringir α_i a ser o mesmo para todos os t_i .

⁸ GLIM é um programa de propósito geral para ajustar modelos lineares, log-lineares, logísticos, probit e outros. Desenvolvido pelo Grupo de Trabalho de Computação Estatística da Royal Statistical Society.

⁹ Os coeficientes de mínimos quadrados não são reportados porque não são prontamente comparáveis aos coeficientes logit. Uma comparação aproximada é possível usando a fórmula de ajuste $b / [p(1 - p)]$.

¹⁰ Embora possa parecer incomum adicionar o termo de perturbação após a função logística ter sido aplicada à combinação linear das variáveis explicativas, esta construção é muito mais tratável do que a alternativa.

¹¹ Para grandes números de variáveis binárias, Prentice e Gloeckler (1978) sugerem uma versão do algoritmo de Newton-Raphson que reduz o cálculo.

¹² O programa GLIM também estimará modelos log-log complementares para tabelas de contingência.

¹³ Essas taxas de risco específicas por evento são formalmente equivalentes às taxas de transição ou intensidades de transição definidas para processos semi-Markov em tempo contínuo.

¹⁴ É possível construir uma generalização da especificação log-log complementar em (13) para múltiplos tipos de eventos, mas tal modelo não pode ser estimado pelos programas de computador existentes.

¹⁵ Programas log-lineares como o ECTA que restringem a soma de um conjunto de parâmetros a ser zero não produzirão diretamente estimativas dos parâmetros definidos em (31).

¹⁶ Assume-se que o intervalo de tempo é suficientemente curto para que não mais do que um evento ocorra em qualquer unidade de tempo discreto.