



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE XXXXXXXXX
DEPARTAMENTO DE XXXXXXXXXX
PROGRAMA DE PÓS-GRADUAÇÃO EM XXXXXXXX
MESTRADO ACADÊMICO EM XXXXXXXX

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

FORTALEZA

2025

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Xxxxxxx do Programa de Pós-Graduação em Xxxxxxx do Centro de Xxxxxxxx da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia Xxxxxx. Área de Concentração: Engenharia Xxxxxx

Orientador: Prof. Dr. João Paulo do Vale Madeiro

FORTALEZA


2025

Para criar sua ficha catalográfica, preencha corretamente o Módulo de Elaboração de Fichas Catalográficas (CATALOG!) disponibilizado no link:

<http://fichacatalografica.ufc.br/>

Em seguida, deve-se renomear o arquivo gerado como “ficha-catalografica” e adicioná-lo ao *template* na pasta “1-pre-textuais”. É necessário, contudo, excluir o antigo arquivo “ficha-catalografica” antes de adicionar o novo.

A figura a seguir mostra os passos enumerados para a inclusão da ficha catalográfica no *Overleaf*.



Clique aqui para inserir o novo arquivo


(3)

Clique nesta pasta para que o arquivo enviado seja inserido neste destino

(1)

Exclua o arquivo antigo

(2)



Clique aqui para enviar o novo arquivo

(4)

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em XXXXXXXX do Programa de Pós-Graduação em XXXXXXXX do Centro de XXXXXXXX da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia XXXXXXXX. Área de Concentração: Engenharia XXXXXXXX

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. João Paulo do Vale Madeiro (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. XXXXXXXX XXXXXXXX XXXXXXXX
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

Ao Prof. Dr. Ricardo Silva Thé Pontes por me orientar em minha tese de doutorado.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ) onde este *template* foi desenvolvido.

Ao Doutorando em Engenharia Elétrica, Ednardo Moreira Rodrigues, e seu assistente, Alan Batista de Oliveira, aluno de graduação em Engenharia Elétrica, pela adequação do *template* utilizado neste trabalho para que o mesmo ficasse de acordo com as normas da biblioteca da Universidade Federal do Ceará (UFC).

Aos bibliotecários da Universidade Federal do Ceará: Francisco Edvander Pires Santos, Juliana Soares Lima, Izabel Lima dos Santos, Kalline Yasmin Soares Feitosa e Eliene Maria Vieira de Moura, pela revisão e discussão da formatação utilizada neste *template*.

Ao aluno Thiago Nascimento do curso de ciência da computação da Universidade Estadual do Ceará que elaborou o *template* do qual este trabalho foi adaptado para Universidade Federal do Ceará.

Ao Prof. Dr. Humberto de Andrade Carmona do Curso de Física da UFC pelo primeiro incentivo para o uso do $\text{\LaTeX}$.

Ao aluno de graduação em engenharia elétrica e amigo, Lohan Costa por me apresentar a plataforma *ShareLatex* que depois migrou para a plataforma *OverLeaf*.

Aos amigos de laboratório, Felipe Bandeira, Renan Barroso e Roney Coelho, pelas discussões sobre os recursos do $\text{\LaTeX}$.

Aos meus pais, irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender.

E à Fundação Cearense de Apoio ao Desenvolvimento (Funcap), na pessoa do Presidente Tarcísio Haroldo Cavalcante Pequeno pelo financiamento da pesquisa de doutorado via bolsa de estudos.

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

RESUMO

Trata-se de dados ECG holter com duração de 24 horas de 3 derivações, coletados em pacientes com suspeita de arritmia cardíaca. O objetivo deste trabalho é desenvolver um algoritmo para detecção automática de eventos dado duração que o paciente esteve em observação médica, utilizando técnicas de aprendizado de máquina. Diferente de algumas pesquisas não irei utilizar técnica de classificação ou encontro de anomalia e nem detecção de séries temporais, mas sim uma abordagem baseada em probabilidades de riscos para detecção de eventos. Em vez de dizer se o paciente tem ou não arritmia, o objetivo é dizer qual a probabilidade do paciente ter um evento de uma parada cardíaca em um determinado período de tempo. Com isso vou utilizar um método de Análise de Sobrevida em Tempo Discreto (Logistic-Hazard) similar à regressão de Cox a diferença que são métodos diferentes porque a regressão de Cox usa tempos contínuos e esse trabalho vai tratar de tempos discretos para análise de sobrevida para prever o risco de eventos cardíacos em pacientes com suspeita de arritmia, com base em dados ECG holter de 24 horas. Os resultados esperados são um modelo preditivo que possa auxiliar médicos na tomada de decisão clínica, identificando pacientes com maior risco de eventos cardíacos adversos. Os sinais de ECG vão entrar como covariáveis no modelo Logistic-Hazard (Risco Logístico) e o tempo até o evento (parada cardíaca) será a variável dependente. Os ECGs vão passar pelo um pré-modelo de extração de características para extrair features relevantes dos sinais antes de serem inseridos no modelo de Análise de Sobrevida em Tempo Discreto (Logistic-Hazard), como se trata de 3 derivações irei usar um modelo convolucional ResNet de 18 camadas profundas por convolução 1D(1x3) para extrair recursos locais ao longo do tempo, junto com alguns dados de apoio para melhorar o aprendizado como idade, gênero e outras features. Como se trata de 3 sinais de derivações, vou utilizar uma rede neural convolucional de 1D para aprender sobre padrões dos sinais como intervalos de ondas como amplitude, anomalias, intervalos que será importante para o modelo Logistic-Hazard.

Palavras-chave: Logistic-Hazard. ResNet-18 1D. Educação de adultos. Escola rural.

ABSTRACT

In this on the radio waves: popular culture, peasants and the Basic Education Movement we analyze the participation of peasants of the Brazilian northeastern region in the Basic Education Movement. The focus of this thesis is to demonstrate how the labors involved with broadcast schools have elaborated actions for maintaining and spreading the schools in their communities, in order to achieve the necessary means to improve their way of life. Peasants of the Basic Education Movement have been coadjuvant of the modernizing catholic proposition of the early 1960s, by means of quite peculiar political and cultural representations. Some of these representations were: a meaning for the school, a role for the union and for the political participation, precepts of the land use rights and labor rights, and the multiple meanings of the radio as a mass communication, information and leisure medium. This study intends to stress that the actions – and the political enrollment – of the northeastern peasant could not ever be separated from the modernizing process. The connection can be observed in different social movements of the period, such as the Basic Education Movement, rural unions, the Catholic Agrarian Youth and the MCP. In this sense, we consider that, if the Brazilian modernization was a guideline for the institutions, political organisms and parties for the social movement, such a modernization was a guideline of demands based on elements of material life. Those elements included, by that time, the agrarian reform, the educational issue and labor urgencies.

Keywords: Adult education. Community schools. Peasants. Popular culture.

LISTA DE FIGURAS

Figura 1 – Gráfico de barras da distribuição de causa dos pacientes.	20
Figura 2 – Fotografia da reitoria da Universidade Federal do Ceará	26
Figura 3 – Gráfico da Atmosfera Superior	27
Figura 4 – Esquema de pré-treinamento MoCo para aprendizado auto-supervisionado de representações do ECG/Holter. O codificador query recebe gradientes diretamente; o codificador key é atualizado por média móvel e alimenta uma fila de exemplos negativos.	33
Figura 5 – Fluxo do encoder ResNet-1D utilizado para extração de características convolucionais temporais dos sinais de ECG/Holter. Cada BasicBlock1D contém duas convoluções 1D com normalização em lote e conexão residual.	34
Figura 6 – Arquitetura híbrida final: extração de características do sinal por ResNet-1D/MoCo, compressão do ECG em gargalo de 16 dimensões, processamento clínico em paralelo, fusão balanceada e predição de logits para modelos de sobrevivência em tempo discreto.	38
Figura 7 – Transformação dos logits brutos nos três modelos de sobrevivência em tempo discreto: LogisticHazard, PMF e DeepHitSingle.	39
Figura 8 – Gráfico de tensão considerando a impedância humana	66
Figura 9 – Gráfico de tensão considerando a impedância humana	66
Figura 10 – Gráfico de tensão considerando a impedância humana	67
Figura 11 – Gráfico de tensão considerando a impedância humana	67
Figura 12 – Gráfico de tensão considerando a impedância humana	67
Figura 13 – Gráfico de tensão considerando a impedância humana	68
Figura 14 – Produção anual das dissertações de mestrado e teses de doutorado entre os anos de 1990 e 2008	69

LISTA DE TABELAS

Tabela 1 – Um Exemplo de tabela alinhada que pode ser longa ou curta	27
Tabela 2 – Modelo de Cox com variáveis do Holter na coorte completa ($n = 992$; 205 eventos).	49
Tabela 3 – Modelo de Cox com variáveis do Holter na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	50
Tabela 4 – Modelo de Cox com variáveis arrítmicas na coorte completa ($n = 992$; 205 eventos).	51
Tabela 5 – Modelo de Cox com variáveis arrítmicas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	52
Tabela 6 – Modelo de Cox com dados clínicos e antropométricos na coorte completa ($n = 992$; 205 eventos).	52
Tabela 7 – Modelo de Cox com dados clínicos e antropométricos na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	53
Tabela 8 – Modelo de Cox com variáveis eletrocardiográficas na coorte completa ($n = 992$; 205 eventos).	54
Tabela 9 – Modelo de Cox com variáveis eletrocardiográficas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	55
Tabela 10 – Análise de Cox univariável — coeficiente, razão de risco, C-index e significância por variável ($n = 992$; 205 eventos).	57
Tabela 11 – Fator de inflação da variância (VIF) — avaliação de multicolinearidade entre as variáveis candidatas.	58
Tabela 12 – Análise de Cox multivariável — variáveis com $p < 0,05$ na análise univariável ($n = 992$; 205 eventos).	59
Tabela 13 – Análise de Cox univariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	61
Tabela 14 – Fator de inflação da variância (VIF) — amostra filtrada com três derivações completas ($n = 898$).	62
Tabela 15 – Análise de Cox multivariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).	63
Tabela 16 – Desempenho dos modelos de sobrevivência profunda segundo o conjunto de covariáveis e a disponibilidade de ECG dos pacientes.	65

Tabela 17 – Notas dos participantes nas avaliações A, B e C	69
---	----

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
CNNs	Redes Neurais Convolucionais
CSV	<i>Comma-Separated Values</i>
DAs	descargas atmosféricas
DCVs	Cardiovascular diseases
ECG	Eletrocardiograma
Hz	Hertz
I3A	<i>Instituto de Investigación de Ingeniería de Aragón</i>
ICC	Insuficiência Cardíaca Crônica
MCEG	modelo do circuito elétrico global
MSC	Morte Súbita Cardíaca
PDF	<i>Portable Document Format</i>
TEST	Tem que Escrever a Sigla no Texto

LISTA DE SÍMBOLOS

A_e	Área efetiva da antena
B	Largura de faixa em que o ruído é medido em Hertz
d	Distância em metros
E	Campo elétrico
FA	Fator da antena
Gr	Ganho de recepção
h	Altura efetiva ou comprimento efetivo de uma antena
I	Corrente elétrica
k	Constante de Boltzmann's
K	Eficiência de irradiação
M	Variação do patamar de ruído em função da RBW
N	Condutor de neutro
NF	Figura de ruído
N_i	Potência do ruído na entrada
N_o	Potência do ruído na saída
P	Potência
R	Resistência
S_i	Potência do sinal na entrada
S_o	Potência do sinal na saída
t	Tempo
V	Tensão
Z_L	Impedância da antena
Z_o	Impedância de referência (50Ω)
λ	Comprimento de onda
Γ	Coefficiente de reflexão
α	Coefficiente de atenuação

β	Coeficiente de fase
δ	Variável de tempo discreto
ε	Variável de erro
θ	Parâmetro do modelo de análise de sobrevivência em tempo discreto (Logistic-Hazard)
λ	Taxa de risco
μ	Média
σ	Desvio padrão
ρ	Correlação
ϕ	Variável de tempo contínuo
ψ	Variável de tempo discreto
ω	Frequência angular

SUMÁRIO

1	INTRODUÇÃO	18
1.1	Motivação	18
1.2	Base de dados	18
1.3	Principais Desafios	19
1.3.1	<i>Desbalanceamento dos dados</i>	<i>19</i>
1.3.2	<i>Grande volume dos sinais</i>	<i>22</i>
2	FUNDAMENTAÇÃO TEÓRICA	23
2.1	Logistic-Hazard	23
2.2	Resnet-18 1D	23
2.3	Momentum Contrast	23
2.4	Citações bibliográficas	23
2.5	Inserindo figuras	25
2.6	Inserindo tabelas	26
2.6.1	<i>Exemplo de subseção</i>	<i>27</i>
2.6.2	<i>Uso de siglas</i>	<i>28</i>
3	METODOLOGIA	29
3.1	Modelos de Análise de Sobrevida	29
3.1.1	<i>Pré-treinamento Auto-supervisionado: MoCo</i>	<i>29</i>
3.1.1.1	<i>Aprendizado Contrastivo como Busca em Dicionário</i>	<i>30</i>
3.1.1.2	<i>Dicionário Dinâmico com Fila e Encoder com Momento</i>	<i>30</i>
3.1.1.3	<i>Melhorias do MoCo v2</i>	<i>31</i>
3.1.1.4	<i>Adaptação para Sinais de ECG</i>	<i>31</i>
3.1.1.5	<i>Configuração do Treinamento</i>	<i>32</i>
3.1.1.6	<i>Escolha do Mecanismo de Aprendizado Contrastivo</i>	<i>32</i>
3.1.2	<i>Pré-treinamento Contrastivo com MoCo</i>	<i>33</i>
3.1.3	<i>Arquitetura Proposta dos Modelos Profundos</i>	<i>34</i>
3.1.4	<i>Encoder ResNet-1D para Sinais de ECG</i>	<i>34</i>
3.1.5	<i>Arquitetura do Encoder: ResNet-18 1D</i>	<i>34</i>
3.1.5.1	<i>Da ResNet-18 2D para a ResNet-18 1D</i>	<i>35</i>
3.1.5.2	<i>Estrutura das 17 Camadas do Encoder</i>	<i>35</i>

3.1.5.3	<i>Justificativa da Escolha da ResNet-18</i>	36
3.1.6	<i>Arquitetura Híbrida Final</i>	37
3.1.7	<i>Módulo de Projeção e Fusão Híbrida</i>	37
3.1.8	<i>Cabeçote de Análise de Sobrevivência</i>	37
3.1.9	<i>Risco Logístico (Logistic-Hazard)</i>	38
3.1.10	<i>Função de Massa de Probabilidade (PMF)</i>	39
3.1.11	<i>DeepHit</i>	39
3.1.12	<i>Formulações de Sobrevivência em Tempo Discreto</i>	39
3.1.13	<i>Discretização do Tempo: Transformação LabTrans</i>	40
3.1.14	<i>Função de Perda por Tipo de Paciente</i>	40
3.1.15	<i>Treinamento: Acumulação de Gradiente e Precisão Mista</i>	41
3.1.16	<i>Avaliação: C-Index e Agregação de Janelas</i>	41
3.2	Exemplo de alíneas	42
3.3	Usando Fórmulas Matemáticas	43
3.4	Usando Código-fonte	45
3.5	Usando Teoremas, Proposições, etc	45
3.6	Usando Questões	46
4	RESULTADOS	47
4.1	Resultados da tabela subject-info.csv	47
4.1.1	<i>Resultados do modelo de Cox para dados Holter</i>	48
4.1.1.1	<i>Resumo dos resultados do modelo de Cox para dados Holter</i>	50
4.1.2	<i>Resultados do modelo de Cox para dados de eventos e condições cardiovasculares</i>	50
4.1.3	<i>Resultados do modelo de Cox para dados demográficos clínicos</i>	52
4.1.4	<i>Resultados do modelo de Cox para dados eletrocardiograma de alta resolução</i>	53
4.2	Modelos de Aprendizado Profundo para Sobrevivência	64
4.2.1	<i>Sobre LogisticHazard</i>	64
4.2.2	<i>Sobre PMF</i>	64
4.2.3	<i>Sobre DeepHitSingle</i>	64
4.3	MoCo (Momentum Contrast)	66
4.4	Resultados do Experimento A	68
4.5	Resultados do Experimento B	69

5	CONCLUSÕES E TRABALHOS FUTUROS	71
	REFERÊNCIAS	72
	APÊNDICES	74
	APÊNDICE A – Exemplo de apêndice	74
	APÊNDICE B – Questionário utilizado para...	75
	APÊNDICE C – Códigos-fontes utilizados para...	76
	APÊNDICE D – <i>IEEE CEFC 2016</i>	77
	ANEXOS	79
	ANEXO A – Exemplo de um anexo	79
	ANEXO B – Exemplo de um anexo em PDF	80

1 INTRODUÇÃO

1.1 Motivação

Doenças cardiovasculares Cardiovascular diseases (DCVs) são a principal causa de morte em todo o mundo, representando aproximadamente 17,9 milhões de mortes por ano, o que corresponde a 31% de todas as mortes globais como mostra a pesquisa (World Health Organization, 2025). Dentre as DCVs, as arritmias cardíacas são condições comuns que podem levar a eventos adversos graves, como parada cardíaca súbita. A detecção precoce e precisa de arritmias é crucial para a prevenção de complicações e melhoria dos resultados clínicos. Segundo o jornal USP doenças cardiovasculares são a principal causa de morte no Brasil, representando cerca de 30% de todas as mortes no país (Jornal da USP, 2024).

Este trabalho trata de dados de pacientes que ficaram em observações clínicas e acompanhamento que apresentaram sintomas de arritmia cardíaca, esses dados foram coletados pela plataforma PhysioNet (PRABHAKARARAO; MANIMEGALAI, 2020a). Em resumo a população do estudo é de 992 pacientes com insuficiência cardíaca crônica Insuficiência Cardíaca Crônica (ICC) esses dados de coletas trata do ano entre abril de 2003 e dezembro de 2004, com um acompanhamento de uma mediana de 44 meses até 2008 de dezembro, alguns desses pacientes apresentaram eventos de morte súbita cardíaca Morte Súbita Cardíaca (MSC), as coletas foram feitas em 8 hospitais universitários espanhóis, na Espanha pela cidades de Barcelona, Sevilha, Cádiz, Murcia, Santiago de Compostela, esses conjunto de dados de sinais e a organização desse banco de dados que foi parar no PhysioNet foi liderada pelo Instituto de Investigación de Ingeniería de Aragón *Instituto de Investigación de Ingeniería de Aragón* (I3A) (PRABHAKARARAO; MANIMEGALAI, 2020a), na Universidade de Zaragoza (Zaragoza, Espanha), pelo grupo do pesquisador Pablo Laguna.

1.2 Base de dados

De acordo com a pesquisa (PRABHAKARARAO; MANIMEGALAI, 2020a), os dados coletados incluem sinais de ECG Holter de 24 horas de 3 derivações (96%) e 2 derivações (4%), dados de eletrocardiograma Eletrocardiograma (ECG) em repouso de alta resolução com três derivações de 20 minutos, além de dados clínicos e demográficos dos pacientes, ecocardiografia e exames laboratoriais de sangue. Esses dados foram registrados em uma

tabela CSV com 105 variáveis. Os dados são ricos tanto em sinais de ECG para o encontro de padrões de ondas e intervalos, como o QT, mudanças nas frequências, amplitude de onda e picos RR, quanto em dados clínicos e demográficos, o que permite uma análise abrangente dos fatores de risco associados a eventos cardíacos adversos. Existem vários métodos para análise usando esses dados; dentre as variáveis citadas, existe duas variáveis que irei usar como ponto de partida que se chama Follow-up period from enrollment (days) (PRABHAKARARAO; MANIMEGALAI, 2020b). Que se trata o tempo do período de acompanhamento dos pacientes, ou seja, o tempo que os pacientes ficaram em observação clínica e acompanhamento, e o Cause of death (PRABHAKARARAO; MANIMEGALAI, 2020b) que se trata da causa da morte dos pacientes, ou seja, se o paciente morreu por causa de uma arritmia cardíaca ou por outra causa. A partir dessas duas variáveis, o objetivo deste trabalho é analisar a relação entre o tempo de acompanhamento dos pacientes e a causa da morte, buscando identificar padrões ou associações que possam contribuir para a compreensão dos fatores de risco relacionados a eventos cardíacos adversos.

1.3 Principais Desafios


1.3.1 Desbalanceamento dos dados

O desbalanceamento dos dados é um desafio comum em estudos médicos, especialmente quando se trata de eventos raros, como a morte súbita cardíaca. Neste conjunto de dados, a maioria dos pacientes está viva (73,2%), enquanto uma proporção menor sofreu eventos adversos (26,8%). Esse desbalanceamento pode dificultar o treinamento de modelos preditivos, pois o modelo pode aprender a classificar a maioria dos casos como "vivo" e ter dificuldade em identificar os casos de "morte súbita cardíaca". Para lidar com esse desafio, técnicas de balanceamento de dados, como o uso de amostragem estratificada ou algoritmos de aprendizado que são robustos ao desbalanceamento, podem ser aplicadas para melhorar a capacidade do modelo de identificar padrões relevantes nos dados.

Os dados utilizados neste trabalho foram obtidos na plataforma PhysioNet (PRABHAKARARAO; MANIMEGALAI, 2020a), que é um repositório de dados fisiológicos e clínicos de pacientes. Irei utilizar os sinais de ECG Holter de 24 horas de 3 derivações, que correspondem a 96% de todos os dados coletados, além dos dados clínicos e demográficos dos pacientes, que estão salvos em formato *Comma-Separated Values* (CSV) (PRABHAKARARAO; MANIMEGALAI,

2020b). Inicialmente, ao analisar a tabela (que no site PhysioNet possui o título subject-info.csv), destaca-se a variável Cause of death (PRABHAKARARAO; MANIMEGALAI, 2020b). A Figura 1 ilustra as causas de morte dos pacientes, que são classificadas em códigos numéricos: o Código 0 representa os pacientes vivos, correspondendo a 73,2% do total; o Código 1 trata de pacientes que morreram de outras causas (não ligadas ao coração) e corresponde a 6,1%; o Código 3 trata-se da Morte Súbita Cardíaca (Sudden Cardiac Death - SCD) 9,5%; por fim, os Códigos 6 e 7 referem-se à morte por falência de bomba (que é a progressão lenta e refratária da insuficiência cardíaca terminal no hospital), englobando 11,2% dos pacientes. Essa categoria.

Figura 1 – Gráfico de barras da distribuição de causa dos pacientes.



Fonte: elaborado pelo autor (2026).

Ao analisar a divisão dos dados, nota-se um desbalanceamento natural entre os pacientes vivos (tratados como dados censurados) e aqueles que sofreram o desfecho fatal. A predominância de pacientes vivos é comum, mas pode tornar mais desafiadora a tarefa de ensinar o modelo a identificar os padrões sutis no ECG relacionados à morte súbita cardíaca. No entanto, ao desconsiderarmos as mortes por outras causas — tratando-as também como censura — e focarmos estritamente nos eventos cardíacos, chegamos a um total de 205 pacientes, o que representa 20,67% da base de dados. Do ponto de vista do treinamento de redes neurais, este é um cenário excelente. Muitos estudos na literatura médica lidam com um desbalanceamento muito mais severo, frequentemente operando com taxas de eventos na casa dos 10% ou menos (??). Portanto,

essa proporção de 20% nos oferece uma quantidade de exemplos positivos bastante sólida para que o modelo consiga aprender de forma robusta. É um desafio desbalanceamento, mas é um cenário muito mais favorável do que o encontrado em muitos outros estudos, o que aumenta as chances de desenvolver um modelo preditivo eficaz para a morte súbita cardíaca. Para resolver este desbalanceamento, existem diversas técnicas, a que irei utilizar é a Momentum Contrast (MOCO) (HE *et al.*, 2019) que ao adaptado ao modelo de sobrevivência, é uma técnica de aprendizado auto-supervisionado que pode ser utilizada para lidar com o desbalanceamento em conjuntos de dados. O MOCO é projetado para aprender representações robustas e discriminativas, mesmo quando há uma quantidade limitada de exemplos positivos (neste caso, pacientes que sofreram morte súbita cardíaca). Ele funciona criando um banco de memória que armazena representações de amostras anteriores, permitindo que o modelo aprenda a distinguir entre amostras positivas e negativas de forma eficaz. Ao utilizar o MOCO, é possível melhorar a capacidade do modelo de identificar padrões relevantes no ECG relacionados à morte súbita cardíaca, mesmo em um cenário desbalanceado.

Vou usar o subject-info.csv como gabarito antes de usar os sinais de ECG, ou seja, vou usar os dados clínicos e demográficos dos pacientes para treinar modelos com redes neurais comun e depois outros modelo com rede neural mas complexa como Redes Neurais Convolucionais Redes Neurais Convolucionais (CNNs) usar os sinais de ECG nas CNNs para comparar entre os modelos se com ECG os resultados são preciso e melhores ou não é tão relevante. Já os dados csv ja são suficiente para ter um bom resultado, menos custo computacional, e mais fácil de interpretar os resultados, já os sinais de ECG são mais complexos, exigem mais processamento e podem ser mais difíceis de interpretar os resultados, mas podem fornecer informações adicionais que não estão presentes nos dados clínicos e demográficos. Portanto, a escolha entre usar os dados clínicos e demográficos ou os sinais de ECG é dois pontos importante primeiro validação de hipotise, que os sinais de ECG pode encontrar padrões relacionados a morte súbita cardíaca, e segundo é o fato que os dados clínicos e demográficos são exames difíceis de serem encontrados, em todos os pacientes pois são solicitado pelo medico apenas em casos mais graves, alem disso alguns são exames caros ou complicado ao realizar, já os sinais de ECG são mais fáceis de serem encontrados, pois são exames mais comuns e baratos, e podem ser realizados em uma grande variedade de pacientes. Portanto, a escolha entre usar os dados clínicos e demográficos ou os sinais de ECG depende dos objetivos do estudo, dos recursos disponíveis e da viabilidade de obtenção dos dados.

1.3.2 Grande volume dos sinais

O grande volume de dados dos sinais de ECG Holter de 24 horas representa um desafio significativo para o processamento e análise. Cada paciente tem um registro contínuo de sinais de ECG ao longo de um período extenso, o que resulta em uma quantidade massiva de dados a ser processada. O processamento eficiente desses dados requer técnicas avançadas de pré-processamento, como filtragem, segmentação e extração de características relevantes. Além disso, o treinamento de modelos preditivos com esse volume de dados pode ser computacionalmente intensivo, exigindo recursos computacionais robustos e estratégias de otimização para garantir que o modelo possa aprender efetivamente a partir dos sinais sem sobrecarregar os sistemas de processamento. Estão registrado 992 paciente com três derivações de ECG Holter de 24 horas, com uma frequência de amostragem de 200 Hertz (Hz), o que resulta em um total de 17.280.000 pontos de dados por paciente (200 amostras por segundo x 60 segundos por minuto x 60 minutos por hora x 24 horas). Isso significa que, para os 992 pacientes, o volume total de dados de ECG Holter é de aproximadamente, treinar bilhões de pontos de dados (17.280.000 pontos por paciente x 992 pacientes), é inviável processar e analisar esse volume de dados sem uma abordagem eficiente de pré-processamento e extração de características. Para lidar com esse desafio, técnicas de redução de dimensionalidade, como a utilização de redes neurais convolucionais para extrair características relevantes dos sinais, podem ser aplicadas para reduzir o volume de dados enquanto preservam as informações essenciais para a análise preditiva.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Logistic-Hazard

texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto. Texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto

2.2 Resnet-18 1D

texto texto. Texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto

2.3 Momentum Contrast

texto texto. Texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto texto

Alguns autores preferem fazer uma “fundamentação teórica” no segundo capítulo, outros, preferem fazer uma “revisão da literatura”. Entretanto, isto é particular de cada trabalho e o autor deve escolher o título mais adequado para o capítulo. Consultar o orientador é importante para determinar o título apropriado.

Evite começar da seção secundária, ou seja, não passe direto do título do capítulo para o título da seção secundária. Escreva um texto para introduzir as seções subsequentes. Lembre-se de utilizar primeira letra maiúscula quando estiver se referindo a um objeto com numeração específica como capítulo, seção, subseção, figura, tabela, quadro, equação, normalmente, se escreve a primeira letra maiúscula da palavra do objeto seguido do *label*. Por exemplo, a Seção 2.4 explica como fazer citações bibliográficas. Observe no código fonte deste texto como foi feita a referência cruzada. Isso permite enumerar a seção do modo automático o que facilita caso novas seções sejam criadas.

2.4 Citações bibliográficas

Esta frase mostra como citar um livro sobre descargas atmosféricas (NADA, a). Também podem ser citados *sites* como nada (b). Você precisa escrever o código da referência no arquivo "referencia.bib" dentro da pasta "elementos-pos-textuais". Veja esse, onde estão alguns

modo ut

- Proin mattis placerat risus sit amet laoreet. Praesent sapien arcu, maximus ac fringilla efficitur, vulputate faucibus sem. Donec aliquet velit eros, sit amet elementum dolor pharetra eget
- Integer eget mattis libero. Praesent ex velit, pulvinar at massa vel, fermentum dictum mauris. Ut feugiat accumsan augue, et ultrices ipsum euismod vitae
 - Integer non lacinia magna. Aenean tempor lorem tellus, non sodales nisl commodo ut
 - Proin mattis placerat risus sit amet laoreet.

2.6.2 *Uso de siglas*

Para utilizar siglas, primeiro defina a sigla no arquivo "lista-de-abreviaturas-e-siglas" dentro da pasta "1-pre-textuais" com o comando

```
\newacronym{ABNT}{ABNT}{Associação Brasileira de Normas Técnicas}
```

Depois chame a sigla com o comando:

```
\gls{ABNT}
```

Fica assim: Associação Brasileira de Normas Técnicas (ABNT). A primeira vez que o comando é usado para uma determinada sigla, aparece o significado por extenso da sigla com a sua abreviação em seguida. A partir da segunda vez que o comando para uma determinada sigla é usado, aparece apenas a sigla. Por exemplo: ABNT.

Veja o código fonte de outros exemplos: Teste de siglas Tem que Escrever a Sigla no Texto (TEST), outros exemplos de siglas: descargas atmosféricas (DAs), modelo do circuito elétrico global (MCEG). Repare que sempre as siglas estão sendo definidas primeiramente no arquivo "lista-de-abreviaturas-e-siglas".

3 METODOLOGIA

3.1 Modelos de Análise de Sobrevida

A abordagem proposta neste trabalho integra sinais de ECG Holter de 24 horas com variáveis clínicas estruturadas em um modelo híbrido para a estimativa do tempo até o evento. O pipeline é composto por três componentes principais: um encoder convolucional profundo para extração de características dos sinais eletrocardiográficos, uma rede de projeção para as variáveis clínicas e um cabeçote de predição baseado em modelos de tempo discreto.

3.1.1 Pré-treinamento Auto-supervisionado: MoCo

Dado o tamanho reduzido do conjunto de dados disponível — aproximadamente 870 pacientes — aliado ao severo desbalanceamento entre as classes, uma vez que a maioria dos pacientes é censurada e apenas uma parcela reduzida apresentou o evento de interesse (morte súbita cardíaca), o treinamento supervisionado direto da ResNet-18 1D a partir de pesos aleatórios tende a produzir representações de baixa qualidade. Nesse cenário, o modelo supervisionado é exposto a poucos exemplos positivos, dificultando o aprendizado de padrões morfológicos discriminativos no ECG. Para contornar essa dupla limitação — escassez de dados e desbalanceamento —, foi adotada uma estratégia de pré-treinamento auto-supervisionado baseada no *Momentum Contrast* (MoCo v2) (HE *et al.*, 2020; CHEN *et al.*, 2020), antes do treinamento supervisionado para análise de sobrevida.

O MoCo foi originalmente proposto para o aprendizado de representações visuais a partir de imagens (HE *et al.*, 2020), onde duas versões aumentadas de uma mesma imagem — obtidas por recortes aleatórios, distorção de cor e *flipping* horizontal — formam um par positivo, e imagens distintas formam pares negativos. O encoder aprende a aproximar as representações do par positivo no espaço de *embedding* e a afastar as dos pares negativos, sem necessidade de rótulos supervisionados. Essa abordagem permite explorar a totalidade dos dados disponíveis para o aprendizado de representações, inclusive os pacientes censurados, que são descartados ou subaproveitados em estratégias supervisionadas.

A adaptação para sinais de ECG Holter substitui as augmentações visuais por perturbações no domínio temporal, aplicadas diretamente na GPU pelo módulo GPU_ECG_Augmenter com probabilidade de 80%. A cada iteração, duas versões aumentadas do mesmo segmento de ECG de 24.000 amostras — equivalentes a aproximadamente 2 minuto de sinal a 200 Hz, com 3

derivações — são geradas e tratadas como par positivo. O encoder, instanciado pela ResNet-18 1D, aprende representações invariantes às perturbações aplicadas, capturando características morfológicas estruturais do sinal independentemente de qualquer rótulo de evento ou censura. Dessa forma, todos os 870 pacientes contribuem igualmente para o pré-treinamento, mitigando o efeito do desbalanceamento antes mesmo do treinamento supervisionado.

Os pesos do encoder obtidos ao final do pré-treinamento são utilizados para inicializar o encoder do modelo híbrido de análise de sobrevivência, substituindo a inicialização aleatória e fornecendo uma base de representação mais rica para o treinamento supervisionado subsequente.

3.1.1.1 *Aprendizado Contrastivo como Busca em Dicionário*

O MoCo formula o aprendizado de representações como um problema de busca em dicionário (HE *et al.*, 2020). Dado um sinal de consulta (*query*) q e um conjunto de chaves (*keys*) $\{k_0, k_1, k_2, \dots\}$, o objetivo é treinar um encoder de forma que q seja similar à sua chave positiva correspondente k^+ e dissimilar a todas as demais chaves negativas. A função de perda contrastiva utilizada é a InfoNCE (HE *et al.*, 2020):

$$\mathcal{L}_q = -\log \frac{\exp(q \cdot k^+ / \tau)}{\sum_{i=0}^K \exp(q \cdot k_i / \tau)} \quad (3.1)$$

onde τ é um hiperparâmetro de temperatura e K é o número total de chaves no dicionário. Intuitivamente, essa perda corresponde ao logaritmo negativo de um classificador *softmax* de $(K + 1)$ classes, cujo objetivo é identificar k^+ dentre todas as chaves disponíveis.

No contexto deste trabalho, uma *query* e uma chave formam um par positivo quando são versões aumentadas do mesmo segmento de ECG, e um par negativo caso contrário. O encoder aprende, portanto, a produzir representações invariantes às augmentações aplicadas, capturando apenas as características morfológicas estruturais do sinal.

3.1.1.2 *Dicionário Dinâmico com Fila e Encoder com Momento*

A principal contribuição do MoCo é manter o dicionário como uma **fila** de amostras codificadas (HE *et al.*, 2020), desacoplando o tamanho do dicionário do tamanho do *mini-batch*. A cada iteração, o *mini-batch* atual é inserido na fila e o *mini-batch* mais antigo é removido. Isso permite que o dicionário seja muito maior do que o que a memória da GPU comportaria em uma abordagem ponta a ponta (*end-to-end*).

Para garantir a consistência das representações armazenadas na fila, o encoder das chaves f_k não é atualizado por retropropagação, mas sim por uma **atualização com momento** (*momentum update*) a partir do encoder de consulta f_q (HE *et al.*, 2020):

$$\theta_k \leftarrow m \theta_k + (1 - m) \theta_q \quad (3.2)$$

onde $m \in [0, 1)$ é o coeficiente de momento. Somente θ_q é atualizado por retropropagação; θ_k evolui lentamente, garantindo que as chaves armazenadas na fila sejam consistentes entre si, mesmo que tenham sido geradas em iterações diferentes. Neste trabalho, o valor $m = 0,999$ foi adotado, conforme recomendado em (HE *et al.*, 2020).

3.1.1.3 Melhorias do MoCo v2

Com base nas melhorias propostas em (CHEN *et al.*, 2020), duas modificações foram incorporadas ao MoCo original. A primeira consiste na adição de uma cabeça de projeção MLP (*projection head*) entre o encoder e o espaço de representação contrastiva, composta por uma camada linear, ativação ReLU e uma segunda camada linear, mapeando a saída do encoder para um espaço de $d = 256$ dimensões. A segunda consiste no uso de augmentações de dados mais agressivas durante o pré-treinamento. Essas modificações melhoram substancialmente a qualidade das representações aprendidas sem exigir *batches* de grande porte (CHEN *et al.*, 2020).

3.1.1.4 Adaptação para Sinais de ECG

A adaptação do MoCo para sinais de ECG Holter envolve duas mudanças principais em relação à formulação original voltada para imagens. Primeiro, o encoder f_q e o encoder f_k são instâncias da ResNet-18 1D descrita na Seção anterior, operando sobre janelas de sinal de 24.000 amostras (correspondentes a aproximadamente 2 minuto de ECG a 200 Hz) com 3 derivações de entrada. Segundo, as augmentações de dados são adaptadas para o domínio temporal, sendo aplicadas diretamente na GPU por meio do módulo GPU_ECG_Augmenter com probabilidade de 80%, gerando duas “visões” distintas do mesmo segmento de sinal.

Para cada *mini-batch*, as augmentações são aplicadas duas vezes sobre o mesmo sinal de entrada, gerando os pares (x^q, x^k) . As representações são obtidas por $q = f_q(x^q)$ e $k = f_k(x^k)$, e a perda InfoNCE é minimizada conforme a Equação 3.1.

3.1.1.5 Configuração do Treinamento

O pré-treinamento foi conduzido com as seguintes configurações: tamanho do dicionário $K = 8.192$, dimensão do espaço de projeção $d = 256$, coeficiente de momento $m = 0,999$, temperatura $\tau = 0,07$, tamanho do mini-*batch* de 256 amostras e taxa de aprendizado inicial de 0,001 com otimizador SGD (momento = 0,9, *weight decay* = 5×10^{-4}). O agendador *ReduceLROnPlateau* foi utilizado para reduzir a taxa de aprendizado por um fator de 0,5 quando a perda não apresentasse melhora por 30 épocas consecutivas. O treinamento foi interrompido antecipadamente (*early stopping*) após 50 épocas sem melhora na perda média, com um máximo de 500 épocas. Os pesos do encoder f_q obtidos ao final do pré-treinamento são utilizados para inicializar o encoder do modelo híbrido de análise de sobrevivência, substituindo a inicialização aleatória.

3.1.1.6 Escolha do Mecanismo de Aprendizado Contrastivo

O aprendizado contrastivo pode ser instanciado por diferentes mecanismos que diferem na forma como as chaves negativas são mantidas e como o encoder de chaves é atualizado (HE *et al.*, 2020). Três abordagens principais são comparadas na literatura: (i) o mecanismo *end-to-end*, no qual as chaves negativas provêm do mesmo mini-*batch* e são atualizadas por retropropagação; (ii) o *memory bank*, no qual as representações de todas as amostras do conjunto de dados são armazenadas em memória e amostradas aleatoriamente a cada iteração; e (iii) o MoCo, que mantém um dicionário dinâmico como fila e atualiza o encoder de chaves por momento (HE *et al.*, 2020).

A comparação experimental conduzida em (HE *et al.*, 2020) demonstra que o MoCo supera os demais mecanismos sob o protocolo de classificação linear no ImageNet, independentemente do tamanho do dicionário. O mecanismo *end-to-end* é limitado pelo tamanho do mini-*batch* — e portanto pelo tamanho do dicionário de negativos disponível —, enquanto o *memory bank* sofre de inconsistência das representações, pois as chaves armazenadas foram codificadas por diferentes versões do encoder ao longo do treinamento. O MoCo resolve ambos os problemas simultaneamente: o dicionário como fila permite um número grande de negativos sem depender do tamanho do batch, e a atualização com momento garante a consistência das chaves armazenadas (HE *et al.*, 2020).

Adicionalmente, (CHEN *et al.*, 2020) demonstra que duas modificações simples

ao MoCo original — a substituição da cabeça de projeção linear por uma MLP e o uso de augmentações mais agressivas — produzem ganhos substanciais de desempenho sem exigir *batches* de grande porte, superando inclusive o SimCLR com *batches* de até 8.192 amostras. A combinação MoCo + MLP head + augmentação forte, denominada MoCo v2, foi adotada neste trabalho por representar a configuração de melhor desempenho relatada nos artigos originais, mantendo o requisito de viabilidade computacional em uma única GPU.

Os hiperparâmetros foram definidos seguindo as recomendações de (HE *et al.*, 2020) e (CHEN *et al.*, 2020): temperatura $\tau = 0,07$, coeficiente de momento $m = 0,999$ e dimensão do espaço de projeção $d = 256$. O tamanho do dicionário foi fixado em $K = 8.192$, valor que garante um conjunto rico de amostras negativas sem exceder a memória disponível na GPU utilizada.

3.1.2 Pré-treinamento Contrastivo com MoCo

A Figura 4 resume o treinamento contrastivo do encoder por Momentum Contrast (MoCo). O mesmo sinal gera duas visões aumentadas: uma alimenta o codificador query, atualizado por gradiente, e a outra alimenta o codificador key, atualizado por média móvel dos pesos. A perda InfoNCE aproxima pares positivos e afasta a query de chaves negativas armazenadas em uma fila dinâmica.




Figura 4 – Esquema de pré-treinamento MoCo para aprendizado auto-supervisionado de representações do ECG/Holter. O codificador query recebe gradientes diretamente; o codificador key é atualizado por média móvel e alimenta uma fila de exemplos negativos.

3.1.3 Arquitetura Proposta dos Modelos Profundos

Esta seção descreve, em formato de fluxograma, os principais componentes computacionais utilizados no pipeline de modelagem profunda para análise de sobrevivência. Os diagramas foram estruturados a partir de modelos implementados manualmente em PyTorch, contemplando o extrator convolucional ResNet-1D, o pré-treinamento contrastivo MoCo, as formulações de tempo discreto e a arquitetura híbrida final com fusão entre ECG e covariáveis clínicas.

3.1.4 Encoder ResNet-1D para Sinais de ECG

A Figura 5 apresenta o fluxo do encoder ResNet-1D utilizado para extrair representações temporais dos sinais de ECG/Holter com três derivações. A rede preserva a dimensão temporal até a saída do encoder, produzindo um mapa de características tridimensional.




Figura 5 – Fluxo do encoder ResNet-1D utilizado para extração de características convolucionais temporais dos sinais de ECG/Holter. Cada BasicBlock1D contém duas convoluções 1D com normalização em lote e conexão residual.

3.1.5 Arquitetura do Encoder: ResNet-18 1D

A extração de características dos sinais de ECG é realizada por uma versão unidimensional da ResNet-18 (HE *et al.*, 2016), utilizada exclusivamente como *encoder*. O termo *encoder* reflete o fato de que apenas o corpo da rede é empregado — ou seja, somente as camadas convolucionais responsáveis pela extração de representações — sem a camada de classificação

final. Essa abordagem é recorrente na literatura quando se deseja obter um vetor de características compacto para uso em tarefas subsequentes, como a análise de sobrevivência proposta neste trabalho.

3.1.5.1 Da ResNet-18 2D para a ResNet-18 1D

A ResNet-18 original foi proposta para o processamento de imagens bidimensionais (HE *et al.*, 2016), operando sobre tensores de entrada com dimensões $[C, H, W]$, onde C é o número de canais, H a altura e W a largura da imagem. A arquitetura é composta por 18 camadas com parâmetros treináveis: uma convolução inicial com kernel 7×7 , quatro grupos de blocos residuais com 2 blocos cada, e uma camada totalmente conectada (*fully connected*) para classificação (HE *et al.*, 2016).

A adaptação para sinais unidimensionais consiste em substituir todas as operações bidimensionais pelas suas equivalentes 1D, tornando a rede adequada ao processamento de séries temporais. A entrada passa a ter dimensões $[C, L]$, onde C é o número de derivações do ECG — 3 neste trabalho — e L é o comprimento temporal do sinal. Todas as convoluções 2D são substituídas por convoluções 1D, e o *batch normalization* e o *max pooling* são igualmente adaptados para operar sobre a dimensão temporal. Essa estratégia é amplamente consolidada na literatura de sinais biomédicos, com aplicações em ECG de derivação única (HANNUN *et al.*, 2019) e em ECG de 12 derivações (RIBEIRO *et al.*, 2020).

3.1.5.2 Estrutura das 17 Camadas do Encoder

A ResNet-18 é composta originalmente por 17 camadas convolucionais e uma camada totalmente conectada de classificação, totalizando 18 camadas com parâmetros treináveis (HE *et al.*, 2016). Neste trabalho, a camada totalmente conectada foi removida, e o encoder resultante — com **17 camadas convolucionais** — é utilizado exclusivamente como extrator de características, produzindo um vetor de 512 dimensões por amostra ao final do processamento.

A arquitetura do encoder é organizada da seguinte forma:

1. **Camada inicial** (conv1): convolução 1D com 64 filtros e kernel de tamanho 7, com *stride* 2, seguida de normalização em lote (*batch normalization*) e ativação ReLU. Uma camada de *max pooling* com kernel 3 e *stride* 2 reduz adicionalmente a resolução temporal, resultando em uma representação inicial com 64 canais. Essa camada corresponde a **1 camada convolucional**.

2. **Grupo 1** (`layer1`, `conv2_x`): dois blocos residuais com 64 filtros e *stride* 1, mantendo a resolução temporal. Cada bloco contém 2 convoluções, totalizando **4 camadas convolucionais**.
3. **Grupo 2** (`layer2`, `conv3_x`): dois blocos residuais com 128 filtros e *stride* 2, reduzindo a resolução temporal à metade e dobrando a profundidade de representação. Totalizando **4 camadas convolucionais**.
4. **Grupo 3** (`layer3`, `conv4_x`): dois blocos residuais com 256 filtros e *stride* 2, com nova redução temporal e aprofundamento da representação. Totalizando **4 camadas convolucionais**.
5. **Grupo 4** (`layer4`, `conv5_x`): dois blocos residuais com 512 filtros e *stride* 2, produzindo a representação de maior abstração semântica. Totalizando **4 camadas convolucionais**.

Somando todas as contribuições: $1 + 4 + 4 + 4 + 4 = 17$ camadas convolucionais, confirmando a estrutura do encoder utilizado.

Cada bloco residual (`BasicBlock1d`) é composto por duas convoluções 1D de kernel 3, cada uma seguida de normalização em lote e ativação ReLU, com uma conexão de atalho (*skip connection*) que soma a entrada do bloco à sua saída. Quando há incompatibilidade de dimensões entre entrada e saída — o que ocorre nos grupos 2, 3 e 4 devido ao *stride* 2 — uma projeção por convolução 1×1 é aplicada na conexão de atalho para alinhar as dimensões. Ao final do encoder, um *Global Average Pooling* reduz a dimensão temporal, produzindo um vetor fixo de 512 dimensões por amostra, independentemente do comprimento da série de entrada.

3.1.5.3 Justificativa da Escolha da ResNet-18

A escolha da ResNet-18 como backbone é motivada por dois fatores principais. Primeiro, o conjunto de dados disponível é composto por aproximadamente 870 pacientes, um volume moderado para o treinamento de redes convolucionais profundas. Arquiteturas mais profundas, como ResNet-34 ou ResNet-50, tendem a demandar volumes maiores de dados para generalizar adequadamente, tornando a ResNet-18 uma escolha mais equilibrada à escala do problema. Segundo, a adaptação unidimensional da ResNet-18 é amplamente empregada na literatura de sinais biomédicos (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020), demonstrando capacidade suficiente para a extração de padrões morfológicos relevantes em sinais de ECG com múltiplas derivações.

Ao final do encoder, um *Global Average Pooling* reduz a representação temporal

para um vetor fixo de 512 dimensões por amostra, independentemente do comprimento da série de entrada.

3.1.6 *Arquitetura Híbrida Final*

A Figura 6 descreve a arquitetura final usada para combinar sinais ECG/Holter e covariáveis clínicas. O treinamento foi organizado em duas etapas. Primeiro, o encoder ResNet-1D foi pré-treinado de forma auto-supervisionada pelo método MoCo, utilizando apenas o objetivo contrastivo para aprender representações do sinal. Em seguida, os pesos aprendidos nessa etapa foram transferidos para o ramo de ECG da arquitetura híbrida. Na etapa supervisionada, a ResNet-1D inicializada com os pesos do MoCo passou a atuar como extrator de características, sendo treinada em conjunto com a rede de covariáveis clínicas, o módulo de fusão e os cabeçotes de sobrevivência em tempo discreto. O mapa temporal extraído do ECG é agregado por média global no eixo temporal e reduzido por um gargalo denso; em paralelo, as covariáveis clínicas passam por uma rede densa própria. Por fim, os vetores de ECG e de covariáveis são concatenados e enviados ao cabeçote de risco em tempo discreto.

3.1.7 *Módulo de Projeção e Fusão Híbrida*

Para equilibrar a contribuição dos sinais de ECG e das variáveis clínicas na decisão final, ambas as modalidades são projetadas em espaços de mesma dimensão antes da fusão. O vetor de 512 features extraídas pelo encoder é comprimido por um *bottleneck* com as camadas $\text{Linear}(512, 64) \rightarrow \text{BatchNorm} \rightarrow \text{ReLU} \rightarrow \text{Dropout} \rightarrow \text{Linear}(64, 16)$, resultando em um vetor de 16 dimensões.

As variáveis clínicas, compostas por 6 preditores numéricos, são processadas por uma rede densa com as camadas $\text{Linear}(6, 32) \rightarrow \text{BatchNorm} \rightarrow \text{ReLU} \rightarrow \text{Dropout} \rightarrow \text{Linear}(32, 16)$, produzindo igualmente um vetor de 16 dimensões.

Os dois vetores são então concatenados, formando uma representação híbrida de 32 dimensões que integra informação morfológica do ECG com o contexto clínico do paciente.

3.1.8 *Cabeçote de Análise de Sobrevivência*

O vetor fundido de 32 dimensões é processado por um cabeçote de predição composto pelas camadas $\text{Linear}(32, 32) \rightarrow \text{BatchNorm} \rightarrow \text{ReLU} \rightarrow \text{Dropout} \rightarrow \text{Linear}(32, K)$, onde K




Figura 6 – Arquitetura híbrida final: extração de características do sinal por ResNet-1D/MoCo, compressão do ECG em gargalo de 16 dimensões, processamento clínico em paralelo, fusão balanceada e predição de logits para modelos de sobrevivência em tempo discreto.

corresponde ao número de intervalos de tempo discretos definidos pela transformação *LabTrans*. A saída é um vetor de logits, cuja interpretação varia conforme o modelo de sobrevivência selecionado, conforme descrito nas subseções seguintes.

3.1.9 Risco Logístico (*Logistic-Hazard*)

O método *Logistic-Hazard* parametriza diretamente os riscos discretos $h(t_k | \mathbf{x})$ para cada intervalo de tempo k , otimizando a verossimilhança de sobrevivência (KVAMME; BORGAN, 2019; EFRON, 1988). A função de risco discreta é obtida aplicando-se a função sigmoide sobre os logits produzidos pelo cabeçote de predição, e a função de sobrevivência é estimada pelo produto acumulado dos complementos dos riscos em cada intervalo. Este método também é referenciado na literatura como Regressão Logística Parcial (BIGANZOLI *et al.*, 1998) e Nnet-sobrevivência (*Nnet-survival*) (GENSHEIMER; NARASIMHAN, 2019).

3.1.10 Função de Massa de Probabilidade (PMF)

O método PMF parametriza a função de massa de probabilidade do tempo até o evento, otimizando diretamente a verossimilhança de sobrevivência (KVAMME; BORGAN, 2019). A distribuição de probabilidade sobre os intervalos de tempo é obtida aplicando-se a função *softmax* sobre os logits da rede, e a função de sobrevivência é estimada pela soma acumulada reversa dessa distribuição. Este método constitui a base de abordagens como o DeepHit e o MTLR (*Multi-Task Logistic Regression*).

3.1.11 DeepHit

O DeepHit é uma extensão do método PMF que incorpora, além da verossimilhança de sobrevivência, um termo de perda por classificação baseado em *ranking*, capaz de lidar com riscos concorrentes (LEE *et al.*, 2018). A função de perda total é definida como $\mathcal{L} = \mathcal{L}_1 + \alpha \cdot \mathcal{L}_2$, onde $\mathcal{L}_1$ corresponde à log-verossimilhança negativa e $\mathcal{L}_2$ é um termo de *ranking* que penaliza inversões na ordenação do risco entre pares de pacientes com diferentes tempos de evento.

3.1.12 Formulações de Sobrevivência em Tempo Discreto

A Figura 7 apresenta as três formulações de tempo discreto usadas no cabeçote de sobrevivência. A rede híbrida retorna logits brutos para os intervalos temporais; em seguida, cada modelo aplica uma transformação probabilística e uma função de perda específica.




Figura 7 – Transformação dos logits brutos nos três modelos de sobrevivência em tempo discreto: LogisticHazard, PMF e DeepHitSingle.

3.1.13 Discretização do Tempo: Transformação LabTrans

A análise de sobrevivência em tempo discreto requer que o tempo contínuo até o evento seja mapeado em um conjunto finito de K intervalos. Para isso, foi implementada a transformação `DiscreteTimeTransform`, inspirada na *LabTrans* da biblioteca `PyCox` (KVAMME; BORGAN, 2019).

Dado um conjunto de tempos de sobrevivência $\{t_i\}$ e indicadores de evento $\{d_i\}$, os pontos de corte $\mathbf{c} = (c_0, c_1, \dots, c_K)$ são determinados pelos quantis da distribuição dos tempos de evento observados (i.e., $d_i = 1$), com $c_0 = 0$ e c_K fixado acima do maior tempo observado no conjunto. O índice de intervalo de cada observação é então obtido por digitalização (*digitize*), sendo clipado ao intervalo $[0, K - 1]$ para evitar extrapolações. O número de intervalos K é um hiperparâmetro do modelo, definido como `num_durations`.

3.1.14 Função de Perda por Tipo de Paciente

Em dados de sobrevivência, as observações são heterogêneas: parte dos pacientes apresentou o evento de interesse (*uncensored*), enquanto os demais foram censurados, ou seja, perderam o acompanhamento antes do desfecho. Cada modelo de perda trata essas duas populações de forma distinta.

Para o *Logistic-Hazard*, pacientes com evento contribuem com a log-verossimilhança negativa do risco no instante t_i ponderada pela sobrevivência acumulada até $t_i - 1$. Pacientes censurados contribuem apenas com a probabilidade de sobreviver até o instante de censura (KVAMME; BORGAN, 2019). Formalmente:

$$\mathcal{L}_{\text{LH}} = -\frac{1}{N} \sum_{i=1}^N [d_i (\log h_{t_i} + \log S(t_i - 1)) + (1 - d_i) \log S(t_i)] \quad (3.3)$$

onde $h_{t_k} = \sigma(\phi_k)$ é o risco discreto no intervalo k , obtido pela função sigmoide sobre o logit ϕ_k , e $S(t_k) = \prod_{j \leq k} (1 - h_{t_j})$ é a função de sobrevivência estimada.

Para os métodos PMF e DeepHit, a distribuição de probabilidade sobre os intervalos é obtida via *softmax* sobre os logits, com um logit auxiliar nulo concatenado ao final para representar sobrevivência além do horizonte de observação (KVAMME; BORGAN, 2019). Pacientes com evento contribuem com $-\log f(t_i)$, onde $f(t_k)$ é a probabilidade de evento no intervalo k , e pacientes censurados contribuem com $-\log S(t_i^+)$, a probabilidade de sobreviver além do instante de censura.

O DeepHit acrescenta um segundo termo de perda baseado em *ranking* (LEE *et al.*, 2018):

$$\mathcal{L}_{\text{DH}} = \mathcal{L}_1 + \alpha \cdot \mathcal{L}_2 \quad (3.4)$$

onde $\mathcal{L}_2$ penaliza pares de pacientes (i, j) em que $t_i < t_j$ e $d_i = 1$, mas o modelo atribui risco cumulativo menor ao paciente i do que ao paciente j no tempo t_i . A penalidade é suavizada por uma função exponencial com parâmetro σ :

$$\mathcal{L}_2 = \sum_{i:d_i=1} \sum_j \mathbf{1}[t_i < t_j] \cdot \exp\left(-\frac{F(t_i | \mathbf{x}_i) - F(t_i | \mathbf{x}_j)}{\sigma}\right) \quad (3.5)$$

3.1.15 Treinamento: Acumulação de Gradiente e Precisão Mista

O treinamento do modelo foi realizado com duas técnicas complementares para viabilizar o uso de *batches* efetivos maiores sem aumentar o consumo de memória da GPU: acumulação de gradiente (*gradient accumulation*) e precisão mista automática (*Automatic Mixed Precision* — AMP) (??).

Na acumulação de gradiente, os gradientes são acumulados ao longo de `accumulation_steps` iterações antes de cada atualização dos pesos. A função de perda de cada *mini-batch* é dividida por `accumulation_steps` antes da retropropagação, de modo que a magnitude dos gradientes acumulados seja equivalente à de um *batch* de tamanho `batch_size × accumulation_steps`. A atualização dos pesos e o zeragem dos gradientes são realizadas apenas ao final de cada ciclo de acumulação. Ao término do laço de treinamento, um passo final é executado caso restem gradientes não aplicados.

A precisão mista é implementada com o `GradScaler` do PyTorch, que escala dinamicamente a função de perda para evitar *underflow* numérico durante as operações em meia-precisão (`float16`), revertendo para precisão simples (`float32`) nas etapas críticas de atualização. As operações de *forward* e cálculo da perda são executadas dentro de um contexto `autocast`, enquanto a retropropagação e a atualização dos pesos utilizam o escalonamento do `GradScaler`.

3.1.16 Avaliação: C-Index e Agregação de Janelas

A métrica principal de avaliação é o índice de concordância (*C-index*), que mede a capacidade discriminativa do modelo em ordenar corretamente pares de pacientes pelo risco predito (??). O *C-index* varia entre 0,5 (aleatoriedade) e 1,0 (discriminação perfeita), sendo

Definição 3.5.1 *Definimos o produto de ...*

Texto texto texto texto texto texto texto texto texto texto texto texto texto texto.

3.6 Usando Questões

Um exemplo de questionário encontra-se no Apêndice B.

4 RESULTADOS

4.1 Resultados da tabela subject-info.csv

Inicialmente fiz teste com resultados de dados clínicos de pacientes da tabela subject-info.csv (PRABHAKARARAO; MANIMEGALAI, 2020b) para o processo de análise de dados, e usar como gabarito para depois adaptar os sinais ECG, apliquei um modelo de risco proporcional de cox uma técnica de análise bastante utilizada na área da saúde, meus estudos começou pela regressão de cox mas a compreender melhor os dados percebi que para o meu caso o melhor modelo é o LogisticHazard pelo simples fatos que o regressão de cox trabalho com o tempo continuos e o meu trabalho vai trabalhar com tempo discreto, e o modelo de regressão de cox tem a suposição de proporcionalidade dos riscos que não se aplica ao meu caso, já o modelo LogisticHazard é uma extensão do modelo de regressão de cox para o caso de tempo discreto, porem não vou descartar os resultados que obtive com a regressão de cox, pois os resultados me ajudaram a compreender melhor os dados e o processo de análise, e também me ajudaram a compreender melhor o modelo LogisticHazard, e os resultados obtidos com a regressão de cox foram bastante satisfatórios, e me deram uma boa base para continuar meus estudos com o modelo LogisticHazard, a biblioteca CoxPHFitter em python (KVAMME *et al.*, 2019) (NADA, 1) que utiliza métodos de Breslow, que corrige eventos que ocorreram no mesmo intervalo de tempo. David Cox assumiu que o tempo era contínuo, ou seja, era impossível duas pessoas morrerem no exato mesmo milissegundo. Porem é muito comum dois ou mais pacientes terem o evento no mesmo dia. neste caso o método de Breslow é utilizado para corrigir esses eventos que ocorreram no mesmo intervalo de tempo, o estimador de Breslow ele permite que a Regressão de Cox calcule os pesos β mesmo quando a vários eventos no mesmo dia.

Calculo matemático que o modelo CoxPHFitter (NADA, 1) definem a função de risco do modelo de regressão de cox da seguinte forma:

$$\underbrace{h(t|x)}_{\text{hazard}} = \underbrace{\widehat{b_0(t)}}_{\text{baseline hazard}} \underbrace{\exp \left(\sum_{i=1}^n b_i(x_i - \bar{x}_i) \right)}_{\text{log-partial hazard}} \quad (4.1)$$

Onde $b_0(t)$ é a função de risco basal, b_i são os coeficientes de regressão, x_i são as covariáveis e $\bar{x}_i$ são as médias das covariáveis. O modelo de regressão de cox é um modelo sem parâmetros, ou seja, não assume nenhuma forma específica para a função de risco basal, e o

modelo de regressão de cox é um modelo semi-paramétrico, pois assume que a função de risco basal é uma função arbitrária, e o modelo de regressão de cox é um modelo multiplicativo, pois assume que a função de risco é multiplicada pela função de risco basal. Quando é semiparamétrico o método utilizado é Breslow, pois resolve o problema de cox. O modelo de regressão de cox é um modelo de risco proporcional, pois assume que a razão de riscos entre dois indivíduos é constante ao longo do tempo, ou seja, a razão de riscos entre dois indivíduos é dada por:

$$\frac{h(t|x_1)}{h(t|x_2)} = \exp \left(\sum_{i=1}^n b_i(x_{1i} - x_{2i}) \right) \quad (4.2)$$

Classifiquei alguns dados em grupo relevante para covariáveis, dados como holter, eletrocardiogramas holter, eventos condicoes cardiovasculares, dados demograficos clinicos, e outros dados de apoio como idade, gênero, esses vão estar presentes em todos dados porque são relevantes para a análise. Analise se baseie em modelo de risco de cox me retornando taxa de risco, intervalo de confiança, matriz de variâncias, erros padrão, log da verossimilhança, com base nos resultados selecionei algumas coveriaveis relevantes para para o treinar junto com os sinais ECG, e tambem comparar o quanto o modelo melhorou com os dados sinais ECG.

Foram avaliadas variáveis derivadas do Holter em modelos de regressão de Cox. As variáveis *Holter available* e *Holter onset (hh:mm:ss)* foram desconsideradas, pois não agregavam informação analítica relevante nesta amostra. A variável *Longest RR pause (ms)* também foi excluída devido à elevada proporção de valores ausentes.

4.1.1 Resultados do modelo de Cox para dados Holter

As variáveis do Holter utilizadas na análise estão descritas na Tabela 2. As variáveis *Holter available* e *Holter onset* foram desconsideradas por não agregarem informação analítica relevante — todos os pacientes apresentaram valor igual a 1 na primeira, e a segunda corresponde apenas ao horário de início do exame. A variável *Longest RR pause (ms)* também foi excluída em razão da elevada proporção de valores ausentes (aproximadamente 80% da amostra). As demais variáveis consideradas foram: ritmo do Holter (*Holter rhythm*), intervalos RR mínimo, médio, máximo e amplitude (*minimum*, *average*, *maximum* e *RR range*), extrassístoles em dupla (*Extrasystole couplets*), extrassístole ventricular (*Ventricular Extrasystole*), bradicardia (*Bradycardia*) e os índices de variabilidade da frequência cardíaca SDNN, SDANN, RMSSD e pNN50. Apresentam-se abaixo dois modelos: o primeiro com a coorte completa ($n = 992$) e o

Tabela 3 – Modelo de Cox com variáveis do Holter na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.34	1.41	0.99–2.00	0.18	0.06	Não
Idade	0.37	1.44	1.21–1.72	0.09	< 0.005	Sim
Ritmo Holter ^a	0.17	1.18	1.03–1.36	0.07	0.02	Sim
RR mín. (ms)	0.16	1.18	0.86–1.60	0.16	0.31	Não
RR méd. (ms)	-0.03	0.97	0.75–1.25	0.13	0.82	Não
RR máx. (ms)	-0.05	0.95	0.48–1.88	0.35	0.89	Não
Amplitude RR (ms)	0.21	1.24	0.58–2.64	0.39	0.58	Não
Extrasys. em dupla ^b	0.10	1.11	1.02–1.21	0.04	0.02	Sim
Extrassístole vent. ^c	0.20	1.23	1.04–1.45	0.09	0.02	Sim
Bradicardia	-0.03	0.97	0.84–1.14	0.08	0.75	Não
SDNN (ms)	-0.99	0.37	0.15–0.92	0.46	0.03	Sim
SDANN (ms)	0.55	1.73	0.74–4.08	0.44	0.21	Não
RMSSD (ms)	0.27	1.31	0.90–1.91	0.19	0.16	Não
pNN50 (%)	-0.12	0.88	0.60–1.29	0.19	0.53	Não
Concordance	0.68					
Partial AIC	2461.23					
Log-likelihood ratio test	72.27 em 14 g.l.; $-\log_2(p) = 30.32$					

^a Ritmo Holter: ritmo cardíaco registrado no Holter (*Holter rhythm*).

^b Extrasys. em dupla: extrassístoles em dupla (*Extrasystole couplets*).

^c Extrassístole vent.: extrassístole ventricular (*Ventricular Extrasystole*).

4.1.1.1 Resumo dos resultados do modelo de Cox para dados Holter

De modo geral, as duas análises apresentaram resultados consistentes. As variáveis idade, Holter rhythm, Extrasystole couplets, Ventricular Extrasystole e SDNN mantiveram associação estatisticamente significativa com o desfecho nas duas análises. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez dos resultados mesmo após a restrição aos pacientes com três derivações completas. O que isso significa é que mesmo com a restrição dos pacientes com três derivações completas, poderei usar essas restrições aos sinais de ECG, ao um modelo convulocional resnet, essa filtragem é porque alguns dos pacientes não tem as 3 derivações completas, então a filtragem não atrapalha nos resultados.

4.1.2 Resultados do modelo de Cox para dados de eventos e condições cardiovasculares

As variáveis de eventos e condições cardiovasculares selecionadas para os modelos reduzidos foram: número de extrassístoles ventriculares por hora, taquicardia ventricular não sus-

tentada com mais de dez batimentos (*Non-sustained ventricular tachycardia*, $CH > 10$), número de extrassístoles supraventriculares em 24 horas e taquiarritmia supraventricular paroxística (*Paroxysmal supraventricular tachyarrhythmia*). As variáveis gênero e idade foram incluídas em todos os modelos como covariáveis de controle padrão.

Para dados de eventos e condições cardiovasculares apresentaram resultados consistentes. Em ambas as análises, apenas idade e taquicardia ventricular não sustentada ($CH > 10$) mantiveram associação estatisticamente significativa com o desfecho. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez dos resultados mesmo após a restrição aos pacientes com três derivações completas. Apresentam-se abaixo dois modelos: o primeiro com a coorte completa ($n = 992$) e o segundo com a amostra filtrada para pacientes com as três derivações completas ($n = 898$).

Tabela 4 – Modelo de Cox com variáveis arrítmicas na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	<i>p</i>	Significância
Gênero	0.24	1.27	0.92–1.77	0.17	0.15	Não
Idade	0.35	1.42	1.21–1.67	0.08	< 0.005	Sim
VE/h ^a	0.02	1.02	0.90–1.16	0.06	0.77	Não
TVNS (CH>10) ^b	0.60	1.83	1.32–2.53	0.17	< 0.005	Sim
SVE/24h ^c	-0.01	0.99	0.88–1.13	0.06	0.93	Não
TASVP ^d	0.11	1.12	0.98–1.28	0.07	0.11	Não
Concordance				0.64		
Partial AIC				2718.25		
Log-likelihood ratio test		53.45 em 6 g.l.; $-\log_2(p) = 29.97$				

^a VE/h: número de extrassístoles ventriculares por hora.

^b TVNS: taquicardia ventricular não sustentada ($CH > 10$ batimentos).

^c SVE/24h: número de extrassístoles supraventriculares em 24 horas.

^d TASVP: taquiarritmia supraventricular paroxística.

Tabela 5 – Modelo de Cox com variáveis arrítmicas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.30	1.36	0.96–1.92	0.18	0.09	Não
Idade	0.39	1.48	1.25–1.76	0.09	< 0.005	Sim
VE/h ^a	0.02	1.02	0.90–1.16	0.07	0.76	Não
TVNS (CH>10) ^b	0.56	1.75	1.25–2.44	0.17	< 0.005	Sim
SVE/24h ^c	-0.02	0.98	0.86–1.12	0.07	0.82	Não
TASVP ^d	0.11	1.12	0.97–1.28	0.07	0.12	Não
Concordance	0.65					
Partial AIC	2464.70					
Log-likelihood ratio test	52.80 em 6 g.l.; $-\log_2(p) = 29.53$					

^a VE/h: número de extrassístoles ventriculares por hora.^b TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).^c SVE/24h: número de extrassístoles supraventriculares em 24 horas.^d TASVP: taquiarritmia supraventricular paroxística.

4.1.3 Resultados do modelo de Cox para dados demográficos clínicos

As variáveis demográficas e clínicas avaliadas foram: peso corporal (*Weight*, kg), altura (*Height*, cm), índice de massa corporal (IMC, kg/m²) e classe funcional da New York Heart Association (NYHA). As variáveis idade e gênero, embora pertençam a este grupo, foram excluídas desta listagem específica por já estarem presentes como covariáveis de controle em todos os modelos analisados.

Tabela 6 – Modelo de Cox com dados clínicos e antropométricos na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.65	1.92	1.28–2.88	0.21	< 0.005	Sim
Idade	0.29	1.34	1.14–1.57	0.08	< 0.005	Sim
Peso (kg)	0.03	1.03	0.25–4.26	0.72	0.97	Não
Altura (cm)	-0.23	0.79	0.34–1.83	0.43	0.59	Não
IMC ^a	-0.26	0.77	0.23–2.58	0.62	0.67	Não
Classe NYHA	0.93	2.54	1.90–3.39	0.15	< 0.005	Sim
Concordance	0.67					
Partial AIC	2693.46					
Log-likelihood ratio test	78.24 em 6 g.l.; $-\log_2(p) = 46.79$					

^a IMC: índice de massa corporal (kg/m²).

Tabela 7 – Modelo de Cox com dados clínicos e antropométricos na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.74	2.09	1.37–3.20	0.22	< 0.005	Sim
Idade	0.33	1.38	1.17–1.64	0.09	< 0.005	Sim
Peso (kg)	0.15	1.16	0.27–5.05	0.75	0.85	Não
Altura (cm)	-0.32	0.73	0.31–1.73	0.44	0.47	Não
IMC ^a	-0.36	0.70	0.20–2.45	0.64	0.58	Não
Classe NYHA	0.93	2.53	1.87–3.41	0.15	< 0.005	Sim
Concordance	0.68					
Partial AIC	2438.61					
Log-likelihood ratio test	78.89 em 6 g.l.; $-\log_2(p) = 47.23$					

^a IMC: índice de massa corporal (kg/m^2).

As duas análises apresentaram resultados consistentes. Em ambas as análises, gênero, idade e classe funcional da NYHA mantiveram associação estatisticamente significativa com o desfecho. As variáveis antropométricas peso, altura e índice de massa corporal não apresentaram associação significativa em nenhuma das coortes. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez desses resultados mesmo após a restrição aos pacientes com três derivações completas.

4.1.4 Resultados do modelo de Cox para dados eletrocardiograma de alta resolução

As variáveis derivadas do eletrocardiograma de alta resolução consideradas na análise foram: disponibilidade do ECG de alta resolução (*High-resolution ECG available*), ritmo do ECG (*ECG rhythm*), presença de ondas Q de necrose (*Q-waves*, $\text{sim} = 1$), intervalo PR (*PR interval*, ms), duração do complexo QRS (*QRS duration*, ms), presença de QRS superior a 120 ms (*QRS > 120 ms*), intervalo QT (*QT interval*, ms), QT corrigido (*QT corrected*), hipertrofia ventricular esquerda (*Left ventricular hypertrophy*, $\text{sim} = 1$) e distúrbio de condução intraventricular (*Intraventricular conduction disorder*).

Tabela 8 – Modelo de Cox com variáveis eletrocardiográficas na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.24	1.27	0.91–1.77	0.17	0.16	Não
Idade	0.35	1.42	1.21–1.67	0.08	< 0.005	Sim
ECG-AR ^a	0.22	1.24	0.90–1.71	0.16	0.19	Não
Ritmo ECG	0.12	1.12	0.97–1.30	0.08	0.13	Não
Ondas Q ^b	0.71	2.03	1.49–2.76	0.16	< 0.005	Sim
Intervalo PR (ms)	0.17	1.19	1.04–1.36	0.07	0.01	Sim
Duração QRS (ms)	0.14	1.15	0.86–1.52	0.14	0.35	Não
QRS > 120 ms	0.10	1.11	0.67–1.84	0.26	0.68	Não
Intervalo QT (ms)	-0.28	0.75	0.63–0.90	0.09	< 0.005	Sim
QT corrigido	0.17	1.18	0.99–1.41	0.09	0.07	Não
HVE ^c	0.11	1.11	0.81–1.52	0.16	0.50	Não
DCI ^d	0.11	1.12	0.97–1.29	0.07	0.13	Não
Concordance	0.67					
Partial AIC	2707.27					
Log-likelihood ratio test	76.43 em 12 g.l.; $-\log_2(p) = 35.56$					

^a ECG-AR: ECG de alta resolução disponível.

^b Ondas Q: presença de ondas Q de necrose (sim = 1).

^c HVE: hipertrofia ventricular esquerda (sim = 1).

^d DCI: distúrbio de condução intraventricular.

Tabela 9 – Modelo de Cox com variáveis eletrocardiográficas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.29	1.34	0.94–1.89	0.18	0.10	Não
Idade	0.39	1.48	1.25–1.76	0.09	< 0.005	Sim
ECG-AR ^a	0.21	1.23	0.86–1.75	0.18	0.26	Não
Ritmo ECG	0.14	1.15	0.99–1.35	0.08	0.07	Não
Ondas Q ^b	0.71	2.02	1.47–2.80	0.16	< 0.005	Sim
Intervalo PR (ms)	0.17	1.18	1.03–1.37	0.07	0.02	Sim
Duração QRS (ms)	0.07	1.07	0.80–1.44	0.15	0.64	Não
QRS > 120 ms	0.24	1.27	0.76–2.14	0.27	0.36	Não
Intervalo QT (ms)	-0.28	0.75	0.63–0.91	0.09	< 0.005	Sim
QT corrigido	0.14	1.15	0.95–1.38	0.10	0.15	Não
HVE ^c	0.06	1.06	0.77–1.48	0.17	0.71	Não
DCI ^d	0.10	1.11	0.95–1.29	0.08	0.19	Não
Concordance	0.68					
Partial AIC	2453.52					
Log-likelihood ratio test	75.98 em 12 g.l.; $-\log_2(p) = 35.28$					

^a ECG-AR: ECG de alta resolução disponível.

^b Ondas Q: presença de ondas Q de necrose (sim = 1).

^c HVE: hipertrofia ventricular esquerda (sim = 1).

^d DCI: distúrbio de condução intraventricular.

As duas análises apresentaram resultados consistentes. Em ambas as análises, idade, presença de ondas Q, intervalo PR e intervalo QT mantiveram associação estatisticamente significativa com o desfecho. Especificamente, ondas Q e intervalo PR associaram-se a maior risco, enquanto o intervalo QT apresentou associação inversa com o desfecho. As demais variáveis eletrocardiográficas, incluindo disponibilidade de ECG de alta resolução, ritmo no ECG, duração do QRS, QRS maior que 120 ms, QT corrigido, hipertrofia ventricular esquerda e distúrbio de condução intraventricular, não apresentaram associação significativa em nenhuma das coortes.

Foram analisadas 32 variáveis candidatas ao modelo de Cox, abrangendo dados demográficos, Holter, eletrocardiográficos e de eventos cardiovasculares. A análise foi conduzida em três etapas: (i) regressão de Cox univariável com teste log-rank e cálculo do índice de concordância (C-index) para cada variável individualmente; (ii) avaliação de multicolinearidade pelo fator de inflação da variância (VIF); e (iii) regressão de Cox multivariável com as variáveis que apresentaram $p < 0,05$ na etapa univariável.

Tabela 10 – Análise de Cox univariável — coeficiente, razão de risco, C-index e significância por variável ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	p (Cox)	C-index	p (log-rank)
<i>Significativas ($p < 0,05$)</i>						
NYHA class	0.96	2.61	1.96–3.47	< 0.005	0.595	< 0.005
Idade	0.39	1.48	1.27–1.73	< 0.005	0.598	< 0.005
TVNS (CH >10) ^a	0.75	2.11	1.60–2.78	< 0.005	0.585	< 0.005
SDANN (ms)	-0.30	0.74	0.64–0.86	< 0.005	0.431	< 0.005
SDNN (ms)	-0.30	0.74	0.64–0.86	< 0.005	0.431	< 0.005
Ondas Q (necrose) ^b	0.52	1.68	1.27–2.22	< 0.005	0.559	< 0.005
Extrasys. em dupla ^c	0.14	1.15	1.07–1.24	< 0.005	0.614	< 0.005
Peso (kg)	-0.26	0.77	0.67–0.89	< 0.005	0.428	0.029
TASVP ^d	0.22	1.25	1.10–1.42	< 0.005	0.556	< 0.005
Extrassístole ventricular	0.28	1.33	1.13–1.56	< 0.005	0.558	—
Duração do QRS (ms)	0.20	1.22	1.08–1.39	0.002	0.570	0.003
VE/h ^e	0.14	1.15	1.05–1.27	0.002	0.597	< 0.005
DCI ^f	0.20	1.22	1.07–1.38	0.002	0.573	0.056
QRS > 120 ms	0.41	1.51	1.15–1.99	0.003	0.552	0.003
IMC (kg/m ²)	-0.22	0.81	0.70–0.93	0.004	0.440	0.020
Ritmo do Holter	0.17	1.19	1.06–1.34	0.004	0.553	0.001
Intervalo PR (ms)	0.19	1.21	1.06–1.37	0.004	0.555	0.532
Ritmo do ECG	0.16	1.18	1.04–1.33	0.007	0.554	< 0.005
QT corrigido	0.14	1.15	1.01–1.32	0.035	0.553	0.021
<i>Não significativas ($p \geq 0,05$)</i>						
ECG alta resolução ^g	0.27	1.31	0.96–1.80	0.088	0.525	—
Altura (cm)	-0.11	0.89	0.78–1.02	0.097	0.459	0.018
Gênero	0.24	1.28	0.92–1.76	0.139	0.522	—
RR mínimo (ms)	0.10	1.11	0.97–1.26	0.141	0.530	0.089
SVE/24h ^h	0.07	1.07	0.97–1.19	0.181	0.564	< 0.005
pNN50 (%)	-0.08	0.93	0.79–1.08	0.326	0.489	0.223
HVE ⁱ	0.10	1.10	0.81–1.50	0.536	0.511	0.536
Intervalo QT (ms)	-0.03	0.97	0.85–1.12	0.687	0.490	0.906
Bradicardia	-0.02	0.98	0.85–1.13	0.774	0.499	0.920
RR máximo (ms)	-0.02	0.98	0.85–1.13	0.803	0.474	0.157
Amplitude RR (ms)	-0.01	0.99	0.86–1.14	0.894	0.478	0.365
RR médio (ms)	-0.01	0.99	0.87–1.14	0.931	0.497	0.503
RMSSD (ms)	-0.00	1.00	0.87–1.14	0.951	0.505	0.514

^a TVNS: taquicardia ventricular não sustentada (CH >10 batimentos).^b Ondas Q: presença de ondas Q de necrose (sim = 1).^c Extrasys. em dupla: *Extrasystole couplets*.^d TASVP: taquiarritmia supraventricular paroxística.^e VE/h: número de extrassístoles ventriculares por hora.^f DCI: distúrbio de condução intraventricular.^g ECG alta resolução: disponibilidade do ECG de alta resolução.^h SVE/24h: número de extrassístoles supraventriculares em 24 horas.ⁱ HVE: hipertrofia ventricular esquerda (sim = 1).HR: razão de risco (*hazard ratio*); IC 95%: intervalo de confiança de 95%; C-index: índice de concordância; —: valor não disponível.

Tabela 11 – Fator de inflação da variância (VIF) — avaliação de multicolinearidade entre as variáveis candidatas.

Variável	VIF	Alerta
<i>Alta multicolinearidade ($VIF > 10$) — excluídas do modelo</i>		
Peso (kg)	85.15	Alta
IMC (kg/m ²)	62.50	Alta
SDNN (ms)	32.31	Alta
Altura (cm)	32.09	Alta
SDANN (ms)	27.95	Alta
<i>Multicolinearidade moderada ($5 < VIF \leq 10$) — uso com cautela</i>		
RMSSD (ms)	6.77	Moderada
RR máximo (ms)	6.37	Moderada
pNN50 (%)	6.23	Moderada
Ritmo do Holter	6.11	Moderada
Amplitude RR (ms)	6.04	Moderada
TASVP ^a	5.54	Moderada
Duração do QRS (ms)	5.03	Moderada
<i>Multicolinearidade aceitável ($VIF \leq 5$)</i>		
Ritmo do ECG	4.70	Aceitável
RR médio (ms)	3.89	Aceitável
QRS > 120 ms	3.77	Aceitável
RR mínimo (ms)	3.32	Aceitável
VE/h ^b	3.05	Aceitável
Intervalo QT (ms)	3.01	Aceitável
QT corrigido	2.51	Aceitável
Extrasys. em dupla ^c	2.36	Aceitável
TVNS (CH>10) ^d	1.78	Aceitável
Gênero	1.66	Aceitável
Idade	1.37	Aceitável
Extrassístole ventricular	1.29	Aceitável
DCI ^e	1.27	Aceitável
ECG alta resolução	1.24	Aceitável
Ondas Q (necrose)	1.17	Aceitável
Intervalo PR (ms)	1.13	Aceitável
NYHA class	1.10	Aceitável
Bradycardia	1.10	Aceitável
SVE/24h ^f	1.09	Aceitável
HVE ^g	1.07	Aceitável

^a TASVP: taquiarritmia supraventricular paroxística.^b VE/h: extrassístoles ventriculares por hora.^c Extrasys. em dupla: *Extrasystole couplets*.^d TVNS: taquicardia ventricular não sustentada (CH>10).^e DCI: distúrbio de condução intraventricular.^f SVE/24h: extrassístoles supraventriculares em 24 horas.^g HVE: hipertrofia ventricular esquerda.

Tabela 12 – Análise de Cox multivariável — variáveis com $p < 0,05$ na análise univariável ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
NYHA class	0.72	2.05	1.53–2.76	0.15	< 0.005	Sim
Idade	0.22	1.25	1.05–1.47	0.09	0.01	Sim
TVNS (CH>10) ^a	0.48	1.61	1.13–2.30	0.18	0.01	Sim
Ondas Q (necrose) ^b	0.60	1.82	1.35–2.47	0.15	< 0.005	Sim
Extrasys. em dupla ^c	0.16	1.17	1.02–1.35	0.07	0.03	Sim
TASVP ^d	0.27	1.31	1.04–1.64	0.12	0.02	Sim
DCI ^e	0.13	1.14	0.98–1.31	0.07	0.08	Não
Intervalo PR (ms)	0.13	1.13	0.99–1.30	0.07	0.07	Não
SDNN (ms)	-0.28	0.76	0.38–1.51	0.35	0.43	Não
SDANN (ms)	0.03	1.03	0.51–2.08	0.36	0.93	Não
Peso (kg)	-0.13	0.88	0.69–1.12	0.12	0.28	Não
IMC (kg/m ²)	-0.10	0.90	0.71–1.14	0.12	0.40	Não
Extrassístole ventricular	0.10	1.10	0.92–1.32	0.09	0.28	Não
VE/h ^f	-0.10	0.90	0.74–1.10	0.10	0.32	Não
Duração do QRS (ms)	0.11	1.11	0.83–1.48	0.15	0.47	Não
QRS > 120 ms	0.04	1.04	0.63–1.73	0.26	0.88	Não
Ritmo do Holter	-0.16	0.86	0.64–1.14	0.15	0.29	Não
Ritmo do ECG	0.03	1.03	0.79–1.33	0.13	0.84	Não
QT corrigido	-0.02	0.98	0.83–1.15	0.09	0.78	Não
Concordance	0.72 (C-index multivariável: 0.718)					
Partial AIC	2667.02					
Log-likelihood ratio test	130.68 em 19 g.l.; $-\log_2(p) = 59.68$					

^a TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).

^b Ondas Q: presença de ondas Q de necrose (sim = 1).

^c Extrasys. em dupla: *Extrasystole couplets*.

^d TASVP: taquiarritmia supraventricular paroxística.

^e DCI: distúrbio de condução intraventricular.

^f VE/h: extrassístoles ventriculares por hora.

HR: razão de risco; IC 95%: intervalo de confiança de 95%; EP: erro padrão.

De modo geral, o modelo multivariável apresentou poder discriminatório satisfatório (Concordance = 0,72). As variáveis que mantiveram associação estatisticamente significativa após o ajuste multivariável foram: classe funcional NYHA, idade, taquicardia ventricular não sustentada (CH>10), presença de ondas Q de necrose, extrassístoles em dupla e taquiarritmia supraventricular paroxística. As demais variáveis, incluindo aquelas com alta multicolinearidade (SDNN, SDANN, peso e IMC), perderam significância após o ajuste conjunto, o que é esperado em modelos com variáveis correlacionadas.

Apresentam-se a seguir os resultados da mesma análise conduzida para a amostra

filtrada com pacientes que possuem as três derivações completas ($n = 898$; 189 eventos), com o objetivo de verificar se a restrição imposta pela filtragem impacta os resultados obtidos na coorte completa.

Tabela 13 – Análise de Cox univariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	p (Cox)	C-index	p (log-rank)
<i>Significativas ($p < 0,05$)</i>						
NYHA class	0.97	2.64	1.97–3.55	< 0.005	0.598	< 0.005
Idade	0.43	1.53	1.30–1.81	< 0.005	0.608	< 0.005
TVNS (CH>10) ^a	0.71	2.04	1.53–2.72	< 0.005	0.583	< 0.005
SDNN (ms)	-0.31	0.74	0.63–0.86	< 0.005	0.428	< 0.005
SDANN (ms)	-0.31	0.73	0.63–0.86	< 0.005	0.429	< 0.005
Extrasys. em dupla ^b	0.14	1.15	1.06–1.25	< 0.005	0.613	< 0.005
Ondas Q (necrose) ^c	0.51	1.66	1.24–2.21	< 0.005	0.557	< 0.005
Peso (kg)	-0.26	0.77	0.66–0.90	< 0.005	0.427	0.030
TASVP ^d	0.23	1.25	1.10–1.43	< 0.005	0.555	< 0.005
Extrassístole vent. ^e	0.27	1.32	1.11–1.56	0.001	0.558	—
DCI ^f	0.21	1.23	1.08–1.41	0.002	0.575	0.042
QRS > 120 ms	0.43	1.54	1.16–2.05	0.003	0.555	0.003
Ritmo ECG	0.18	1.20	1.06–1.36	0.003	0.559	< 0.005
VE/h ^g	0.14	1.15	1.05–1.27	0.005	0.597	< 0.005
Ritmo Holter	0.18	1.20	1.06–1.35	0.005	0.554	0.001
Intervalo PR (ms)	0.19	1.21	1.06–1.39	0.006	0.554	0.718
IMC ^h	-0.21	0.81	0.70–0.94	0.006	0.440	0.019
Duração QRS (ms)	0.19	1.21	1.06–1.38	0.006	0.569	< 0.005
<i>Não significativas ($p \geq 0,05$)</i>						
Gênero	0.29	1.34	0.95–1.88	0.092	0.527	—
Altura (cm)	-0.12	0.89	0.77–1.02	0.092	0.460	0.038
RR mín. (ms)	0.12	1.12	0.98–1.29	0.101	0.532	0.120
QT corrigido	0.11	1.12	0.97–1.29	0.118	0.542	0.042
ECG-AR ⁱ	0.27	1.31	0.93–1.85	0.129	0.522	—
SVE/24h ^j	0.06	1.07	0.95–1.19	0.254	0.564	0.003
pNN50 (%)	-0.08	0.93	0.79–1.09	0.349	0.489	0.193
Intervalo QT (ms)	-0.05	0.95	0.82–1.10	0.490	0.481	0.852
Amplitude RR (ms)	-0.04	0.96	0.83–1.11	0.587	0.469	0.243
HVE ^k	0.03	1.03	0.75–1.43	0.837	0.505	0.837
Bradicardia	-0.01	0.99	0.85–1.14	0.866	0.501	0.934
RR máx. (ms)	-0.01	0.99	0.85–1.15	0.884	0.478	0.108
RMSSD (ms)	-0.01	0.99	0.86–1.14	0.920	0.505	0.438
RR méd. (ms)	0.00	1.00	0.87–1.16	0.959	0.499	0.383

^a TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).

^b Extrasys. em dupla: extrassístoles em dupla (*Extrasystole couplets*).

^c Ondas Q: presença de ondas Q de necrose (sim = 1).

^d TASVP: taquiarritmia supraventricular paroxística.

^e Extrassístole vent.: extrassístole ventricular.

^f DCI: distúrbio de condução intraventricular.

^g VE/h: extrassístoles ventriculares por hora.

^h IMC: índice de massa corporal (kg/m^2).

ⁱ ECG-AR: ECG de alta resolução disponível.

^j SVE/24h: extrassístoles supraventriculares em 24 horas.

^k HVE: hipertrofia ventricular esquerda (sim = 1).

HR: razão de risco; IC 95%: intervalo de confiança de 95%; C-index: índice de concordância; —: valor não

Tabela 14 – Fator de inflação da variância (VIF) — amostra filtrada com três derivações completas ($n = 898$).

Variável	VIF	Alerta
<i>Alta multicolinearidade ($VIF > 10$) — excluídas do modelo</i>		
Peso (kg)	82.03	Alta
IMC (kg/m^2)	60.05	Alta
SDNN (ms)	32.56	Alta
Altura (cm)	30.80	Alta
SDANN (ms)	28.16	Alta
Amplitude RR (ms)	19.56	Alta
RR máx. (ms)	17.17	Alta
<i>Multicolinearidade moderada ($5 < VIF \leq 10$) — uso com cautela</i>		
RMSSD (ms)	6.82	Moderada
Ritmo Holter	6.38	Moderada
pNN50 (%)	6.27	Moderada
Ritmo ECG	5.65	Moderada
TASVP ^a	5.63	Moderada
Duração QRS (ms)	5.08	Moderada
<i>Multicolinearidade aceitável ($VIF \leq 5$)</i>		
RR mín. (ms)	4.93	Aceitável
RR méd. (ms)	4.01	Aceitável
QRS > 120 ms	3.75	Aceitável
Intervalo QT (ms)	3.16	Aceitável
VE/h ^b	3.03	Aceitável
QT corrigido	2.64	Aceitável
Extrasys. em dupla ^c	2.36	Aceitável
TVNS (CH >10) ^d	1.76	Aceitável
Gênero	1.66	Aceitável
Idade	1.40	Aceitável
DCI ^e	1.30	Aceitável
Extrassístole vent.	1.26	Aceitável
Ondas Q (necrose)	1.19	Aceitável
Intervalo PR (ms)	1.14	Aceitável
ECG-AR ^f	1.11	Aceitável
NYHA class	1.11	Aceitável
Bradycardia	1.10	Aceitável
SVE/24h ^g	1.09	Aceitável
HVE ^h	1.08	Aceitável

^a TASVP: taquiarritmia supraventricular paroxística.^b VE/h: extrassístoles ventriculares por hora.^c Extrasys. em dupla: *Extrasystole couplets*.^d TVNS: taquicardia ventricular não sustentada (CH >10).^e DCI: distúrbio de condução intraventricular.^f ECG-AR: ECG de alta resolução disponível.^g SVE/24h: extrassístoles supraventriculares em 24 horas.^h HVE: hipertrofia ventricular esquerda.

Tabela 15 – Análise de Cox multivariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
NYHA class	0.72	2.05	1.51–2.79	0.16	< 0.005	Sim
Idade	0.25	1.28	1.08–1.53	0.09	< 0.005	Sim
TVNS (CH>10) ^a	0.42	1.53	1.06–2.21	0.19	0.02	Sim
Ondas Q (necrose) ^b	0.61	1.84	1.34–2.52	0.16	< 0.005	Sim
Extrasys. em dupla ^c	0.16	1.18	1.01–1.36	0.07	0.03	Sim
TASVP ^d	0.22	1.25	0.99–1.58	0.12	0.06	Não
Intervalo PR (ms)	0.13	1.14	0.99–1.32	0.07	0.07	Não
DCI ^e	0.11	1.12	0.96–1.30	0.08	0.15	Não
SDNN (ms)	-0.29	0.75	0.37–1.53	0.37	0.43	Não
SDANN (ms)	0.03	1.03	0.50–2.14	0.37	0.93	Não
Peso (kg)	-0.13	0.88	0.69–1.13	0.13	0.33	Não
IMC (kg/m ²)	-0.10	0.91	0.71–1.16	0.12	0.44	Não
Extrassístole vent.	0.09	1.09	0.91–1.31	0.09	0.35	Não
VE/h ^f	-0.10	0.91	0.74–1.12	0.11	0.36	Não
Ritmo Holter	-0.20	0.82	0.59–1.15	0.17	0.25	Não
QRS > 120 ms	0.20	1.22	0.72–2.07	0.27	0.46	Não
Ritmo ECG	0.13	1.14	0.84–1.56	0.16	0.40	Não
Duração QRS (ms)	-0.00	1.00	0.76–1.31	0.14	0.99	Não
Concordance	0.72 (C-index multivariável: 0.718)					
Partial AIC	2418.97					
Log-likelihood ratio test	122.53 em 18 g.l.; $-\log_2(p) = 55.99$					

^a TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).

^b Ondas Q: presença de ondas Q de necrose (sim = 1).

^c Extrasys. em dupla: *Extrasystole couplets*.

^d TASVP: taquiarritmia supraventricular paroxística.

^e DCI: distúrbio de condução intraventricular.

^f VE/h: extrassístoles ventriculares por hora.

HR: razão de risco; IC 95%: intervalo de confiança de 95%; EP: erro padrão.

Os resultados da amostra filtrada ($n = 898$) foram amplamente consistentes com os da coorte completa ($n = 992$). Na análise univariável, 18 variáveis apresentaram associação significativa ($p < 0,05$), em comparação com 19 na coorte completa — a única diferença foi a ausência de significância para o QT corrigido na amostra filtrada. O padrão de multicolinearidade foi semelhante, com dois grupos adicionais de alta colinearidade (amplitude RR e RR máximo, com $VIF > 10$) identificados na amostra filtrada. No modelo multivariável, as mesmas variáveis principais mantiveram significância: NYHA class, idade, TVNS (CH>10), ondas Q de necrose e extrassístoles em dupla. O C-index multivariável permaneceu idêntico (0,718), confirmando a

robustez dos resultados após a filtragem.

4.2 Modelos de Aprendizado Profundo para Sobrevivência

Aqui são apresentados os resultados dos modelos de sobrevivência profunda treinados com os mesmos conjuntos de covariáveis utilizados na análise de Cox, tanto para a coorte completa ($n = 992$) quanto para a amostra filtrada ($n = 898$). Os modelos avaliados foram: LogisticHazard, PMF e DeepHitSingle, utilizando a implementação disponível na biblioteca `pycox`.

4.2.1 Sobre *LogisticHazard*

4.2.2 Sobre *PMF*

4.2.3 Sobre *DeepHitSingle*

A Tabela 16 resume o desempenho dos modelos de sobrevivência profunda segundo o tipo de colunas utilizado, a filtragem dos pacientes com ECG, e as principais métricas de discriminação e calibração. Em todos os experimentos, foram utilizados *batch size* de 256 e *dropout* de 0,5.

Tabela 16 – Desempenho dos modelos de sobrevivência profunda segundo o conjunto de covariáveis e a disponibilidade de ECG dos pacientes.

Modelo	Covariáveis ^a	Coorte ^b	C-index	Brier	NBLL	Loss (treino)	Loss (val.)	Época
<i>Holter (H)</i>								
LogisticHazard	H	C992	0,5300	0,1782	0,5790	1,1192	1,0597	28
PMF	H	C992	0,6062	0,1740	0,5631	0,9059	1,1039	46
DeepHitSingle	H	C992	0,6239	0,1784	0,5633	0,3410	0,3653	59
LogisticHazard	H	C898	0,6257	0,1756	0,5618	1,5659	1,0911	34
PMF	H	C898	0,6848	0,1670	0,5260	0,9912	1,0724	41
DeepHitSingle	H	C898	0,7234	0,1661	0,5265	0,3352	0,3428	99
<i>Eletrocardiogramas Holter (EH)</i>								
LogisticHazard	EH	C992	0,6089	0,1732	0,5706	1,0588	1,0645	50
PMF	EH	C992	0,6086	0,1676	0,5579	0,9864	1,0542	49
DeepHitSingle	EH	C992	0,5721	0,1775	0,5686	0,3353	0,3463	69
LogisticHazard	EH	C898	0,5699	0,1797	0,5759	0,9176	1,1579	29
PMF	EH	C898	0,6145	0,1709	0,5400	1,0422	1,1741	39
DeepHitSingle	EH	C898	0,5896	0,1930	0,5958	0,3483	0,3810	69
<i>Eventos e Condições Cardiovasculares (EC)</i>								
LogisticHazard	EC	C992	0,5656	0,1771	0,5667	1,1943	1,1249	27
PMF	EC	C992	0,5897	0,1767	0,5760	1,0138	1,0853	41
DeepHitSingle	EC	C992	0,5812	0,2896	0,8420	0,6048	0,4321	30
LogisticHazard	EC	C898	0,6412	0,1682	0,5448	1,0169	1,2437	28
PMF	EC	C898	0,7151	0,1664	0,5137	1,0058	1,2551	33
DeepHitSingle	EC	C898	0,7000	0,2567	0,7409	0,4386	0,6774	34
<i>Conjunto de Covariáveis Prognósticas Seleccionadas (CPS)^c</i>								
LogisticHazard	CPS	C992	0,6464	0,1672	0,5553	1,0285	1,0508	69
PMF	CPS	C992	0,5840	0,1720	0,5726	0,9828	1,0793	36
DeepHitSingle	CPS	C992	0,6175	0,1726	0,5573	0,3625	0,3573	67
LogisticHazard	CPS	C898	0,6753	0,1666	0,5304	1,1640	1,1131	50
PMF	CPS	C898	0,6965	0,1599	0,5133	1,0212	1,0743	48
DeepHitSingle	CPS	C898	0,6776	0,2268	0,6701	0,4485	0,4122	49

Em todos os experimentos: *batch size* = 256; *dropout* = 0,5. Valores em negrito indicam o melhor desempenho dentro de cada grupo de covariáveis. Loss (val.): *loss* de validação.

^a Grupos de covariáveis: H = Holter; EH = Eletrocardiogramas Holter; EC = Eventos e Condições Cardiovasculares; CPS = Conjunto de Covariáveis Prognósticas Seleccionadas.


^b Coorte: C992 = coorte completa ($n = 992$; 205 eventos); C898 = amostra com três derivações de ECG completas ($n = 898$; 189 eventos).

^c O conjunto CPS é composto por variáveis com associação estatisticamente significativa nas análises de Cox: dados demográficos (idade, gênero e classe NYHA); eventos cardiovasculares [taquicardia ventricular não sustentada ($CH > 10$) e taquiarritmia supraventricular paroxística]; e achado eletrocardiográfico [ondas Q de necrose (Q -waves, $sim = 1$)].

De forma geral, os melhores desempenhos foram observados com filtragem de pacientes com ECG (“Com”). Entre os modelos baseados apenas em colunas do Holter, o melhor C-index foi obtido pelo *DeepHitSingle* com filtragem (0,7234). No conjunto *eventos_condicoes_cardiovasculares*, o melhor desempenho foi alcançado pelo *PMF* com filtragem (C-index 0,7151; Brier score 0,1664; NLL 0,5137). Para o conjunto de *Covariáveis selecionadas*, o melhor C-index também ocorreu com o *PMF* com filtragem (0,6965), enquanto o menor Brier score foi 0,1599 no mesmo cenário.


4.3 MoCo (Momentum Contrast)

Figura 8 – Gráfico de tensão considerando a impedância humana




Fonte: elaborado pelo autor (2016).

Figura 9 – Gráfico de tensão considerando a impedância humana




Fonte: elaborado pelo autor (2016).

Figura 10 – Gráfico de tensão considerando a impedância humana




Fonte: elaborado pelo autor (2016).

Figura 11 – Gráfico de tensão considerando a impedância humana



Fonte: elaborado pelo autor (2016).

Figura 12 – Gráfico de tensão considerando a impedância humana



Fonte: elaborado pelo autor (2016).

5 CONCLUSÕES E TRABALHOS FUTUROS

Parte final do texto na qual se apresentam as conclusões apoiadas no desenvolvimento do assunto. É a recapitulação sintética dos resultados obtidos. Pode apresentar recomendações e sugestões para pesquisas futuras.

REFERÊNCIAS

[S.l.: s.n.].

[S.l.: s.n.].

[S.l.].

Dissertação (Mestrado).

Tese (Doutorado).

[S.l.].

BIGANZOLI, E.; BORACCHI, P.; MARIANI, L.; MARUBINI, E. Feed forward neural networks for the analysis of censored survival data: A partial logistic regression approach. **Statistics in Medicine**, Wiley, v. 17, n. 10, p. 1169–1186, 1998. Disponível em: <[https://onlinelibrary.wiley.com/doi/abs/10.1002/\(SICI\)1097-0258\(19980530\)17:10%3C1169::AID-SIM796%3E3.0.CO;2-D](https://onlinelibrary.wiley.com/doi/abs/10.1002/(SICI)1097-0258(19980530)17:10%3C1169::AID-SIM796%3E3.0.CO;2-D)>. Acesso em: 09 mai. 2026.

CHEN, X.; FAN, H.; GIRSHICK, R.; HE, K. Improved baselines with momentum contrastive learning. **arXiv preprint arXiv:2003.04297**, 2020.

EFRON, B. Logistic regression, survival analysis, and the Kaplan-Meier curve. **Journal of the American Statistical Association**, Taylor & Francis, v. 83, n. 402, p. 414–425, 1988. Disponível em: <<https://www.jstor.org/stable/2529811>>. Acesso em: 09 mai. 2026.

GENSHEIMER, M. F.; NARASIMHAN, B. A scalable discrete-time survival model for neural networks. **PeerJ**, PeerJ Inc., v. 7, p. e6257, 2019. Disponível em: <<https://peerj.com/articles/6257/>>. Acesso em: 09 mai. 2026.

HANNUN, A. Y.; RAJPURKAR, P.; HAGHPANAHI, M.; TISON, G. H.; BOURN, C.; TURAKHIA, M. P.; NG, A. Y. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. **Nature Medicine**, Nature Publishing Group, v. 25, n. 1, p. 65–69, 2019.

HE, K.; FAN, H.; WU, Y.; XIE, S.; GIRSHICK, R. Momentum contrast for unsupervised visual representation learning. **arXiv preprint arXiv:1911.05722**, 2019. Disponível em: <<https://arxiv.org/abs/1911.05722>>. Acesso em: 05 mar. 2026.

HE, K.; FAN, H.; WU, Y.; XIE, S.; GIRSHICK, R. Momentum contrast for unsupervised visual representation learning. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2020. p. 9729–9738.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2016. p. 770–778.

Jornal da USP. **Doenças cardiovasculares são a principal causa de mortes no Brasil, segundo o Ministério da Saúde**. 2024. Disponível em: <<https://jornal.usp.br/radio-usp/doencas-cardiovasculares-sao-a-principal-caoa-de-mortes-no-brasil-segundo-o-ministerio-da-saude/>>. Acesso em: 03 mar. 2026.

KVAMME, H.; BORGAN, Ø. Continuous and discrete-time survival prediction with neural networks. **arXiv preprint**, arXiv:1910.06724, 2019. Disponível em: <<https://arxiv.org/abs/1910.06724>>. Acesso em: 09 mai. 2026.

KVAMME, H.; BORGAN, Ø.; SCHEEL, I. Time-to-event prediction with neural networks and cox regression. **Journal of Machine Learning Research**, v. 20, n. 129, p. 1–30, 2019.

LEE, C.; ZAME, W. R.; YOON, J.; SCHAAR, M. van der. DeepHit: A deep learning approach to survival analysis with competing risks. In: **Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence**. AAAI Press, 2018. (AAAI 2018), p. 2314–2321. Disponível em: <http://medianetlab.ee.ucla.edu/papers/AAAI_2018_DeepHit>. Acesso em: 09 mai. 2026.

PRABHAKARARAO, E.; MANIMEGALAI, P. **A Multimodal User-Interface System for Computational Analysis of Sudden Cardiac Death (MUSIC)**. 2020. PhysioNet. Version 1.0.0. Disponível em: <<https://physionet.org>>. Acesso em: 02 mar. 2026.

PRABHAKARARAO, E.; MANIMEGALAI, P. **A Multimodal User-Interface System for Computational Analysis of Sudden Cardiac Death (MUSIC)**. 2020. PhysioNet. Disponível em arquivo csv. Disponível em: <<https://physionet.org>>. Acesso em: 02 mar. 2026.

RIBEIRO, A. H.; RIBEIRO, M. H.; PAIXÃO, G. M. M.; OLIVEIRA, D. M.; GOMES, P. R.; CANAZART, J. A.; FERREIRA, M. P. S.; ANDERSSON, C. R.; MACFARLANE, P. W.; WAGNER, M. J.; SCHÖN, T. B.; RIBEIRO, A. L. P. Automatic diagnosis of the 12-lead ECG using a deep neural network. **Nature Communications**, Nature Publishing Group, v. 11, p. 1760, 2020.

World Health Organization. **Cardiovascular diseases (CVDs)**. 2025. Disponível em: <[https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))>. Acesso em: 03 mar. 2026.

APÊNDICE A – EXEMPLO DE APÊNDICE

Um apêndice é um documento elaborado pelo autor, diferentemente do anexo. Geralmente, se coloca como apêndice, questionários, códigos de programação, tabelas que tomariam muito espaço no meio do trabalho. Artigos, resumos ou qualquer publicação relacionada ao trabalho podem ser utilizados como apêndice.

APÊNDICE B – QUESTIONÁRIO UTILIZADO PARA...

Questão 1. Esta é a primeira questão com alguns itens:

- (a) Este é o primeiro item
- (b) Segundo item

Questão 2. Esta é a segunda questão:

- (a) Este é o primeiro item
- (b) Segundo item

Questão 3. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc dictum sed tortor nec viverra. consectetur adipiscing elit. Nunc dictum sed tortor nec viverra.

- (a) consectetur
- (b) adipiscing
- (c) Nunc
- (d) dictum

APÊNDICE C – CÓDIGOS-FONTES UTILIZADOS PARA...

Código-fonte 1 – Hello World em C++

```
1 #include <iostream>
2 using namespace std;
3 int main() {
4     cout<<"Hello World!"<<endl;
5     system("pause");
6 }
```

Código-fonte 2 – Hello World em Java

```
1 public class HelloWorld {
2     public static void main(String[] args) {
3         System.out.println("Hello World!");
4     }
5 }
```

APÊNDICE D – IEEE CEFC 2016

Digest submetido ao The 17th Biennial Conference on Eletromagnetic Field Computation, Miami FL - NOV 13-16, 2016, USA.

Lightning Incidence Model Based on the Electric Field Gradient: 3D Electrostatic Analyses

Ednardo M. Rodrigues, Ricardo S. T. Pontes and Tobias R. Fernandes Neto

Federal University of Ceará, Department of Electrical Engineering, Fortaleza CE, BRAZIL
ednardorodrigues@dee.ufc.br

Abstract— The paper deals with the 3D electrostatic analysis of a lightning strike in a hangar and a power transmission line. The lightning incidence model is based on the electric field gradient. Finally, the simulation results are described and discussed.

Index Terms—Lightning, Electrostatic, Finite element.

I. INTRODUCTION

In [1], a 2D electrostatic analysis of a new lightning incidence model based on the electric field gradient (EFG) was presented. Moreover, the simulations results were carried out for a building and a power transmission line and they were compared with the classical electrogeometrical model (EGM), the rolling-sphere technique (RST) and the leader progression model (LPM) [2]. The present paper estimates the trajectory of lightning strikes from the thundercloud to a grounded metal roof of a hangar. Furthermore, the same procedure will be carried out for 500kV power transmission lines.

II. ELECTROSTATIC ANALYSES

A lightning occurs when the electric field is higher than the breakeven field (400kV/m —3MV/m) [2]. This model is based on the electric field gradient described by

$$\vec{E}_L(\vec{r}) \approx \vec{E}_b(\vec{r}) + \lambda_t \nabla E_b(\vec{r}), \quad (1)$$

$\vec{E}_b(\vec{r})$ is the background electric field, which is function of the position $\vec{r}$ and it is generated by the electric potential difference (EPD) between the cloud and the ground. λ_t is the lightning step length (~50m) [3], and $\vec{E}_L(\vec{r})$ is the lightning electric field. More details about Eq. (1) can be found in [1].

A 3D finite element method (FEM) model of a hangar and a power transmission line (TL) were designed by using the electrostatic module. All simulations were carried out within a cubic domain of 250m x 250m x 250m. The upper level of each domain is defined with -12.5MV, while the lower level is the ground. This is equivalent to a real thundercloud with a potential of (-100MV) at 2km of altitude [4].

The dimensions of the hangar are: 8.60m height, 77.37m width and 229.00m length. The aluminum metal roof has 0.7mm thickness and it is grounded. The second simulation is for a TL composed by three phase conductors, equally spaced by 11.5m and positioned at 40.5m above the reference plane. The TLs are protected by two earth wires spaced by 19m over 54.47m of the reference plane.

III. RESULTS

In order to evaluate the 3D model, the software COMSOL Multiphysics® was used in a computer with quad-core processor of 2.6GHz. For the hangar, the simulation time was around 4s. The necessary physical memory for the simulation

was 1.34GB and 5.6GB of virtual memory. The electric field is very intense at the roof (about 80MV/m) and the lightning (cyan lines) strikes the building roof, as shown in Fig. 1a. In summary, it is not necessary to add air terminals, as long the roof is grounded. The simulation time for the TL was around 6 min, using 15GB of physical memory and 32GB of virtual memory. As shown in Fig 1b, the cyan lines strike the earth wires.




Fig. 1. Case of studies: (a) hangar and (b) power transmission line.

IV. CONCLUSIONS

The EFG simulations predicted that the aluminum metal roof is able to protect the hangar against lightning strikes. In the TL simulation, the earth wires have fulfilled the protection for the phase conductors. Finally, the protection zone and the design of lightning protection system can be evaluated by 3D electrostatic analyses, which are closer to the reality than the 2D analyses. However, 3D models are often more complex and require more simulation time.

REFERENCES

- [1] E. M. Rodrigues, *Novel Lightning Incidence Model Based on the Electric Field Gradient: 2D Electrostatic Analyses*. GROUND'2016 & 7th LPE, 2016.
- [2] V. Cooray, *Lightning protection*, The Institution of Engineering and Technology, 2009.
- [3] V.A. Rakov and M. A. Uman, *Lightning: physics and effects*. Cambridge University Press, 2007.
- [4] S. Visacro, *Descargas atmosféricas: Uma Abordagem de Engenharia (Lightning strike: An Engineering approach)*, Artliber, 2005.

ANEXO A – EXEMPLO DE UM ANEXO

Um anexo é um documento que não foi elaborado pelo autor, ou seja, o autor apenas anexa. Anexos podem ser tabelas, mapas, diagramas, *datasheets*, manuais e etc.

ANEXO B – EXEMPLO DE UM ANEXO EM PDF

O autor pode anexar um *Portable Document Format* (PDF), traduzido como formato portátil de documento. Veja o código fonte utilizado para anexar o arquivo “Sikasil.pdf” que foi colocado dentro da pasta “anexos” que por sua vez está dentro da pasta “elementos-pos-textuais”. Tenha muita atenção na hora de especificar o local do arquivo. Recomenda-se não utilizar caracteres especiais para nomear pastas e, principalmente, arquivos.

Pode-se fazer uma descrição sucinta do arquivo anexado.

Sikasil® GS-630

Glazing sealant for structural & non-structural use

Technical Product Data

Chemical base	1-C silicone
Color (CQP ¹ 001-1)	See Product Overview
Cure mechanism	Moisture-curing
Cure type	Neutral
Density (uncured) (CQP 006-4)	1.4 kg/l approx.
Non-sag properties (CQP 061-4 / ISO 7390)	< 2 mm approx.
Application temperature	5 - 40°C (41 - 104°F)
Skin time ² (CQP 019-2)	10 min approx.
Tack-free time ² (CQP 019-1)	60 min approx.
Curing speed (CQP 049-1)	See diagram 1
Shore A-hardness (CQP 023-1 / ISO 868)	32 approx.
Tensile strength (CQP 036-1 / ISO 37)	1.2 N/mm ² approx.
Elongation at break (CQP 036-1 / ISO 37)	480% approx.
Tear propagation resistance (CQP 045-1 / ISO 34)	6 N/mm approx.
100% modulus (CQP 036-1 / ISO 37)	0.6 N/mm ² approx.
Movement accommodation capability (ASTM C 719)	±50%
Thermal resistance (CQP 513-1)	long term
Short term	4 h
	1 h
Service temperature	-40 - 150°C approx. (-40 - 302°F)
Shelf life (storage below 25°C) (CQP 016-1)	15 months

¹) CQP = Corporate Quality Procedure²) 23°C (73°F) / 50% r.h.**Description**

Sikasil® GS-630 is a durable, neutral-curing silicone sealant and adhesive which combines mechanical strength with high elongation. It adheres excellent to a wide range of substrates.

Sikasil® GS-630 is manufactured in accordance with ISO 9001 quality assurance system and the responsible care program.

Product Benefits

- Outstanding UV and weathering resistance
- Excellent adhesion to glass, coated glass, metals and plastics
- Fast curing
- Long-term durability
- High movement capability

Areas of Application

Sikasil® GS-630 is a silicone sealant and adhesive designed for sealing, bonding and mending tasks in a wide variety of industrial applications, e. g. structural and nonstructural applications in facades.

This product is suitable for professional experienced users only. Tests with actual substrates and conditions have to be performed to ensure adhesion and material compatibility.



Cure Mechanism

Sikasil® GS-630 cures by reaction with atmospheric moisture. The reaction thus starts at the surface and proceeds to the core of the joint. The curing speed depends on the relative humidity and the temperature (see diagram 1 below). Heating above 50°C to speed-up the vulcanization is not advisable as it may lead to bubble formation. At low temperatures the water content of the air is lower and the curing reaction proceeds more slowly.




Diagram 1: Curing speed 1C-Sikasil®

Application Limits

All Sikasil® WS, FS, SG, IG, WT and other engineering silicone sealants and adhesives are compatible with each other. Sikasil® WS and FS sealants as well as other Sika engineering silicone sealants are compatible with SikaGlaze® IG sealants. All other sealants have to be approved by Sika before using them in combination with Sikasil® GS-630. Where two or more different reactive sealants are used, allow the first to cure completely before applying the next.

Do not use Sikasil® GS-630 on pre-stressed polyacrylate and polycarbonate elements as it may cause environmental stress cracking (crazing).

The compatibility of gaskets, backer rods and other accessory materials with Sikasil® GS-630 must be tested in advance. Joints deeper than 15 mm should be avoided.

The above information is offered for general guidance only. Advice on specific applications will be given on request.

Method of Application

Surface preparation

Surfaces must be clean, dry and free from oil, grease and dust.

Advice on specific applications and surface pretreatment methods is available from the Technical Service Department of Sika Industry.

Application

After suitable joint and substrate preparation, Sikasil® GS-630 is gunned into place. Joints must be properly dimensioned as changes are no longer possible after construction. For optimum performance the joint width should be designed according to the movement capability of the sealant based on the actual expected movement. The minimum joint depth is 6 mm and a width / depth ratio of 2:1 must be respected if used for weatherproofing. For backfilling it is recommended to use closed cell, sealant compatible foam backer rods e.g. high resilience polyethylene foam rod. If joints are too shallow for backing material to be employed, we recommend using a polyethylene tape. This acts as a release film (bond breaker), allowing the joint to move and the silicone to stretch freely.

For more information please contact the Technical Service Department of Sika Industry.

Tooling and finishing

Tooling and finishing must be carried out within the skin time of the adhesive.

When tooling freshly applied Sikasil® GS-630 press the adhesive to the joint flanks to get a good wetting of the bonding surface.

Removal

Uncured Sikasil® GS-630 may be removed from tools and equipment with Sika® Remover-208 or another suitable solvent. Once cured, the material can only be removed mechanically.

Hands and exposed skin should be washed immediately using Sika® Handclean Towel or a suitable industrial hand cleaner and water. Do not use solvents!

Overpainting

Sikasil® GS-630 cannot be over-painted.

Further Information

Copies of the following publications are available on request:

- Material Safety Data Sheet

Packaging Information

Unipack	600 ml
Cartridge	300 ml
Pail	26 kg
Drum	280 kg

Value Bases

All technical data stated in this Product Data Sheet are based on laboratory tests. Actual measured data may vary due to circumstances beyond our control.

Health and Safety Information

For information and advice regarding transportation, handling, storage and disposal of chemical products, users should refer to the actual Material Safety Data Sheets containing physical, ecological, toxicological and other safety-related data.

Legal Notes

The information, and, in particular, the recommendations relating to the application and end-use of Sika products, are given in good faith based on Sika's current knowledge and experience of the products when properly stored, handled and applied under normal conditions in accordance with Sika's recommendations. In practice, the differences in materials, substrates and actual site conditions are such that no warranty in respect of merchantability or of fitness for a particular purpose, nor any liability arising out of any legal relationship whatsoever, can be inferred either from this information, or from any written recommendations, or from any other advice offered. The user of the product must test the product's suitability for the intended application and purpose. Sika reserves the right to change the properties of its products. The proprietary rights of third parties must be observed. All orders are accepted subject to our current terms of sale and delivery. Users must always refer to the most recent issue of the local Product Data Sheet for the product concerned, copies of which will be supplied on request.

Further information available at:

www.sika.ch

www.sika.com

Sika Schweiz AG

Industry

Tüffenwies 16

CH-8048 Zurich

Switzerland

Tel. +41 44 436 40 40

Fax +41 44 436 45 30

