

UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE XXXXXXXX

DEPARTAMENTO DE XXXXXXXXX

PROGRAMA DE PÓS-GRADUAÇÃO EM XXXXXXX

MESTRADO ACADÊMICO EM XXXXXXX

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

FORTALEZA

2025

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Xxxxxxx do Programa de Pós-Graduação em Xxxxxxx do Centro de Xxxxxxxx da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia Xxxxxx. Área de Concentração: Engenharia Xxxxxx

Orientador: Prof. Dr. João Paulo do Vale Madeiro

FORTALEZA

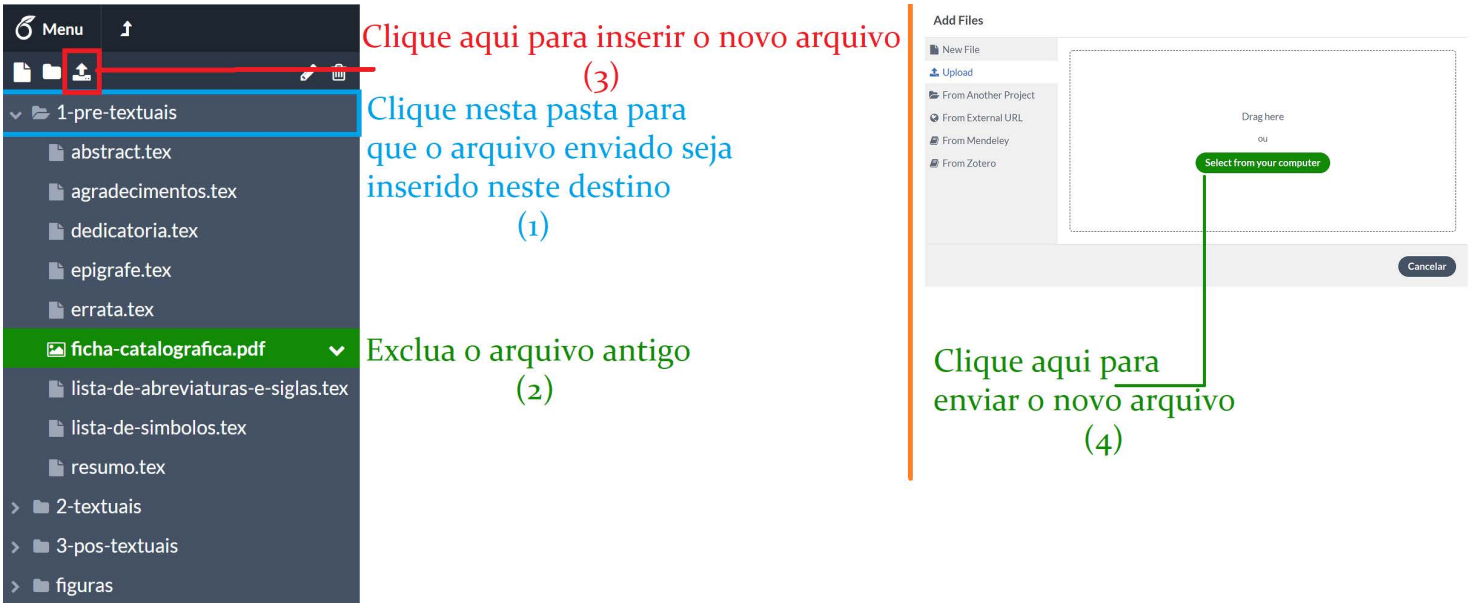
2025

Para criar sua ficha catalográfica, preencha corretamente o Módulo de Elaboração de Fichas Catalográficas (CATALOG!) disponibilizado no link:

http://fichacatalografica.ufc.br/

Em seguida, deve-se renomear o arquivo gerado como "ficha-catalografica" e adicioná-lo ao *template* na pasta "1-pre-textuais". É necessário, contudo, excluir o antigo arquivo "ficha-catalografica" antes de adicionar o novo.

A figura a seguir mostra os passos enumerados para a inclusão da ficha catalográfica no *Overleaf*.



DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Xxxxxxx do Programa de Pós-Graduação em Xxxxxxx do Centro de Xxxxxxxx da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia Xxxxxx. Área de Concentração: Engenharia Xxxxxx

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. João Paulo do Vale Madeiro (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

Ao Prof. Dr. Ricardo Silva Thé Pontes por me orientar em minha tese de doutorado.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ) onde este *template* foi desenvolvido.

Ao Doutorando em Engenharia Elétrica, Ednardo Moreira Rodrigues, e seu assistente, Alan Batista de Oliveira, aluno de graduação em Engenharia Elétrica, pela adequação do *template* utilizado neste trabalho para que o mesmo ficasse de acordo com as normas da biblioteca da Universidade Federal do Ceará (UFC).

Aos bibliotecários da Universidade Federal do Ceará: Francisco Edvander Pires Santos, Juliana Soares Lima, Izabel Lima dos Santos, Kalline Yasmin Soares Feitosa e Eliene Maria Vieira de Moura, pela revisão e discussão da formatação utilizada neste *template*.

Ao aluno Thiago Nascimento do curso de ciência da computação da Universidade Estadual do Ceará que elaborou o *template* do qual este trabalho foi adaptado para Universidade Federal do Ceará.

Ao Prof. Dr. Humberto de Andrade Carmona do Curso de Física da UFC pelo primeiro incentivo para o uso do LaTeX.

Ao aluno de graduação em engenharia elétrica e amigo, Lohan Costa por me apresentar a plataforma *ShareLatex* que depois migrou para a plataforma *OverLeaf*.

Aos amigos de laboratório, Felipe Bandeira, Renan Barroso e Roney Coelho, pelas discussões sobre os recursos do LaTeX.

Aos meus pais, irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender.

E à Fundação Cearense de Apoio ao Desenvolvimento (Funcap), na pessoa do Presidente Tarcísio Haroldo Cavalcante Pequeno pelo financiamento da pesquisa de doutorado via bolsa de estudos.

"O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado."

(Ariano Suassuna)

RESUMO

Este trabalho propõe um modelo preditivo baseado em análise de sobrevivência em tempo discreto para estimar o risco de morte súbita cardíaca em pacientes com insuficiência cardíaca crônica. Os dados utilizados foram obtidos da base MUSIC, disponível na plataforma PhysioNet, e compreendem sinais de eletrocardiograma (ECG) Holter de 24 horas com três derivações, além de variáveis clínicas e demográficas de 992 pacientes acompanhados em hospitais universitários espanhóis entre 2003 e 2008. Diferentemente de abordagens tradicionais que tratam o problema como classificação binária ou detecção de anomalias em séries temporais, este trabalho adota uma abordagem probabilística baseada em análise de sobrevivência: em vez de indicar se o paciente apresenta ou não uma arritmia, o modelo estima a probabilidade de ocorrência de um evento cardíaco adverso em cada intervalo de tempo ao longo do período de acompanhamento. Para isso, são implementadas e comparadas três funções de perda para modelos de sobrevivência em tempo discreto — *Logistic-Hazard*, *probability mass function* (PMF) e *DeepHitSingle* —, todas baseadas na verossimilhança para dados com censura à direita. Os sinais de ECG são processados por uma rede neural convolucional residual unidimensional (ResNet-18 1D), que extrai representações locais ao longo do tempo a partir das três derivações do sinal. Para lidar com a escassez de exemplos rotulados, o encoder é pré-treinado de forma auto-supervisionada pelo método *Momentum Contrast* (MoCo) sobre todos os sinais disponíveis, antes do ajuste fino supervisionado para a tarefa de sobrevivência. As representações extraídas do ECG são combinadas com variáveis clínicas — como idade, gênero e parâmetros ecocardiográficos — por meio de uma arquitetura de fusão simétrica, garantindo contribuição equilibrada de ambas as fontes de informação. O desempenho dos modelos é avaliado por três métricas complementares: o índice de concordância dependente do tempo (C^{td}), que mede a capacidade do modelo de ordenar corretamente os pacientes por nível de risco ao longo do tempo; o *Integrated Brier Score* (IBS), que avalia o erro quadrático médio entre as probabilidades estimadas e os desfechos observados, capturando calibração e discriminação conjuntamente; e o *Integrated Negative Binomial Log-Likelihood* (Int. NBLL), que penaliza pela qualidade probabilística da distribuição de sobrevivência estimada. Os resultados esperados são um modelo preditivo capaz de auxiliar médicos na tomada de decisão clínica, identificando pacientes com maior risco de eventos cardíacos adversos a partir de dados de ECG Holter de rotina, de baixo custo e ampla disponibilidade.

Palavras-chave: Análise de Sobrevivência. *Logistic-Hazard*. ResNet-18 1D. Morte Súbita Cardíaca. Aprendizado Auto-Supervisionado. *Momentum Contrast*. ECG Holter.

ABSTRACT

This work proposes a predictive model based on discrete-time survival analysis to estimate the risk of sudden cardiac death in patients with chronic heart failure. The data were obtained from the MUSIC database, available on the PhysioNet platform, and comprise 24-hour three-lead Holter electrocardiogram (ECG) signals along with clinical and demographic variables from 992 patients followed at Spanish university hospitals between 2003 and 2008. Unlike traditional approaches that frame the problem as binary classification or time-series anomaly detection, this work adopts a probabilistic survival analysis approach: rather than indicating whether a patient has or does not have an arrhythmia, the model estimates the probability of an adverse cardiac event occurring within each time interval over the follow-up period. To this end, three loss functions for discrete-time survival models are implemented and compared — *Logistic-Hazard*, PMF, and *DeepHitSingle* —, all grounded in the right-censored likelihood framework. The ECG signals are processed by a one-dimensional residual convolutional neural network (ResNet-18 1D), which extracts local temporal representations from the three signal leads. To address the scarcity of labeled positive examples, the encoder is pre-trained in a self-supervised manner using the *Momentum Contrast* (MoCo) method over all available signals, prior to supervised fine-tuning for the survival task. The ECG representations are then combined with clinical variables — such as age, gender, and echocardiographic parameters — through a symmetric fusion architecture that ensures balanced contributions from both information sources. Model performance is evaluated using three complementary metrics: the time-dependent concordance index (C^{td}), which measures the model's ability to correctly rank patients by risk level across the follow-up period; the *Integrated Brier Score* (IBS), which assesses the mean squared error between estimated probabilities and observed outcomes, jointly capturing calibration and discrimination; and the *Integrated Negative Binomial Log-Likelihood* (Int. NBLL), which penalizes the probabilistic quality of the estimated survival distribution. The expected outcome is a predictive model capable of supporting clinical decision-making by identifying patients at higher risk of adverse cardiac events from routine, low-cost, and widely available Holter ECG data.

Keywords: Survival Analysis. *Logistic-Hazard*. ResNet-18 1D. Sudden Cardiac Death. Self-Supervised Learning. *Momentum Contrast*. Holter ECG.

LISTA DE FIGURAS

Figura 1 – Gráfico de barras da distribuição de causa dos pacientes. 23

Figura 2 – Esquema de pré-treinamento MoCo para aprendizado auto-supervisionado de representações do ECG/Holter. O codificador query recebe gradientes diretamente; o codificador key é atualizado por média móvel e alimenta uma fila de exemplos negativos. 56

Figura 3 – Fluxo do encoder ResNet-1D utilizado para extração de características convolucionais temporais dos sinais de ECG/Holter. Cada BasicBlock1D contém duas convoluções 1D com normalização em lote e conexão residual. 56

Figura 4 – Arquitetura híbrida final: extração de características do sinal por ResNet-1D/MoCo, compressão do ECG em gargalo de 16 dimensões, processamento clínico em paralelo, fusão balanceada e predição de logits para modelos de sobrevivência em tempo discreto. 60

Figura 5 – Transformação dos logits brutos nos três modelos de sobrevivência em tempo discreto: LogisticHazard, PMF e DeepHitSingle. 62

Figura 6 – Gráfico de tensão considerando a impedância humana 84

Figura 7 – Gráfico de tensão considerando a impedância humana 84

Figura 8 – Gráfico de tensão considerando a impedância humana 85

Figura 9 – Gráfico de tensão considerando a impedância humana 85

Figura 10 – Gráfico de tensão considerando a impedância humana 85

LISTA DE TABELAS

Tabela 1 – Hiperparâmetros do pré-treinamento MoCo no domínio ECG. 40
Tabela 2 – Síntese comparativa dos hiperparâmetros e características arquiteturais das cinco variações experimentais do MoCo. 52
Tabela 3 – Modelo de Cox com variáveis do Holter na coorte completa ($n = 992$; 205 eventos). 67
Tabela 4 – Modelo de Cox com variáveis do Holter na amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 68
Tabela 5 – Modelo de Cox com variáveis arrítmicas na coorte completa ($n = 992$; 205 eventos). 69
Tabela 6 – Modelo de Cox com variáveis arrítmicas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 70
Tabela 7 – Modelo de Cox com dados clínicos e antropométricos na coorte completa ($n = 992$; 205 eventos). 70
Tabela 8 – Modelo de Cox com dados clínicos e antropométricos na amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 71
Tabela 9 – Modelo de Cox com variáveis eletrocardiográficas na coorte completa ($n = 992$; 205 eventos). 72
Tabela 10 – Modelo de Cox com variáveis eletrocardiográficas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 73
Tabela 11 – Análise de Cox univariável — coeficiente, razão de risco, C-index e significância por variável ($n = 992$; 205 eventos). 75
Tabela 12 – Fator de inflação da variância (VIF) — avaliação de multicolinearidade entre as variáveis candidatas. 76
Tabela 13 – Análise de Cox multivariável — variáveis com $p < 0{,}05$ na análise univariável ($n = 992$; 205 eventos). 77
Tabela 14 – Análise de Cox univariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 79
Tabela 15 – Fator de inflação da variância (VIF) — amostra filtrada com três derivações completas ($n = 898$). 80
Tabela 16 – Análise de Cox multivariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos). 81

Tabela 17 – Desempenho dos modelos de sobrevivência profunda segundo o conjunto de covariáveis e a disponibilidade de ECG dos pacientes. 83

LISTA DE ABREVIATURAS E SIGLAS

CNNs	Redes Neurais Convolucionais
CSV	*Comma-Separated Values*
DCVs	Cardiovascular diseases
ECG	Eletrocardiograma
Hz	Hertz
I3A	*Instituto de Investigación de Ingeniería de Aragón*
ICC	Insuficiência Cardíaca Crônica
MSC	Morte Súbita Cardíaca
PDF	*Portable Document Format*
PMF	*probability mass function*

LISTA DE SÍMBOLOS

t	Tempo (contínuo)
t_k, c_k	Ponto de corte / limite do intervalo de tempo discreto k
m	Número de intervalos (bins) de tempo discreto
φ	Vetor de logits da rede $(\varphi_0, \ldots, \varphi_{m-1})$
h_k	Risco (hazard) discreto no intervalo k
$\sigma(\cdot)$	Função sigmoide
$S(t \mid x)$	Função de sobrevivência
d_i	Indicador de evento/censura do paciente i (1 = evento, 0 = censura)
t_i	Tempo observado (evento ou censura) do paciente i
N	Número de amostras/pacientes no lote (batch)
p_k	Massa de probabilidade no intervalo k (PMF)
$F(t_k \mid x)$	Função de distribuição acumulada (CDF)
$\eta(i, j)$	Penalidade de ordenação entre o par de pacientes (i, j)
α	Peso do termo de ranking (DeepHit) / peso do evento na perda
σ	Hiperparâmetro de suavização da perda de ordenação (DeepHit)
ε	Constante de regularização (evita divisão por zero)
q	Representação de consulta (query) no MoCo
k^+	Chave positiva no MoCo
k_j^-	Chave negativa j no MoCo
τ	Temperatura da perda InfoNCE
K	Tamanho do dicionário/fila de negativos (MoCo)
θ_q, θ_k	Parâmetros dos encoders de consulta e de chave
m	Coeficiente de momento do encoder de chave (EMA)
d	Dimensão do espaço de projeção/embedding
B	Tamanho do mini-batch
$x^{(1)}, x^{(2)}$	Visões aumentadas do sinal de ECG

$\mathscr{A}$	Distribuição de aumentação de dados
h	Representação extraída pelo encoder (backbone)
z	Vetor de projeção (cabeça MLP contrastiva)
s_t	Fator de escala do GradScaler (precisão mista)
g_t	Gradiente na iteração t
β	Coeficiente de momento do otimizador SGD
λ	Decaimento de peso (weight decay)
η	Taxa de aprendizado
θ_t	Parâmetros do modelo na iteração t
v_t	Velocidade (momento) do SGD
C	Número de canais/derivações do sinal de ECG
L	Comprimento da janela temporal do sinal
C_{td}	Índice de concordância dependente do tempo
$\hat{S}(t \mid x)$	Função de sobrevivência estimada
$BS(t)$	Brier Score no instante t
$\hat{w}_i(t)$	Peso de ponderação por censura inversa (IPCW)
$\hat{G}(t)$	Estimador de Kaplan-Meier da distribuição de censura
t_{max}	Horizonte máximo de tempo de avaliação
$NBLL(t)$	Log-verossimilhança binomial negativa no instante t
$b_0(t)$	Risco basal (Cox)
b_i	Coeficiente de regressão (Cox)
x_i	Covariável i (Cox)
$\bar{x}_i$	Média da covariável i (Cox)

SUMÁRIO

1 INTRODUÇÃO 19
1.1 Motivação 19
1.2 Base de Dados 19
1.3 Principais Desafios 22
1.3.1 Desbalanceamento dos dados 22
1.3.2 Grande volume dos sinais 24
2 FUNDAMENTAÇÃO TEÓRICA 26
2.1 Análise de Sobrevivência em Tempo Discreto com Redes Neurais 26
2.1.1 Logistic-Hazard 27
2.1.2 PMF — Probability Mass Function 28
2.1.3 DeepHitSingle 29
2.2 Arquitetura — ResNet-18 Unidimensional 31
2.2.1 Aprendizado Profundo Residual 31
2.2.2 Adaptação para Sinais Unidimensionais 32
2.2.3 Remoção do Global Average Pooling e Atenção Temporal 32
2.2.4 Modelo Híbrido de Sobrevivência 33
2.3 Aprendizado por Representação Contrastiva 34
2.3.1 MoCo v1: Contraste como Busca em Dicionário Dinâmico 35
2.3.1.1 Fila de Representações *35*
2.3.1.2 Encoder de Momento *35*
2.3.1.3 Função de Perda InfoNCE *36*
2.3.2 MoCo v2: Cabeça de Projeção MLP e Aumentação Aprimorada 37
2.3.2.1 Cabeça de Projeção Não Linear *37*
2.3.2.2 Aumentação de Dados Aprimorada *37*
2.3.3 MoCo v3: Perda Simétrica e Estabilidade de Treinamento 38
2.3.3.1 Perda Contrastiva Simétrica *38*
2.3.3.2 Instabilidade de Treinamento e Mitigação *38*
2.3.4 Síntese do Arcabouço Implementado 39
2.3.5 Relevância do Arcabouço para o Pré-Treinamento em ECG Holter 40
2.4 Métricas de Avaliação 41

2.4.1 ***Índice de Concordância Dependente do Tempo (C^{td})*** 42
2.4.2 ***Integrated Brier Score (IBS)*** 43
2.4.3 ***Integrated Negative Binomial Log-Likelihood (Int. NBLL)*** 44
2.4.4 ***Complementaridade das Métricas e Protocolo de Avaliação*** 45
3 **METODOLOGIA** 46
3.1 **Modelos de Análise de Sobrevivência** 46
3.1.1 ***Justificativa da Versão do MoCo Adotada*** 46
3.1.2 ***Pré-treinamento Auto-supervisionado: MoCo*** 47
3.1.2.1 *Aprendizado Contrastivo como Busca em Dicionário* *48*
3.1.2.2 *Dicionário Dinâmico com Fila e Encoder com Momento* *48*
3.1.2.3 *Melhorias do MoCo v2* *49*
3.1.2.4 *Adaptação para Sinais de ECG* *49*
3.1.2.5 *Configuração do Treinamento* *49*
3.1.2.6 *Escolha do Mecanismo de Aprendizado Contrastivo* *50*
3.2 **Processo Iterativo de Desenvolvimento do MoCo: Variações Experimentais** 51
3.2.1 ***Versões 1 e 2: Adaptação Base e Otimização Algorítmica*** 51
3.2.2 ***Versão 3: Regime Rigoroso com Fila Expandida*** 52
3.2.3 ***Versão 4: Regime Ultra-Conservador como Controle Ablativo*** 53
3.2.4 ***Versão 5: Integração de Atenção Temporal e Transformer*** 54
3.2.5 ***Justificativa da Seleção Final: Versão 5*** 54
3.2.6 ***Pré-treinamento Contrastivo com MoCo*** 55
3.2.7 ***Arquitetura Proposta dos Modelos Profundos*** 55
3.2.8 ***Encoder ResNet-1D para Sinais de ECG*** 56
3.2.9 ***Arquitetura do Encoder: ResNet-18 1D*** 57
3.2.9.1 *Da ResNet-18 2D para a ResNet-18 1D* *57*
3.2.9.2 *Estrutura das 17 Camadas do Encoder* *57*
3.2.9.3 *Justificativa da Escolha da ResNet-18* *58*
3.2.10 ***Arquitetura Híbrida Final*** 59
3.2.11 ***Módulo de Projeção e Fusão Híbrida*** 59
3.2.12 ***Cabeçote de Análise de Sobrevivência*** 60
3.2.13 ***Risco Logístico (Logistic-Hazard)*** 60
3.2.14 ***Função de Massa de Probabilidade (PMF)*** 61

3.2.15 ***DeepHit*** . . . 61
3.2.16 ***Formulações de Sobrevivência em Tempo Discreto*** . . . 61
3.2.17 ***Discretização do Tempo: Transformação LabTrans*** . . . 61
3.2.18 ***Função de Perda por Tipo de Paciente*** . . . 62
3.2.19 ***Treinamento: Acumulação de Gradiente e Precisão Mista*** . . . 63
3.2.20 ***Avaliação: C-Index e Agregação de Janelas*** . . . 64
4 RESULTADOS . . . 65
4.1 Resultados da tabela subject-info.csv . . . 65
4.1.1 ***Resultados do modelo de Cox para dados Holter*** . . . 66
4.1.1.1 *Resumo dos resultados do modelo de Cox para dados Holter* . . . *68*
4.1.2 ***Resultados do modelo de Cox para dados de eventos e condições cardiovasculares*** . . . 68
4.1.3 ***Resultados do modelo de Cox para dados demográficos clínicos*** . . . 70
4.1.4 ***Resultados do modelo de Cox para dados eletrocardiograma de alta resolução*** 71
4.2 Modelos de Aprendizado Profundo para Sobrevivência . . . 82
4.2.1 ***Sobre LogisticHazard*** . . . 82
4.2.2 ***Sobre PMF*** . . . 82
4.2.3 ***Sobre DeepHitSingle*** . . . 82
4.3 MoCo (Momentum Contrast) . . . 84
5 CONCLUSÕES E TRABALHOS FUTUROS . . . 86
REFERÊNCIAS . . . 87
APÊNDICES . . . 89
APÊNDICE A – Exemplo de apêndice . . . 89
APÊNDICE B – Questionário utilizado para... . . . 90
APÊNDICE C – Códigos-fontes utilizados para... . . . 91
APÊNDICE D – *IEEE CEFC 2016* . . . 92
ANEXOS . . . 94
ANEXO A – Exemplo de um anexo . . . 94
ANEXO B – Exemplo de um anexo em PDF . . . 95

1 INTRODUÇÃO

1.1 Motivação

Doenças cardiovasculares Cardiovascular diseases (DCVs) são a principal causa de morte em todo o mundo, representando aproximadamente 17,9 milhões de mortes por ano, o que corresponde a 31% de todas as mortes globais como mostra a pesquisa (World Health Organization, 2025). Dentre as DCVs, as arritmias cardíacas são condições comuns que podem levar a eventos adversos graves, como parada cardíaca súbita. A detecção precoce e precisa de arritmias é crucial para a prevenção de complicações e melhoria dos resultados clínicos. Segundo o jornal USP doenças cardiovasculares são a principal causa de morte no Brasil, representando cerca de 30% de todas as mortes no país (Jornal da USP, 2024).

Este trabalho trata de dados de pacientes que ficaram em observações clínicas e acompanhamento que apresentaram sitomas de arritmia cardíaca, esses dados foram coletados pela plataforma PhysioNet (PRABHAKARARAO; MANIMEGALAI, 2020a). Em resumo a população do estudo é de 992 pacientes com Insuficiência Cardíaca Crônica (ICC) esses dados de coletas trata do ano entre abril de 2003 e dezembro de 2004, com um acompanhamento de uma mediana de 44 meses até 2008 de dezembro, alguns desses pacientes apresentaram eventos de Morte Súbita Cardíaca (MSC), as coletas foram feitas em 8 hospitais universitários espanhóis, na Espanha pela cidades de Barcelona, Sevilha, Cádiz, Múrcia, Santiago de Compostela, esses conjunto de dados de sinais e a organização desse banco de dados que foi parar no PhysioNet foi liderada pelo Instituto de Investigación de Ingeniería de Aragón *Instituto de Investigación de Ingeniería de Aragón* (I3A) (PRABHAKARARAO; MANIMEGALAI, 2020a), na Universidade de Zaragoza (Zaragoza, Espanha), pelo grupo do pesquisador Pablo Laguna.

1.2 Base de Dados

De acordo com Prabhakararao e Manimegalai (2020a), os dados coletados incluem sinais de ECG Holter de 24 horas com três derivações (96%) e duas derivações (4%), registros de eletrocardiograma (Eletrocardiograma (ECG)) em repouso de alta resolução com três derivações e duração de 20 minutos, além de dados clínicos e demográficos dos pacientes, ecocardiografia e exames laboratoriais de sangue. Todas essas informações foram consolidadas em uma tabela no formato *Comma-Separated Values* (CSV) com 105 variáveis (PRABHAKARARAO; MANI-

MEGALAI, 2020b). Os dados são ricos tanto em sinais de ECG — que permitem identificar padrões de ondas e intervalos como QT, variações de frequência, amplitude de onda e intervalos RR — quanto em variáveis clínicas e demográficas, possibilitando uma análise abrangente dos fatores de risco associados a eventos cardíacos adversos.

Dentre as 105 variáveis disponíveis, duas constituem o ponto de partida deste trabalho. A primeira é o *Follow-up period from enrollment (days)* (PRABHAKARARAO; MANIMEGALAI, 2020b), que registra o tempo, em dias, durante o qual cada paciente permaneceu sob observação clínica desde a data de inclusão no estudo. A segunda é a variável *Cause of death* (PRABHAKARARAO; MANIMEGALAI, 2020b), que classifica o desfecho de cada paciente por meio de códigos numéricos: o Código 0 corresponde a pacientes vivos ao final do acompanhamento (73,2%); o Código 1 indica óbito por causas não cardíacas (6,1%); o Código 3 corresponde à Morte Súbita Cardíaca (MSC), de origem elétrica (9,5%); e os Códigos 6 e 7 referem-se à morte por falência de bomba cardíaca, isto é, à progressão terminal da insuficiência cardíaca no ambiente hospitalar (11,2%).

Do ponto de vista fisiopatológico, os dois tipos de desfecho cardíaco fatal presentes nesta base de dados possuem mecanismos distintos. A Morte Súbita Cardíaca (Código 3) é um evento de natureza **elétrica**: o sistema de condução cardíaca sofre uma disfunção abrupta — tipicamente uma fibrilação ventricular — que interrompe o ritmo coordenado do coração em segundos, independentemente da condição mecânica do músculo cardíaco. Já a falência de bomba (Códigos 6 e 7) é um evento de natureza **mecânica**: o miocárdio perde progressivamente a capacidade de ejetar sangue de forma eficiente, em um processo gradual e clinicamente anunciado, associado à deterioração da função sistólica ou diastólica. Essa distinção fisiopatológica implica que os dois desfechos possuem assinaturas morfológicas distintas no sinal de ECG, o que tem consequências diretas sobre a definição do evento de interesse nos experimentos deste trabalho.

Diante disso, este trabalho adota dois cenários experimentais complementares, conforme detalhado a seguir.

Cenário 1 — Mortalidade Cardíaca Geral (Desfecho Composto). Neste cenário, o evento de interesse é definido como qualquer óbito de causa cardíaca, englobando tanto a Morte Súbita Cardíaca (Código 3) quanto a falência de bomba (Códigos 6 e 7). Pacientes com óbito por causas não cardíacas (Código 1) são tratados como censurados, à semelhança dos pacientes vivos ao final do acompanhamento (Código 0). Esse agrupamento resulta em 205 pacientes com evento (20,67% da base), proporção considerada favorável para o treinamento de

modelos preditivos baseados em redes neurais (**??**). A justificativa clínica para esse cenário é que, do ponto de vista do médico assistente, ambos os desfechos representam a progressão fatal da doença cardíaca e demandam estratificação precoce de risco. A justificativa metodológica é que o maior número de eventos positivos permite um aprendizado mais robusto das representações do sinal de ECG pelo modelo, especialmente na etapa de pré-treinamento auto-supervisionado com o Momentum Contrast (MoCo).

Cenário 2 — Morte Súbita Cardíaca (Desfecho Específico). Neste cenário, o evento de interesse é restrito exclusivamente à Morte Súbita Cardíaca (Código 3), que representa 9,5% dos pacientes (94 casos). Todos os demais pacientes — incluindo os que faleceram por falência de bomba (Códigos 6 e 7) ou por causas não cardíacas (Código 1) — são tratados como censurados. Esse cenário é clinicamente mais específico, pois a MSC possui uma assinatura morfológica própria no ECG — relacionada a alterações do intervalo QT, variabilidade da frequência cardíaca e padrões de repolarização ventricular — que o modelo deve aprender a identificar de forma isolada. A desvantagem é o maior grau de desbalanceamento, que exige estratégias adicionais de regularização e ponderação durante o treinamento.

A comparação entre os dois cenários permite avaliar, de forma estruturada, tanto a capacidade do modelo de capturar o risco cardíaco fatal em sentido amplo quanto sua capacidade de discriminar especificamente o mecanismo elétrico da morte súbita — contribuindo para a compreensão do valor preditivo incremental do sinal de ECG Holter em cada contexto clínico.

Cenário 3: Eventos Cardiovasculares Adversos Maiores (Desfecho Composto MACE).

Neste terceiro cenário, adota-se a formulação de um desfecho composto inspirado no padrão-ouro de ensaios clínicos cardiológicos internacionais, conhecido como MACE (*Major Adverse Cardiovascular Events*). O evento de interesse é definido por uma lógica binária inclusiva (OR), sendo assinalado como positivo caso o paciente apresente Morte Súbita Cardíaca em até 4 anos, ou progressão para Insuficiência Cardíaca severa em até 4 anos, ou óbito cardiovascular documentado durante o acompanhamento. A fusão dessas condições eleva substancialmente a prevalência da classe minoritária, resultando em 266 pacientes com evento positivo, aproximadamente 30% da coorte válida de estudo.

A adoção deste cenário justifica-se por uma dupla necessidade, unindo a prática clínica à ciência de dados. Do ponto de vista clínico, o desfecho composto absorve as ambiguidades inerentes à classificação médica nos registros de óbito, especialmente em cenários nos quais

a fronteira entre falência mecânica progressiva e colapso elétrico terminal é frequentemente sobreposta no momento do preenchimento do laudo. Além disso, o MACE reflete com maior precisão a vulnerabilidade sistêmica global do miocárdio a curto e médio prazo.

Do ponto de vista computacional e metodológico, a ampliação do número de eventos atua como uma solução intrínseca para o severo desbalanceamento de classes, aqui denominado "Paradoxo da Maioria". Essa densidade amostral ampliada fornece o volume necessário de exemplos positivos para que a arquitetura de aprendizado profundo, em especial os blocos de autoatenção (Transformers), consiga estabilizar o cálculo de gradientes e mapear características anômalas no ECG sem colapsar rumo à previsão majoritária nula, isto é, risco zero.

1.3 Principais Desafios

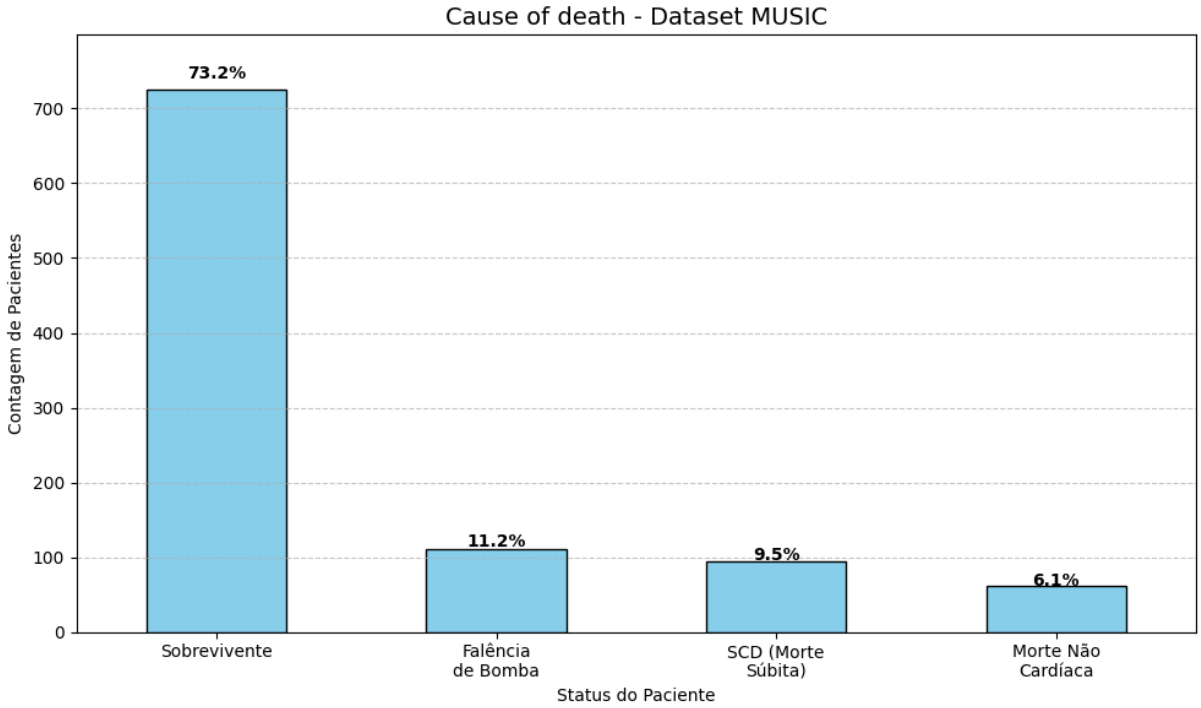
1.3.1 Desbalanceamento dos dados

O desbalanceamento dos dados é um desafio comum em estudos médicos, especialmente quando se trata de eventos raros, como a morte súbita cardíaca. Neste conjunto de dados, a maioria dos pacientes está viva (73,2%), enquanto uma proporção menor sofreu eventos adversos (26,8%). Esse desbalanceamento pode dificultar o treinamento de modelos preditivos, pois o modelo pode aprender a classificar a maioria dos casos como "vivo"e ter dificuldade em identificar os casos de "morte súbita cardíaca". Para lidar com esse desafio, técnicas de balanceamento de dados, como o uso de amostragem estratificada ou algoritmos de aprendizado que são robustos ao desbalanceamento, podem ser aplicadas para melhorar a capacidade do modelo de identificar padrões relevantes nos dados.

Os dados utilizados neste trabalho foram obtidos na plataforma PhysioNet (PRABHAKARARAO; MANIMEGALAI, 2020a), que é um repositório de dados fisiológicos e clínicos de pacientes. Irei utilizar os sinais de ECG Holter de 24 horas de 3 derivações, que correspondem a 96% de todos os dados coletados, além dos dados clínicos e demográficos dos pacientes, que estão salvos em formato CSV (PRABHAKARARAO; MANIMEGALAI, 2020b). Inicialmente, ao analisar a tabela (que no site PhysioNet possui o título subject-info.csv), destaca-se a variável Cause of death (PRABHAKARARAO; MANIMEGALAI, 2020b). A Figura 1 ilustra as causas de morte dos pacientes, que são classificadas em códigos numéricos: o Código 0 representa os pacientes vivos, correspondendo a 73,2% do total; o Código 1 trata de pacientes que morreram de outras causas (não ligadas ao coração) e corresponde a 6,1%; o Código 3 trata-se da Morte

Súbita Cardíaca (Sudden Cardiac Death - SCD) 9,5%; por fim, os Códigos 6 e 7 referem-se à morte por falência de bomba (que é a progressão lenta e refratária da insuficiência cardíaca terminal no hospital), englobando 11,2% dos pacientes. Essa categoria.

Figura 1 – Gráfico de barras da distribuição de causa dos pacientes.



Fonte: elaborado pelo autor (2026).

Ao analisar a divisão dos dados, nota-se um desbalanceamento natural entre os pacientes vivos (tratados como dados censurados) e aqueles que sofreram o desfecho fatal. A predominância de pacientes vivos é comum, mas pode tornar mais desafiadora a tarefa de ensinar o modelo a identificar os padrões sutis no ECG relacionados à morte súbita cardíaca. No entanto, ao desconsiderarmos as mortes por outras causas — tratando-as também como censura — e focarmos estritamente nos eventos cardíacos, chegamos a um total de 205 pacientes, o que representa 20,67% da base de dados. Do ponto de vista do treinamento de redes neurais, este é um cenário excelente. Muitos estudos na literatura médica lidam com um desbalanceamento muito mais severo, frequentemente operando com taxas de eventos na casa dos 10% ou menos (**??**). Portanto, essa proporção de 20% nos oferece uma quantidade de exemplos positivos bastante sólida para que o modelo consiga aprender de forma robusta. É um desafio desbaleamento, mas é um cenário muito mais favorável do que o encontrado em muitos outros estudos, o que aumenta as chances de desenvolver um modelo preditivo eficaz para a morte súbita cardíaca. Para resolver este desbalanceamento, existem diversas técnicas, a que irei utulizar é a Momentum Contrast

(MOCO) (NADA, a) que ao adaptado ao modelo de sobrevivência, é uma técnica de aprendizado auto-supervisionado que pode ser utilizada para lidar com o desbalanceamento em conjuntos de dados. O MOCO é projetado para aprender representações robustas e discriminativas, mesmo quando há uma quantidade limitada de exemplos positivos (neste caso, pacientes que sofreram morte súbita cardíaca). Ele funciona criando um banco de memória que armazena representações de amostras anteriores, permitindo que o modelo aprenda a distinguir entre amostras positivas e negativas de forma eficaz. Ao utilizar o MOCO, é possível melhorar a capacidade do modelo de identificar padrões relevantes no ECG relacionados à morte súbita cardíaca, mesmo em um cenário desbalanceado.

Vou usar o subject-info.csv como gabarito antes de usar os sinais de ECG, ou seja, vou usar os dados clínicos e demográficos dos pacientes para treinar modelos com redes neurais comun e depois outros modelo com rede neural mas complexa como Redes Neurais Convolucionais Redes Neurais Convolucionais (CNNs) usar os sinais de ECG nas CNNs para comparar entre os modelos se com ECG os resultados são preciso e melhores ou não é tão relevante. Já os dados csv ja são suficiente para ter um bom resultado, menos custo computacional, e mais fácil de interpretar os resultados, já os sinais de ECG são mais complexos, exigem mais processamento e podem ser mais difíceis de interpretar os resultados, mas podem fornecer informações adicionais que não estão presentes nos dados clínicos e demográficos. Portanto, a escolha entre usar os dados clínicos e demográficos ou os sinais de ECG é dois pontos importante primeiro validação de hipotise, que os sinais de ECG pode encontrar padrões relacionados a morte súbita cardíaca, e segundo é o fato que os dados clínicos e demográficos são exames dificis de serem encontrados, em todos os pacientes pois são solicitado pelo medico apenas em casos mais graves, alem disso alguns são exames caros ou complicado ao realizar, já os sinais de ECG são mais fáceis de serem encontrados, pois são exames mais comuns e baratos, e podem ser realizados em uma grande variedade de pacientes. Portanto, a escolha entre usar os dados clínicos e demográficos ou os sinais de ECG depende dos objetivos do estudo, dos recursos disponíveis e da viabilidade de obtenção dos dados.

1.3.2 Grande volume dos sinais

O grande volume de dados dos sinais de ECG Holter de 24 horas representa um desafio significativo para o processamento e análise. Cada paciente tem um registro contínuo de sinais de ECG ao longo de um período extenso, o que resulta em uma quantidade massiva de

dados a ser processada. O processamento eficiente desses dados requer técnicas avançadas de pré-processamento, como filtragem, segmentação e extração de características relevantes. Além disso, o treinamento de modelos preditivos com esse volume de dados pode ser computacionalmente intensivo, exigindo recursos computacionais robustos e estratégias de otimização para garantir que o modelo possa aprender efetivamente a partir dos sinais sem sobrecarregar os sistemas de processamento. Estão registrado 992 paciente com três derivações de ECG Holter de 24 horas, com uma frequência de amostragem de 200 Hertz (Hz), o que resulta em um total de 17.280.000 pontos de dados por paciente (200 amostras por segundo x 60 segundos por minuto x 60 minutos por hora x 24 horas). Isso significa que, para os 992 pacientes, o volume total de dados de ECG Holter é de aproximadamente, treinar bilhões de pontos de dados (17.280.000 pontos por paciente x 992 pacientes), é inviavel processar e analisar esse volume de dados sem uma abordagem eficiente de pré-processamento e extração de características. Para lidar com esse desafio, técnicas de redução de dimensionalidade, como a utilização de redes neurais convolucionais para extrair características relevantes dos sinais, podem ser aplicadas para reduzir o volume de dados enquanto preservam as informações essenciais para a análise preditiva.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Análise de Sobrevivência em Tempo Discreto com Redes Neurais

A análise de sobrevivência, também denominada análise de tempo até o evento (*time-to-event analysis*), é um conjunto de técnicas estatísticas destinadas a modelar o tempo decorrido até a ocorrência de um evento de interesse, considerando explicitamente a presença de censura. No contexto deste trabalho, o evento de interesse é o óbito de causa cardíaca, incluindo Morte Súbita Cardíaca ou falência de bomba cardíaca, e a censura corresponde aos pacientes cujo acompanhamento clínico foi encerrado sem a ocorrência do desfecho fatal, seja por alta hospitalar, perda de seguimento ou término do período de estudo.

A censura é um aspecto estrutural dos dados clínicos longitudinais e não pode ser ignorada: excluir pacientes censurados implica viés de seleção, ao passo que tratá-los como se tivessem experimentado o evento introduz viés de informação. Modelos baseados na verossimilhança para dados com censura à direita (*right-censored likelihood*) resolvem esse problema ao incorporar, para cada paciente, a contribuição probabilística adequada ao seu status observado: a probabilidade de ocorrência do evento no tempo observado, para pacientes com evento, e a probabilidade de sobrevivência até o tempo de censura, para pacientes censurados.

A abordagem adotada neste trabalho é a da análise de sobrevivência em tempo discreto com redes neurais, na qual o eixo temporal contínuo é discretizado em m intervalos

$$[c_0, c_1),\ [c_1, c_2),\ \ldots,\ [c_{m-1}, c_m), \tag{2.1}$$

e a rede neural aprende a distribuição do tempo de falha sobre esses intervalos. Conforme proposto por Kvamme e Borgan (2019), os pontos de corte são definidos pelos quantis da distribuição empírica dos tempos de evento observados, em contraste com o esquema equidistante comumente utilizado. Os autores demonstram que tal estratégia é preferível especialmente em conjuntos de dados de menor dimensão, como o presente estudo com 992 pacientes. Esse esquema de discretização é implementado pela classe `DiscreteTimeTransform`, que ajusta os cortes com base nos quantis dos tempos dos pacientes com evento e garante que o horizonte temporal seja sempre coberto pelo último intervalo.

A rede neural recebe as covariáveis de cada paciente, incluindo sinais de ECG e dados clínicos, e produz um vetor de logits

$$\boldsymbol{\phi} = (\phi_0, \phi_1, \ldots, \phi_{m-1}) \in \mathbb{R}^m, \tag{2.2}$$

a partir do qual as probabilidades de sobrevivência são computadas de acordo com a parametrização adotada. Três funções de perda foram implementadas e avaliadas comparativamente neste estudo, cada uma correspondendo a uma parametrização distinta da distribuição do tempo de falha: *Logistic-Hazard*, *PMF* e *DeepHitSingle*.

2.1.1 Logistic-Hazard

A formulação *Logistic-Hazard*, denominada *Nnet-Survival* por Gensheimer e Narasimhan (2019), parametriza a função de risco discreta h_k, definida como a probabilidade condicional de o evento ocorrer no intervalo k, dado que o paciente sobreviveu até o início desse intervalo. Trata-se de um modelo teoricamente fundamentado na verossimilhança de modelos de sobrevivência em tempo discreto, formulados no contexto sociológico por Allison (1982) e conectados à regressão logística por Efron (1988). A aplicação de redes neurais *feedforward* a esse arcabouço foi explorada por Biganzoli *et al.* (1998) por meio de uma abordagem de regressão logística parcial para dados censurados. Gensheimer e Narasimhan (2019) unificam e formalizam essa linha, propondo o treinamento com gradiente estocástico por mini-batches, o que torna o modelo escalável a grandes conjuntos de dados, e demonstram sua competitividade com modelos como *Cox-nnet* e *DeepSurv*.

Para cada bin temporal $k \in \{0, 1, \ldots, m-1\}$, o risco discreto é obtido pela aplicação da função sigmoide sobre o logit correspondente:

$$h_k = \sigma(\phi_k) = \frac{1}{1+e^{-\phi_k}}. \tag{2.3}$$

A função de sobrevivência discreta é construída como o produto acumulado dos complementos do risco ao longo dos intervalos precedentes:

$$S(t_k) = \prod_{j=0}^{k}(1-h_j). \tag{2.4}$$

A função de perda é a log-verossimilhança negativa do modelo de sobrevivência em tempo discreto. Para um paciente com evento ($d_i = 1$) no intervalo de índice k_i, a contribuição à perda é a log-probabilidade conjunta de ter sobrevivido até $k_i - 1$ e de ter falhado em k_i:

$$\ell_i = -\log h_{k_i} - \log S(t_{k_i-1}). \tag{2.5}$$

Para um paciente censurado ($d_i = 0$) no intervalo k_i, a contribuição é a log-probabilidade de sobrevivência até o momento da censura:

$$\ell_i = -\log S(t_{k_i}). \tag{2.6}$$

A perda total do *batch* é a média das contribuições individuais:

$$\mathscr{L} = \frac{1}{N}\sum_{i=1}^{N} \ell_i. \tag{2.7}$$

Conforme Kvamme e Borgan (2019), que comparam sistematicamente as parametrizações via hazard discreto e via PMF em simulações e dados reais, a parametrização pelo hazard discreto, correspondente ao *Logistic-Hazard*, apresenta desempenho ligeiramente superior à parametrização pela PMF na maioria dos cenários avaliados, embora ambas sejam competitivas. Essa constatação motivou a inclusão do *Logistic-Hazard* como linha de base primária neste trabalho.

2.1.2 PMF — Probability Mass Function

A formulação PMF, proposta e analisada por Kvamme e Borgan (2019), parametriza diretamente a função de massa de probabilidade p_k sobre os intervalos de tempo discretizados, tratando a distribuição do tempo de falha como um objeto probabilístico explicitamente normalizado. Em vez de estimar funções de risco condicionais para cada bin individualmente, como na formulação *Logistic-Hazard*, o modelo estima a probabilidade de o evento ocorrer especificamente no intervalo k, de forma que $\sum_k p_k = 1$.

Para garantir essa propriedade de normalização ao longo de todo o horizonte temporal, incluindo a possibilidade de sobrevivência além do último intervalo observado, Kvamme e Borgan (2019) propõem adicionar um logit artificial $\phi_m = 0$ ao vetor de saída da rede e aplicar a função *softmax* sobre o vetor aumentado de dimensão $m+1$:

$$p_k = \frac{e^{\phi_k}}{\sum_{j=0}^{m} e^{\phi_j}}, \quad k = 0, 1, \ldots, m, \tag{2.8}$$

onde $\phi_m = 0$ representa o logit do bin artificial correspondente à sobrevivência além do horizonte de observação. A função de sobrevivência é obtida pela soma acumulada reversa da PMF; isto é, a probabilidade de o paciente sobreviver além do bin k é a soma das probabilidades de evento em todos os bins posteriores:

$$S(t_k) = \sum_{j=k+1}^{m} p_j. \tag{2.9}$$

A função de perda é a log-verossimilhança negativa baseada nessa distribuição conjunta. Para pacientes com evento ($d_i = 1$), penaliza-se a log-probabilidade da massa no bin

correto; para censurados ($d_i = 0$), penaliza-se a log-probabilidade de sobrevivência além do bin de censura:

$$\ell_i = \begin{cases} -\log p_{k_i}, & \text{se } d_i = 1, \\ -\log S(t_{k_i}), & \text{se } d_i = 0. \end{cases} \tag{2.10}$$

A distinção conceitual fundamental entre PMF e *Logistic-Hazard* reside na estrutura das dependências entre os logits: no *Logistic-Hazard*, cada ϕ_k define independentemente o risco no bin k por meio da sigmoide, de modo que a função de sobrevivência emerge como um produto; na PMF, todos os ϕ_k competem globalmente via *softmax*, de modo que um aumento do logit em um bin necessariamente reduz a probabilidade dos demais. Essa interdependência torna a PMF conceitualmente mais próxima de uma distribuição de probabilidade discreta genuína, mas impõe ao otimizador um espaço de gradientes mais acoplado.

2.1.3 DeepHitSingle

O DeepHit, proposto por Lee *et al.* (2018) para a conferência AAAI 2018, representa um avanço qualitativo em relação às formulações anteriores ao incorporar um termo de perda de ordenação (*ranking loss*) à função objetivo, além do termo de verossimilhança. A motivação central é que a maximização da verossimilhança, objetivo compartilhado pelo *Logistic-Hazard* e pelo PMF, otimiza a qualidade das probabilidades absolutas estimadas, mas não garante que o modelo aprenda a ordenar corretamente os pacientes segundo seu risco relativo. Um modelo pode estar bem calibrado em termos de probabilidades e ainda assim cometer erros sistemáticos de ordenação entre pares de pacientes, o que é clinicamente inaceitável em um sistema de estratificação de risco.

Conforme Lee *et al.* (2018), o DeepHit aprende diretamente a distribuição dos tempos de sobrevivência por meio de uma rede neural profunda, sem assumir qualquer forma paramétrica para o processo estocástico subjacente e permitindo que a relação entre as covariáveis e o risco varie ao longo do tempo. Essas propriedades superam as limitações do modelo de Cox proporcional de risco, que impõe a hipótese de proporcionalidade dos hazards e a invariância temporal dos efeitos das covariáveis.

A função de perda total do DeepHit é uma combinação linear de dois termos complementares:

$$\mathscr{L}_{\text{total}} = \mathscr{L}_1 + \alpha \mathscr{L}_2. \tag{2.11}$$

O primeiro termo, de log-verossimilhança ($\mathscr{L}_1$), é idêntico à formulação PMF descrita anteriormente, com a adição do logit artificial $\phi_m = 0$ e aplicação de *softmax*. Esse termo garante que a distribuição de probabilidade estimada seja globalmente coerente com os desfechos observados.

O segundo termo, a perda de ordenação ($\mathscr{L}_2$), penaliza pares de pacientes (i, j) em que o paciente i faleceu antes do paciente j ($t_i < t_j$, $d_i = 1$), mas o modelo atribuiu menor risco cumulativo a i do que a j no instante t_i. Para cada par válido, a penalidade é proporcional à função exponencial da diferença de risco:

$$\eta(i, j) = \exp\left(-\frac{F(t_i \mid \mathbf{x}_i) - F(t_i \mid \mathbf{x}_j)}{\sigma}\right), \tag{2.12}$$

onde

$$F(t_k \mid \mathbf{x}) = \sum_{j=0}^{k} p_j(\mathbf{x}) \tag{2.13}$$

é a função de distribuição acumulada (CDF) do modelo para o paciente com covariáveis $\mathbf{x}$, e $\sigma > 0$ é um hiperparâmetro de suavização. A lógica da penalidade é a seguinte: quando $F(t_i \mid \mathbf{x}_i) > F(t_i \mid \mathbf{x}_j)$, isto é, quando o modelo atribui corretamente maior risco cumulativo ao paciente que faleceu primeiro, a diferença é positiva, o expoente é negativo e $\eta \to 0$, produzindo penalidade próxima de zero. Quando a ordenação está incorreta, a diferença é negativa ou nula, o expoente tende a zero e $\eta \to 1$, maximizando a penalidade. A perda de ordenação do *batch* é normalizada pela quantidade de pares válidos:

$$\mathscr{L}_2 = \frac{\displaystyle\sum_{i:\, d_i=1} \sum_{j:\, t_i<t_j} \eta(i, j)}{\displaystyle\sum_{i:\, d_i=1} \sum_{j:\, t_i<t_j} 1 + \varepsilon}. \tag{2.14}$$

O hiperparâmetro α controla o equilíbrio entre calibração probabilística ($\mathscr{L}_1$) e discriminação relativa ($\mathscr{L}_2$). A minimização conjunta dos dois termos promove modelos que são simultaneamente bem calibrados em probabilidade e capazes de distinguir corretamente pacientes de alto e baixo risco, características essenciais para aplicações de prognóstico clínico.

No presente trabalho, o *DeepHitSingle* designa a variante para risco único (*single risk*), em oposição à formulação original com riscos competitivos (*competing risks*). Adicionalmente, para compensar o desbalanceamento da base de dados, em que eventos cardíacos representam aproximadamente 20,67% dos pacientes, aplica-se um fator de ponderação `peso_evento = 4.0` sobre as contribuições de pacientes com evento no termo $\mathscr{L}_1$, de modo a elevar proporcionalmente o gradiente produzido por esses casos na otimização.

2.2 Arquitetura — ResNet-18 Unidimensional

2.2.1 Aprendizado Profundo Residual

As redes neurais residuais (*Residual Networks* — ResNets) foram propostas por He *et al.* (2016) como solução ao problema da degradação observado em redes muito profundas: empiricamente, o aumento indiscriminado da profundidade de uma rede produzia piora no desempenho de treinamento, não apenas de generalização, revelando dificuldades de otimização mais fundamentais do que o sobreajuste. A hipótese de He *et al.* (2016) é que é mais fácil para a rede aprender um mapeamento residual $\mathscr{F}(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$ do que aprender diretamente o mapeamento original $H(\mathbf{x})$, especialmente quando $H(\mathbf{x}) \approx \mathbf{x}$, isto é, quando a transformação ideal é próxima da identidade. Isso é viabilizado pelas conexões de atalho (*skip connections*), que somam a entrada de cada bloco à sua saída transformada:

$$\mathbf{y} = \mathscr{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}. \tag{2.15}$$

Essas conexões criam caminhos de gradiente diretos ao longo de toda a rede durante a retropropagação, mitigando o desvanecimento do gradiente e permitindo o treinamento estável de arquiteturas com dezenas ou centenas de camadas. He *et al.* (2016) demonstram que a ResNet-18 e modelos mais profundos superam consistentemente redes sem conexões residuais de mesma ou maior profundidade, tanto em tarefas de classificação de imagens quanto em detecção de objetos.

A adequação da arquitetura ResNet ao domínio do eletrocardiograma foi demonstrada em trabalhos de referência na área. Hannun *et al.* (2019) empregaram uma rede residual profunda de 34 camadas para classificação de arritmias em ECGs ambulatoriais de derivação única, atingindo desempenho equivalente ou superior ao de cardiologistas em 12 categorias de ritmo. Ribeiro *et al.* (2020) desenvolveram uma ResNet de 9 camadas para o diagnóstico automático do ECG de 12 derivações em mais de dois milhões de registros, demonstrando acurácia de nível especialista em seis categorias de alterações clínicas. Esses trabalhos consolidam a ResNet como arquitetura de referência para o processamento de sinais de ECG e fundamentam sua adoção no presente estudo.

2.2.2 Adaptação para Sinais Unidimensionais

A transposição da ResNet-18 para o domínio de sinais temporais consiste na substituição das convoluções bidimensionais, projetadas para imagens com largura e altura, por convoluções unidimensionais, que operam ao longo do único eixo temporal do sinal de ECG. Todas as demais propriedades arquiteturais são preservadas: estrutura dos blocos residuais, dimensionalidade dos canais, normalização em lote e função de ativação ReLU.

O bloco residual básico (`BasicBlock1D`) é composto por duas convoluções 1D com kernel de tamanho 3 e preenchimento (*padding*) de 1, garantindo que o comprimento temporal do sinal seja preservado dentro do bloco quando não há *stride*. Entre as convoluções, aplica-se normalização em lote (*Batch Normalization*) e ativação ReLU:

$$\mathbf{y} = \mathrm{ReLU}(\mathrm{BN}_2(\mathrm{Conv}_2(\mathrm{ReLU}(\mathrm{BN}_1(\mathrm{Conv}_1(\mathbf{x})))))) + \mathrm{shortcut}(\mathbf{x})). \tag{2.16}$$

A conexão de atalho $\mathrm{shortcut}(\mathbf{x})$ é a identidade quando as dimensões de entrada e saída do bloco coincidem. Quando há mudança de *stride* ou de número de canais, caso em que as dimensões são incompatíveis, aplica-se uma projeção linear por convolução 1×1 (*downsample*) ao caminho da identidade, conforme especificado por He *et al.* (2016).

A rede completa (`ResNet1d`) é organizada da seguinte forma: uma camada de entrada com convolução de kernel 7, *stride* 2 e 64 canais de saída, seguida de normalização em lote, ReLU e *max pooling* com kernel 3 e *stride* 2, responsável pela primeira redução da dimensão temporal. Em seguida, quatro grupos de blocos residuais (`layer1` a `layer4`) ampliam progressivamente o número de canais para 64, 128, 256 e 512, com redução adicional do comprimento temporal por *stride* 2 nos grupos 2, 3 e 4. O tensor de entrada tem forma $[\mathrm{batch}, 1, L]$, correspondendo a uma derivação de ECG por janela de sinal de comprimento L, e o tensor de saída tem forma $[\mathrm{batch}, 512, L']$, onde L' é o comprimento temporal após as subamostragens acumuladas.

2.2.3 Remoção do Global Average Pooling e Atenção Temporal

Na implementação canônica da ResNet-18 para classificação de imagens, a saída da última camada convolucional é submetida a *Global Average Pooling* (GAP), que colapsa a dimensão espacial, ou temporal no caso 1D, por média simples, produzindo um vetor de dimensão fixa independente do tamanho da entrada. No presente trabalho, essa camada foi deliberadamente removida, preservando a dimensão temporal na saída do encoder:

$$\text{saída do encoder} : [\mathrm{batch}, 512, L'] \quad \text{(3D, dimensão temporal preservada).} \tag{2.17}$$

A justificativa para essa decisão é de natureza clínica: o GAP pondera igualmente todos os instantes temporais do sinal de ECG, diluindo indistintamente eventos cardíacos breves e clinicamente relevantes, como batimentos ectópicos, pausas sinusais ou alterações transitórias do segmento ST, que podem ser decisivos para a predição de morte súbita cardíaca. Ao preservar a dimensão temporal, é possível aplicar estratégias de agregação seletiva que concentrem a representação final nas regiões do sinal com maior valor prognóstico.

Para essa finalidade, foi implementado um mecanismo de atenção temporal (*TemporalAttention*) como alternativa ao GAP. Dado o tensor de saída da ResNet $\mathbf{H} \in \mathbb{R}^{B\times 512\times L'}$, o módulo computa para cada posição temporal $l \in \{1,\ldots,L'\}$ um escore de atenção escalar por meio de uma pequena rede *feedforward* de duas camadas com ativação tangente hiperbólica:

$$a_l = \mathbf{v}^\top \tanh(W_1\mathbf{h}_l + \mathbf{b}_1) \in \mathbb{R}. \tag{2.18}$$

Os escores são normalizados via *softmax* ao longo do eixo temporal, produzindo pesos de atenção $\alpha_l = \mathrm{softmax}(a_l)$. O vetor de contexto é então obtido por soma ponderada das representações em cada instante:

$$\mathbf{c} = \sum_{l=1}^{L'} \alpha_l \mathbf{h}_l \in \mathbb{R}^{512}. \tag{2.19}$$

O vetor $\mathbf{c}$ constitui a representação condensada da janela de ECG, com contribuição proporcional de cada instante temporal à sua relevância prognóstica aprendida pelo modelo. Instantes com padrões morfológicos normais recebem pesos baixos; instantes com alterações relevantes recebem pesos elevados. Na versão atual do modelo (`ModeloSurvivalHibrido`), por razões de regularização e estabilidade durante o desenvolvimento, o módulo de atenção foi temporariamente substituído por média simples ao longo da dimensão temporal (`features.mean(dim=2)`), equivalente ao GAP, mas a arquitetura de atenção permanece implementada para comparação experimental futura.

2.2.4 Modelo Híbrido de Sobrevivência

O modelo final integra as representações extraídas do sinal de ECG com as variáveis clínicas e demográficas dos pacientes por meio de uma arquitetura de fusão simétrica. Após a extração de características pelo encoder ResNet-18 1D e a agregação temporal, o vetor de 512 dimensões é comprimido por um módulo gargalo (*ECG bottleneck*) composto por duas camadas lineares com ativação ReLU e *Dropout*, produzindo uma representação de 16 dimensões.

Paralelamente, as variáveis clínicas são processadas por uma rede *feedforward* de duas camadas (*clinical net*), também produzindo um vetor de 16 dimensões.

A fusão das duas modalidades ocorre por concatenação, resultando em um vetor de 32 dimensões:

$$\mathbf{z} = [\mathbf{e}_{16}; \mathbf{c}_{16}] \in \mathbb{R}^{32} \tag{2.20}$$

onde $\mathbf{e}_{16}$ é a representação do ECG após o gargalo e $\mathbf{c}_{16}$ é a representação clínica. Esse vetor é então processado pela camada de saída (*head*), composta por camadas lineares com ReLU e *Dropout*, produzindo os logits $\boldsymbol{\phi} \in \mathbb{R}^m$ correspondentes aos m bins temporais.

2.3 Aprendizado por Representação Contrastiva

O aprendizado auto-supervisionado por contraste (*self-supervised contrastive learning*) é um paradigma de treinamento em que um modelo aprende representações de dados sem rótulos explícitos, maximizando a similaridade entre diferentes visões aumentadas de uma mesma amostra e minimizando-a em relação a amostras distintas. A motivação central é aprender, a partir de grandes volumes de dados não rotulados, representações que capturem estrutura semântica transferível para tarefas supervisionadas *downstream*, especialmente quando os dados rotulados são escassos.

No contexto deste trabalho, esse paradigma é particularmente relevante: a base de dados MUSIC contém 992 pacientes com registros de ECG Holter de 24 horas, mas apenas 205 deles apresentam o evento de interesse (óbito cardíaco), correspondendo a 20,67% da amostra. O pré-treinamento auto-supervisionado permite utilizar os sinais de ECG de todos os pacientes, independentemente do status de evento, para aprender representações ricas do sinal cardíaco antes do ajuste fino (*fine-tuning*) supervisionado para a tarefa de sobrevivência.

A família de métodos *Momentum Contrast* (MoCo), desenvolvida pelo Facebook AI Research (FAIR) ao longo de três versões progressivas, constitui a base do pré-treinamento do encoder ResNet-18 1D utilizado neste trabalho. Cada versão endereça limitações específicas da anterior, formando uma progressão coerente que culmina na adaptação para *Vision Transformers*. A implementação adotada consolida os avanços das três versões em um arcabouço unificado, aplicado ao domínio de sinais de ECG unidimensionais.

2.3.1 MoCo v1: Contraste como Busca em Dicionário Dinâmico

nada (a) propõem o *Momentum Contrast* a partir da perspectiva do aprendizado contrastivo como um problema de busca em dicionário (*dictionary look-up*): dada uma amostra de consulta (*query*) $\mathbf{q}$, o objetivo é identificar, em um dicionário de representações, a chave positiva $\mathbf{k}_+$ correspondente à mesma amostra original entre K chaves negativas $\{\mathbf{k}_j^-\}_{j=1}^K$.

A principal contribuição do MoCo v1 é a construção de um dicionário dinâmico por meio de dois mecanismos interdependentes: uma fila (*queue*) de representações e um encoder de chave atualizado por momento (*momentum-updated encoder*).

2.3.1.1 Fila de Representações

O dicionário é mantido como uma fila FIFO (*First-In, First-Out*) de representações de mini-batches anteriores (NADA, a). A cada iteração de treinamento, as representações produzidas pelo encoder de chave no mini-batch corrente são enfileiradas, e as representações do mini-batch mais antigo são removidas. Seja B o tamanho do mini-batch; após $\lfloor K/B \rfloor$ iterações, o dicionário contém aproximadamente K representações negativas disponíveis para a função de perda.

Essa estrutura desacopla o número de amostras negativas do tamanho do mini-batch, permitindo que $K \gg B$. No presente trabalho, adota-se $K = 8192$ e $B = 256$, de modo que o dicionário mantém $K/B = 32$ mini-batches de histórico. Esse valor de K é deliberadamente menor do que os $K = 65536$ usados originalmente no ImageNet (NADA, a), refletindo a escala do conjunto de ECG (992 pacientes $\times$ 100 janelas/paciente = 99.200 amostras), onde uma fila excessivamente grande introduziria representações muito desatualizadas.

2.3.1.2 Encoder de Momento

O encoder de chave f_k não é atualizado por retropropagação direta, mas sim por média móvel exponencial (*Exponential Moving Average*, EMA) dos parâmetros do encoder de consulta f_q (NADA, a):

$$\theta_k \leftarrow m\,\theta_k + (1-m)\,\theta_q, \tag{2.21}$$

onde $m \in [0,1)$ é o coeficiente de momento, adotado como $m = 0{,}999$ neste trabalho. A Equação (2.21) implica que, a cada iteração, θ_k se aproxima de θ_q com passo relativo de apenas

$1 - m = 0{,}001$, ou seja, o encoder de chave evolui $1000\times$ mais lentamente do que o encoder de consulta. Essa atualização lenta garante a consistência das representações armazenadas na fila: chaves produzidas em mini-batches anteriores ainda são representações válidas do espaço aprendido, pois f_k não sofreu saltos abruptos que tornariam as chaves antigas incompatíveis com as consultas correntes.

O valor $m = 0{,}999$ é mais conservador do que os valores $m \in \{0{,}99, 0{,}999\}$ explorados em nada (a), sendo preferível em domínios com alta variabilidade intra-amostra como o ECG Holter de 24 horas, onde o mesmo paciente apresenta morfologias distintas ao longo do dia, pois estabiliza o dicionário frente a oscilações rápidas no encoder de consulta.

2.3.1.3 Função de Perda InfoNCE

A função de perda utilizada é a InfoNCE (*Noise Contrastive Estimation*) (OORD *et al.*, 2018), que formula o problema contrastivo como uma classificação entre $K+1$ candidatos: identificar a chave positiva $\mathbf{k}_+$ entre um conjunto composto por $\mathbf{k}_+$ e K chaves negativas $\{\mathbf{k}_j^-\}_{j=1}^K$. A similaridade entre representações é medida pelo produto escalar no espaço ℓ_2-normalizado:

$$\mathscr{L}_{\text{InfoNCE}} = -\log \frac{\exp(\mathbf{q}\cdot\mathbf{k}_+/\tau)}{\exp(\mathbf{q}\cdot\mathbf{k}_+/\tau) + \sum_{j=1}^{K}\exp\left(\mathbf{q}\cdot\mathbf{k}_j^-/\tau\right)}, \tag{2.22}$$

onde $\tau > 0$ é um hiperparâmetro de temperatura que controla a suavidade (*sharpness*) da distribuição sobre os candidatos. Valores baixos de τ tornam a distribuição mais concentrada, penalizando mais severamente as chaves negativas com alta similaridade à consulta.

A temperatura adotada é $\tau = 0{,}07$, idêntica à reportada por nada (a) como ótima para o ImageNet. No contexto de ECG, a temperatura baixa é justificada pela alta discriminabilidade esperada entre padrões morfológicos distintos, como fibrilação atrial e ritmo sinusal, mas exige que as representações estejam bem normalizadas para evitar saturação dos exponenciais, condição garantida pela normalização ℓ_2 aplicada nas projeções do modelo.

Na implementação, a perda InfoNCE é computada como uma entropia cruzada categórica padrão (`nn.CrossEntropyLoss`) sobre os logits $\mathbf{l} \in \mathbb{R}^{K+1}$, onde a classe correta é sempre o índice 0, correspondente à chave positiva. Os logits são construídos como:

$$\mathbf{l} = \left[\frac{\mathbf{q}\cdot\mathbf{k}_+}{\tau}; \frac{\mathbf{q}\cdot\mathbf{k}_1^-}{\tau}; \ldots; \frac{\mathbf{q}\cdot\mathbf{k}_K^-}{\tau}\right] \in \mathbb{R}^{K+1}, \tag{2.23}$$

de modo que minimizar $\mathscr{L}_{\text{InfoNCE}}$ é equivalente a maximizar a probabilidade *softmax* da classe 0, o que corresponde matematicamente à Equação (3.1).

2.3.2 MoCo v2: Cabeça de Projeção MLP e Aumentação Aprimorada

O MoCo v2, proposto por Chen *et al.* (2020b), verifica sistematicamente a eficácia de dois aprimoramentos identificados pelo SimCLR (CHEN *et al.*, 2020a) e os incorpora ao arcabouço MoCo, demonstrando que ganhos expressivos são possíveis sem aumentar o custo computacional da fila.

2.3.2.1 Cabeça de Projeção Não Linear

A camada de projeção linear ao final do encoder é substituída por uma rede de duas camadas com ativação ReLU:

$$\mathbf{z} = W_2\,\mathrm{ReLU}(W_1\,\mathbf{h}), \tag{2.24}$$

onde $\mathbf{h} \in \mathbb{R}^d$ é a representação extraída pelo encoder (*backbone*), $W_1 \in \mathbb{R}^{d_h \times d}$ é a matriz de pesos da camada oculta com dimensão d_h, e $\mathbf{z} \in \mathbb{R}^{d_z}$ é o vetor de projeção sobre o qual a perda InfoNCE opera. Na implementação do presente trabalho, adota-se $d_z = 256$, valor do hiperparâmetro `moco_dim`.

A cabeça de projeção é utilizada exclusivamente durante o pré-treinamento e descartada no *fine-tuning* supervisionado. A representação transferida para o modelo de sobrevivência é $\mathbf{h}$, não $\mathbf{z}$. A motivação é que a perda contrastiva pode demandar invariâncias, por exemplo invariância a aumentações de amplitude, que não são desejáveis na representação final; a cabeça de projeção absorve essas transformações, preservando a riqueza semântica de $\mathbf{h}$.

2.3.2.2 Aumentação de Dados Aprimorada

Seguindo Chen *et al.* (2020b), a estratégia de aumentação é enriquecida com perturbações adicionais sobre o sinal. No domínio de ECG unidimensional, essas perturbações são implementadas em GPU pelo módulo `GPU_ECG_Augmenter` com probabilidade de aplicação $p = 0{,}80$, o que significa que, em expectativa, 80% das janelas de sinal recebem pelo menos uma transformação estocástica a cada passagem.

Dada uma janela de sinal $\mathbf{x} \in \mathbb{R}^{C \times L}$, com C canais e $L = 24000$ amostras correspondentes a 24 segundos a 1000 Hz, duas visões aumentadas independentes são geradas:

$$\mathbf{x}^{(1)} = \mathscr{T}_1(\mathbf{x}), \qquad \mathbf{x}^{(2)} = \mathscr{T}_2(\mathbf{x}), \tag{2.25}$$

onde $\mathscr{T}_1, \mathscr{T}_2 \overset{\text{i.i.d.}}{\sim} \mathscr{A}$ são realizações independentes da distribuição de aumentação $\mathscr{A}$. As visões $\mathbf{x}^{(1)}$ e $\mathbf{x}^{(2)}$ constituem o par consulta–chave (`im_q`, `im_k`) da iteração corrente. Crucialmente, as aumentações são aplicadas após a transferência dos dados para a GPU, eliminando o gargalo de CPU que penalizaria o *throughput* com janelas de 24.000 amostras.

2.3.3 MoCo v3: Perda Simétrica e Estabilidade de Treinamento

O MoCo v3, apresentado por Chen *et al.* (2021), não introduz um método fundamentalmente novo, mas endereça o problema central de instabilidade de treinamento que degrada o aprendizado auto-supervisionado com arquiteturas modernas. A contribuição principal, a perda contrastiva simétrica, é incorporada integralmente na implementação deste trabalho.

2.3.3.1 Perda Contrastiva Simétrica

Enquanto o MoCo v1/v2 computa a perda InfoNCE em uma única direção (consulta $\rightarrow$ chave), o MoCo v3 adota uma perda simétrica com dois termos mutuamente invertidos (CHEN *et al.*, 2021):

$$\mathscr{L}_{\text{sym}} = \frac{1}{2}\mathscr{L}_{\text{InfoNCE}}\Big(f_q(\mathbf{x}^{(1)}), f_k(\mathbf{x}^{(2)})\Big) + \frac{1}{2}\mathscr{L}_{\text{InfoNCE}}\Big(f_q(\mathbf{x}^{(2)}), f_k(\mathbf{x}^{(1)})\Big). \tag{2.26}$$

A Equação (2.26) trata cada visão alternadamente como consulta e como chave, duplicando o número efetivo de pares positivos por amostra sem aumentar o custo de memória. Além do enriquecimento do sinal de aprendizado, a simetria remove o viés direcional implícito na perda assimétrica, o que é relevante no domínio de ECG, onde $\mathscr{T}_1$ e $\mathscr{T}_2$ são equiprováveis e não existe uma visão canonicamente "mais limpa" que a outra.

2.3.3.2 Instabilidade de Treinamento e Mitigação

Chen *et al.* (2021) identificam que a instabilidade se manifesta como oscilações abruptas na curva de perda (*loss dips*), correlacionadas com quedas de desempenho na avaliação *downstream*. No presente trabalho, três mecanismos complementares de mitigação são empregados.

Precisão mista automática (AMP). O treinamento utiliza `torch.cuda.amp` com `GradScaler`, que escala dinamicamente o gradiente para evitar *underflow* em `float16` sem comprometer a acurácia numérica das atualizações em `float32`. O escalonador mantém um

fator de escala s_t que é multiplicado pelos gradientes antes da retropropagação:

$$\hat{\mathbf{g}}_t = s_t\,\mathbf{g}_t, \tag{2.27}$$

e ajustado adaptativamente: se nenhum gradiente tornar-se `inf` ou `NaN` por `growth_interval` iterações, s_t é multiplicado por `growth_factor`; se ocorrer *overflow*, o passo é descartado e s_t é reduzido.

Otimizador SGD com momento. O otimizador adotado é o Gradiente Descendente Estocástico com momento $\beta = 0{,}9$ e decaimento de peso $\lambda = 5 \times 10^{-4}$:

$$\mathbf{v}_{t+1} = \beta\,\mathbf{v}_t - \eta_t\,(\nabla_\theta \mathscr{L}_t + \lambda\,\theta_t), \tag{2.28}$$

$$\theta_{t+1} = \theta_t + \mathbf{v}_{t+1}, \tag{2.29}$$

onde η_t é a taxa de aprendizado na iteração t, inicializada em $\eta_0 = 10^{-3}$. O momento $\beta = 0{,}9$ acumula direções de gradiente consistentes ao longo das iterações, suavizando o caminho de otimização e reduzindo a variância estocástica do mini-batch, o que é especialmente benéfico com $B = 256$ amostras em um espaço de representação de dimensão $d_z = 256$.

Escalonamento adaptativo da taxa de aprendizado. O scheduler `ReduceLROnPlateau` monitora a perda média por época e reduz η_t por um fator de 0,5 quando não há melhora por 30 épocas consecutivas, com piso mínimo $\eta_{\min} = 10^{-6}$:

$$\eta_{t+1} = \begin{cases} 0{,}5\,\eta_t, & \text{se não houver melhora por 30 épocas,} \\ \eta_t, & \text{caso contrário.} \end{cases} \tag{2.30}$$

Esse mecanismo adapta automaticamente o passo de otimização à paisagem de perda do pré-treinamento contrastivo, que tipicamente apresenta um platô longo seguido de descida suave, padrão esperado em domínios com distribuição de aumentação $\mathscr{A}$ de alta variância.

2.3.4 Síntese do Arcabouço Implementado

A implementação adotada neste trabalho consolida os três avanços da família MoCo em um único arcabouço denominado `MoCo_ResNet1D`. O fluxo computacional de uma iteração pode ser descrito em quatro estágios.

Estágio 1: aumentação dupla na GPU. Dada uma janela de ECG $\mathbf{x} \in \mathbb{R}^{C \times 24000}$ do mini-batch corrente, o `GPU_ECG_Augmenter` produz dois sinais perturbados independentes $\mathbf{x}^{(1)}$ e $\mathbf{x}^{(2)}$ conforme a Equação (2.25).

Estágio 2: codificação e projeção. As visões são processadas pelos encoders de consulta e chave, respectivamente. Para cada visão $v \in \{1,2\}$, o encoder ResNet-18 1D extrai a representação $\mathbf{h}^{(v)} \in \mathbb{R}^d$, e a cabeça de projeção MLP produz o vetor normalizado $\mathbf{z}^{(v)}/\|\mathbf{z}^{(v)}\|_2 \in \mathbb{R}^{256}$.

Estágio 3: construção dos logits e perda simétrica. Para cada direção, os logits $\mathbf{l}^{(v)} \in \mathbb{R}^{K+1}$ são construídos conforme a Equação (2.23) com as $K = 8192$ chaves da fila, e a perda simétrica $\mathscr{L}_{\text{sym}}$ é computada conforme a Equação (2.26).

Estágio 4: atualização dos parâmetros. O encoder de consulta f_q é atualizado por retropropagação através de $\mathscr{L}_{\text{sym}}$ via SGD, conforme as Equações (2.28)–(2.29), com AMP conforme a Equação (2.27). O encoder de chave f_k é atualizado exclusivamente por EMA, conforme a Equação (2.21), com $m = 0{,}999$.

A Tabela 1 sumariza os hiperparâmetros adotados e sua justificativa formal.

Tabela 1 – Hiperparâmetros do pré-treinamento MoCo no domínio ECG.

Símbolo	Valor	Parâmetro	Justificativa
K	8.192	Tamanho da fila	Aproximadamente 8% do conjunto total; evita chaves obsoletas.
m	0,999	Momento do encoder	Alta estabilidade para ECG com variabilidade intra-dia.
τ	0,07	Temperatura InfoNCE	Distribuição concentrada; consistente com nada (a).
d_z	256	Dimensão da projeção	Compromisso entre capacidade e generalização.
B	256	Tamanho do mini-batch	$K/B = 32$ mini-batches de histórico na fila.
η_0	10^{-3}	Taxa de aprendizado	SGD com momento; escalonado adaptativamente.
λ	5×10^{-4}	Decaimento de peso	Regularização ℓ_2 padrão para pré-treinamento.
β	0,9	Momento SGD	Suavização do caminho de otimização.
L	24.000	Comprimento da janela	24 s a 1.000 Hz; captura ciclos cardíacos completos.
p	0,80	Probabilidade de aumentação	80% das amostras recebem perturbação por passagem.

2.3.5 Relevância do Arcabouço para o Pré-Treinamento em ECG Holter

A adoção do arcabouço MoCo no pré-treinamento do encoder ResNet-18 1D é motivada por dois fatores estruturais do problema.

O primeiro é a escassez de rótulos positivos: com 205 eventos em 992 pacien-

tes (20,67%), o treinamento supervisionado direto enfrenta risco de sobreajuste e de subrepresentação de padrões morfológicos raros. O pré-treinamento contrastivo utiliza os sinais de todos os 992 pacientes, isto é, $992 \times 100 = 99.200$ janelas de 24 s, para construir representações discriminativas sem qualquer supervisão de sobrevivência. O encoder aprende a distinguir padrões de ECG a partir de 99.200 instâncias, enquanto o *fine-tuning* supervisionado posterior dispõe de apenas 992 rótulos de evento.

O segundo é a vantagem da fila de negativos em cenários de baixa prevalência. A fila com $K = 8192$ representações garante que, a cada iteração, o encoder enfrenta um espectro amplo de morfologias de ECG como amostras negativas. Em um mini-batch de $B = 256$ amostras com 20,67% de prevalência de evento, o modelo veria em média apenas aproximadamente 53 amostras do grupo de evento por iteração supervisionada; no pré-treinamento contrastivo, todos os 256 sinais do batch contribuem igualmente como âncoras, com $K = 8192$ negativos adicionais da fila, independentemente de seu rótulo de sobrevivência.

Após o pré-treinamento, os pesos do encoder f_q são transferidos para o modelo híbrido de sobrevivência (`ModeloSurvivalHibrido`), onde o parâmetro `freeze_encoder` governa se θ_q permanece congelado durante o *fine-tuning*, favorecendo a regularização em regimes de poucos dados, ou é ajustado conjuntamente com o restante do modelo.

2.4 Métricas de Avaliação

A avaliação rigorosa de modelos de sobrevivência exige métricas distintas das empregadas em problemas de classificação ou regressão tradicionais, em razão de duas particularidades estruturais dos dados de tempo até o evento: a presença de censura à direita, que implica informação parcial sobre parte dos pacientes, e a natureza probabilística e temporal da saída do modelo, que é uma função de sobrevivência $\hat{S}(t \mid \mathbf{x})$ definida ao longo de um horizonte contínuo de tempo, e não um escalar único.

Neste trabalho, três métricas complementares são empregadas: o índice de concordância dependente do tempo (C^{td}), proposto por **??**), que avalia a capacidade discriminativa do modelo; o *Integrated Brier Score* (IBS), introduzido por **??**) e aprimorado por **??**), que avalia conjuntamente calibração e discriminação por meio do erro quadrático médio ponderado; e o *Integrated Negative Binomial Log-Likelihood* (Int. NBLL), formalizado por Kvamme *et al.* (2019) com base nos fundamentos do IBS, que avalia a qualidade probabilística da distribuição estimada. Cada uma dessas métricas captura um aspecto distinto e complementar do desempenho

preditivo, e seu uso conjunto proporciona uma avaliação abrangente e robusta dos modelos desenvolvidos.

2.4.1 Índice de Concordância Dependente do Tempo (C^{td})

O índice de concordância original, proposto por Harrell et al. (1982), é a extensão da área sob a curva ROC (AUC-ROC) ao contexto de dados censurados: ele mede a proporção de pares de pacientes comparáveis para os quais o modelo ordena corretamente o risco relativo. Contudo, esse índice original baseia-se em escores de risco escalares, tipicamente a função de risco cumulativo em um instante fixo ou o índice de prognóstico linear, o que o torna inadequado para modelos cujos efeitos das covariáveis variam com o tempo, como os modelos de risco não proporcional implementados neste trabalho.

Para superar essa limitação, **??**) propõem o índice de concordância dependente do tempo C^{td}, no qual a totalidade da função de sobrevivência estimada $\hat{S}(t \mid \mathbf{x})$ é utilizada como predição de desfecho, em vez de um único escore escalar. A definição de concordância é reformulada de modo a levar em conta o instante específico de cada comparação: um par de pacientes (i, j) com $T_i < T_j$ e $D_i = 1$ é considerado concordante se o modelo atribui, no instante T_i, uma probabilidade de sobrevivência menor ao paciente i do que ao paciente j, isto é, se $\hat{S}(T_i \mid \mathbf{x}_i) < \hat{S}(T_i \mid \mathbf{x}_j)$. Formalmente:

$$C^{\text{td}} = P\left[\hat{S}(T_i \mid \mathbf{x}_i) < \hat{S}(T_i \mid \mathbf{x}_j) \mid T_i < T_j,\ D_i = 1\right]. \tag{2.31}$$

Essa definição é mais geral do que a do C-Index de Harrell, pois avalia a ordenação dos riscos no instante do evento de cada par, e não em um instante fixo global, sendo adequada para modelos com hazards não proporcionais e com covariáveis de efeito dependente do tempo. Conforme **??**), essa formulação resume a capacidade discriminativa ao longo de todo o horizonte temporal de acompanhamento.

Valores de $C^{\text{td}} = 0{,}5$ indicam poder discriminativo equivalente ao acaso, enquanto $C^{\text{td}} = 1{,}0$ indica discriminação perfeita. A estimativa amostral é obtida pela proporção de pares concordantes sobre o total de pares comparáveis, com correção para a censura por meio de pesos IPCW (*Inverse Probability of Censoring Weighting*), assegurando consistência da estimativa mesmo quando a censura é informativa em relação às covariáveis.

Na implementação deste trabalho, o C^{td} é calculado após agregação dos escores de risco por paciente: como cada paciente contribui com múltiplas janelas de sinal de ECG no

dataloader, os escores de risco individuais de cada janela são agregados por média antes do cálculo da métrica. Essa decisão garante que o índice de concordância reflita o desempenho ao nível do indivíduo clínico, unidade de análise relevante para o prognóstico, e não ao nível da janela de sinal, que seria conceitualmente inadequado para a tarefa.

2.4.2 Integrated Brier Score (IBS)

O Brier Score foi originalmente proposto por Brier (1950) para avaliar a acurácia de previsões probabilísticas em meteorologia e, posteriormente, adaptado ao contexto da análise de sobrevivência. **??**) introduzem uma versão dependente do tempo do Brier Score para dados de sobrevivência com censura à direita, definindo-o como o erro quadrático médio entre a probabilidade de sobrevivência estimada e o desfecho binário observado em cada instante t:

$$\mathrm{BS}(t) = \frac{1}{N}\sum_{i=1}^{N}\left[\hat{S}(t \mid \mathbf{x}_i) - \mathbf{1}(T_i > t)\right]^2 \hat{w}_i(t), \tag{2.32}$$

onde $\mathbf{1}(T_i > t)$ é o indicador de sobrevivência do paciente i além do instante t, e $\hat{w}_i(t)$ são pesos de ponderação por censura inversa (IPCW), estimados pelo inverso da probabilidade de não censura até o instante t segundo o estimador de Kaplan-Meier. Esses pesos garantem que pacientes censurados antes de t sejam excluídos da avaliação de forma não enviesada: para pacientes com $T_i > t$, ainda em risco, $\hat{w}_i(t) = 1/\hat{G}(t)$; para pacientes com evento antes de t ($T_i \leq t$, $D_i = 1$), $\hat{w}_i(t) = 1/\hat{G}(T_i)$; para censurados antes de t ($T_i \leq t$, $D_i = 0$), o peso é zero, pois seu desfecho real é desconhecido.

??) demonstram que o estimador IPCW de **??**) é consistente sob a hipótese de independência entre os tempos de censura e os tempos de evento dado as covariáveis, e propõem estimadores modificados baseados em modelos de regressão para a distribuição de censura que preservam a consistência mesmo quando essa independência condicional não se verifica exatamente, cenário relevante em estudos clínicos observacionais como o presente.

O Brier Score no instante t mede conjuntamente calibração e discriminação: um modelo perfeitamente calibrado e com discriminação perfeita produz $\mathrm{BS}(t) = 0$; um modelo nulo baseado exclusivamente na curva de Kaplan-Meier da população, sem qualquer covariável individual, serve como referência, tipicamente produzindo $\mathrm{BS}(t) \approx 0{,}25$ para eventos com prevalência próxima de 50%.

O *Integrated Brier Score* (IBS) integra numericamente o $\mathrm{BS}(t)$ ao longo de todos os instantes do horizonte de avaliação $[0, t_{\max}]$, fornecendo uma medida escalar global de

desempenho:

$$\text{IBS} = \frac{1}{t_{\max}} \int_0^{t_{\max}} \text{BS}(t)\, dt. \tag{2.33}$$

Valores de IBS menores indicam melhor desempenho. O IBS é calculado neste trabalho via a classe `EvalSurv` da biblioteca `pycox` (KVAMME, 2019), implementada em Kvamme *et al.* (2019), que adota a estimativa IPCW de **??**) com a correção de consistência de **??**) como ponderação padrão.

2.4.3 Integrated Negative Binomial Log-Likelihood (Int. NBLL)

O *Negative Binomial Log-Likelihood* (NBLL) integrado é uma métrica de avaliação probabilística baseada em regras de pontuação (*scoring rules*) para dados de sobrevivência. Kvamme *et al.* (2019) a formalizam no contexto de modelos de sobrevivência com redes neurais, utilizando os mesmos fundamentos estatísticos do IBS, mas substituindo o erro quadrático, função de perda de Brier, pela log-verossimilhança binomial negativa como medida de discrepância entre a distribuição estimada e o desfecho observado.

Para cada instante t, o NBLL é definido como:

$$\text{NBLL}(t) = -\frac{1}{N} \sum_{i=1}^{N} \left[\mathbf{1}(T_i > t) \log \hat{S}(t \mid \mathbf{x}_i) + \mathbf{1}(T_i \leq t) \log\big(1 - \hat{S}(t \mid \mathbf{x}_i)\big) \right] \hat{w}_i(t), \tag{2.34}$$

com os mesmos pesos IPCW $\hat{w}_i(t)$ utilizados no Brier Score. A integração ao longo do horizonte temporal produz o Int. NBLL:

$$\text{Int. NBLL} = \frac{1}{t_{\max}} \int_0^{t_{\max}} \text{NBLL}(t)\, dt. \tag{2.35}$$

A penalidade logarítmica do NBLL é mais severa do que a penalidade quadrática do IBS para previsões extremamente mal calibradas: enquanto o erro quadrático cresce no máximo até 1, por exemplo para previsão de $\hat{S} = 1$ quando o evento já ocorreu, a penalidade logarítmica cresce ilimitadamente, com $-\log(0) \to \infty$. Isso torna o Int. NBLL particularmente sensível à concentração e ao posicionamento da distribuição estimada: um modelo que distribui elevada probabilidade de sobrevivência a um paciente que veio a óbito recebe penalidade desproporcional, incentivando o modelo a ser bem calibrado especialmente nas regiões temporais de maior risco.

Do ponto de vista da teoria da decisão, tanto o Brier Score quanto o NBLL são regras de pontuação próprias (*proper scoring rules*) (**??**), o que garante que sua minimização induz o modelo a fornecer probabilidades que refletem genuinamente suas crenças sobre o desfecho, e

não estratégias que minimizam a penalidade por subestimação ou superestimação sistemática. A integração temporal de ambas as métricas ao longo do horizonte de acompanhamento é adotada por Kvamme *et al.* (2019) como protocolo de avaliação padrão nos experimentos comparativos da biblioteca `pycox`, o que fundamenta sua adoção no presente trabalho.

2.4.4 Complementaridade das Métricas e Protocolo de Avaliação

As três métricas empregadas neste trabalho capturam dimensões distintas e complementares do desempenho preditivo:

- O C^{td} é uma métrica exclusivamente de discriminação: ele avalia se o modelo é capaz de ordenar corretamente os pacientes por nível de risco, independentemente de quão bem calibradas estejam as probabilidades absolutas. Um modelo que sistematicamente superestima ou subestima a sobrevivência, mas mantém a ordenação correta entre os pacientes, pode exibir C^{td} elevado com IBS e Int. NBLL ruins.
- O IBS é uma métrica conjunta de calibração e discriminação: penaliza tanto erros de ordenação quanto desvios das probabilidades absolutas em relação aos desfechos observados, sendo, portanto, mais exigente do que o C^{td} isoladamente.
- O Int. NBLL é uma métrica de qualidade probabilística: por ser baseado na log-verossimilhança, é mais sensível a erros nas caudas da distribuição, onde o modelo expressa alta confiança, e penaliza de forma mais intensa as previsões muito mal calibradas do que o IBS.

Essa complementaridade é essencial para uma avaliação robusta no contexto clínico deste estudo: um modelo de estratificação de risco para morte súbita cardíaca deve ser simultaneamente discriminativo, capaz de separar pacientes de alto e baixo risco; calibrado, para que as probabilidades estimadas possam ser interpretadas clinicamente; e probabilisticamente coerente, para que as distribuições de tempo de evento reflitam adequadamente a incerteza prognóstica. O uso conjunto das três métricas mitiga o risco de selecionar um modelo que seja excelente em uma dimensão às custas das demais.

3 METODOLOGIA

3.1 Modelos de Análise de Sobrevivência

A abordagem proposta neste trabalho integra sinais de ECG Holter de 24 horas com variáveis clínicas estruturadas em um modelo híbrido para a estimativa do tempo até o evento. O pipeline é composto por três componentes principais: um encoder convolucional profundo para extração de características dos sinais eletrocardiográficos, uma rede de projeção para as variáveis clínicas e um cabeçote de predição baseado em modelos de tempo discreto.

3.1.1 Justificativa da Versão do MoCo Adotada

Embora a literatura sobre *Momentum Contrast* apresente evoluções sucessivas do método — MoCo v1 (HE *et al.*, 2020), MoCo v2 (CHEN *et al.*, 2020b) e MoCo v3 (CHEN *et al.*, 2021) —, este trabalho adota a formulação da segunda versão, que combina a fila dinâmica de amostras negativas (*queue*) e o encoder de momentum do MoCo v1 com o cabeçote de projeção não linear e as augmentações mais fortes introduzidas no MoCo v2. A escolha se justifica pela natureza do problema de instabilidade que o MoCo v3 se propõe a resolver: Chen, Xie e He (2021) demonstram que os colapsos e oscilações de perda observados no treinamento contrastivo de larga escala decorrem, majoritariamente, da camada de projeção linear de *patches* característica de *Vision Transformers* (ViT), que o MoCo v3 corrige congelando essa camada com pesos aleatórios fixos. Uma vez que o encoder utilizado neste trabalho é uma ResNet-18 1D — e não um ViT —, essa fonte específica de instabilidade não se aplica, tornando desnecessária a principal motivação para a adoção do v3.

Adicionalmente, o MoCo v3 substitui a fila de negativos por *batches* de tamanho elevado (da ordem de milhares de amostras) para garantir contraste suficiente apenas com os negativos do próprio lote. Dado o tamanho reduzido do conjunto de dados disponível (aproximadamente 870 pacientes) e as limitações de memória de GPU associadas ao processamento de sinais de ECG de alta resolução temporal (24.000 amostras por segmento), a manutenção da fila de negativos ($K = 8192$) foi preferida à sua remoção, uma vez que ela permite manter um número expressivo de comparações negativas por passo de treinamento mesmo com *batch sizes* moderados (256), o que seria inviável na formulação estritamente definida pelo v3.

3.1.2 Pré-treinamento Auto-supervisionado: MoCo

Dado o tamanho reduzido do conjunto de dados disponível — aproximadamente 870 pacientes — aliado ao severo desbalanceamento entre as classes, uma vez que a maioria dos pacientes é censurada e apenas uma parcela reduzida apresentou o evento de interesse (morte súbita cardíaca), o treinamento supervisionado direto da ResNet-18 1D a partir de pesos aleatórios tende a produzir representações de baixa qualidade. Nesse cenário, o modelo supervisionado é exposto a poucos exemplos positivos, dificultando o aprendizado de padrões morfológicos discriminativos no ECG. Para contornar essa dupla limitação — escassez de dados e desbalanceamento —, foi adotada uma estratégia de pré-treinamento auto-supervisionado baseada no *Momentum Contrast* (MoCo v2) (HE *et al.*, 2020; CHEN *et al.*, 2020b), antes do treinamento supervisionado para análise de sobrevivência.

O MoCo foi originalmente proposto para o aprendizado de representações visuais a partir de imagens (HE *et al.*, 2020), onde duas versões augmentadas de uma mesma imagem — obtidas por recortes aleatórios, distorção de cor e *flipping* horizontal — formam um par positivo, e imagens distintas formam pares negativos. O encoder aprende a aproximar as representações do par positivo no espaço de *embedding* e a afastar as dos pares negativos, sem necessidade de rótulos supervisionados. Essa abordagem permite explorar a totalidade dos dados disponíveis para o aprendizado de representações, inclusive os pacientes censurados, que são descartados ou subaproveitados em estratégias supervisionadas.

A adaptação para sinais de ECG Holter substitui as augmentações visuais por perturbações no domínio temporal, aplicadas diretamente na GPU pelo módulo `GPU_ECG_Augmenter` com probabilidade de 80%. A cada iteração, duas versões augmentadas do mesmo segmento de ECG de 24.000 amostras — equivalentes a aproximadamente 2 minuto de sinal a 200 Hz, com 3 derivações — são geradas e tratadas como par positivo. O encoder, instanciado pela ResNet-18 1D, aprende representações invariantes às perturbações aplicadas, capturando características morfológicas estruturais do sinal independentemente de qualquer rótulo de evento ou censura. Dessa forma, todos os 870 pacientes contribuem igualmente para o pré-treinamento, mitigando o efeito do desbalanceamento antes mesmo do treinamento supervisionado.

Os pesos do encoder obtidos ao final do pré-treinamento são utilizados para inicializar o encoder do modelo híbrido de análise de sobrevivência, substituindo a inicialização aleatória e fornecendo uma base de representação mais rica para o treinamento supervisionado subsequente.

3.1.2.1 Aprendizado Contrastivo como Busca em Dicionário

O MoCo formula o aprendizado de representações como um problema de busca em dicionário (HE *et al.*, 2020). Dado um sinal de consulta (*query*) q e um conjunto de chaves (*keys*) $\{k_0, k_1, k_2, \ldots\}$, o objetivo é treinar um encoder de forma que q seja similar à sua chave positiva correspondente k^+ e dissimilar a todas as demais chaves negativas. A função de perda contrastiva utilizada é a InfoNCE (HE *et al.*, 2020):

$$\mathscr{L}_q = -\log \frac{\exp(q \cdot k^+/\tau)}{\sum_{i=0}^{K} \exp(q \cdot k_i/\tau)} \tag{3.1}$$

onde τ é um hiperparâmetro de temperatura e K é o número total de chaves no dicionário. Intuitivamente, essa perda corresponde ao logaritmo negativo de um classificador *softmax* de $(K+1)$ classes, cujo objetivo é identificar k^+ dentre todas as chaves disponíveis.

No contexto deste trabalho, uma *query* e uma chave formam um par positivo quando são versões augmentadas do mesmo segmento de ECG, e um par negativo caso contrário. O encoder aprende, portanto, a produzir representações invariantes às augmentações aplicadas, capturando apenas as características morfológicas estruturais do sinal.

3.1.2.2 Dicionário Dinâmico com Fila e Encoder com Momento

A principal contribuição do MoCo é manter o dicionário como uma **fila** de amostras codificadas (HE *et al.*, 2020), desacoplando o tamanho do dicionário do tamanho do mini-*batch*. A cada iteração, o mini-batch atual é inserido na fila e o mini-batch mais antigo é removido. Isso permite que o dicionário seja muito maior do que o que a memória da GPU comportaria em uma abordagem ponta a ponta (*end-to-end*).

Para garantir a consistência das representações armazenadas na fila, o encoder das chaves f_k não é atualizado por retropropagação, mas sim por uma **atualização com momento** (*momentum update*) a partir do encoder de consulta f_q (HE *et al.*, 2020):

$$\theta_k \leftarrow m\,\theta_k + (1-m)\,\theta_q \tag{3.2}$$

onde $m \in [0,1)$ é o coeficiente de momento. Somente θ_q é atualizado por retropropagação; θ_k evolui lentamente, garantindo que as chaves armazenadas na fila sejam consistentes entre si,

mesmo que tenham sido geradas em iterações diferentes. Neste trabalho, o valor $m = 0{,}999$ foi adotado, conforme recomendado em (HE *et al.*, 2020).

3.1.2.3 Melhorias do MoCo v2

Com base nas melhorias propostas em (CHEN *et al.*, 2020b), duas modificações foram incorporadas ao MoCo original. A primeira consiste na adição de uma cabeça de projeção MLP (*projection head*) entre o encoder e o espaço de representação contrastiva, composta por uma camada linear, ativação ReLU e uma segunda camada linear, mapeando a saída do encoder para um espaço de $d = 256$ dimensões. A segunda consiste no uso de augmentações de dados mais agressivas durante o pré-treinamento. Essas modificações melhoram substancialmente a qualidade das representações aprendidas sem exigir *batches* de grande porte (CHEN *et al.*, 2020b).

3.1.2.4 Adaptação para Sinais de ECG

A adaptação do MoCo para sinais de ECG Holter envolve duas mudanças principais em relação à formulação original voltada para imagens. Primeiro, o encoder f_q e o encoder f_k são instâncias da ResNet-18 1D descrita na Seção anterior, operando sobre janelas de sinal de 24.000 amostras (correspondentes a aproximadamente 2 minuto de ECG a 200 Hz) com 3 derivações de entrada. Segundo, as augmentações de dados são adaptadas para o domínio temporal, sendo aplicadas diretamente na GPU por meio do módulo `GPU_ECG_Augmenter` com probabilidade de 80%, gerando duas "visões" distintas do mesmo segmento de sinal.

Para cada mini-*batch*, as augmentações são aplicadas duas vezes sobre o mesmo sinal de entrada, gerando os pares (x^q, x^k). As representações são obtidas por $q = f_q(x^q)$ e $k = f_k(x^k)$, e a perda InfoNCE é minimizada conforme a Equação 3.1.

3.1.2.5 Configuração do Treinamento

O pré-treinamento foi conduzido com as seguintes configurações: tamanho do dicionário $K = 8.192$, dimensão do espaço de projeção $d = 256$, coeficiente de momento $m = 0{,}999$, temperatura $\tau = 0{,}07$, tamanho do mini-*batch* de 256 amostras e taxa de aprendizado inicial de 0,001 com otimizador SGD (momento $= 0{,}9$, *weight decay* $= 5 \times 10^{-4}$). O agendador *ReduceLROnPlateau* foi utilizado para reduzir a taxa de aprendizado por um fator de 0,5 quando

a perda não apresentasse melhora por 30 épocas consecutivas. O treinamento foi interrompido antecipadamente (*early stopping*) após 50 épocas sem melhora na perda média, com um máximo de 500 épocas. Os pesos do encoder f_q obtidos ao final do pré-treinamento são utilizados para inicializar o encoder do modelo híbrido de análise de sobrevivência, substituindo a inicialização aleatória.

3.1.2.6 Escolha do Mecanismo de Aprendizado Contrastivo

O aprendizado contrastivo pode ser instanciado por diferentes mecanismos que diferem na forma como as chaves negativas são mantidas e como o encoder de chaves é atualizado (HE *et al.*, 2020). Três abordagens principais são comparadas na literatura: (i) o mecanismo *end-to-end*, no qual as chaves negativas provêm do mesmo mini-*batch* e são atualizadas por retropropagação; (ii) o *memory bank*, no qual as representações de todas as amostras do conjunto de dados são armazenadas em memória e amostradas aleatoriamente a cada iteração; e (iii) o MoCo, que mantém um dicionário dinâmico como fila e atualiza o encoder de chaves por momento (HE *et al.*, 2020).

A comparação experimental conduzida em (HE *et al.*, 2020) demonstra que o MoCo supera os demais mecanismos sob o protocolo de classificação linear no ImageNet, independentemente do tamanho do dicionário. O mecanismo *end-to-end* é limitado pelo tamanho do mini-*batch* — e portanto pelo tamanho do dicionário de negativos disponível —, enquanto o *memory bank* sofre de inconsistência das representações, pois as chaves armazenadas foram codificadas por diferentes versões do encoder ao longo do treinamento. O MoCo resolve ambos os problemas simultaneamente: o dicionário como fila permite um número grande de negativos sem depender do tamanho do batch, e a atualização com momento garante a consistência das chaves armazenadas (HE *et al.*, 2020).

Adicionalmente, (CHEN *et al.*, 2020b) demonstra que duas modificações simples ao MoCo original — a substituição da cabeça de projeção linear por uma MLP e o uso de augmentações mais agressivas — produzem ganhos substanciais de desempenho sem exigir *batches* de grande porte, superando inclusive o SimCLR com *batches* de até 8.192 amostras. A combinação MoCo + MLP head + augmentação forte, denominada MoCo v2, foi adotada neste trabalho por representar a configuração de melhor desempenho relatada nos artigos originais, mantendo o requisito de viabilidade computacional em uma única GPU.

Os hiperparâmetros foram definidos seguindo as recomendações de (HE *et al.*, 2020)

e (CHEN *et al.*, 2020b): temperatura $\tau = 0{,}07$, coeficiente de momento $m = 0{,}999$ e dimensão do espaço de projeção $d = 256$. O tamanho do dicionário foi fixado em $K = 8.192$, valor que garante um conjunto rico de amostras negativas sem exceder a memória disponível na GPU utilizada.

3.2 Processo Iterativo de Desenvolvimento do MoCo: Variações Experimentais

Ao longo do processo experimental, o framework *Momentum Contrast* (MoCo) foi submetido a sucessivas iterações de adaptação e refinamento visando otimizar seu desempenho em cenários de dados escassos e desbalanceados. Esse processo iterativo não representa uma evolução metodológica disruptiva, mas sim um refinamento gradual dos componentes arquiteturais e das parametrizações, motivado por hipóteses específicas sobre a capacidade expressiva do modelo e a qualidade das representações aprendidas.

As variações implementadas focalizaram-se primordialmente em três eixos: (i) a arquitetura do encoder base, explorando diferentes implementações de ResNet-18 1D, incluindo versão manual, implementação via biblioteca `tsai` e versões com mecanismos de atenção e Transformer; (ii) os hiperparâmetros do contraste, incluindo tamanho da fila de negativos (K), dimensionalidade do *embedding* (d) e temperatura da função *softmax* (τ); e (iii) as estratégias de augmentação de dados e configurações de treinamento, como agressividade das transformações, tamanho da janela temporal e critérios de parada.

Cada versão foi avaliada segundo métricas de convergência, estabilidade numérica e qualidade das representações, com as descobertas de versões anteriores informando decisões de design em versões subsequentes. Essa abordagem permite identificar quais modificações geram melhorias genuínas e quais constituem artefatos de ajuste de hiperescala, fornecendo fundamentação empírica para a seleção final do modelo. A Tabela 2 sintetiza os principais hiperparâmetros e características arquiteturais de cada versão, facilitando a comparação sistemática.

3.2.1 Versões 1 e 2: Adaptação Base e Otimização Algorítmica

O ponto de partida consistiu na implementação direta da formulação do MoCo v2, transpondo os mecanismos de contraste visual para o domínio temporal de sinais de ECG Holter. A Versão 1 utilizou uma ResNet-18 1D manual como encoder base, configurada conforme a Tabela 2: fila de negativos de tamanho $K = 4096$, dimensão de *embedding* $d = 128$, coeficiente

Tabela 2 – Síntese comparativa dos hiperparâmetros e características arquiteturais das cinco variações experimentais do MoCo.

Parâmetro	**Versão 1**	**Versão 2**	**Versão 3**	**Versão 4**	**Versão 5**
Arquitetura base	ResNet-18 1D manual	XResNet1d18 (`tsai`)	ResNet-18 1D manual	ResNet-18 1D manual	ResNet-18 1D + Transformer
Dimensão do *embedding* (d)	128	128	256	128	256
Tamanho da fila (K)	4.096	4.096	8.192	4.096	8.192
Coeficiente de *momentum* (m)	0,999	0,999	0,999	0,999	0,999
Temperatura (τ)	0,07	0,07	0,07	0,07	0,07
Batch size	256	256	256	256	256
Window size (amostras)	12.000	12.000	24.000	12.000	24.000
Tempo equivalente	$\sim$1 min	$\sim$1 min	$\sim$2 min	$\sim$1 min	$\sim$2 min
Probabilidade de augmentação	80%	80%	70%	80%	80%
Weight decay	1×10^{-4}	1×10^{-4}	5×10^{-4}	1×10^{-4}	5×10^{-4}
Épocas máximas	200	200	500	300	500
Early stopping (*patience*)	–	–	50	–	50
Amostras por paciente	100	100	100	100	100
Mecanismo de atenção	Não	Não	Não	Não	Sim (Transformer)
LR scheduler	*Cosine Annealing*	*Cosine Annealing*	`ReduceLROnPlateau`	*Cosine Annealing*	`ReduceLROnPlateau`

de *momentum* $m = 0{,}999$ e temperatura $\tau = 0{,}07$, conforme recomendações originais.

Os segmentos de ECG foram processados em janelas de 12.000 amostras, aproximadamente 1 minuto a 200 Hz com três derivações, com *batch size* de 256 amostras e treinamento de 200 épocas. As augmentações foram aplicadas diretamente em GPU mediante perturbações no domínio temporal: escalonamento aleatório de 0,8 a 1,2$\times$, ruído gaussiano com variância 0,05 e mascaramento temporal de 10% da janela, com probabilidade de 80%. Essa configuração serviu como *baseline*, validando a viabilidade da abordagem contrastiva para ECG e estabelecendo a arquitetura fundamental.

A Versão 2 substituiu a implementação manual pela arquitetura XResNet1d18 disponibilizada pela biblioteca `tsai`, incorporando otimizações algorítmicas mediante refinamentos em inicialização de pesos, normalização de camadas e composição de blocos residuais. Embora mantendo os mesmos hiperparâmetros da Versão 1, essas melhorias de implementação reduziram a complexidade computacional e estabilizaram o treinamento. Contudo, as curvas de perda e as representações aprendidas não exibiram divergências significativas em relação à Versão 1, indicando que o modelo havia convergido próximo a um ponto de equilíbrio local. Essa observação empiricamente validada motivou a exploração de estratégias mais agressivas nas versões subsequentes.

3.2.2 Versão 3: Regime Rigoroso com Fila Expandida

Motivada pela hipótese de que o tamanho reduzido da fila de negativos ($K = 4096$) comprometia a qualidade do contraste em datasets limitados, a Versão 3 adotou uma configuração rigorosa com expansão sistemática dos hiperparâmetros. A dimensão do *embedding* foi dobrada para $d = 256$, ampliando o espaço de representação e permitindo capturar estruturas mais complexas dos padrões morfológicos do ECG.

Concomitantemente, a fila de negativos foi expandida para $K = 8192$, dobrando o número de comparações negativas por iteração e reduzindo o risco de colapso da representação. Essa expansão foi viabilizada pela retomada de um encoder ResNet-18 1D manual em vez da biblioteca `tsai`, proporcionando controle fino sobre a alocação de memória e evitando abstrações que pudessem limitar otimizações em GPU.

O tamanho da janela de ECG foi aumentado para 24.000 amostras, aproximadamente 2 minutos, fornecendo mais contexto temporal e capturando variações fisiológicas de maior escala, incluindo ciclos completos de variabilidade da frequência cardíaca. A agressividade de augmentação foi levemente reduzida para 70% de probabilidade, evitando degradação excessiva que pudesse prejudicar o aprendizado de padrões sutis, enquanto o *weight decay* foi aumentado para 5×10^{-4}, fornecendo regularização mais forte. O número de épocas foi elevado para 500 com estratégia de parada antecipada (*patience* = 50), permitindo exploração mais profunda do espaço de parâmetros com proteção contra *overfitting*. Essa configuração produziu representações de maior qualidade, validando experimentalmente a hipótese de que datasets escassos beneficiam-se de dicionários de negativos maiores e janelas temporais mais extensas.

3.2.3 Versão 4: Regime Ultra-Conservador como Controle Ablativo

A Versão 4 representou uma reversão estratégica, retornando aos hiperparâmetros da Versão 1 ($d = 128$, $K = 4096$, *window size* = 12.000 amostras e *weight decay* = 10^{-4}), com extensão moderada do treinamento para 300 épocas. Essa configuração foi proposta como controle ablativo, testando a hipótese nula de que as expansões da Versão 3 ofereciam ganho real ou se consistiam meramente em artefatos de ajuste de escala sem impacto substantivo na aprendizagem de representações.

O objetivo específico era isolar o efeito de mudanças individuais de hiperparâmetros, como dimensão de *embedding*, tamanho da fila e tamanho da janela, por meio de uma configuração regredida, permitindo posterior análise comparativa entre as curvas de treinamento. Embora mais eficiente computacionalmente, com redução aproximada de 40% no uso de memória em relação à Versão 3, a Versão 4 confirmou empiricamente que a Versão 3 representava um avanço genuíno, não apenas um artefato de *scaling*, validando que a expansão de hiperparâmetros correspondia a ganhos reais na qualidade do contraste.

3.2.4 Versão 5: Integração de Atenção Temporal e Transformer

Considerando que sinais de ECG contêm dependências de longo prazo estruturadas, por exemplo variações cíclicas no intervalo RR, mudanças de ritmo cardíaco ao longo de 24 horas e correlações entre diferentes derivações, a Versão 5 incorporou mecanismos explícitos de atenção ao encoder contrastivo, representando o primeiro desvio significativo da arquitetura ResNet pura.

Conforme a Tabela 2, a arquitetura compõe-se de três componentes sequenciais: (1) uma ResNet-18 1D que extrai características locais em múltiplas escalas temporais, produzindo um tensor de dimensão $[\text{batch}, 512, \text{seq_len}]$; (2) um encoder Transformer com 8 cabeçotes de atenção (`nhead = 8`), dimensão *feedforward* de 1.024 dimensões e *dropout* de 0,3, operando sobre a sequência temporal para aprender dependências globais entre regiões distantes do sinal; e (3) um cabeçote de projeção MLP que mapeia as representações aprendidas para o espaço contrastivo de $d = 256$ dimensões.

O módulo `GPU_ECG_Augmenter`, integrado à pipeline de treinamento, aplica as mesmas perturbações calibradas com probabilidade de 80% diretamente em GPU, reduzindo o overhead de transferência de dados CPU–GPU. A configuração de treinamento mantém os hiperparâmetros expandidos da Versão 3: fila $K = 8192$, *embedding* $d = 256$, *window size* = 24.000 e *weight decay* = 5×10^{-4}, preservando os ganhos comprovados enquanto adiciona a capacidade expressiva do Transformer. Essa arquitetura híbrida permite que o modelo aprenda não apenas características morfológicas locais, extraídas pela ResNet, mas também padrões temporais estruturados de variação, aprendidos pelo Transformer, potencialmente capturando fenômenos fisiológicos como variabilidade da frequência cardíaca, mudanças progressivas de ritmo ao longo de 24 horas e correlações entre derivações.

3.2.5 Justificativa da Seleção Final: Versão 5

A escolha da Versão 5 como modelo de pré-treinamento definitivo fundamenta-se em três critérios convergentes. Primeiro, a incorporação de mecanismos de atenção Transformer permite capturar dependências temporais de longo prazo inerentes a registros Holter de 24 horas, indo além das características locais extraíveis por convoluções puras; a comparação com a Versão 4 demonstra que esse ganho arquitetural não estava disponível em modelos puramente convolucionais.

Segundo, a configuração parametrizada segundo os aprendizados das Versões 3 e 4, com fila expandida $K = 8192$, *embedding* de alta dimensão $d = 256$ e janelas maiores de 24.000 amostras, fornece sinal contrastivo suficiente mesmo em cenários de dados limitados, com aproximadamente 870 pacientes, mitigando o risco de colapso de representação. Terceiro, a execução de augmentações em GPU elimina gargalos de entrada e saída e de transferência de dados, permitindo treinamento mais eficiente e escalável.

Os pesos aprendidos pelo `encoder_q`, composto por ResNet e Transformer, na Versão 5 são posteriormente utilizados para inicializar o *backbone* do modelo híbrido de análise de sobrevivência, substituindo pesos aleatórios e fornecendo uma base de representação rica para o aprendizado supervisionado subsequente. Essa estratégia progressiva de otimização e integração de componentes arquiteturais, sintetizada na Tabela 2, garante que o pré-treinamento auto-supervisionado capture tanto estruturas morfológicas quanto dinâmicas fisiológicas relevantes para a predição de eventos cardíacos adversos.

3.2.6 Pré-treinamento Contrastivo com MoCo

A Figura 2 resume o treinamento contrastivo do encoder por Momentum Contrast (MoCo). O mesmo sinal gera duas visões aumentadas: uma alimenta o codificador query, atualizado por gradiente, e a outra alimenta o codificador key, atualizado por média móvel dos pesos. A perda InfoNCE aproxima pares positivos e afasta a query de chaves negativas armazenadas em uma fila dinâmica.

3.2.7 Arquitetura Proposta dos Modelos Profundos

Esta seção descreve, em formato de fluxograma, os principais componentes computacionais utilizados no pipeline de modelagem profunda para análise de sobrevivência. Os diagramas foram estruturados a partir de modelos implementados manualmente em PyTorch, contemplando o extrator convolucional ResNet-1D, o pré-treinamento contrastivo MoCo, as formulações de tempo discreto e a arquitetura híbrida final com fusão entre ECG e covariáveis clínicas.

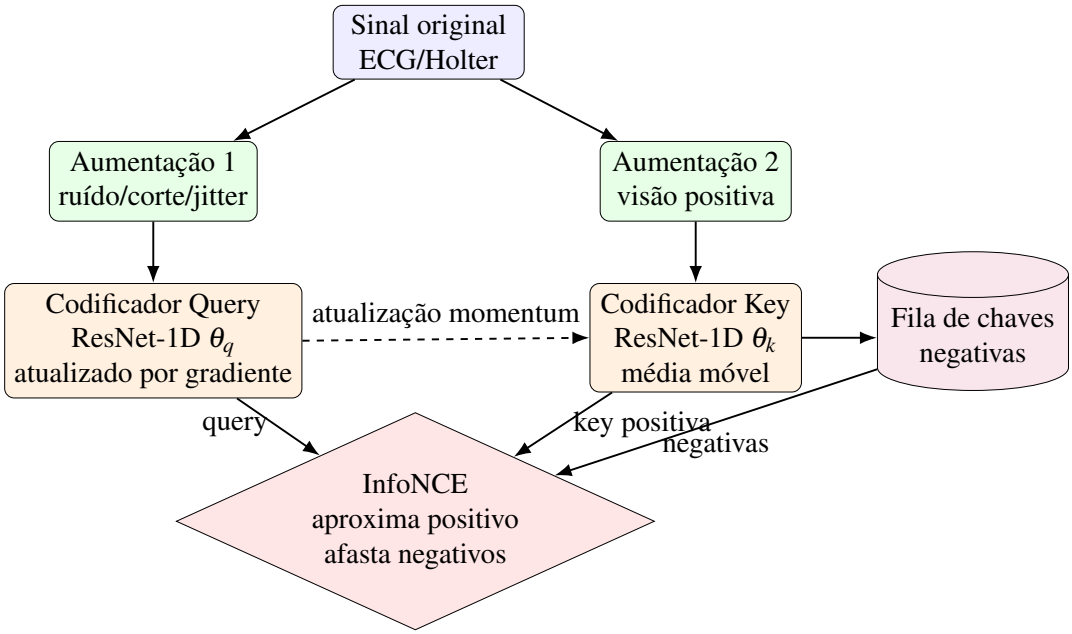


Figura 2 – Esquema de pré-treinamento MoCo para aprendizado auto-supervisionado de representações do ECG/Holter. O codificador query recebe gradientes diretamente; o codificador key é atualizado por média móvel e alimenta uma fila de exemplos negativos.

3.2.8 Encoder ResNet-1D para Sinais de ECG

A Figura 3 apresenta o fluxo do encoder ResNet-1D utilizado para extrair representações temporais dos sinais de ECG/Holter com três derivações. A rede preserva a dimensão temporal até a saída do encoder, produzindo um mapa de características tridimensional.

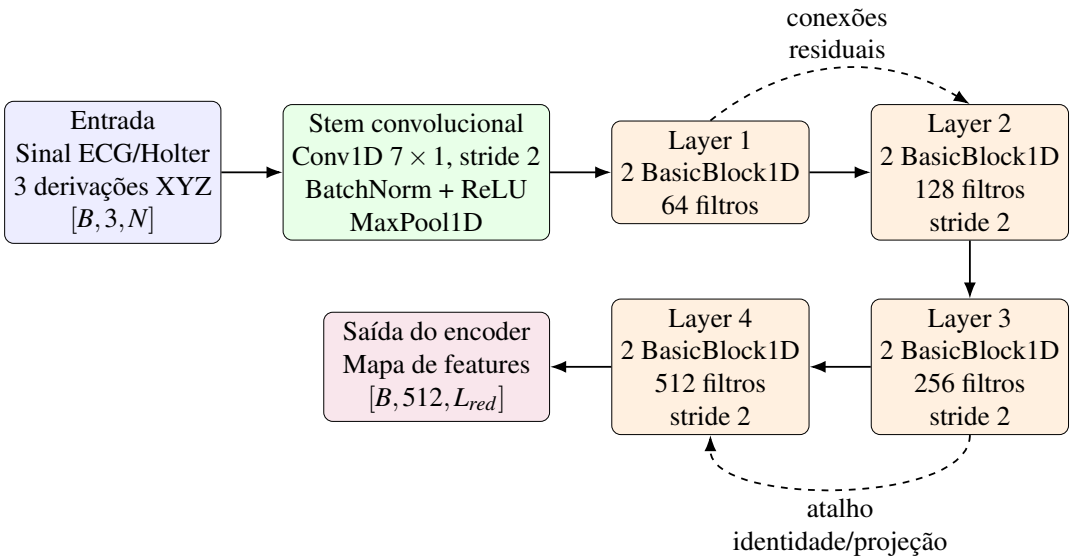


Figura 3 – Fluxo do encoder ResNet-1D utilizado para extração de características convolucionais temporais dos sinais de ECG/Holter. Cada BasicBlock1D contém duas convoluções 1D com normalização em lote e conexão residual.

3.2.9 Arquitetura do Encoder: ResNet-18 1D

A extração de características dos sinais de ECG é realizada por uma versão unidimensional da ResNet-18 (HE *et al.*, 2016), utilizada exclusivamente como *encoder*. O termo *encoder* reflete o fato de que apenas o corpo da rede é empregado — ou seja, somente as camadas convolucionais responsáveis pela extração de representações — sem a camada de classificação final. Essa abordagem é recorrente na literatura quando se deseja obter um vetor de características compacto para uso em tarefas subsequentes, como a análise de sobrevivência proposta neste trabalho.

3.2.9.1 Da ResNet-18 2D para a ResNet-18 1D

A ResNet-18 original foi proposta para o processamento de imagens bidimensionais (HE *et al.*, 2016), operando sobre tensores de entrada com dimensões $[C, H, W]$, onde C é o número de canais, H a altura e W a largura da imagem. A arquitetura é composta por 18 camadas com parâmetros treináveis: uma convolução inicial com kernel 7×7, quatro grupos de blocos residuais com 2 blocos cada, e uma camada totalmente conectada (*fully connected*) para classificação (HE *et al.*, 2016).

A adaptação para sinais unidimensionais consiste em substituir todas as operações bidimensionais pelas suas equivalentes 1D, tornando a rede adequada ao processamento de séries temporais. A entrada passa a ter dimensões $[C, L]$, onde C é o número de derivações do ECG — 3 neste trabalho — e L é o comprimento temporal do sinal. Todas as convoluções 2D são substituídas por convoluções 1D, e o *batch normalization* e o *max pooling* são igualmente adaptados para operar sobre a dimensão temporal. Essa estratégia é amplamente consolidada na literatura de sinais biomédicos, com aplicações em ECG de derivação única (HANNUN *et al.*, 2019) e em ECG de 12 derivações (RIBEIRO *et al.*, 2020).

3.2.9.2 Estrutura das 17 Camadas do Encoder

A ResNet-18 é composta originalmente por 17 camadas convolucionais e uma camada totalmente conectada de classificação, totalizando 18 camadas com parâmetros treináveis (HE *et al.*, 2016). Neste trabalho, a camada totalmente conectada foi removida, e o encoder resultante — com **17 camadas convolucionais** — é utilizado exclusivamente como extrator de características, produzindo um vetor de 512 dimensões por amostra ao final do processamento.

A arquitetura do encoder é organizada da seguinte forma:

1. **Camada inicial** (`conv1`): convolução 1D com 64 filtros e kernel de tamanho 7, com *stride* 2, seguida de normalização em lote (*batch normalization*) e ativação ReLU. Uma camada de *max pooling* com kernel 3 e *stride* 2 reduz adicionalmente a resolução temporal, resultando em uma representação inicial com 64 canais. Essa camada corresponde a **1 camada convolucional**.
2. **Grupo 1** (`layer1`, `conv2_x`): dois blocos residuais com 64 filtros e *stride* 1, mantendo a resolução temporal. Cada bloco contém 2 convoluções, totalizando **4 camadas convolucionais**.
3. **Grupo 2** (`layer2`, `conv3_x`): dois blocos residuais com 128 filtros e *stride* 2, reduzindo a resolução temporal à metade e dobrando a profundidade de representação. Totalizando **4 camadas convolucionais**.
4. **Grupo 3** (`layer3`, `conv4_x`): dois blocos residuais com 256 filtros e *stride* 2, com nova redução temporal e aprofundamento da representação. Totalizando **4 camadas convolucionais**.
5. **Grupo 4** (`layer4`, `conv5_x`): dois blocos residuais com 512 filtros e *stride* 2, produzindo a representação de maior abstração semântica. Totalizando **4 camadas convolucionais**.

Somando todas as contribuições: $1+4+4+4+4 = 17$ camadas convolucionais, confirmando a estrutura do encoder utilizado.

Cada bloco residual (`BasicBlock1d`) é composto por duas convoluções 1D de kernel 3, cada uma seguida de normalização em lote e ativação ReLU, com uma conexão de atalho (*skip connection*) que soma a entrada do bloco à sua saída. Quando há incompatibilidade de dimensões entre entrada e saída — o que ocorre nos grupos 2, 3 e 4 devido ao *stride* 2 — uma projeção por convolução 1×1 é aplicada na conexão de atalho para alinhar as dimensões. Ao final do encoder, um *Global Average Pooling* reduz a dimensão temporal, produzindo um vetor fixo de 512 dimensões por amostra, independentemente do comprimento da série de entrada.

3.2.9.3 Justificativa da Escolha da ResNet-18

A escolha da ResNet-18 como backbone é motivada por dois fatores principais. Primeiro, o conjunto de dados disponível é composto por aproximadamente 870 pacientes, um volume moderado para o treinamento de redes convolucionais profundas. Arquiteturas mais profundas, como ResNet-34 ou ResNet-50, tendem a demandar volumes maiores de dados para

generalizar adequadamente, tornando a ResNet-18 uma escolha mais equilibrada à escala do problema. Segundo, a adaptação unidimensional da ResNet-18 é amplamente empregada na literatura de sinais biomédicos (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020), demonstrando capacidade suficiente para a extração de padrões morfológicos relevantes em sinais de ECG com múltiplas derivações.

Ao final do encoder, um *Global Average Pooling* reduz a representação temporal para um vetor fixo de 512 dimensões por amostra, independentemente do comprimento da série de entrada.

3.2.10 Arquitetura Híbrida Final

A Figura 4 descreve a arquitetura final usada para combinar sinais ECG/Holter e covariáveis clínicas. O treinamento foi organizado em duas etapas. Primeiro, o encoder ResNet-1D foi pré-treinado de forma auto-supervisionada pelo método MoCo, utilizando apenas o objetivo contrastivo para aprender representações do sinal. Em seguida, os pesos aprendidos nessa etapa foram transferidos para o ramo de ECG da arquitetura híbrida. Na etapa supervisionada, a ResNet-1D inicializada com os pesos do MoCo passou a atuar como extrator de características, sendo treinada em conjunto com a rede de covariáveis clínicas, o módulo de fusão e os cabeçotes de sobrevivência em tempo discreto. O mapa temporal extraído do ECG é agregado por média global no eixo temporal e reduzido por um gargalo denso; em paralelo, as covariáveis clínicas passam por uma rede densa própria. Por fim, os vetores de ECG e de covariáveis são concatenados e enviados ao cabeçote de risco em tempo discreto.

3.2.11 Módulo de Projeção e Fusão Híbrida

Para equilibrar a contribuição dos sinais de ECG e das variáveis clínicas na decisão final, ambas as modalidades são projetadas em espaços de mesma dimensão antes da fusão. O vetor de 512 features extraídas pelo encoder é comprimido por um *bottleneck* com as camadas Linear(512, 64) $\rightarrow$ BatchNorm $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ Linear(64, 16), resultando em um vetor de 16 dimensões.

As variáveis clínicas, compostas por 6 preditores numéricos, são processadas por uma rede densa com as camadas Linear(6, 32) $\rightarrow$ BatchNorm $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ Linear(32, 16), produzindo igualmente um vetor de 16 dimensões.

Os dois vetores são então concatenados, formando uma representação híbrida de 32

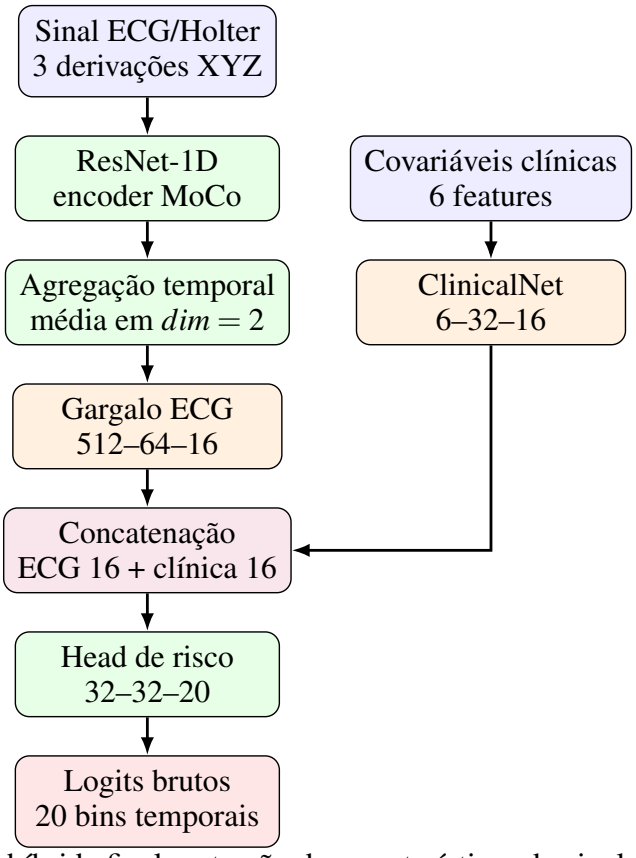


Figura 4 – Arquitetura híbrida final: extração de características do sinal por ResNet-1D/MoCo, compressão do ECG em gargalo de 16 dimensões, processamento clínico em paralelo, fusão balanceada e predição de logits para modelos de sobrevivência em tempo discreto.

dimensões que integra informação morfológica do ECG com o contexto clínico do paciente.

3.2.12 Cabeçote de Análise de Sobrevivência

O vetor fundido de 32 dimensões é processado por um cabeçote de predição composto pelas camadas Linear(32, 32) $\rightarrow$ BatchNorm $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ Linear(32, K), onde K corresponde ao número de intervalos de tempo discretos definidos pela transformação *LabTrans*. A saída é um vetor de logits, cuja interpretação varia conforme o modelo de sobrevivência selecionado, conforme descrito nas subseções seguintes.

3.2.13 Risco Logístico (Logistic-Hazard)

O método *Logistic-Hazard* parametriza diretamente os riscos discretos $h(t_k \mid \mathbf{x})$ para cada intervalo de tempo k, otimizando a verossimilhança de sobrevivência (KVAMME; BORGAN, 2019; EFRON, 1988). A função de risco discreta é obtida aplicando-se a função sigmoide sobre os logits produzidos pelo cabeçote de predição, e a função de sobrevivência é

estimada pelo produto acumulado dos complementos dos riscos em cada intervalo. Este método também é referenciado na literatura como Regressão Logística Parcial (BIGANZOLI *et al.*, 1998) e Nnet-sobrevivência (*Nnet-survival*) (GENSHEIMER; NARASIMHAN, 2019).

3.2.14 Função de Massa de Probabilidade (PMF)

O método PMF parametriza a função de massa de probabilidade do tempo até o evento, otimizando diretamente a verossimilhança de sobrevivência (KVAMME; BORGAN, 2019). A distribuição de probabilidade sobre os intervalos de tempo é obtida aplicando-se a função *softmax* sobre os logits da rede, e a função de sobrevivência é estimada pela soma acumulada reversa dessa distribuição. Este método constitui a base de abordagens como o DeepHit e o MTLR (*Multi-Task Logistic Regression*).

3.2.15 DeepHit

O DeepHit é uma extensão do método PMF que incorpora, além da verossimilhança de sobrevivência, um termo de perda por classificação baseado em *ranking*, capaz de lidar com riscos concorrentes (LEE *et al.*, 2018). A função de perda total é definida como $\mathscr{L} = \mathscr{L}_1 + \alpha \cdot \mathscr{L}_2$, onde $\mathscr{L}_1$ corresponde à log-verossimilhança negativa e $\mathscr{L}_2$ é um termo de *ranking* que penaliza inversões na ordenação do risco entre pares de pacientes com diferentes tempos de evento.

3.2.16 Formulações de Sobrevivência em Tempo Discreto

A Figura 5 apresenta as três formulações de tempo discreto usadas no cabeçote de sobrevivência. A rede híbrida retorna logits brutos para os intervalos temporais; em seguida, cada modelo aplica uma transformação probabilística e uma função de perda específica.

3.2.17 Discretização do Tempo: Transformação LabTrans

A análise de sobrevivência em tempo discreto requer que o tempo contínuo até o evento seja mapeado em um conjunto finito de K intervalos. Para isso, foi implementada a transformação `DiscreteTimeTransform`, inspirada na *LabTrans* da biblioteca PyCox (KVAMME; BORGAN, 2019).

Dado um conjunto de tempos de sobrevivência $\{t_i\}$ e indicadores de evento $\{d_i\}$, os pontos de corte $\mathbf{c} = (c_0, c_1, \ldots, c_K)$ são determinados pelos quantis da distribuição dos tempos

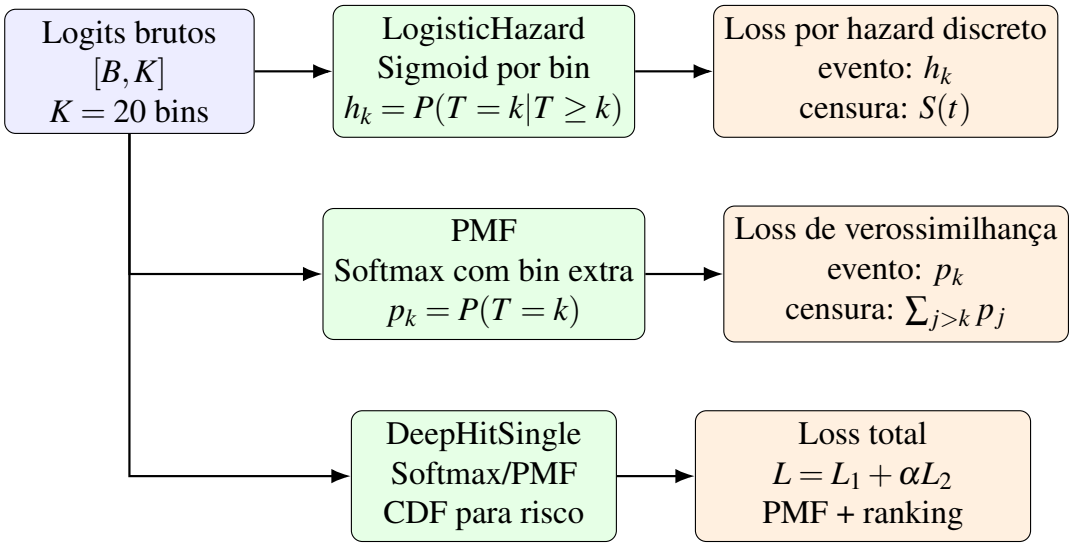


Figura 5 – Transformação dos logits brutos nos três modelos de sobrevivência em tempo discreto: LogisticHazard, PMF e DeepHitSingle.

de evento observados (i.e., $d_i = 1$), com $c_0 = 0$ e c_K fixado acima do maior tempo observado no conjunto. O índice de intervalo de cada observação é então obtido por digitalização (*digitize*), sendo clipado ao intervalo $[0, K-1]$ para evitar extrapolações. O número de intervalos K é um hiperparâmetro do modelo, definido como `num_durations`.

3.2.18 Função de Perda por Tipo de Paciente

Em dados de sobrevivência, as observações são heterogêneas: parte dos pacientes apresentou o evento de interesse (*uncensored*), enquanto os demais foram censurados, ou seja, perderam o acompanhamento antes do desfecho. Cada modelo de perda trata essas duas populações de forma distinta.

Para o *Logistic-Hazard*, pacientes com evento contribuem com a log-verossimilhança negativa do risco no instante t_i ponderada pela sobrevivência acumulada até $t_i - 1$. Pacientes censurados contribuem apenas com a probabilidade de sobreviver até o instante de censura (KVAMME; BORGAN, 2019). Formalmente:

$$\mathscr{L}_{\text{LH}} = -\frac{1}{N}\sum_{i=1}^{N}\left[d_i\left(\log h_{t_i} + \log S(t_i - 1)\right) + (1 - d_i)\log S(t_i)\right] \tag{3.3}$$

onde $h_{t_k} = \sigma(\phi_k)$ é o risco discreto no intervalo k, obtido pela função sigmoide sobre o logit ϕ_k, e $S(t_k) = \prod_{j \leq k}(1 - h_{t_j})$ é a função de sobrevivência estimada.

Para os métodos PMF e DeepHit, a distribuição de probabilidade sobre os intervalos é obtida via *softmax* sobre os logits, com um logit auxiliar nulo concatenado ao final para representar sobrevivência além do horizonte de observação (KVAMME; BORGAN, 2019).

Pacientes com evento contribuem com $-\log f(t_i)$, onde $f(t_k)$ é a probabilidade de evento no intervalo k, e pacientes censurados contribuem com $-\log S(t_i^+)$, a probabilidade de sobreviver além do instante de censura.

O DeepHit acrescenta um segundo termo de perda baseado em *ranking* (LEE *et al.*, 2018):

$$\mathscr{L}_{\text{DH}} = \mathscr{L}_1 + \alpha \cdot \mathscr{L}_2 \tag{3.4}$$

onde $\mathscr{L}_2$ penaliza pares de pacientes (i, j) em que $t_i < t_j$ e $d_i = 1$, mas o modelo atribui risco cumulativo menor ao paciente i do que ao paciente j no tempo t_i. A penalidade é suavizada por uma função exponencial com parâmetro σ:

$$\mathscr{L}_2 = \sum_{i:d_i=1} \sum_{j} \mathbf{1}[t_i < t_j] \cdot \exp\left(-\frac{F(t_i \mid \mathbf{x}_i) - F(t_i \mid \mathbf{x}_j)}{\sigma}\right) \tag{3.5}$$

3.2.19 Treinamento: Acumulação de Gradiente e Precisão Mista

O treinamento do modelo foi realizado com duas técnicas complementares para viabilizar o uso de *batches* efetivos maiores sem aumentar o consumo de memória da GPU: acumulação de gradiente (*gradient accumulation*) e precisão mista automática (*Automatic Mixed Precision* — AMP) (**??**).

Na acumulação de gradiente, os gradientes são acumulados ao longo de `accumulation_steps` iterações antes de cada atualização dos pesos. A função de perda de cada mini-*batch* é dividida por `accumulation_steps` antes da retropropagação, de modo que a magnitude dos gradientes acumulados seja equivalente à de um *batch* de tamanho `batch_size` $\times$ `accumulation_steps`. A atualização dos pesos e o zeragem dos gradientes são realizadas apenas ao final de cada ciclo de acumulação. Ao término do laço de treinamento, um passo final é executado caso restem gradientes não aplicados.

A precisão mista é implementada com o `GradScaler` do PyTorch, que escala dinamicamente a função de perda para evitar *underflow* numérico durante as operações em meia-precisão (`float16`), revertendo para precisão simples (`float32`) nas etapas críticas de atualização. As operações de *forward* e cálculo da perda são executadas dentro de um contexto `autocast`, enquanto a retropropagação e a atualização dos pesos utilizam o escalonamento do `GradScaler`.

3.2.20 Avaliação: C-Index e Agregação de Janelas

A métrica principal de avaliação é o índice de concordância (*C-index*), que mede a capacidade discriminativa do modelo em ordenar corretamente pares de pacientes pelo risco predito (**??**). O *C-index* varia entre 0,5 (aleatoriedade) e 1,0 (discriminação perfeita), sendo calculado sobre os escores de risco derivados da função de sobrevivência estimada no último intervalo de tempo.

Como os sinais de ECG Holter de 24 horas são segmentados em janelas para o treinamento, cada paciente pode gerar múltiplas predições de risco. Para obter um escore único por paciente na avaliação, foi implementada uma estratégia de agregação com três variantes:

- **Máximo** (*max*): considera o maior escore de risco entre todas as janelas do paciente, privilegiando a detecção de episódios de alto risco isolados;
- **Média** (*mean*): utiliza a média dos escores de risco, representando o risco global ao longo do registro;
- **Percentil 90** (*p90*): considera o percentil 90 da distribuição de escores, oferecendo um compromisso entre a sensibilidade a picos e a robustez a ruídos.

4 RESULTADOS

4.1 Resultados da tabela subject-info.csv

Inicialmente fiz teste com resultados de dados clínicos de pacientes da tabela subject-info.csv (PRABHAKARARAO; MANIMEGALAI, 2020b) para o processo de análise de dados, e usar como gabarito para depois adaptar os sinais ECG, apliquei um modelo de risco proporcional de cox uma técnica de análise bastante utilizada na área da saúde, meus estudos começou pela regressão de cox mas a comprender melhor os dados percebi que para o meu caso o melhor modelo é o LogisticHazard pelo simples fatos que o regressão de cox trabalho com o tempo continuos e o meu trabalho vai trabalhar com tempo discreto, e o modelo de regressão de cox tem a suposição de proporcionalidade dos riscos que não se aplica ao meu caso, já o modelo LogisticHazard é uma extensão do modelo de regressão de cox para o caso de tempo discreto, porem não vou discartar os resultados que obtive com a regressão de cox, pois os resultados me ajudaram a compreender melhor os dados e o processo de análise, e também me ajudaram a compreender melhor o modelo LogisticHazard, e os resultados obtidos com a regressão de cox foram bastante satisfatórios, e me deram uma boa base para continuar meus estudos com o modelo LogisticHazard,a biblioteca CoxPHFitter em python (KVAMME *et al.*, 2019) (NADA, b) que utiliza métodos de Breslow, que corrigi eventos que ocorreram no mesmo intervalo de tempo. David Cox assumiu que o tempo era contínuo, ou seja, era impossível duas pessoas morrerem no exato mesmo milissegundo. Porem é muito comum dois ou mais pacientes terem o evento no mesmo dia. neste caso o método de Breslow é utilizado para corrigir esses eventos que ocorreram no mesmo intervalo de tempo, o estimador de Breslow ele permite que a Regressão de Cox calcule os pesos β mesmo quando a vários eventos no mesmo dia.

Calculo matemático que o modelo CoxPHFitter (NADA, b) definem a função de risco do modelo de regressão de cox da seguinte forma:

$$\underbrace{h(t|x)}_{\text{hazard}} = \overbrace{b_0(t)}^{\text{baseline hazard}} \underbrace{\exp\overbrace{\left(\sum_{i=1}^{n} b_i(x_i - \bar{x}_i)\right)}^{\text{log-partial hazard}}}_{\text{partial hazard}} \tag{4.1}$$

Onde $b_0(t)$ é a função de risco basal, b_i são os coeficientes de regressão, x_i são as covariáveis e $\bar{x}_i$ são as médias das covariáveis. O modelo de regressão de cox é um modelo sem parâmetros, ou seja, não assume nenhuma forma específica para a função de risco basal, e o

modelo de regressão de cox é um modelo semi-paramétrico, pois assume que a função de risco basal é uma função arbitrária, e o modelo de regressão de cox é um modelo multiplicativo, pois assume que a função de risco é multiplicada pela função de risco basal. Quando é semiparametrico o metodo utilizado é Breslow, pois resolve o problema de cox. O modelo de regressão de cox é um modelo de risco proporcional, pois assume que a razão de riscos entre dois indivíduos é constante ao longo do tempo, ou seja, a razão de riscos entre dois indivíduos é dada por:

$$\frac{h(t|x_1)}{h(t|x_2)} = \exp\left(\sum_{i=1}^{n} b_i(x_{1i} - x_{2i})\right) \tag{4.2}$$

Classifiquei alguns dados em grupo relevante para covariáveis, dados como holter, eletrocardiogramas holter, eventos condicoes cardiovasculares, dados demograficos clinicos, e outros dados de apoio como idade, gênero, esses vão estar presentes em todos dados porque são relevantes para a análise. Analise se baseie em modelo de risco de cox me retornando taxa de risco, intervalo de confiança, matriz de variâncias, erros padrão, log da verossimilhança, com base nos resultados selecionei algumas coveriaveis relevantes para para o treinar junto com os sinais ECG, e tambem comparar o quanto o modelo melhorou com os dados sinais ECG.

Foram avaliadas variáveis derivadas do Holter em modelos de regressão de Cox. As variáveis *Holter available* e *Holter onset (hh:mm:ss)* foram desconsideradas, pois não agregavam informação analítica relevante nesta amostra. A variável *Longest RR pause (ms)* também foi excluída devido à elevada proporção de valores ausentes.

4.1.1 Resultados do modelo de Cox para dados Holter

As variáveis do Holter utilizadas na análise estão descritas na Tabela 3. As variáveis *Holter available* e *Holter onset* foram desconsideradas por não agregarem informação analítica relevante — todos os pacientes apresentaram valor igual a 1 na primeira, e a segunda corresponde apenas ao horário de início do exame. A variável *Longest RR pause (ms)* também foi excluída em razão da elevada proporção de valores ausentes (aproximadamente 80% da amostra). As demais variáveis consideradas foram: ritmo do Holter (*Holter rhythm*), intervalos RR mínimo, médio, máximo e amplitude (*minimum*, *average*, *maximum* e *RR range*), extrassístoles em dupla (*Extrasystole couplets*), extrassístole ventricular (*Ventricular Extrasystole*), bradicardia (*Bradycardia*) e os índices de variabilidade da frequência cardíaca SDNN, SDANN, RMSSD e pNN50. Apresentam-se abaixo dois modelos: o primeiro com a coorte completa ($n = 992$) e o

segundo com a amostra filtrada para pacientes com as três derivações completas ($n = 898$).

Tabela 3 – Modelo de Cox com variáveis do Holter na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.28	1.33	0.95–1.85	0.17	0.10	Não
Idade	0.33	1.39	1.18–1.64	0.08	< 0.005	Sim
Ritmo Holter[a]	0.15	1.17	1.02–1.33	0.07	0.02	Sim
RR mín. (ms)	0.11	1.12	0.90–1.39	0.11	0.32	Não
RR méd. (ms)	-0.00	1.00	0.78–1.27	0.12	0.97	Não
RR máx. (ms)	-0.01	0.99	0.70–1.39	0.17	0.95	Não
Amplitude RR (ms)	0.15	1.16	0.82–1.66	0.18	0.40	Não
Extrasys. em dupla[b]	0.10	1.11	1.02–1.20	0.04	0.01	Sim
Extrasssístole vent.[c]	0.23	1.26	1.07–1.49	0.08	0.01	Sim
Bradicardia	-0.03	0.97	0.83–1.13	0.08	0.66	Não
SDNN (ms)	-0.92	0.40	0.17–0.93	0.44	0.03	Sim
SDANN (ms)	0.51	1.66	0.74–3.75	0.41	0.22	Não
RMSSD (ms)	0.31	1.37	0.96–1.94	0.18	0.08	Não
pNN50 (%)	-0.18	0.84	0.58–1.20	0.18	0.33	Não
Concordance			0.67			
Partial AIC			2714.94			
Log-likelihood ratio test			72.76 em 14 g.l.; $-\log_2(p) = 30.62$			

[a] Ritmo Holter: ritmo cardíaco registrado no Holter (*Holter rhythm*).
[b] Extrasys. em dupla: extrassístoles em dupla (*Extrasystole couplets*).
[c] Extrassístole vent.: extrassístole ventricular (*Ventricular Extrasystole*).

Tabela 4 – Modelo de Cox com variáveis do Holter na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.34	1.41	0.99–2.00	0.18	0.06	Não
Idade	0.37	1.44	1.21–1.72	0.09	< 0.005	Sim
Ritmo Holter[a]	0.17	1.18	1.03–1.36	0.07	0.02	Sim
RR mín. (ms)	0.16	1.18	0.86–1.60	0.16	0.31	Não
RR méd. (ms)	-0.03	0.97	0.75–1.25	0.13	0.82	Não
RR máx. (ms)	-0.05	0.95	0.48–1.88	0.35	0.89	Não
Amplitude RR (ms)	0.21	1.24	0.58–2.64	0.39	0.58	Não
Extrasys. em dupla[b]	0.10	1.11	1.02–1.21	0.04	0.02	Sim
Extrasssístole vent.[c]	0.20	1.23	1.04–1.45	0.09	0.02	Sim
Bradicardia	-0.03	0.97	0.84–1.14	0.08	0.75	Não
SDNN (ms)	-0.99	0.37	0.15–0.92	0.46	0.03	Sim
SDANN (ms)	0.55	1.73	0.74–4.08	0.44	0.21	Não
RMSSD (ms)	0.27	1.31	0.90–1.91	0.19	0.16	Não
pNN50 (%)	-0.12	0.88	0.60–1.29	0.19	0.53	Não
Concordance			0.68			
Partial AIC			2461.23			
Log-likelihood ratio test			72.27 em 14 g.l.; $-\log_2(p) = 30.32$			

[a] Ritmo Holter: ritmo cardíaco registrado no Holter (*Holter rhythm*).
[b] Extrasys. em dupla: extrassístoles em dupla (*Extrasystole couplets*).
[c] Extrassístole vent.: extrassístole ventricular (*Ventricular Extrasystole*).

4.1.1.1 Resumo dos resultados do modelo de Cox para dados Holter

De modo geral, as duas análises apresentaram resultados consistentes. As variáveis idade, Holter rhythm, Extrasystole couplets, Ventricular Extrasystole e SDNN mantiveram associação estatisticamente significativa com o desfecho nas duas análises. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez dos resultados mesmo após a restrição aos pacientes com três derivações completas. O que isso significa é que mesmo com a restrição dos pacientes com três derivações completas, poderei usar essas restriçoes aos sinais de ECG, ao um modelo convulocional resnet, essa filtagem é porque alguns dos pacientes não tem as 3 derivações completas, então a filtragem não atrapallha nos resultados.

4.1.2 Resultados do modelo de Cox para dados de eventos e condições cardiovasculares

As variáveis de eventos e condições cardiovasculares selecionadas para os modelos reduzidos foram: número de extrassístoles ventriculares por hora, taquicardia ventricular não sus-

tentada com mais de dez batimentos (*Non-sustained ventricular tachycardia*, CH>10), número de extrassístoles supraventriculares em 24 horas e taquiarritmia supraventricular paroxística (*Paroxysmal supraventricular tachyarrhythmia*). As variáveis gênero e idade foram incluídas em todos os modelos como covariáveis de controle padrão.

Para dados de eventos e condições cardiovasculares apresentaram resultados consistentes. Em ambas as análises, apenas idade e taquicardia ventricular não sustentada (CH>10) mantiveram associação estatisticamente significativa com o desfecho. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez dos resultados mesmo após a restrição aos pacientes com três derivações completas. Apresentam-se abaixo dois modelos: o primeiro com a coorte completa ($n = 992$) e o segundo com a amostra filtrada para pacientes com as três derivações completas ($n = 898$).

Tabela 5 – Modelo de Cox com variáveis arrítmicas na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.24	1.27	0.92–1.77	0.17	0.15	Não
Idade	0.35	1.42	1.21–1.67	0.08	< 0.005	Sim
VE/h[a]	0.02	1.02	0.90–1.16	0.06	0.77	Não
TVNS (CH>10)[b]	0.60	1.83	1.32–2.53	0.17	< 0.005	Sim
SVE/24h[c]	-0.01	0.99	0.88–1.13	0.06	0.93	Não
TASVP[d]	0.11	1.12	0.98–1.28	0.07	0.11	Não
Concordance			0.64			
Partial AIC			2718.25			
Log-likelihood ratio test			53.45 em 6 g.l.; $-\log_2(p) = 29.97$			

[a] VE/h: número de extrassístoles ventriculares por hora.
[b] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[c] SVE/24h: número de extrassístoles supraventriculares em 24 horas.
[d] TASVP: taquiarritmia supraventricular paroxística.

Tabela 6 – Modelo de Cox com variáveis arrítmicas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.30	1.36	0.96–1.92	0.18	0.09	Não
Idade	0.39	1.48	1.25–1.76	0.09	< 0.005	Sim
VE/h[a]	0.02	1.02	0.90–1.16	0.07	0.76	Não
TVNS (CH>10)[b]	0.56	1.75	1.25–2.44	0.17	< 0.005	Sim
SVE/24h[c]	-0.02	0.98	0.86–1.12	0.07	0.82	Não
TASVP[d]	0.11	1.12	0.97–1.28	0.07	0.12	Não
Concordance			0.65			
Partial AIC			2464.70			
Log-likelihood ratio test			52.80 em 6 g.l.; $-\log_2(p) = 29.53$			

[a] VE/h: número de extrassístoles ventriculares por hora.
[b] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[c] SVE/24h: número de extrassístoles supraventriculares em 24 horas.
[d] TASVP: taquiarritmia supraventricular paroxística.

4.1.3 Resultados do modelo de Cox para dados demográficos clínicos

As variáveis demográficas e clínicas avaliadas foram: peso corporal (*Weight*, kg), altura (*Height*, cm), índice de massa corporal (IMC, kg/m^2) e classe funcional da New York Heart Association (NYHA). As variáveis idade e gênero, embora pertençam a este grupo, foram excluídas desta listagem específica por já estarem presentes como covariáveis de controle em todos os modelos analisados.

Tabela 7 – Modelo de Cox com dados clínicos e antropométricos na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.65	1.92	1.28–2.88	0.21	< 0.005	Sim
Idade	0.29	1.34	1.14–1.57	0.08	< 0.005	Sim
Peso (kg)	0.03	1.03	0.25–4.26	0.72	0.97	Não
Altura (cm)	-0.23	0.79	0.34–1.83	0.43	0.59	Não
IMC[a]	-0.26	0.77	0.23–2.58	0.62	0.67	Não
Classe NYHA	0.93	2.54	1.90–3.39	0.15	< 0.005	Sim
Concordance			0.67			
Partial AIC			2693.46			
Log-likelihood ratio test			78.24 em 6 g.l.; $-\log_2(p) = 46.79$			

[a] IMC: índice de massa corporal (kg/m^2).

Tabela 8 – Modelo de Cox com dados clínicos e antropométricos na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.74	2.09	1.37–3.20	0.22	< 0.005	Sim
Idade	0.33	1.38	1.17–1.64	0.09	< 0.005	Sim
Peso (kg)	0.15	1.16	0.27–5.05	0.75	0.85	Não
Altura (cm)	-0.32	0.73	0.31–1.73	0.44	0.47	Não
IMC[a]	-0.36	0.70	0.20–2.45	0.64	0.58	Não
Classe NYHA	0.93	2.53	1.87–3.41	0.15	< 0.005	Sim
Concordance			0.68			
Partial AIC			2438.61			
Log-likelihood ratio test			78.89 em 6 g.l.; $-\log_2(p) = 47.23$			

[a] IMC: índice de massa corporal (kg/m^2).

As duas análises apresentaram resultados consistentes. Em ambas as análises, gênero, idade e classe funcional da NYHA mantiveram associação estatisticamente significativa com o desfecho. As variáveis antropométricas peso, altura e índice de massa corporal não apresentaram associação significativa em nenhuma das coortes. A semelhança entre os achados da coorte completa e da amostra filtrada sugere robustez desses resultados mesmo após a restrição aos pacientes com três derivações completas.

4.1.4 Resultados do modelo de Cox para dados eletrocardiograma de alta resolução

As variáveis derivadas do eletrocardiograma de alta resolução consideradas na análise foram: disponibilidade do ECG de alta resolução (*High-resolution ECG available*), ritmo do ECG (*ECG rhythm*), presença de ondas Q de necrose (*Q-waves*, sim = 1), intervalo PR (*PR interval*, ms), duração do complexo QRS (*QRS duration*, ms), presença de QRS superior a 120 ms (*QRS* $>$ *120 ms*), intervalo QT (*QT interval*, ms), QT corrigido (*QT corrected*), hipertrofia ventricular esquerda (*Left ventricular hypertrophy*, sim = 1) e distúrbio de condução intraventricular (*Intraventricular conduction disorder*).

Tabela 9 – Modelo de Cox com variáveis eletrocardiográficas na coorte completa ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.24	1.27	0.91–1.77	0.17	0.16	Não
Idade	0.35	1.42	1.21–1.67	0.08	< 0.005	Sim
ECG-AR[a]	0.22	1.24	0.90–1.71	0.16	0.19	Não
Ritmo ECG	0.12	1.12	0.97–1.30	0.08	0.13	Não
Ondas Q[b]	0.71	2.03	1.49–2.76	0.16	< 0.005	Sim
Intervalo PR (ms)	0.17	1.19	1.04–1.36	0.07	0.01	Sim
Duração QRS (ms)	0.14	1.15	0.86–1.52	0.14	0.35	Não
QRS > 120 ms	0.10	1.11	0.67–1.84	0.26	0.68	Não
Intervalo QT (ms)	-0.28	0.75	0.63–0.90	0.09	< 0.005	Sim
QT corrigido	0.17	1.18	0.99–1.41	0.09	0.07	Não
HVE[c]	0.11	1.11	0.81–1.52	0.16	0.50	Não
DCI[d]	0.11	1.12	0.97–1.29	0.07	0.13	Não
Concordance			0.67			
Partial AIC			2707.27			
Log-likelihood ratio test			76.43 em 12 g.l.; $-\log_2(p) = 35.56$			

[a] ECG-AR: ECG de alta resolução disponível.
[b] Ondas Q: presença de ondas Q de necrose (sim = 1).
[c] HVE: hipertrofia ventricular esquerda (sim = 1).
[d] DCI: distúrbio de condução intraventricular.

Tabela 10 – Modelo de Cox com variáveis eletrocardiográficas na amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
Gênero	0.29	1.34	0.94–1.89	0.18	0.10	Não
Idade	0.39	1.48	1.25–1.76	0.09	< 0.005	Sim
ECG-AR[a]	0.21	1.23	0.86–1.75	0.18	0.26	Não
Ritmo ECG	0.14	1.15	0.99–1.35	0.08	0.07	Não
Ondas Q[b]	0.71	2.02	1.47–2.80	0.16	< 0.005	Sim
Intervalo PR (ms)	0.17	1.18	1.03–1.37	0.07	0.02	Sim
Duração QRS (ms)	0.07	1.07	0.80–1.44	0.15	0.64	Não
QRS > 120 ms	0.24	1.27	0.76–2.14	0.27	0.36	Não
Intervalo QT (ms)	-0.28	0.75	0.63–0.91	0.09	< 0.005	Sim
QT corrigido	0.14	1.15	0.95–1.38	0.10	0.15	Não
HVE[c]	0.06	1.06	0.77–1.48	0.17	0.71	Não
DCI[d]	0.10	1.11	0.95–1.29	0.08	0.19	Não
Concordance			0.68			
Partial AIC			2453.52			
Log-likelihood ratio test			75.98 em 12 g.l.; $-\log_2(p) = 35.28$			

[a] ECG-AR: ECG de alta resolução disponível.
[b] Ondas Q: presença de ondas Q de necrose (sim = 1).
[c] HVE: hipertrofia ventricular esquerda (sim = 1).
[d] DCI: distúrbio de condução intraventricular.

As duas análises apresentaram resultados consistentes. Em ambas as análises, idade, presença de ondas Q, intervalo PR e intervalo QT mantiveram associação estatisticamente significativa com o desfecho. Especificamente, ondas Q e intervalo PR associaram-se a maior risco, enquanto o intervalo QT apresentou associação inversa com o desfecho. As demais variáveis eletrocardiográficas, incluindo disponibilidade de ECG de alta resolução, ritmo no ECG, duração do QRS, QRS maior que 120 ms, QT corrigido, hipertrofia ventricular esquerda e distúrbio de condução intraventricular, não apresentaram associação significativa em nenhuma das coortes.

Foram analisadas 32 variáveis candidatas ao modelo de Cox, abrangendo dados demográficos, Holter, eletrocardiográficos e de eventos cardiovasculares. A análise foi conduzida em três etapas: (i) regressão de Cox univariável com teste log-rank e cálculo do índice de concordância (C-index) para cada variável individualmente; (ii) avaliação de multicolinearidade pelo fator de inflação da variância (VIF); e (iii) regressão de Cox multivariável com as variáveis que apresentaram $p < 0{,}05$ na etapa univariável.

Tabela 11 – Análise de Cox univariável — coeficiente, razão de risco, C-index e significância por variável ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	p (Cox)	C-index	p (log-rank)
Significativas ($p < 0{,}05$)						
NYHA class	0.96	2.61	1.96–3.47	< 0.005	0.595	< 0.005
Idade	0.39	1.48	1.27–1.73	< 0.005	0.598	< 0.005
TVNS (CH>10)[a]	0.75	2.11	1.60–2.78	< 0.005	0.585	< 0.005
SDANN (ms)	-0.30	0.74	0.64–0.86	< 0.005	0.431	< 0.005
SDNN (ms)	-0.30	0.74	0.64–0.86	< 0.005	0.431	< 0.005
Ondas Q (necrose)[b]	0.52	1.68	1.27–2.22	< 0.005	0.559	< 0.005
Extrasys. em dupla[c]	0.14	1.15	1.07–1.24	< 0.005	0.614	< 0.005
Peso (kg)	-0.26	0.77	0.67–0.89	< 0.005	0.428	0.029
TASVP[d]	0.22	1.25	1.10–1.42	< 0.005	0.556	< 0.005
Extrassístole ventricular	0.28	1.33	1.13–1.56	< 0.005	0.558	—
Duração do QRS (ms)	0.20	1.22	1.08–1.39	0.002	0.570	0.003
VE/h[e]	0.14	1.15	1.05–1.27	0.002	0.597	< 0.005
DCI[f]	0.20	1.22	1.07–1.38	0.002	0.573	0.056
QRS > 120 ms	0.41	1.51	1.15–1.99	0.003	0.552	0.003
IMC (kg/m^2)	-0.22	0.81	0.70–0.93	0.004	0.440	0.020
Ritmo do Holter	0.17	1.19	1.06–1.34	0.004	0.553	0.001
Intervalo PR (ms)	0.19	1.21	1.06–1.37	0.004	0.555	0.532
Ritmo do ECG	0.16	1.18	1.04–1.33	0.007	0.554	< 0.005
QT corrigido	0.14	1.15	1.01–1.32	0.035	0.553	0.021
Não significativas ($p \geq 0{,}05$)						
ECG alta resolução[g]	0.27	1.31	0.96–1.80	0.088	0.525	—
Altura (cm)	-0.11	0.89	0.78–1.02	0.097	0.459	0.018
Gênero	0.24	1.28	0.92–1.76	0.139	0.522	—
RR mínimo (ms)	0.10	1.11	0.97–1.26	0.141	0.530	0.089
SVE/24h[h]	0.07	1.07	0.97–1.19	0.181	0.564	< 0.005
pNN50 (%)	-0.08	0.93	0.79–1.08	0.326	0.489	0.223
HVE[i]	0.10	1.10	0.81–1.50	0.536	0.511	0.536
Intervalo QT (ms)	-0.03	0.97	0.85–1.12	0.687	0.490	0.906
Bradicardia	-0.02	0.98	0.85–1.13	0.774	0.499	0.920
RR máximo (ms)	-0.02	0.98	0.85–1.13	0.803	0.474	0.157
Amplitude RR (ms)	-0.01	0.99	0.86–1.14	0.894	0.478	0.365
RR médio (ms)	-0.01	0.99	0.87–1.14	0.931	0.497	0.503
RMSSD (ms)	-0.00	1.00	0.87–1.14	0.951	0.505	0.514

[a] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[b] Ondas Q: presença de ondas Q de necrose (sim = 1).
[c] Extrasys. em dupla: *Extrasystole couplets*.
[d] TASVP: taquiarritmia supraventricular paroxística.
[e] VE/h: número de extrassístoles ventriculares por hora.
[f] DCI: distúrbio de condução intraventricular.
[g] ECG alta resolução: disponibilidade do ECG de alta resolução.
[h] SVE/24h: número de extrassístoles supraventriculares em 24 horas.
[i] HVE: hipertrofia ventricular esquerda (sim = 1).
HR: razão de risco (*hazard ratio*); IC 95%: intervalo de confiança de 95%; C-index: índice de concordância; —: valor não disponível.

Tabela 12 – Fator de inflação da variância (VIF) — avaliação de multicolinearidade entre as variáveis candidatas.

Variável	VIF	Alerta
Alta multicolinearidade (VIF $>$ 10) — excluídas do modelo		
Peso (kg)	85.15	Alta
IMC (kg/m^2)	62.50	Alta
SDNN (ms)	32.31	Alta
Altura (cm)	32.09	Alta
SDANN (ms)	27.95	Alta
Multicolinearidade moderada (5 $<$ VIF $\leq$ 10) — uso com cautela		
RMSSD (ms)	6.77	Moderada
RR máximo (ms)	6.37	Moderada
pNN50 (%)	6.23	Moderada
Ritmo do Holter	6.11	Moderada
Amplitude RR (ms)	6.04	Moderada
TASVP[a]	5.54	Moderada
Duração do QRS (ms)	5.03	Moderada
Multicolinearidade aceitável (VIF $\leq$ 5)		
Ritmo do ECG	4.70	Aceitável
RR médio (ms)	3.89	Aceitável
QRS $>$ 120 ms	3.77	Aceitável
RR mínimo (ms)	3.32	Aceitável
VE/h[b]	3.05	Aceitável
Intervalo QT (ms)	3.01	Aceitável
QT corrigido	2.51	Aceitável
Extrasys. em dupla[c]	2.36	Aceitável
TVNS (CH$>$10)[d]	1.78	Aceitável
Gênero	1.66	Aceitável
Idade	1.37	Aceitável
Extrasssístole ventricular	1.29	Aceitável
DCI[e]	1.27	Aceitável
ECG alta resolução	1.24	Aceitável
Ondas Q (necrose)	1.17	Aceitável
Intervalo PR (ms)	1.13	Aceitável
NYHA class	1.10	Aceitável
Bradicardia	1.10	Aceitável
SVE/24h[f]	1.09	Aceitável
HVE[g]	1.07	Aceitável

[a] TASVP: taquiarritmia supraventricular paroxística.
[b] VE/h: extrassístoles ventriculares por hora.
[c] Extrasys. em dupla: *Extrasystole couplets*.
[d] TVNS: taquicardia ventricular não sustentada (CH$>$10).
[e] DCI: distúrbio de condução intraventricular.
[f] SVE/24h: extrassístoles supraventriculares em 24 horas.
[g] HVE: hipertrofia ventricular esquerda.

Tabela 13 – Análise de Cox multivariável — variáveis com $p < 0{,}05$ na análise univariável ($n = 992$; 205 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
NYHA class	0.72	2.05	1.53–2.76	0.15	< 0.005	Sim
Idade	0.22	1.25	1.05–1.47	0.09	0.01	Sim
TVNS (CH>10)[a]	0.48	1.61	1.13–2.30	0.18	0.01	Sim
Ondas Q (necrose)[b]	0.60	1.82	1.35–2.47	0.15	< 0.005	Sim
Extrasys. em dupla[c]	0.16	1.17	1.02–1.35	0.07	0.03	Sim
TASVP[d]	0.27	1.31	1.04–1.64	0.12	0.02	Sim
DCI[e]	0.13	1.14	0.98–1.31	0.07	0.08	Não
Intervalo PR (ms)	0.13	1.13	0.99–1.30	0.07	0.07	Não
SDNN (ms)	-0.28	0.76	0.38–1.51	0.35	0.43	Não
SDANN (ms)	0.03	1.03	0.51–2.08	0.36	0.93	Não
Peso (kg)	-0.13	0.88	0.69–1.12	0.12	0.28	Não
IMC (kg/m^2)	-0.10	0.90	0.71–1.14	0.12	0.40	Não
Extrasssístole ventricular	0.10	1.10	0.92–1.32	0.09	0.28	Não
VE/h[f]	-0.10	0.90	0.74–1.10	0.10	0.32	Não
Duração do QRS (ms)	0.11	1.11	0.83–1.48	0.15	0.47	Não
QRS > 120 ms	0.04	1.04	0.63–1.73	0.26	0.88	Não
Ritmo do Holter	-0.16	0.86	0.64–1.14	0.15	0.29	Não
Ritmo do ECG	0.03	1.03	0.79–1.33	0.13	0.84	Não
QT corrigido	-0.02	0.98	0.83–1.15	0.09	0.78	Não
Concordance	0.72 (C-index multivariável: 0.718)					
Partial AIC	2667.02					
Log-likelihood ratio test	130.68 em 19 g.l.; $-\log_2(p) = 59.68$					

[a] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[b] Ondas Q: presença de ondas Q de necrose (sim = 1).
[c] Extrasys. em dupla: *Extrasystole couplets*.
[d] TASVP: taquiarritmia supraventricular paroxística.
[e] DCI: distúrbio de condução intraventricular.
[f] VE/h: extrassístoles ventriculares por hora.
HR: razão de risco; IC 95%: intervalo de confiança de 95%; EP: erro padrão.

De modo geral, o modelo multivariável apresentou poder discriminatório satisfatório (Concordance = 0,72). As variáveis que mantiveram associação estatisticamente significativa após o ajuste multivariável foram: classe funcional NYHA, idade, taquicardia ventricular não sustentada (CH>10), presença de ondas Q de necrose, extrassístoles em dupla e taquiarritmia supraventricular paroxística. As demais variáveis, incluindo aquelas com alta multicolinearidade (SDNN, SDANN, peso e IMC), perderam significância após o ajuste conjunto, o que é esperado em modelos com variáveis correlacionadas.

Apresentam-se a seguir os resultados da mesma análise conduzida para a amostra

filtrada com pacientes que possuem as três derivações completas ($n = 898$; 189 eventos), com o objetivo de verificar se a restrição imposta pela filtragem impacta os resultados obtidos na coorte completa.

Tabela 14 – Análise de Cox univariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	p (Cox)	C-index	p (log-rank)
Significativas ($p < 0{,}05$)						
NYHA class	0.97	2.64	1.97–3.55	< 0.005	0.598	< 0.005
Idade	0.43	1.53	1.30–1.81	< 0.005	0.608	< 0.005
TVNS (CH>10)[a]	0.71	2.04	1.53–2.72	< 0.005	0.583	< 0.005
SDNN (ms)	-0.31	0.74	0.63–0.86	< 0.005	0.428	< 0.005
SDANN (ms)	-0.31	0.73	0.63–0.86	< 0.005	0.429	< 0.005
Extrasys. em dupla[b]	0.14	1.15	1.06–1.25	< 0.005	0.613	< 0.005
Ondas Q (necrose)[c]	0.51	1.66	1.24–2.21	< 0.005	0.557	< 0.005
Peso (kg)	-0.26	0.77	0.66–0.90	< 0.005	0.427	0.030
TASVP[d]	0.23	1.25	1.10–1.43	< 0.005	0.555	< 0.005
Extrasssístole vent.[e]	0.27	1.32	1.11–1.56	0.001	0.558	—
DCI[f]	0.21	1.23	1.08–1.41	0.002	0.575	0.042
QRS > 120 ms	0.43	1.54	1.16–2.05	0.003	0.555	0.003
Ritmo ECG	0.18	1.20	1.06–1.36	0.003	0.559	< 0.005
VE/h[g]	0.14	1.15	1.05–1.27	0.005	0.597	< 0.005
Ritmo Holter	0.18	1.20	1.06–1.35	0.005	0.554	0.001
Intervalo PR (ms)	0.19	1.21	1.06–1.39	0.006	0.554	0.718
IMC[h]	-0.21	0.81	0.70–0.94	0.006	0.440	0.019
Duração QRS (ms)	0.19	1.21	1.06–1.38	0.006	0.569	< 0.005
Não significativas ($p \geq 0{,}05$)						
Gênero	0.29	1.34	0.95–1.88	0.092	0.527	—
Altura (cm)	-0.12	0.89	0.77–1.02	0.092	0.460	0.038
RR mín. (ms)	0.12	1.12	0.98–1.29	0.101	0.532	0.120
QT corrigido	0.11	1.12	0.97–1.29	0.118	0.542	0.042
ECG-AR[i]	0.27	1.31	0.93–1.85	0.129	0.522	—
SVE/24h[j]	0.06	1.07	0.95–1.19	0.254	0.564	0.003
pNN50 (%)	-0.08	0.93	0.79–1.09	0.349	0.489	0.193
Intervalo QT (ms)	-0.05	0.95	0.82–1.10	0.490	0.481	0.852
Amplitude RR (ms)	-0.04	0.96	0.83–1.11	0.587	0.469	0.243
HVE[k]	0.03	1.03	0.75–1.43	0.837	0.505	0.837
Bradicardia	-0.01	0.99	0.85–1.14	0.866	0.501	0.934
RR máx. (ms)	-0.01	0.99	0.85–1.15	0.884	0.478	0.108
RMSSD (ms)	-0.01	0.99	0.86–1.14	0.920	0.505	0.438
RR méd. (ms)	0.00	1.00	0.87–1.16	0.959	0.499	0.383

[a] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[b] Extrasys. em dupla: extrassístoles em dupla (*Extrasystole couplets*).
[c] Ondas Q: presença de ondas Q de necrose (sim = 1).
[d] TASVP: taquiarritmia supraventricular paroxística.
[e] Extrassístole vent.: extrassístole ventricular.
[f] DCI: distúrbio de condução intraventricular.
[g] VE/h: extrassístoles ventriculares por hora.
[h] IMC: índice de massa corporal (kg/m^2).
[i] ECG-AR: ECG de alta resolução disponível.
[j] SVE/24h: extrassístoles supraventriculares em 24 horas.
[k] HVE: hipertrofia ventricular esquerda (sim = 1).
HR: razão de risco; IC 95%: intervalo de confiança de 95%; C-index: índice de concordância; —: valor não

Tabela 15 – Fator de inflação da variância (VIF) — amostra filtrada com três derivações completas ($n = 898$).

Variável	VIF	Alerta
Alta multicolinearidade (VIF $>$ 10) — excluídas do modelo		
Peso (kg)	82.03	Alta
IMC (kg/m^2)	60.05	Alta
SDNN (ms)	32.56	Alta
Altura (cm)	30.80	Alta
SDANN (ms)	28.16	Alta
Amplitude RR (ms)	19.56	Alta
RR máx. (ms)	17.17	Alta
Multicolinearidade moderada (5 $<$ VIF $\leq$ 10) — uso com cautela		
RMSSD (ms)	6.82	Moderada
Ritmo Holter	6.38	Moderada
pNN50 (%)	6.27	Moderada
Ritmo ECG	5.65	Moderada
TASVP[a]	5.63	Moderada
Duração QRS (ms)	5.08	Moderada
Multicolinearidade aceitável (VIF $\leq$ 5)		
RR mín. (ms)	4.93	Aceitável
RR méd. (ms)	4.01	Aceitável
QRS $>$ 120 ms	3.75	Aceitável
Intervalo QT (ms)	3.16	Aceitável
VE/h[b]	3.03	Aceitável
QT corrigido	2.64	Aceitável
Extrasys. em dupla[c]	2.36	Aceitável
TVNS (CH$>$10)[d]	1.76	Aceitável
Gênero	1.66	Aceitável
Idade	1.40	Aceitável
DCI[e]	1.30	Aceitável
Extrasssístole vent.	1.26	Aceitável
Ondas Q (necrose)	1.19	Aceitável
Intervalo PR (ms)	1.14	Aceitável
ECG-AR[f]	1.11	Aceitável
NYHA class	1.11	Aceitável
Bradicardia	1.10	Aceitável
SVE/24h[g]	1.09	Aceitável
HVE[h]	1.08	Aceitável

[a] TASVP: taquiarritmia supraventricular paroxística.
[b] VE/h: extrassístoles ventriculares por hora.
[c] Extrasys. em dupla: *Extrasystole couplets*.
[d] TVNS: taquicardia ventricular não sustentada (CH$>$10).
[e] DCI: distúrbio de condução intraventricular.
[f] ECG-AR: ECG de alta resolução disponível.
[g] SVE/24h: extrassístoles supraventriculares em 24 horas.
[h] HVE: hipertrofia ventricular esquerda.

Tabela 16 – Análise de Cox multivariável — amostra filtrada com três derivações completas ($n = 898$; 189 eventos).

Variável	Coef.	HR	IC 95% HR	EP	p	Significância
NYHA class	0.72	2.05	1.51–2.79	0.16	< 0.005	Sim
Idade	0.25	1.28	1.08–1.53	0.09	< 0.005	Sim
TVNS (CH>10)[a]	0.42	1.53	1.06–2.21	0.19	0.02	Sim
Ondas Q (necrose)[b]	0.61	1.84	1.34–2.52	0.16	< 0.005	Sim
Extrasys. em dupla[c]	0.16	1.18	1.01–1.36	0.07	0.03	Sim
TASVP[d]	0.22	1.25	0.99–1.58	0.12	0.06	Não
Intervalo PR (ms)	0.13	1.14	0.99–1.32	0.07	0.07	Não
DCI[e]	0.11	1.12	0.96–1.30	0.08	0.15	Não
SDNN (ms)	-0.29	0.75	0.37–1.53	0.37	0.43	Não
SDANN (ms)	0.03	1.03	0.50–2.14	0.37	0.93	Não
Peso (kg)	-0.13	0.88	0.69–1.13	0.13	0.33	Não
IMC (kg/m^2)	-0.10	0.91	0.71–1.16	0.12	0.44	Não
Extrasssístole vent.	0.09	1.09	0.91–1.31	0.09	0.35	Não
VE/h[f]	-0.10	0.91	0.74–1.12	0.11	0.36	Não
Ritmo Holter	-0.20	0.82	0.59–1.15	0.17	0.25	Não
QRS > 120 ms	0.20	1.22	0.72–2.07	0.27	0.46	Não
Ritmo ECG	0.13	1.14	0.84–1.56	0.16	0.40	Não
Duração QRS (ms)	-0.00	1.00	0.76–1.31	0.14	0.99	Não
Concordance		0.72 (C-index multivariável: 0.718)				
Partial AIC		2418.97				
Log-likelihood ratio test		122.53 em 18 g.l.; $-\log_2(p) = 55.99$				

[a] TVNS: taquicardia ventricular não sustentada (CH>10 batimentos).
[b] Ondas Q: presença de ondas Q de necrose (sim = 1).
[c] Extrasys. em dupla: *Extrasystole couplets*.
[d] TASVP: taquiarritmia supraventricular paroxística.
[e] DCI: distúrbio de condução intraventricular.
[f] VE/h: extrassístoles ventriculares por hora.
HR: razão de risco; IC 95%: intervalo de confiança de 95%; EP: erro padrão.

Os resultados da amostra filtrada ($n = 898$) foram amplamente consistentes com os da coorte completa ($n = 992$). Na análise univariável, 18 variáveis apresentaram associação significativa ($p < 0{,}05$), em comparação com 19 na coorte completa — a única diferença foi a ausência de significância para o QT corrigido na amostra filtrada. O padrão de multicolinearidade foi semelhante, com dois grupos adicionais de alta colinearidade (amplitude RR e RR máximo, com VIF > 10) identificados na amostra filtrada. No modelo multivariável, as mesmas variáveis principais mantiveram significância: NYHA class, idade, TVNS (CH>10), ondas Q de necrose e extrassístoles em dupla. O C-index multivariável permaneceu idêntico (0,718), confirmando a

robustez dos resultados após a filtragem.

4.2 Modelos de Aprendizado Profundo para Sobrevivência

Aqui são apresentados os resultados dos modelos de sobrevivência profunda treinados com os mesmos conjuntos de covariáveis utilizados na análise de Cox, tanto para a coorte completa ($n = 992$) quanto para a amostra filtrada ($n = 898$). Os modelos avaliados foram: LogisticHazard, PMF e DeepHitSingle, utilizando a implementação disponível na biblioteca `pycox`.

4.2.1 Sobre LogisticHazard

4.2.2 Sobre PMF

4.2.3 Sobre DeepHitSingle

A Tabela 17 resume o desempenho dos modelos de sobrevivência profunda segundo o tipo de colunas utilizado, a filtragem dos pacientes com ECG, e as principais métricas de discriminação e calibração. Em todos os experimentos, foram utilizados *batch size* de 256 e *dropout* de 0,5.

Tabela 17 – Desempenho dos modelos de sobrevivência profunda segundo o conjunto de covariáveis e a disponibilidade de ECG dos pacientes.

Modelo	Covariáveis[a]	Coorte[b]	C-index	Brier	NBLL	Loss (treino)	Loss (val.)	Época
Holter (H)								
LogisticHazard	H	C992	0,5300	0,1782	0,5790	1,1192	1,0597	28
PMF	H	C992	0,6062	0,1740	0,5631	0,9059	1,1039	46
DeepHitSingle	H	C992	0,6239	0,1784	0,5633	0,3410	0,3653	59
LogisticHazard	H	C898	0,6257	0,1756	0,5618	1,5659	1,0911	34
PMF	H	C898	0,6848	0,1670	0,5260	0,9912	1,0724	41
DeepHitSingle	H	C898	**0,7234**	0,1661	0,5265	0,3352	0,3428	99
Eletrocardiogramas Holter (EH)								
LogisticHazard	EH	C992	0,6089	0,1732	0,5706	1,0588	1,0645	50
PMF	EH	C992	0,6086	0,1676	0,5579	0,9864	1,0542	49
DeepHitSingle	EH	C992	0,5721	0,1775	0,5686	0,3353	0,3463	69
LogisticHazard	EH	C898	0,5699	0,1797	0,5759	0,9176	1,1579	29
PMF	EH	C898	0,6145	0,1709	0,5400	1,0422	1,1741	39
DeepHitSingle	EH	C898	0,5896	0,1930	0,5958	0,3483	0,3810	69
Eventos e Condições Cardiovasculares (EC)								
LogisticHazard	EC	C992	0,5656	0,1771	0,5667	1,1943	1,1249	27
PMF	EC	C992	0,5897	0,1767	0,5760	1,0138	1,0853	41
DeepHitSingle	EC	C992	0,5812	0,2896	0,8420	0,6048	0,4321	30
LogisticHazard	EC	C898	0,6412	0,1682	0,5448	1,0169	1,2437	28
PMF	EC	C898	**0,7151**	**0,1664**	**0,5137**	1,0058	1,2551	33
DeepHitSingle	EC	C898	0,7000	0,2567	0,7409	0,4386	0,6774	34
Conjunto de Covariáveis Prognósticas Selecionadas (CPS)[c]								
LogisticHazard	CPS	C992	0,6464	0,1672	0,5553	1,0285	1,0508	69
PMF	CPS	C992	0,5840	0,1720	0,5726	0,9828	1,0793	36
DeepHitSingle	CPS	C992	0,6175	0,1726	0,5573	0,3625	0,3573	67
LogisticHazard	CPS	C898	0,6753	0,1666	0,5304	1,1640	1,1131	50
PMF	CPS	C898	**0,6965**	**0,1599**	**0,5133**	1,0212	1,0743	48
DeepHitSingle	CPS	C898	0,6776	0,2268	0,6701	0,4485	0,4122	49

Em todos os experimentos: *batch size* = 256; *dropout* = 0,5. Valores em negrito indicam o melhor desempenho dentro de cada grupo de covariáveis. Loss (val.): *loss* de validação.

[a] Grupos de covariáveis: H = Holter; EH = Eletrocardiogramas Holter; EC = Eventos e Condições Cardiovasculares; CPS = Conjunto de Covariáveis Prognósticas Selecionadas.

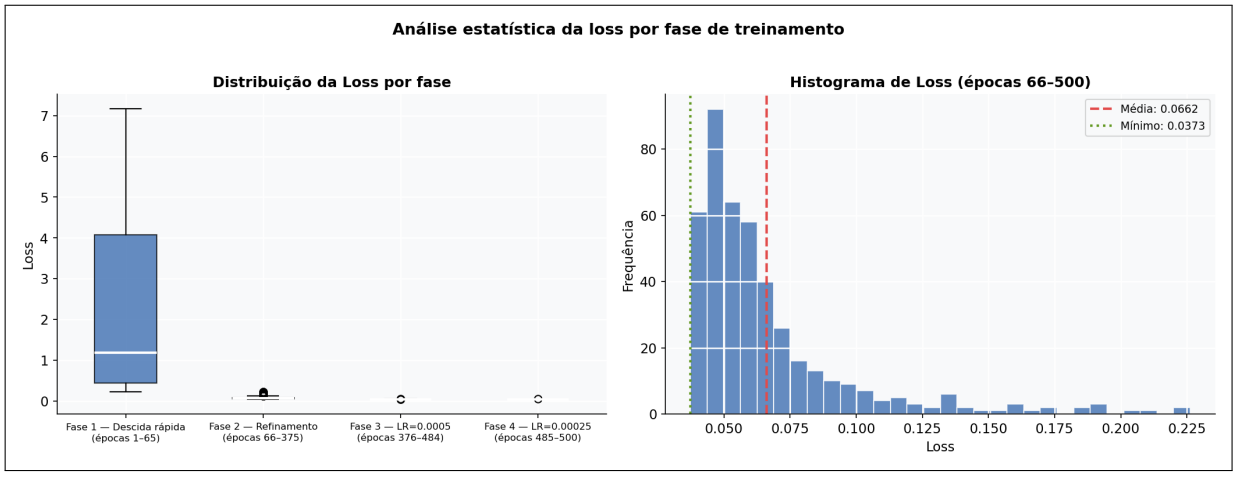
[b] Coorte: C992 = coorte completa ($n = 992$; 205 eventos); C898 = amostra com três derivações de ECG completas ($n = 898$; 189 eventos).

[c] O conjunto CPS é composto por variáveis com associação estatisticamente significativa nas análises de Cox: dados demográficos (idade, gênero e classe NYHA); eventos cardiovasculares [taquicardia ventricular não sustentada (CH>10) e taquiarritmia supraventricular paroxística]; e achado eletrocardiográfico [ondas Q de necrose (*Q-waves*, sim = 1)].

De forma geral, os melhores desempenhos foram observados com filtragem de pacientes com ECG (“Com”). Entre os modelos baseados apenas em colunas do Holter, o melhor C-index foi obtido pelo *DeepHitSingle* com filtragem (0,7234). No conjunto *eventos_condicoes_cardiovasculares*, o melhor desempenho foi alcançado pelo *PMF* com filtragem (C-index 0,7151; Brier score 0,1664; NBLL 0,5137). Para o conjunto de *Covariáveis selecionadas*, o melhor C-index também ocorreu com o *PMF* com filtragem (0,6965), enquanto o menor Brier score foi 0,1599 no mesmo cenário.

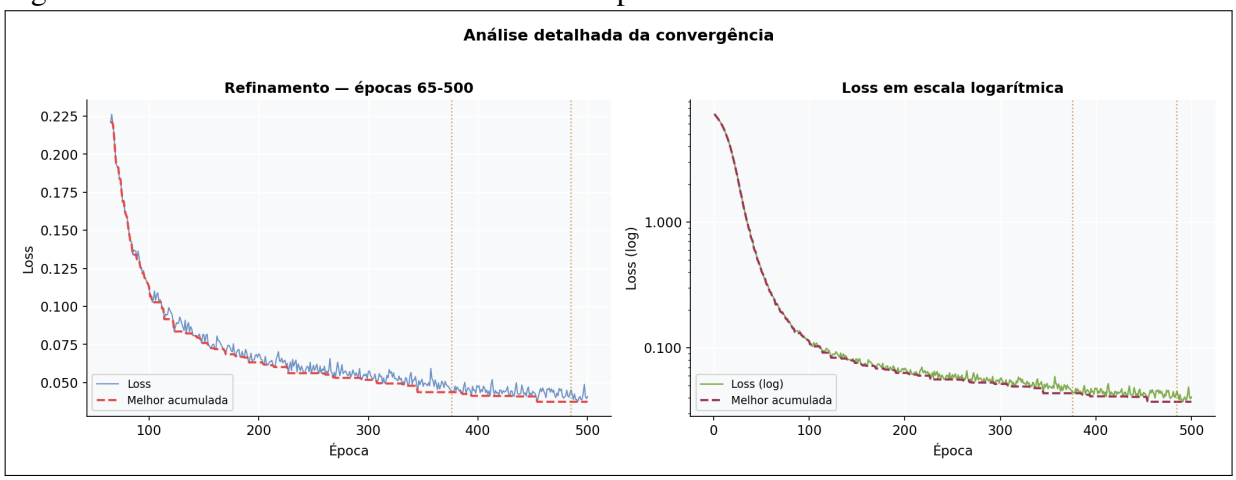
4.3 MoCo (Momentum Contrast)

Figura 6 – Gráfico de tensão considerando a impedância humana



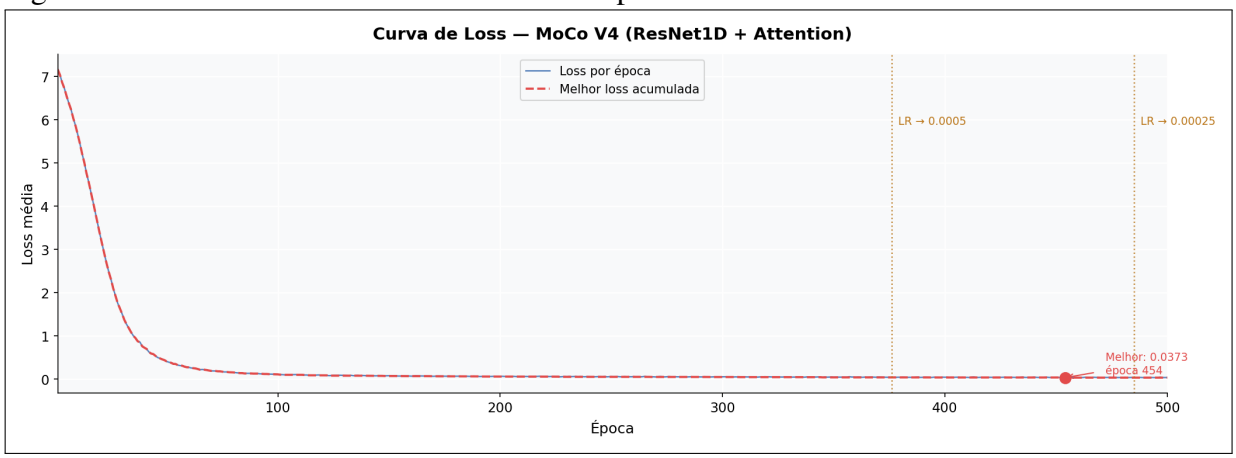
Fonte: elaborado pelo autor (2016).

Figura 7 – Gráfico de tensão considerando a impedância humana



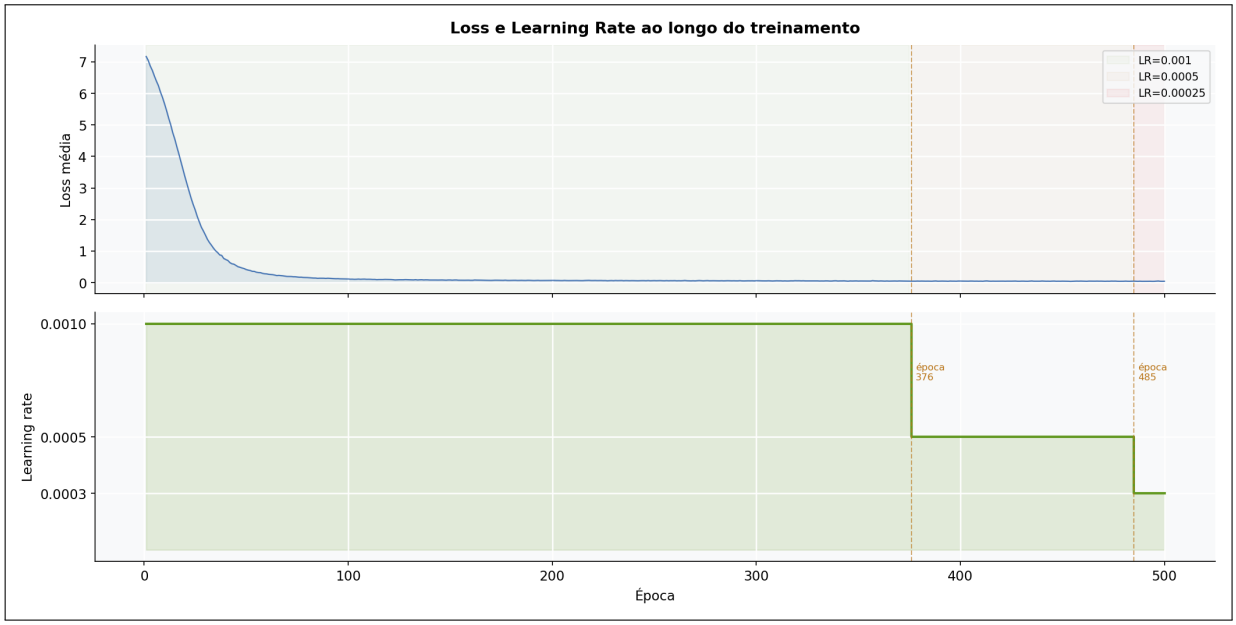
Fonte: elaborado pelo autor (2016).

Figura 8 – Gráfico de tensão considerando a impedância humana



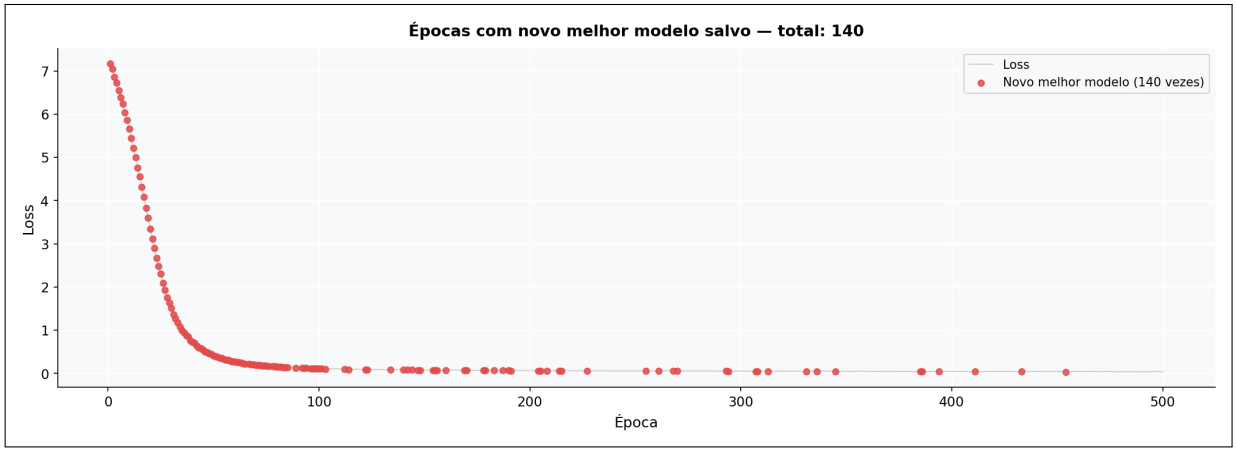
Fonte: elaborado pelo autor (2016).

Figura 9 – Gráfico de tensão considerando a impedância humana



Fonte: elaborado pelo autor (2016).

Figura 10 – Gráfico de tensão considerando a impedância humana



Fonte: elaborado pelo autor (2016).

5 CONCLUSÕES E TRABALHOS FUTUROS

Parte final do texto na qual se apresentam as conclusões apoiadas no desenvolvimento do assunto. É a recapitulação sintética dos resultados obtidos. Pode apresentar recomendações e sugestões para pesquisas futuras.

REFERÊNCIAS

ALLISON, P. D. Discrete-time methods for the analysis of event histories. **Sociological Methodology**, American Sociological Association, v. 13, p. 61–98, 1982. Disponível em: <https://www.jstor.org/stable/270718>. Acesso em: 17 mar. 2026.

BIGANZOLI, E.; BORACCHI, P.; MARIANI, L.; MARUBINI, E. Feed forward neural networks for the analysis of censored survival data: A partial logistic regression approach. **Statistics in Medicine**, Wiley, v. 17, n. 10, p. 1169–1186, 1998. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1002/(SICI)1097-0258(19980530)17:10%3C1169::AID-SIM796%3E3.0.CO;2-D>. Acesso em: 09 mai. 2026.

CHEN, T.; KORNBLITH, S.; NOROUZI, M.; HINTON, G. A simple framework for contrastive learning of visual representations. In: **Proceedings of the 37th International Conference on Machine Learning (ICML)**. [s.n.], 2020. p. 1597–1607. Disponível em: <https://arxiv.org/abs/2002.05709>. Acesso em: 05 mar. 2026.

CHEN, X.; FAN, H.; GIRSHICK, R.; HE, K. Improved baselines with momentum contrastive learning. **arXiv preprint arXiv:2003.04297**, 2020. Disponível em: <https://arxiv.org/abs/2003.04297>. Acesso em: 05 mar. 2026.

CHEN, X.; XIE, S.; HE, K. An empirical study of training self-supervised vision transformers. In: **Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)**. [s.n.], 2021. p. 9640–9649. Disponível em: <https://arxiv.org/abs/2104.02057>. Acesso em: 05 mar. 2026.

EFRON, B. Logistic regression, survival analysis, and the Kaplan-Meier curve. **Journal of the American Statistical Association**, Taylor & Francis, v. 83, n. 402, p. 414–425, 1988. Disponível em: <https://www.jstor.org/stable/2529811>. Acesso em: 09 mai. 2026.

GENSHEIMER, M. F.; NARASIMHAN, B. A scalable discrete-time survival model for neural networks. **PeerJ**, PeerJ Inc., v. 7, p. e6257, 2019. Disponível em: <https://peerj.com/articles/6257/>. Acesso em: 09 mai. 2026.

HANNUN, A. Y.; RAJPURKAR, P.; HAGHPANAHI, M.; TISON, G. H.; BOURN, C.; TURAKHIA, M. P.; NG, A. Y. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. **Nature Medicine**, Nature Publishing Group, v. 25, n. 1, p. 65–69, 2019.

HE, K.; FAN, H.; WU, Y.; XIE, S.; GIRSHICK, R. Momentum contrast for unsupervised visual representation learning. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2020. p. 9729–9738.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2016. p. 770–778.

Jornal da USP. **Doenças cardiovasculares são a principal causa de mortes no Brasil, segundo o Ministério da Saúde**. 2024. Disponível em: <https://jornal.usp.br/radio-usp/doencas-cardiovasculares-sao-a-principal-causa-de-mortes-no-brasil-segundo-o-ministerio-da-saude/>. Acesso em: 03 mar. 2026.

KVAMME, H. **pycox: Survival analysis with PyTorch**. [S.l.]: GitHub, 2019. <https://github.com/havakv/pycox>. Acesso em: 20 mar. 2026.

KVAMME, H.; BORGAN, Ø. Continuous and discrete-time survival prediction with neural networks. **arXiv preprint**, arXiv:1910.06724, 2019. Disponível em: <https://arxiv.org/abs/1910.06724>. Acesso em: 09 mai. 2026.

KVAMME, H.; BORGAN, Ø.; SCHEEL, I. Time-to-event prediction with neural networks and cox regression. **Journal of Machine Learning Research**, v. 20, n. 129, p. 1–30, 2019.

LEE, C.; ZAME, W. R.; YOON, J.; SCHAAR, M. van der. DeepHit: A deep learning approach to survival analysis with competing risks. In: **Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence**. AAAI Press, 2018. (AAAI 2018), p. 2314–2321. Disponível em: <http://medianetlab.ee.ucla.edu/papers/AAAI_2018_DeepHit>. Acesso em: 09 mai. 2026.

OORD, A. van den; LI, Y.; VINYALS, O. Representation learning with contrastive predictive coding. **arXiv preprint arXiv:1807.03748**, 2018. Disponível em: <https://arxiv.org/abs/1807.03748>. Acesso em: 05 mar. 2026.

PRABHAKARARAO, E.; MANIMEGALAI, P. **A Multimodal User-Interface System for Computational Analysis of Sudden Cardiac Death (MUSIC)**. 2020. PhysioNet. Version 1.0.0. Disponível em: <https://physionet.org>. Acesso em: 02 mar. 2026.

PRABHAKARARAO, E.; MANIMEGALAI, P. **A Multimodal User-Interface System for Computational Analysis of Sudden Cardiac Death (MUSIC)**. 2020. PhysioNet. Disponível em arquivo csv. Disponível em: <https://physionet.org>. Acesso em: 02 mar. 2026.

RIBEIRO, A. H.; RIBEIRO, M. H.; PAIXÃO, G. M. M.; OLIVEIRA, D. M.; GOMES, P. R.; CANAZART, J. A.; FERREIRA, M. P. S.; ANDERSSON, C. R.; MACFARLANE, P. W.; WAGNER, M. J.; SCHÖN, T. B.; RIBEIRO, A. L. P. Automatic diagnosis of the 12-lead ECG using a deep neural network. **Nature Communications**, Nature Publishing Group, v. 11, p. 1760, 2020.

World Health Organization. **Cardiovascular diseases (CVDs)**. 2025. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)>. Acesso em: 03 mar. 2026.

APÊNDICE A – EXEMPLO DE APÊNDICE

Um apêndice é um documento elaborado pelo autor, diferentemente do anexo. Geralmente, se coloca como apêndice, questionários, códigos de programação, tabelas que tomariam muito espaço no meio do trabalho. Artigos, resumos ou qualquer publicação relacionada ao trabalho podem ser utilizados como apêndice.

APÊNDICE B – QUESTIONÁRIO UTILIZADO PARA...

Questão 1. Esta é a primeira questão com alguns itens:

(a) Este é o primeiro item

(b) Segundo item

Questão 2. Esta é a segunda questão:

(a) Este é o primeiro item

(b) Segundo item

Questão 3. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc dictum sed tortor nec viverra. consectetur adipiscing elit. Nunc dictum sed tortor nec viverra.

(a) consectetur

(b) adipiscing

(c) Nunc

(d) dictum

APÊNDICE C – CÓDIGOS-FONTES UTILIZADOS PARA...

Código-fonte 1 – Hello World em C++

```
1 #include <iostream>
2 using namespace std;
3 int main() {
4   cout<<"Hello World!"<<endl;
5   system("pause");
6 }
```

Código-fonte 2 – Hello World em Java

```
1 public class HelloWorld {
2   public static void main(String[] args) {
3     System.out.println("Hello World!");
4   }
5 }
```

APÊNDICE D – *IEEE CEFC 2016*

Digest submetido ao *The 17th Biennial Conference on Eletromagnetic Field Computation, Miami FL - NOV 13-16, 2016, USA*.

Lightning Incidence Model Based on the Electric Field Gradient: 3D Electrostatic Analyses

Ednardo M. Rodrigues, Ricardo S. T. Pontes and Tobias R. Fernandes Neto

Federal University of Ceará, Department of Electrical Engineering, Fortaleza CE, BRAZIL
ednardorodrigues@dee.ufc.br

***Abstract*— The paper deals with the 3D electrostatic analysis of a lightning strike in a hangar and a power transmission line. The lightning incidence model is based on the electric field gradient. Finally, the simulation results are described and discussed.**

***Index Terms*—Lightning, Electrostatic, Finite element.**

I. Introduction

In [1], a 2D electrostatic analysis of a new lightning incidence model based on the electric field gradient (EFG) was presented. Moreover, the simulations results were carried out for a building and a power transmission line and they were compared with the classical electrogeometrical model (EGM), the rolling-sphere technique (RST) and the leader progression model (LPM) [2]. The present paper estimates the trajectory of lightning strikes from the thundercloud to a grounded metal roof of a hangar. Furthermore, the same procedure will be carried out for 500kV power transmission lines.

II. Electrostatic Analyses

A lightning occurs when the electric field is higher than the breakeven field (400kV/m —3MV/m) [2]. This model is based on the electric field gradient described by

$$\vec{E}_L(\vec{r}) \approx \vec{E}_b(\vec{r}) + \lambda_t \nabla E_b(\vec{r}), \qquad (1)$$

$\vec{E}_b(\vec{r})$ is the background electric field, which is function of the position $\vec{r}$ and it is generated by the electric potential difference (EPD) between the cloud and the ground. λ_t is the lightning step length (~50m) [3], and $\vec{E}_L(\vec{r})$ is the lightning electric field. More details about Eq. (1) can be found in [1].

A 3D finite element method (FEM) model of a hangar and a power transmission line (TL) were designed by using the electrostatic module. All simulations were carried out within a cubic domain of 250m x 250m x 250m. The upper level of each domain is defined with -12.5MV, while the lower level is the ground. This is equivalent to a real thundercloud with a potential of (-100MV) at 2km of altitude [4].

The dimensions of the hangar are: 8.60m height, 77.37m width and 229.00m length. The aluminum metal roof has 0.7mm thickness and it is grounded. The second simulation is for a TL composed by three phase conductors, equally spaced by 11.5m and positioned at 40.5m above the reference plane. The TLs are protected by two earth wires spaced by 19m over 54.47m of the reference plane.

III. Results

In order to evaluate the 3D model, the software COMSOL Multiphysics® was used in a computer with quad-core processor of 2.6GHz. For the hangar, the simulation time was around 4s. The necessary physical memory for the simulation was 1.34GB and 5.6GB of virtual memory. The electric field is very intense at the roof (about 80MV/m) and the lightning (cyan lines) strikes the building roof, as shown in Fig. 1a. In summary, it is not necessary to add air terminals, as long the roof is grounded. The simulation time for the TL was around 6 min, using 15GB of physical memory and 32GB of virtual memory. As shown in Fig 1b, the cyan lines strike the earth wires.

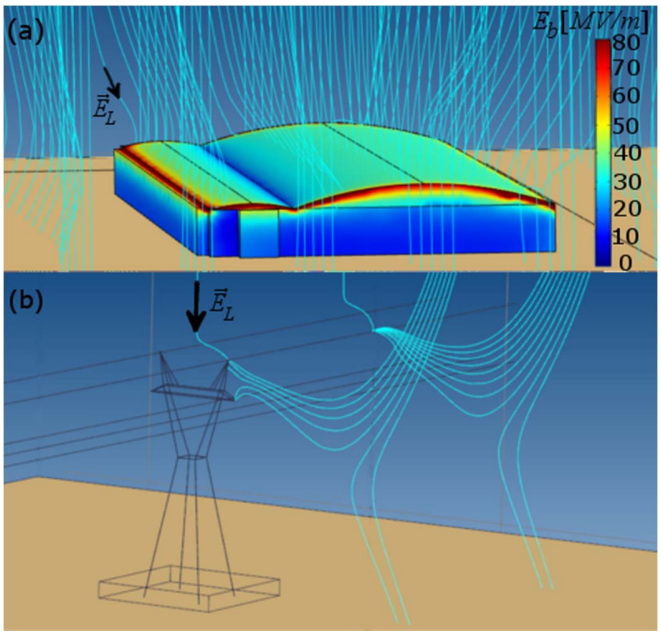


Fig. 1. Case of studies: (a) hangar and (b) power transmission line.

IV. Conclusions

The EFG simulations predicted that the aluminum metal roof is able to protect the hangar against lightning strikes. In the TL simulation, the earth wires have fulfilled the protection for the phase conductors. Finally, the protection zone and the design of lightning protection system can be evaluated by 3D electrostatic analyses, which are closer to the reality than the 2D analyses. However, 3D models are often more complex and require more simulation time.

References

[1] E. M. Rodrigues, *Novel Lightning Incidence Model Based on the Electric Field Gradient: 2D Electrostatic Analyses.* GROUND'2016 & 7th LPE. 2016.

[2] V. Cooray, *Lightning protection*, The Institution of Engineering and Technology. 2009.

[3] V.A. Rakov and M. A. Uman, *Lightning: physics and effects*. Cambridge University Press. 2007.

[4] S. Visacro, *Descargas atmosféricas: Uma Abordagem de Engenharia (Lightning strike: An Engineering approach)*, Artliber, 2005.

978-1-5090-1032-5/16/$31.00 ©2016 IEEE

ANEXO A – EXEMPLO DE UM ANEXO

Um anexo é um documento que não foi elaborado pelo autor, ou seja, o autor apenas anexa. Anexos podem ser tabelas, mapas, diagramas, *datasheets*, manuais e etc.

ANEXO B – EXEMPLO DE UM ANEXO EM PDF

O autor pode anexar um *Portable Document Format* (PDF), traduzido como formato portátil de documento. Veja o código fonte utilizado para anexar o arquivo “Sikasil.pdf” que foi colocado dentro da pasta “anexos” que por sua vez está dentro da pasta “elementos-pos-textuais”. Tenha muita atenção na hora de especificar o local do arquivo. Recomenda-se não utilizar caracteres especiais para nomear pastas e, principalmente, arquivos.

Pode-se fazer uma descrição sucinta do arquivo anexado.

Industry

Sikasil® GS-630

Glazing sealant for structural & non-structural use

Technical Product Data

Chemical base		1-C silicone
Color (CQP[1] 001-1)		See Product Overview
Cure mechanism		Moisture-curing
Cure type		Neutral
Density (uncured) (CQP 006-4)		1.4 kg/l approx.
Non-sag properties (CQP 061-4 / ISO 7390)		< 2 mm approx.
Application temperature		5 - 40°C (41 - 104°F)
Skin time[2] (CQP 019-2)		10 min approx.
Tack-free time[2] (CQP 019-1)		60 min approx.
Curing speed (CQP 049-1)		See diagram 1
Shore A-hardness (CQP 023-1 / ISO 868)		32 approx.
Tensile strength (CQP 036-1 / ISO 37)		1.2 N/mm^2 approx.
Elongation at break (CQP 036-1 / ISO 37)		480% approx.
Tear propagation resistance (CQP 045-1 / ISO 34)		6 N/mm approx.
100% modulus (CQP 036-1 / ISO 37)		0.6 N/mm^2 approx.
Movement accommodation capability (ASTM C 719)		±50%
Thermal resistance (CQP 513-1) Short term	long term 4 h 1 h	180°C (356°F) approx. 200°C (392°F) approx. 220°C (428°F) approx.
Service temperature		-40 - 150°C approx. (-40 - 302°F)
Shelf life (storage below 25°C) (CQP 016-1)		15 months

[1] CQP = Corporate Quality Procedure [2] 23°C (73°F) / 50% r.h.

Description

Sikasil® GS-630 is a durable, neutral-curing silicone sealant and adhesive which combines mechanical strength with high elongation. It adheres excellent to a wide range of substrates.
Sikasil® GS-630 is manufactured in accordance with ISO 9001 quality assurance system and the responsible care program.

Product Benefits

- Outstanding UV and weathering resistance
- Excellent adhesion to glass, coated glass, metals and plastics
- Fast curing
- Long-term durability
- High movement capability

Areas of Application

Sikasil® GS-630 is a silicone sealant and adhesive designed for sealing, bonding and mending tasks in a wide variety of industrial applications, e. g. structural and nonstructural applications in facades.
This product is suitable for professional experienced users only. Tests with actual substrates and conditions have to be performed to ensure adhesion and material compatibility.

Cure Mechanism

Sikasil® GS-630 cures by reaction with atmospheric moisture. The reaction thus starts at the surface and proceeds to the core of the joint. The curing speed depends on the relative humidity and the temperature (see diagram 1 below). Heating above 50°C to speed-up the vulcanization is not advisable as it may lead to bubble formation. At low temperatures the water content of the air is lower and the curing reaction proceeds more slowly.

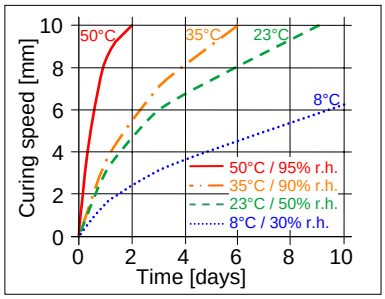


Diagram 1: Curing speed 1C-Sikasil®

Application Limits

All Sikasil® WS, FS, SG, IG, WT and other engineering silicone sealants and adhesives are compatible with each other. Sikasil® WS and FS sealants as well as other Sika engineering silicone sealants are compatible with SikaGlaze® IG sealants. All other sealants have to be approved by Sika before using them in combination with Sikasil® GS-630. Where two or more different reactive sealants are used, allow the first to cure completely before applying the next.

Do not use Sikasil® GS-630 on pre-stressed polyacrylate and polycarbonate elements as it may cause environmental stress cracking (crazing).

The compatibility of gaskets, backer rods and other accessory materials with Sikasil® GS-630 must be tested in advance.

Joints deeper than 15 mm should be avoided.

The above information is offered for general guidance only. Advice on specific applications will be given on request.

Method of Application

Surface preparation

Surfaces must be clean, dry and free from oil, grease and dust.

Advice on specific applications and surface pretreatment methods is available from the Technical Service Department of Sika Industry.

Application

After suitable joint and substrate preparation, Sikasil® GS-630 is gunned into place. Joints must be properly dimensioned as changes are no longer possible after construction. For optimum performance the joint width should be designed according to the movement capability of the sealant based on the actual expected movement. The minimum joint depth is 6 mm and a width / depth ratio of 2:1 must be respected if used for weatherproofing. For backfilling it is recommended to use closed cell, sealant compatible foam backer rods e.g. high resilience polyethylene foam rod. If joints are too shallow for backing material to be employed, we recommend using a polyethylene tape. This acts as a release film (bond breaker), allowing the joint to move and the silicone to stretch freely.

For more information please contact the Technical Service Department of Sika Industry.

Tooling and finishing

Tooling and finishing must be carried out within the skin time of the adhesive.

When tooling freshly applied Sikasil® GS-630 press the adhesive to the joint flanks to get a good wetting of the bonding surface.

Removal

Uncured Sikasil® GS-630 may be removed from tools and equipment with Sika® Remover-208 or another suitable solvent. Once cured, the material can only be removed mechanically.

Hands and exposed skin should be washed immediately using Sika® Handclean Towel or a suitable industrial hand cleaner and water. Do not use solvents!

Overpainting

Sikasil® GS-630 cannot be overpainted.

Further Information

Copies of the following publications are available on request:

- Material Safety Data Sheet

Packaging Information

Unipack	600 ml
Cartridge	300 ml
Pail	26 kg
Drum	280 kg

Value Bases

All technical data stated in this Product Data Sheet are based on laboratory tests. Actual measured data may vary due to circumstances beyond our control.

Health and Safety Information

For information and advice regarding transportation, handling, storage and disposal of chemical products, users should refer to the actual Material Safety Data Sheets containing physical, ecological, toxicological and other safety-related data.

Legal Notes

The information, and, in particular, the recommendations relating to the application and end-use of Sika products, are given in good faith based on Sika's current knowledge and experience of the products when properly stored, handled and applied under normal conditions in accordance with Sika's recommendations. In practice, the differences in materials, substrates and actual site conditions are such that no warranty in respect of merchantability or of fitness for a particular purpose, nor any liability arising out of any legal relationship whatsoever, can be inferred either from this information, or from any written recommendations, or from any other advice offered. The user of the product must test the product's suitability for the intended application and purpose. Sika reserves the right to change the properties of its products. The proprietary rights of third parties must be observed. All orders are accepted subject to our current terms of sale and delivery. Users must always refer to the most recent issue of the local Product Data Sheet for the product concerned, copies of which will be supplied on request.

Further information available at:
www.sika.ch
www.sika.com

Sika Schweiz AG
Industry
Tüffenwies 16
CH-8048 Zurich
Switzerland
Tel. +41 44 436 40 40
Fax +41 44 436 45 30